


UNIVERSIDAD NACIONAL DE INGENIERIA
UNIDAD DE POSGRADO FACULTAD DE INGENIERIA
INDUSTRIAL Y DE SISTEMAS / ESCUELA DE
POSGRADO



Tesis

**“Estimación del riesgo de paralización de Obras Públicas en
el Perú por incumplimiento contractual usando modelos de
Inteligencia Artificial”**

**PARA OBTENER EL GRADO ACADÉMICO DE MAESTRO CON MENCIÓN
EN INTELIGENCIA ARTIFICIAL**



ASESOR:

SAMUEL OPORTO

LIMA, PERU

2025

Tabla de contenido

INTRODUCCIÓN	7
CAPÍTULO I	10
PLANTEAMIENTO DEL PROBLEMA.....	10
1.1 Diagnóstico	10
1.2 Identificación y Descripción del Problema de Estudio	13
1.3. Formulación del Problema.....	19
1.3.2. Problema General	19
1.3.3. Problemas Específicos.....	19
1.4. Objetivos	20
1.4.1. Objetivo General	20
1.4.2. Objetivos Específicos	20
1.5. Diseño Factorial de la Investigación	20
1.5.1. Identificación de Variables	20
1.5.1.1. Variables Independientes (Factores)	21
1.5.1.2. Variables Dependientes (Métricas)	21
1.5.2. Niveles de los Factores.....	21
1.5.3. Matriz de Experimentos	22
1.5.4. Representación Gráfica del Diseño Factorial	23
1.5.5. Hipótesis Experimentales	23
CAPÍTULO II	24
MARCO TEÓRICO	24
2.1. Antecedentes Bibliográficos.....	24
2.2. Bases Teóricas	25
2.3. Definición de Términos	26
2.3.1. Inversión pública.....	26
2.3.2. Proyecto de inversión	26
2.3.3. Obra pública	26
2.3.4. Ejecución contractual.....	26
2.3.5. Incumplimiento contractual	27
2.3.6. Resolución de contrato.....	27
2.3.7. Paralización de obra	27
2.3.8. Expediente técnico	27

2.3.9.	Avance físico	27
2.3.10.	Avance financiero	27
CAPÍTULO III		28
PROPUESTA Y DESARROLLO DE LA SOLUCIÓN		28
3.1.	Presentación de la Propuesta de Solución	28
3.1.1.	Planteamiento General	28
3.1.2.	Planteamiento Matemático	28
3.1.3.	Arquitectura de la Solución	29
3.2.	Desarrollo de la Propuesta de Solución	31
3.2.1.	Adquisición de Datos	31
3.2.1.1.	Fuentes de Datos	31
3.2.1.2.	Procedimiento de Extracción	35
3.2.2.	Carga a Área de ensayo e integración del conjunto de datos inicial	36
3.2.2.1.	Diseño de la Capa de ensayo	36
3.2.2.2.	Canalización de los procesos ETL	36
3.2.2.3.	Integración de Datasets	37
3.2.3.	Preparación y Limpieza de Datos	37
3.2.3.1.	Proceso de Limpieza	37
3.2.3.2.	Definición de la Variable Objetivo	38
3.2.4.	Análisis Exploratorio de Datos	39
3.2.4.1.	Distribución Temporal respecto a la fecha de inicio de ejecución de obras.	39
3.2.4.2.	Distribución de la Variable Objetivo	39
3.2.4.3.	Análisis de Variables Predictoras	40
3.2.4.4.	Características calculadas	41
3.2.5.	Ingeniería de Características	42
3.2.5.1.	Codificación de Variables Categóricas	42
3.2.5.2.	Frequency Encoding para Alta Cardinalidad	42
3.2.5.3.	Dataset Final para Modelamiento	42
3.2.6.	Entrenamiento de Modelos	43
3.2.6.1.	Estrategia de Partición de Datos	43
3.2.6.2.	Modelos Evaluados	43
3.2.6.3.	Búsqueda de Hiperparámetros	43
3.2.6.4.	Optimización de Umbral de Decisión	44

3.2.7.	Comparación y Selección de Modelos	45
3.2.7.1.	Métricas de Evaluación	45
3.2.7.2.	Proceso de Comparación	45
3.3.	Análisis de los Datos y Resultados.....	46
3.3.1.	Métricas Comparativas en el Conjunto de Prueba	47
3.3.2.	Selección del Mejor Modelo y Matriz de Confusión.....	48
3.3.3.	Importancia de Variables del Modelo Seleccionado.....	49
3.4.	Discusión e Interpretación de los Resultados	50
3.4.1.	Contraste con la Hipótesis H3.....	50
3.4.2.	Limitaciones del Estudio	50
3.5.	Estimación del Impacto de la Solución.....	51
3.5.1.	Impacto Operativo.....	51
3.5.2.	Impacto en la Gestión de Riesgos.....	51
CAPÍTULO IV.....		52
CONCLUSIONES Y RECOMENDACIONES.....		52
4.1	Conclusiones.....	52
4.2	Recomendaciones.....	53
Referencias		55
Anexos		57
Anexo 1 Matriz de consistencia		57

Lista de Tablas

Tabla 1 Principales causas de paralización de obras públicas a nivel nacional (diciembre 2024).....	15
Tabla 2 Obras públicas paralizadas según nivel de gobierno (diciembre 2024).....	17
Tabla 3 Obras públicas paralizadas según sector (diciembre 2024)	18
Tabla 4: Variables independientes del diseño factorial.....	21
Tabla 5: Variables dependientes del diseño factorial.....	21
Tabla 6: Niveles de los factores del diseño factorial.....	22
Tabla 7: Matriz de experimentos del diseño factorial.....	23
Tabla 8: Distribución de experimentos según factores P y T	23
Tabla 9: Fuentes de datos utilizadas en el estudio	32
Tabla 10: Causales de paralización consideradas para la clase positiva	35
Tabla 11: Tablas de la capa de staging	36
Tabla 12: Estandarización de variables categóricas.....	38
Tabla 13: Distribución de la variable objetivo.....	40
Tabla 14: Características de tasas de paralización y variables agregadas incorporadas en la segunda iteración	41
Tabla 15: Composición del vector de características	43
Tabla 16: Partición de datos	43
Tabla 17: Métricas de evaluación utilizadas.....	45
Tabla 18: Métricas comparativas (mejor corrida por modelo, conjunto de prueba)..	47
Tabla 19: Matriz de confusión del modelo seleccionado (CatBoost, conjunto de prueba).....	48
Tabla 20: Lista de 10 variables más influyentes del mejor modelo (CatBoost).....	49

Lista de Figuras

Figura 1: Representación de una Obra Pública	7
Figura 2: Caracterización de la inversión de obra pública a través de sus diferentes características.....	11
Figura 3: Diagrama de transición de estados en la ejecución de una obra publica	14
Figura 4: Grafo de factores de paralización de obra, se observa una red de causales jerárquicos	16
Figura 5 Reporte de estado en el sistema de seguimiento de las inversiones	17
Figura 6: Arquitectura del sistema de estimación de riesgo de paralización.....	30
Figura 7: Diagrama E-R de las principales entidades de datos del negocio	33
Figura 8: Frecuencia de paralizaciones por incumplimiento contractual respecto al total de obras no paralizadas	34
Figura 9 Distribución de clases final del conjunto de datos	38
Figura 10 Distribución de la fecha inicio de obra considerando todas las modalidades de ejecución	39
Figura 11: Grafico de barras de modelos, ordenado por relevancia en el valor de la metrica obtenida	47
Figura 12: Mapa de calor que muestra la normalización de los valores de las diferentes métricas para la obtención de un solo indicador de elección	48

INTRODUCCIÓN

En el contexto socioeconómico del Perú, la inversión pública juega un papel fundamental como motor de desarrollo y progreso. A través de ella, el estado peruano busca mejorar la calidad de vida de sus ciudadanos, impulsando la infraestructura, los servicios básicos y la productividad nacional. Un proyecto de inversión corresponde a intervenciones temporales que se financian total o parcialmente con recursos públicos, destinadas a la formación de capital físico, humano, institucional, intelectual o natural, que tenga como propósito crear, ampliar, mejorar o recuperar la capacidad de producción de bienes o servicios (Contraloría General de la Republica del Perú, 2025). Una Obra pública se define a las inversiones con componente de infraestructura, incluyendo la construcción, reconstrucción, remodelación, demolición, renovación, mantenimiento, habilitación y rehabilitación de bienes inmuebles, tales como edificaciones, estructuras, excavaciones, perforaciones, carreteras, puentes, entre otros, que requieren dirección técnica, expediente técnico, mano de obra, materiales y/o equipos, cuya ejecución, operación o mantenimiento implique la participación del Estado (Contraloría General de la Republica del Perú, 2025), tal como se representa en la siguiente figura Figura 1: :




Figura 1: Representación de una Obra Pública

Fuente: Elaboración Propia

La paralización de una obra pública se entiende como la interrupción indefinida o prolongada de su ejecución física (Contraloría General de la Republica del Perú, 2025), lo que impide su conclusión y puesta en funcionamiento.

Según el *Informe de Obras Paralizadas en el Territorio Nacional a diciembre de 2024*, se registraron 2,476 obras paralizadas en todo el Perú, con un costo total de 43, 118 millones de soles, de las cuales el 72 % corresponde a gobiernos locales, las causas más recurrentes incluyen el incumplimiento contractual por parte de contratistas (Contraloría General de la Republica del Perú, 2025).

Este escenario muestra una limitación fundamental en la gestión pública: la ausencia de mecanismos predictivos que permitan de forma anticipada estimar el riesgo de paralización desde etapas tempranas del ciclo de inversión. A pesar de los avances en la digitalización de procesos y disponibilidad de datos estructurados, la toma de decisiones continúa siendo reactiva y sujeta a diagnósticos ex post, lo que restringe la capacidad de prevenir consecuencias críticas para el uso de los recursos públicos.

En este sentido, en el presente trabajo propone implementar un modelo de clasificación utilizando aprendizaje automático (machine learning) que permita estimar la medida de probabilidad asociada al riesgo de paralización de obras públicas por incumplimiento contractual. El modelo se basará en datos históricos del Banco de Inversiones del Ministerio de Economía y Finanzas y se medirá mediante pruebas como precisión, F1 score y ROC AUC. Además, se explotarán métodos de interpretabilidad como SHAP para investigar la contribución individual de cada característica a las predicciones, otorgando transparencia y confianza en los resultados (Lundberg & Lee, 2017).

La presente investigación toma como referencia estudios aplicados de inteligencia artificial orientados a prever retrasos en proyectos de construcción, como el desarrollado por (Nnaemeka Egwim et al., 2021), donde se evaluaron distintos algoritmos de aprendizaje automático aplicados a un dataset real del sector infraestructura. En dicho estudio, los modelos basados en árboles de decisión, como Random Forest y XGBoost, alcanzaron altos niveles de precisión en la predicción de retrasos y resultaron más adecuados para escenarios donde la interpretabilidad y la capacidad de acción son necesarias para los tomadores de decisiones (Nnaemeka Egwim et al., 2021)

Por lo tanto, esta investigación propone el uso de la inteligencia artificial como una herramienta clave de soporte al impulso de las políticas públicas más inteligentes, eficientes e impulsada por datos. Porque una obra inconclusa no representa únicamente una pérdida económica sino también significa una promesa incumplida y una necesidad básica que continúa sin resolverse que afecta a miles de peruanos.

CAPÍTULO I

PLANTEAMIENTO DEL PROBLEMA

1.1 Diagnóstico

Según el informe de la Contraloría General de la República (CGR) publicado en abril de 2025, a diciembre de 2024 se contabilizaban 2,476 obras públicas paralizadas, con un costo total de S/ 43,118 millones. El 72 % de estos proyectos corresponde a gobiernos locales, evidenciando que la descentralización de la inversión pública no ha venido acompañada de capacidades técnicas suficientes para su ejecución eficiente (Contraloría General de la Republica del Perú, 2025). Las principales causas de paralización reportadas son: incumplimiento de contrato (25.4 %), falta de recursos financieros, liquidez (21.2 %) y deficiencia en el expediente técnico (10.9 %). En particular, el incumplimiento contractual afectó a 628 obras, representando también un monto proporcional del 36.9 % del total paralizado, lo que equivale a S/ 15,913 millones (Contraloría General de la Republica del Perú, 2025)

En esa perspectiva, la causa relacionada al incumplimiento contractual puede materializarse a través de situaciones específicas tales como: Supervisión, control, arbitraje, abandono de obra por parte del contratista, adicionales, penalidades, riesgos sociales (Contraloría General de la Republica del Perú, 2025). A pesar de que el incumplimiento contractual representa una de las principales causas de paralización de obras públicas en el Perú, este riesgo no es actualmente evaluado de manera predictiva durante la etapa de ejecución. En el marco del sistema de inversión pública, una obra constituye parte del componente de infraestructura de un proyecto, y su desarrollo está expuesto a diversas condiciones operativas, contractuales y de gestión. Muchas de estas condiciones se encuentran registradas en sistemas oficiales como el Banco de Inversiones del Ministerio de Economía y Finanzas (MEF), el cual recopila información estructurada sobre atributos relevantes: nivel de gobierno, modalidad de ejecución, función del proyecto, presupuesto, duración, ubicación geográfica, así como estados de avance físico y financiero. Estos elementos permiten caracterizar formalmente una obra pública en ejecución, y al mismo tiempo representan dimensiones críticas que podrían ser aprovechadas para anticipar escenarios de riesgo. La figura **¡Error! No se encuentra el origen de la referencia.** muestra una representación esquemática de estas dimensiones, las cuales ofrecen una base informativa suficiente para aplicar modelos de aprendizaje

automático orientados a estimar, con anticipación, la probabilidad de paralización por causas contractuales.




Figura 2: Caracterización de la inversión de obra pública a través de sus diferentes características

Fuente: Elaboración Propia

Actualmente, la respuesta del estado frente a las paralizaciones de obra por lo general es reactiva. Las auditorías, informes de control o intervenciones correctivas se ejecutan una vez que el daño ya está hecho, cuando el contrato ha sido resuelto, los plazos han sido vencidos o los recursos han sido comprometidos sin resultados tangibles. Esta dinámica en la respuesta del estado no solo limita su capacidad preventiva, sino que además continúa manteniendo un modelo ineficiente de gestión

donde la información no se transforma en conocimiento útil, ni en alertas tempranas a la hora de tomar decisiones.

En el Perú, las iniciativas orientadas a aplicar inteligencia artificial en la gestión pública aún son incipientes, en la mayoría de los casos están limitadas a propuestas de investigación. Por ejemplo, un estudio académico publicado en *Interfases* (2018) propone el uso de redes neuronales artificiales para mejorar la eficiencia del procedimiento de selección de proveedores en obras públicas, como parte del proceso de licitación (Solís-Villanueva, 2018). Sin embargo, este enfoque no ha sido adoptado formalmente por el Organismo Supervisor de las Contrataciones del Estado (OSCE) ni ha sido extendido hacia fases contractuales o plataformas operativas como Invierte.pe o el Sistema Integrado de Administración Financiera (SIAF).

Esta limitada adopción de enfoques predictivos representa un vacío de alto impacto, puesto que se dispone de información relevante, por ejemplo, historial de contratistas, ubicación de obras, tiempo promedio de ejecución, modificaciones contractuales, acciones de control, tipología de inversiones; sin embargo, dicha información no es transformada ni utilizada como variables predictivas, no se convierte en variables predictivas. Esta carencia impide estimar el riesgo para identificar obras con riesgo de paralización de manera anticipada, y también limita la toma de decisiones basadas en evidencia por parte de gestores de las entidades públicas.

Finalmente, cualquier intento de incorporar soluciones basadas en inteligencia artificial debe también resolver el desafío de la interpretabilidad. No es suficiente con estimar el riesgo de la paralización de las obras públicas, también es indispensable entender por qué se paralizarán. En ese sentido, herramientas como SHAP permiten que los modelos predictivos generen explicaciones comprensibles para usuarios técnicos y no técnicos, garantizando transparencia en la toma de decisiones y mayor aceptación institucional (Lundberg & Lee, 2017).

A partir de todo lo expuesto, la problemática puede sintetizarse en los siguientes puntos:

- La paralización de obras públicas sigue siendo un problema relevante con impactos económicos y sociales para el Estado.

- El 25.4 % de las paralizaciones se debe a incumplimiento contractual, una causa prevenible si se monitorean indicadores clave desde el inicio de su ejecución.
- A pesar de la existencia de datos estructurados y herramientas tecnológicas, no se han implementado modelos predictivos que estimen el riesgo de paralizaciones de obras públicas en el Perú.

La magnitud del problema de las paralizaciones de obras públicas se repite año tras año, evidenciando su prevalencia en el tiempo. Sin embargo, la creciente disponibilidad de herramientas de análisis predictivo convierte este escenario en una oportunidad concreta para aplicar inteligencia artificial en favor de una gestión más eficiente.

1.2 Identificación y Descripción del Problema de Estudio

Planteamiento del Problema

En el Perú, uno de los problemas estructurales más persistentes en el ámbito de la inversión pública es la paralización de obras públicas, con alta incidencia en los gobiernos locales y regionales. Esta situación afecta el cumplimiento de metas de cierre de brechas de infraestructura, genera pérdida de recursos públicos e impide el acceso oportuno de la población a la infraestructura y los servicios públicos.

Ciclo del fenómeno

Las obras públicas pasan por una serie de estados durante su ciclo de vida (ver Fig. 3). El estado Paralizado se da cuando se cumplen las siguientes condiciones (Subgerencia de Seguimiento y Evaluación del Sistema Nacional de Control, 2025):

La obra se ejecuta bajo las modalidades por contrata, administración directa, convenios de Estado a Estado, Asociaciones Público-Privadas que tengan componente de infraestructura, Obras por Impuestos, intervenciones de infraestructura ejecutadas por núcleos ejecutores u otras modalidades establecidas por ley.

La obra se encuentra en ejecución física de acuerdo con las condiciones establecidas para su inicio en el marco normativo de cada modalidad

La obra no se ha concluido y no reporta avance en su ejecución física por seis (06) meses o más, por causas atribuibles a situaciones de controversia, abandono,

deficiencias del expediente técnico, factores climáticos, situaciones imprevisibles posteriores al perfeccionamiento del contrato.




Figura 3: Diagrama de transición de estados en la ejecución de una obra pública

Fuente: Elaboración Propia

Tipificación del fenómeno

La Contraloría General de la República clasifica las paralizaciones de obras públicas en función de causas específicas, como se presenta en el informe oficial a diciembre de 2024 (Contraloría General de la Republica del Perú, 2025). De las 2,476 obras paralizadas, las principales causas identificadas se pueden visualizar en la siguiente tabla:

Causales de Paralización	Costo Actualizado (Millones de soles)	% Costo	N.º Obras Paralizadas	% N.º Obras
Incumplimiento de contrato	15,913.4	36.9%	628	25.4%
Falta de recursos financieros y liquidez	2,140.4	5.0%	526	21.2%
Deficiencia en el expediente técnico	3,217.8	7.5%	271	10.9%
Abandono de obra	699.5	1.6%	247	10.0%
Discrepancias, controversias y arbitraje	14,889.4	34.5%	225	9.1%
Incumplimiento del pago de valorizaciones u otros	951.8	2.2%	71	2.9%
Eventos climáticos	987.0	2.3%	70	2.8%
Conflictos sociales	1,078.1	2.5%	71	2.9%
Disponibilidad de terreno	560.8	1.3%	56	2.3%
Falta de permisos, licencias y autorizaciones	120.2	0.3%	46	1.9%
Interferencias	289.3	0.7%	27	1.1%
Desabastecimiento sostenido de materiales	402.5	0.9%	25	1.0%
Otros*	1,592.1	3.7%	214	8.6%
TOTAL	43,118.9	100%	2476	100%

Tabla 1: Principales causas de paralización de obras públicas a nivel nacional (diciembre 2024)

Fuente: Contraloría General de la República (Subgerencia de Seguimiento y Evaluación del Sistema Nacional de Control, 2025)

La Tabla 1, muestra que el incumplimiento de contrato destaca como la principal causa tanto en número de obras como en impacto económico, con S/ 15,913.4 millones, que representa el 36.9 % del costo total paralizado (Contraloría General de la Republica del Perú, 2025), Dado su impacto crítico y su prevalencia, esta causa ha sido seleccionada como el foco de análisis exclusivo de esta investigación.

Para facilitar la comprensión integral de esta problemática, se ha diseñado un diagrama que representa un grafo que agrupa y representa jerárquicamente las distintas causas identificadas (ver Fig. 4), diferenciando entre factores técnicos, contractuales, financieros y externos. Esta representación visual permite apreciar la interrelación entre las causales y sus posibles puntos de intervención, siendo una herramienta útil para orientar los enfoques predictivos posteriores.




Figura 4: Grafo de factores de paralización de obra, se observa una red de causales jerárquicos

Fuente: Elaboración Propia

Ejemplo de paralización de una Obra Pública

“2314836: Construcción y Equipamiento del Instituto de Medicina Tropical de la UNTRM (Amazonas)”

Costo: S/ 62.3 millones, estado: paralizado, motivo: resolución contractual por parte de la entidad

VI. REGISTRO DE OBRAS PARALIZADAS (LEY N° 31589 Y SUS MODIFICATORIAS)			
FECHA DE REGISTRO	21/02/2025	CÓDIGO INFOBRAS	172730
DESCRIPCIÓN DE LA OBRA	CONSTRUCCION Y EQUIPAMIENTO DEL INSTITUTO DE MEDICINA TROPICAL DE LA UNIVERSIDAD NACIONAL TORIBIO RODRIGUEZ DE MENDOZA DE AMAZONAS, SEDE CHACHAPOYAS PROVINCIA DE CHACHAPOYAS, REGION AMAZONAS		
MODALIDAD	ADMINISTRACIÓN INDIRECTA - POR CONTRATA		
AVANCE FÍSICO	18.12 %	FECHA DE PARALIZACIÓN	10/09/2024
MOTIVOS DE PARALIZACIÓN	La obra se encuentra en Resolución de contrato, debido a que el contratista el 16 de agosto del 2024 con CARTAn°053-2024-JAGUI.SAC-CHA-RL-CARTA NOTARIAL interpuso la resolución de contrato unilateralmente. La entidad rechaza esta resolución con CARTA N°0099-2024-MINEDU/VMGP/UE118, otorgándole 15 días para revertir sus incumplimientos fundamentales bajo apercibimiento de resolución de contrato el cual se dio con CARTA N°0127-2024-MINEDU/VMGP/UE.118. La constatación de obra se dio los días 2 y 3 de octubre del 2024.		
INFORME DE ESTADO SITUACIONAL	INFORME SITUACIONAL DEL MEMORANDO N°171-2025-MINEDU/VMGP/UE.118-OGI	RESOLUCIÓN QUE APRUEBA LA LISTA PRIORIZADA	No registrado
SITUACIÓN DE LA OBRA PARALIZADA	21/02/2025 En elaboración o aprobación del expediente técnico de saldo de obra		

Figura 5 Reporte de estado en el sistema de seguimiento de las inversiones

Fuente: (MEF - Portal de Seguimiento, s. f.).

Cuantificación del fenómeno

Según el informe de la CGR, los gobiernos locales concentran el 72 % del total de obras paralizadas, tal como se puede visualizar en la siguiente Tabla:

Nivel de Gobierno	N.º Obras Paralizadas	% N.º Obras
G. LOCAL	1,782	72.0%
G. NACIONAL	384	15.5%
G. REGIONAL	310	12.5%
TOTAL	2,476	100%

Tabla 2 Obras públicas paralizadas según nivel de gobierno (diciembre 2024)

Fuente: Contraloría General de la República (Subgerencia de Seguimiento y Evaluación del Sistema Nacional de Control, 2025)

Así mismo, los sectores más afectados son Transporte, Saneamiento, Educación, Agricultura y Salud, tanto en número de proyectos como en volumen presupuestal, tal como se muestra en la siguiente tabla:

Sector	Costo Actualizado	% Costo	N.º Obras Paralizadas	% N.º Obras
Transportes y comunicaciones	11,597.9	26.9%	715	28.9%
Vivienda, construcción y saneamiento	7,861.2	18.2%	518	20.9%
Educación	2,274.2	5.3%	364	14.7%
Agricultura	7,699.5	17.9%	322	13.0%
Salud	5,017.7	11.6%	83	3.4%
Otros sectores	8,668.4	20.1%	474	19.1%
TOTAL	43,118.9	100%	2,476	100%

Tabla 3 Obras públicas paralizadas según sector (diciembre 2024)

Fuente: Contraloría General de la República (Subgerencia de Seguimiento y Evaluación del Sistema Nacional de Control, 2025)

1.3. Formulación del Problema

1.3.2. Problema General

En la gestión de obras públicas en el Perú, se presenta una insuficiente identificación y articulación de los factores asociados a la paralización de obras por incumplimiento contractual, a partir de la información disponible en la normativa vigente, la literatura especializada y los registros administrativos de fuentes públicas. Esta situación limita la comprensión integral del fenómeno y dificulta la toma de decisiones oportunas orientadas a la prevención y gestión del riesgo de paralización durante la ejecución contractual.

1.3.3. Problemas Específicos

1. Existe una insuficiente identificación sistemática y actualizada de los factores de riesgo asociados a la paralización de obras por incumplimiento contractual, integrando de manera coherente la literatura especializada, la normativa vigente y los registros administrativos de fuentes públicas oficiales; esta carencia debilita el sustento conceptual y operativo del estudio.
2. Se evidencia dispersión y heterogeneidad en los datos disponibles, así como la ausencia de procesos estandarizados de obtención, limpieza, estandarización, control de calidad e ingeniería de características, lo que impide conformar un dataset analítico reproducible adecuado para el aprendizaje automático.
3. Persiste la indeterminación del modelo de aprendizaje automático más adecuado y de sus configuraciones, debido a la falta de un marco comparativo de ajuste, entrenamiento y evaluación con métricas homogéneas, lo que dificulta una selección informada y la documentación de hiperparámetros y condiciones de uso.
4. Existe limitada interpretabilidad de las salidas del modelo, por la ausencia de técnicas de inteligencia artificial explicable que generen interpretaciones a nivel agregado y por obra, identifiquen los factores determinantes del riesgo y establezcan criterios de interpretación claros para la toma de decisiones.

1.4. Objetivos

1.4.1. Objetivo General

Analizar la incidencia y articulación de los factores de riesgo asociados a la paralización de obras públicas por incumplimiento contractual, mediante el examen de la normativa vigente, la literatura especializada y la evidencia contenida en los registros administrativos de fuentes públicas oficiales, con la finalidad de generar un marco de conocimiento técnico que sustente la comprensión y prevención del riesgo en la ejecución de inversiones.

1.4.2. Objetivos Específicos

1. Identificar los factores de riesgo asociados a la paralización de obras por incumplimiento contractual a partir de la literatura especializada, la normativa vigente y los registros administrativos de fuentes públicas oficiales.
2. Implementar la obtención y preparación de datos, incluyendo limpieza, estandarización y control de calidad, así como la ingeniería de características necesaria para el análisis con aprendizaje automático.
3. Comparar modelos de aprendizaje automático, mediante su ajuste, entrenamiento y evaluación con métricas pertinentes, para seleccionar el candidato de mejor desempeño y documentar sus hiperparámetros y condiciones de uso.
4. Aplicar técnicas de inteligencia artificial explicable para generar interpretaciones del modelo a nivel agregado y por obra, identificando los factores determinantes del riesgo y estableciendo criterios de interpretación para la toma de decisiones.

1.5. Diseño Factorial de la Investigación

1.5.1. Identificación de Variables

El diseño experimental considera variables independientes (factores) que se manipulan sistemáticamente para evaluar su efecto sobre las variables dependientes (métricas de desempeño del modelo).

1.5.1.1. Variables Independientes (Factores)

Factor	Código	Descripción
Algoritmo de clasificación	A	Familia de modelo de aprendizaje automático
Preprocesamiento	P	Aplicación de escalado a variables numéricas
Optimización de hiperparámetros	T	Búsqueda sistemática de hiperparámetros
Optimización de umbral	U	Ajuste del umbral de decisión

Tabla 4: Variables independientes del diseño factorial

1.5.1.2. Variables Dependientes (Métricas)

Métrica	Código	Descripción	Prioridad
Recall	REC	Proporción de positivos correctamente detectados	Alta
PR-AUC	PRA	Área bajo la curva Precision-Recall	Alta
F2-Score	F2	Media armónica ponderada ($\beta=2$)	Alta
F1-Score	F1	Media armónica equilibrada	Media
Precision	PRE	Proporción de predicciones positivas correctas	Media

Tabla 5: Variables dependientes del diseño factorial

1.5.2. Niveles de los Factores

Cada factor experimental toma valores discretos denominados “niveles”. La siguiente tabla presenta los niveles definidos para cada factor:

Factor	Nivel	Código	Descripción
A: Algoritmo	1	A1	Logistic Regression (baseline)
	2	A2	Random Forest
	3	A3	XGBoost
	4	A4	LightGBM
	5	A5	CatBoost
P: Preprocesamiento	0	P0	Sin escalado
	1	P1	StandardScaler

Factor	Nivel	Código	Descripción
T: Tuning	0	T0	Parámetros por defecto
	1	T1	RandomizedSearchCV (50 iter, 5-fold CV)
U: Umbral	0	U0	Umbral fijo (0.50)
	1	U1	Umbral optimizado en validación

Tabla 6: Niveles de los factores del diseño factorial

1.5.3. Matriz de Experimentos

La combinación factorial completa de los niveles genera el siguiente conjunto de experimentos. Para mantener la viabilidad computacional, se define un diseño factorial fraccionado que prioriza las combinaciones de mayor interés:

Exp.	Algoritmo (A)	Escalado (P)	Tuning (T)	Umbral (U)	Código
1	Logistic Regression	Sí	No	Fijo	A1-P1-T0-U0
2	Logistic Regression	Sí	Sí	Optimizado	A1-P1-T1-U1
3	Random Forest	No	No	Fijo	A2-P0-T0-U0
4	Random Forest	No	Sí	Optimizado	A2-P0-T1-U1
5	Random Forest	Sí	Sí	Optimizado	A2-P1-T1-U1
6	XGBoost	No	No	Fijo	A3-P0-T0-U0
7	XGBoost	No	Sí	Optimizado	A3-P0-T1-U1
8	XGBoost	Sí	Sí	Optimizado	A3-P1-T1-U1
9	LightGBM	No	No	Fijo	A4-P0-T0-U0
10	LightGBM	No	Sí	Optimizado	A4-P0-T1-U1
11	LightGBM	Sí	Sí	Optimizado	A4-P1-T1-U1
12	CatBoost	No	No	Fijo	A5-P0-T0-U0
13	CatBoost	No	Sí	Optimizado	A5-P0-T1-U1
14	CatBoost	Sí	Sí	Optimizado	A5-P1-T1-U1

Tabla 7: Matriz de experimentos del diseño factorial

1.5.4. Representación Gráfica del Diseño Factorial

	T0 (Default)	T1 (Optimizado)
P0 (Sin escalado)	Exp. 3, 6, 9, 12	Exp. 4, 7, 10, 13
P1 (Con escalado)	Exp. 1	Exp. 2, 5, 8, 11, 14

Nota: Cruzado con Factor A (Algoritmo): A1=LogReg, A2=RF, A3=XGB, A4=LGBM, A5=CatBoost

Tabla 8: Distribución de experimentos según factores P y T

1.5.5. Hipótesis Experimentales

Del diseño factorial se derivan las siguientes hipótesis experimentales que serán evaluadas:

HE1 (Efecto del Algoritmo): El factor Algoritmo (A) tiene un efecto significativo sobre las métricas de desempeño, existiendo al menos un algoritmo con desempeño superior a los demás.

$$H_0: \mu_{A1} = \mu_{A2} = \mu_{A3} = \mu_{A4} = \mu_{A5}$$

$$H_1: \exists i, j \text{ tal que } \mu_{Ai} \neq \mu_{Aj}$$

HE2 (Efecto del Preprocesamiento): El factor Preprocesamiento (P) tiene un efecto significativo sobre el desempeño del modelo.

$$H_0: \mu_{P0} = \mu_{P1}$$

$$H_1: \mu_{P0} \neq \mu_{P1}$$

HE3 (Efecto del Tuning): La optimización de hiperparámetros (T) mejora significativamente el desempeño del modelo.

$$H_0: \mu_{T0} = \mu_{T1}$$

$$H_1: \mu_{T1} > \mu_{T0}$$

HE4 (Efecto del Umbral): La optimización del umbral de decisión (U) mejora las métricas orientadas a recall.

$$H_0: \mu_{U0} = \mu_{U1}$$

$$H_1: \mu_{U1} > \mu_{U0}$$

CAPÍTULO II

MARCO TEÓRICO

2.1. Antecedentes Bibliográficos

- (Gondia et al., 2020), Este estudio fue pionero en identificar y desarrollar modelos de Machine Learning para el análisis y la predicción precisa de riesgos de retraso en proyectos de construcción. Los autores identificaron 59 factores de riesgo clave a través de una revisión bibliográfica y consulta con expertos. Compilaron un conjunto de datos multivariante de 51 proyectos de construcción de edificios terminados en Egipto, donde los proyectos debían haber incurrido en excesos de tiempo (Time Overrun, $TO > 0$). La magnitud del retraso se categorizó en tres clases: $<30\%$ TO (menor), $30\%-60\%$ TO (moderado) y $>60\%$ TO (mayor). A partir de un análisis exploratorio de datos, confirmaron la alta complejidad e interdependencia de las fuentes de riesgo. Aplicaron dos algoritmos de clasificación de aprendizaje supervisado: Árbol de Decisión (DT) y Naive Bayes (NB), seleccionados por su idoneidad con conjuntos de datos pequeños. La evaluación del rendimiento predictivo se realizó mediante matrices de confusión y validación cruzada de 10 pliegues, un método fiable para minimizar sesgos y varianza. El modelo Naive Bayes superó al modelo de Árbol de Decisión en rendimiento general y en casi todas las medidas de rendimiento por clase, lo que se atribuyó al pequeño tamaño del conjunto de datos y a la independencia condicional de las variables, una suposición que era evidente en el conjunto de datos estudiado. El estudio enfatizó el uso de datos objetivos para una toma de decisiones basada en evidencia.
- («Predicting Construction Delay Risks in Saudi Arabian Projects», 2025), Esta investigación evaluó el rendimiento de tres algoritmos avanzados de Machine Learning (CatBoost, XGBoost y Light Gradient Boosting Machine - LGBM) para predecir retrasos en proyectos de construcción en Arabia Saudita. Al igual que Gondia et al., identificó 59 factores de riesgo clave a través de una revisión y consulta con expertos. El estudio utilizó un conjunto de datos de 62 proyectos de construcción en Arabia Saudita que habían incurrido en retrasos ($TO > 0$), clasificando la magnitud del retraso en las mismas tres categorías ($<30\%$, $30\%-60\%$, $>60\%$). La metodología empleó K-fold cross-validation (10-

fold) y optimización de hiperparámetros para asegurar la robustez del modelo. Los resultados demostraron que LGBM superó consistentemente a CatBoost y XGBoost en la predicción de riesgos de retraso en todas las categorías de TO, mostrando la mayor precisión de prueba (0.85) y la menor tasa de clasificación errónea (0.15). El estudio destacó el valor de LGBM como una herramienta predictiva robusta para la gestión de proyectos, permitiendo decisiones proactivas y estrategias de mitigación específicas. Además, resaltó la adaptabilidad de la metodología para ser entrenada con datos de otras regiones.

- («Bayesian Networks in Project Management», 2023), Aunque no se centra en la predicción de paralizaciones con aprendizaje automático, este estudio realizó una revisión exhaustiva del uso de Redes Bayesianas (BNs) en la gestión de proyectos. El autor señaló que las BNs son teóricamente ideales para la gestión de proyectos debido a su capacidad para representar gráficamente dependencias entre variables, facilita la toma de decisiones con datos incompletos y permitir un razonamiento explicable y transparente, a diferencia de técnicas de "caja negra" como las Redes Neuronales Artificiales (ANN) o las Máquinas de Vectores de Soporte (SVM). La revisión de 102 artículos publicados entre 2004 y 2021 mostró que las BNs se utilizan predominantemente para la Predicción (34.3%), siendo el área de "Construcción e Infraestructura" la más estudiada (55.9%). Aunque las BNs básicas son las más comunes, se observó una tendencia creciente en las BNs "Combinadas" y "Extendidas". Este estudio subraya la importancia de la interpretabilidad y la capacidad de manejar incertidumbre, aspectos cruciales también para el presente proyecto.

2.2. Bases Teóricas

La ejecución contractual constituye una fase crítica dentro del ciclo de vida de las inversiones públicas. De acuerdo con la Ley N.º 32069, Ley General de Contrataciones Públicas, la ejecución contractual comprende el conjunto de actos y obligaciones que deben cumplir tanto la entidad contratante como el contratista desde la suscripción del contrato hasta su culminación, liquidación y cierre.

El incumplimiento de las obligaciones contractuales durante esta fase puede derivar en la aplicación de penalidades, la resolución del contrato y, en escenarios críticos, en la paralización de la obra. Desde un enfoque de gestión pública, la paralización de obras representa una falla sistémica en la articulación entre planificación, contratación y ejecución.

2.3. Definición de Términos

2.3.1. Inversión pública

“La inversión pública es la aplicación de recursos públicos destinada a la creación, ampliación, mejoramiento o recuperación de la capacidad productora de bienes y servicios, orientada al cierre de brechas de infraestructura o de acceso a servicios públicos.” (Ministerio de Economía y Finanzas, Invierte.pe).

2.3.2. Proyecto de inversión

“El proyecto de inversión es una intervención temporal que utiliza recursos públicos para crear, ampliar, mejorar o recuperar la capacidad de producción de bienes o servicios públicos, cuyos beneficios se generan durante su vida útil.” (Ministerio de Economía y Finanzas, Invierte.pe).

2.3.3. Obra pública

“Se considera obra pública a toda construcción, reconstrucción, remodelación, demolición o mantenimiento ejecutado con recursos públicos, destinada a la prestación de servicios públicos o al cumplimiento de fines del Estado.” (Contraloría General de la República).

2.3.4. Ejecución contractual

“La ejecución contractual es la etapa del proceso de contratación que se inicia con la suscripción del contrato y culmina con su liquidación, en la cual las partes cumplen las obligaciones y prestaciones pactadas.” (Ley N.º 32069 – Ley General de Contrataciones Públicas).

2.3.5. Incumplimiento contractual

“Se configura el incumplimiento contractual cuando el contratista no ejecuta, total o parcialmente, las obligaciones asumidas en el contrato, conforme a las condiciones, plazos y especificaciones establecidas.” (Reglamento de la Ley N.º 32069, D.S. N.º 009-2025-EF).

2.3.6. Resolución de contrato

“La resolución del contrato es el acto mediante el cual la entidad o el contratista pone fin al vínculo contractual por la ocurrencia de causales expresamente previstas en la normativa vigente.” (Reglamento de la Ley N.º 32069, D.S. N.º 009-2025-EF).

2.3.7. Paralización de obra

“Se entiende por obra pública paralizada aquella que ha interrumpido su ejecución física por un periodo determinado, debido a causas técnicas, contractuales, legales, económicas o administrativas.” (Contraloría General de la República).

2.3.8. Expediente técnico

“El expediente técnico es el conjunto de documentos que contienen la descripción técnica, económica y financiera necesaria para la ejecución de una obra pública.” (Ministerio de Economía y Finanzas / Invierte.pe).

2.3.9. Avance físico

“El avance físico representa el porcentaje de ejecución de una obra respecto al total programado, medido en función de las partidas ejecutadas.” (Contraloría General de la República – Infobras).

2.3.10. Avance financiero

“El avance financiero corresponde al nivel de ejecución del gasto asociado a una obra pública en relación con el presupuesto asignado.” (Contraloría General de la República – Infobras).

CAPÍTULO III

PROPUESTA Y DESARROLLO DE LA SOLUCIÓN

3.1. Presentación de la Propuesta de Solución

3.1.1. Planteamiento General

La propuesta de solución consiste en el diseño e implementación de un sistema de aprendizaje automático supervisado para la estimación del riesgo de paralización de obras públicas por incumplimiento contractual. El sistema integra múltiples fuentes de datos administrativos oficiales, aplica técnicas de ingeniería de características orientadas al dominio, y evalúa comparativamente diversos algoritmos de clasificación para seleccionar el modelo de mejor desempeño.

La solución involucra los siguientes módulos:

1. **Adquisición de datos:** Extracción de registros desde fuentes oficiales (MEF, CGR, OSCE)
2. **Carga a Staging:** Ingestión de datos crudos a una capa de almacenamiento intermedio
3. **Preparación y limpieza:** Transformación, estandarización e integración de datasets
4. **Análisis exploratorio:** Caracterización estadística del dataset integrado
5. **Ingeniería de características:** Construcción del vector de características para modelamiento
6. **Entrenamiento de modelos:** Ajuste y validación de algoritmos de clasificación
7. **Comparación y selección:** Evaluación comparativa para selección del mejor modelo

3.1.2. Planteamiento Matemático

El problema se formula como una tarea de clasificación binaria supervisada, la clasificación es un problema de modelado predictivo que implica predecir la etiqueta de clase para una observación.

Sea $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$ un conjunto de datos donde:

- $\mathbf{x}_i \in \mathbb{R}^p$ representa el vector de p características de la i -ésima obra pública

- $y_i \in \{0,1\}$ indica si la obra se paralizó por incumplimiento contractual ($y_i = 1$) o no ($y_i = 0$)
- N es el número total de observaciones

El objetivo es encontrar una función de clasificación (predictor) $f: \mathbb{R}^p \rightarrow [0,1]$ que estime la probabilidad de paralización:

$$\hat{p}_i = f(\mathbf{x}_i) = P(y_i = 1 | \mathbf{x}_i)$$

Dado el desbalance de clases observado (aproximadamente 7.6% de casos positivos), se priorizan métricas que penalicen los falsos negativos. Se define el F-beta score como métrica principal:

$$F_\beta = (1 + \beta^2) \cdot \frac{\text{Precision} \cdot \text{Recall}}{(\beta^2 \cdot \text{Precision}) + \text{Recall}}$$

Con $\beta = 2$ (F2-Score), se otorga mayor peso al Recall, lo cual resulta apropiado cuando el costo de no detectar una obra en riesgo supera al costo de una falsa alarma.

Adicionalmente, se utiliza el Área Bajo la Curva Precision-Recall (PR-AUC) como métrica complementaria, definida como:

$$\text{PR-AUC} = \int_0^1 P(r) dr$$

donde $P(r)$ representa la precisión como función del recall r .

3.1.3. Arquitectura de la Solución

La Figura 3.1. presenta la canalización de aprendizaje automático desarrollado para la predicción de paralización de obras públicas. El flujo se organiza en cuatro capas principales: La ingesta e Integración de Datos, donde se extraen datos desde las fuentes oficiales CGR, MEF y OSCE, almacenándose en formato raw para luego cargarse en base de datos y consolidarse en un dataset integrado; La ingeniería de Características, que comprende el análisis exploratorio de datos (EDA) y la transformación de variables para generar el dataset de características; El entrenamiento y Validación, donde se ejecutan múltiples experimentos con diferentes algoritmos y configuraciones, generando métricas de evaluación; y el análisis de Resultados, que compara los experimentos realizados para seleccionar el modelo

con mejor desempeño predictivo. La arquitectura propuesta permite la trazabilidad completa desde los datos crudos hasta el modelo final, facilitando la reproducibilidad de los experimentos y el versionamiento de los artefactos generados.




Figura 6: Arquitectura del sistema de estimación de riesgo de paralización

Fuente: Elaboración Propia

3.2. Desarrollo de la Propuesta de Solución

1. Existe una insuficiente identificación sistemática y actualizada de los factores de riesgo asociados a la paralización de obras por incumplimiento contractual, integrando de manera coherente la literatura especializada, la normativa vigente y los registros administrativos de fuentes públicas oficiales; esta carencia debilita el sustento conceptual y operativo del estudio.
2. Se evidencia dispersión y heterogeneidad en los datos disponibles, así como la ausencia de procesos estandarizados de obtención, limpieza, estandarización, control de calidad e ingeniería de características, lo que impide conformar un dataset analítico reproducible adecuado para el aprendizaje automático.
3. Persiste la indeterminación del modelo de aprendizaje automático más adecuado y de sus configuraciones, debido a la falta de un marco comparativo de ajuste, entrenamiento y evaluación con métricas homogéneas, lo que dificulta una selección informada y la documentación de hiperparámetros y condiciones de uso.
4. Existe limitada interpretabilidad de las salidas del modelo, por la ausencia de técnicas de inteligencia artificial explicable que generen interpretaciones a nivel agregado y por obra, identifiquen los factores determinantes del riesgo y establezcan criterios de interpretación claros para la toma de decisiones.
5. Identificar los factores de riesgo asociados a la paralización de obras por incumplimiento contractual a partir de la literatura especializada, la normativa vigente y los registros administrativos de fuentes públicas oficiales.
6. Implementar la obtención y preparación de datos, incluyendo limpieza, estandarización y control de calidad, así como la ingeniería de características necesaria para el análisis con aprendizaje automático.
7. Comparar modelos de aprendizaje automático, mediante su ajuste, entrenamiento y evaluación con métricas pertinentes, para seleccionar el candidato de mejor desempeño y documentar sus hiperparámetros y condiciones de uso.
8. Aplicar técnicas de inteligencia artificial explicable para generar interpretaciones del modelo a nivel agregado y por obra, identificando los factores determinantes del riesgo y estableciendo criterios de interpretación para la toma de decisiones.

8.1.1. Adquisición de Datos

8.1.1.1. Fuentes de Datos

Se identificaron tres fuentes de datos administrativos que contienen información relevante sobre obras públicas en el Perú:

Fuente	Institución	Descripción	Formato
Banco de Inversiones	MEF	Proyectos de inversión pública registrados	CSV

Fuente	Institución	Descripción	Formato
INFObras	CGR	Obras públicas y obras paralizadas	XLS
Portal de Contrataciones	OECE	Contrataciones del Estado	CSV

Tabla 9: Fuentes de datos utilizadas en el estudio

En la figura Diagrama E-R de las principales entidades de datos del negocio se muestra el diagrama entidad relación del negocio de ejecución de obras asociadas a una inversión pública, se nombras las diferentes entidades, relaciones y atributos relevantes para el contexto




Figura 7: Diagrama E-R de las principales entidades de datos del negocio

Considerando las obras publicas con registros válidos, que se encuentren en con un estado finalizado, en ejecución o paralizadas, se presenta un diagrama de frecuencia de las paralizaciones por incumplimiento contractual




Figura 8: Frecuencia de paralizaciones por incumplimiento contractual respecto al total de obras no paralizadas

Fuente: Elaboración Propia

Filtros primarios (funcionales) para la obtención del conjunto de datos:

1. Se excluirán de la base inicial las obras que no hayan iniciado su ejecución, es decir no se considerarán obras con sin ejecución.
2. Se considerará obras públicas que tengan registrada una fecha de inicio de obra (fecha_inicio_obra).
3. Debido a que el alcance del trabajo está enmarcado en el dominio de la inversión pública (Iniverte.pe) solo se considerarán las obras publicas que estén asociados a un código de inversión existente en el banco de inversiones del MEF.
4. Se contempla trabajar el universo de obras públicas cuya modalidad de ejecución de obra es por Contrata.
5. Con respecto al causal de paralización se ha realizado una categorización de este concepto y se considerarán como las causales de paralización relacionadas a motivos contractuales, por lo tanto se considera incumplimientos del contrato ya sea por la entidad o el contratista, La **¡Error! No se encuentra el origen de la referencia.** 0 muestra las causales de paralización consideradas para la clase positiva.
6. Se consideran obras publicas ejecutadas por el gobierno nacional (Gobierno Nacional) nivel_gobierno = "GOBIERNO NACIONAL"

Causal de paralización	Categoría
Incumplimiento de contrato	CONTRACTUAL
Proceso arbitral	CONTRACTUAL
Resolución de contrato	CONTRACTUAL
Discrepancias controversias y arbitraje	CONTRACTUAL
Resolución del contrato de supervisión de obra	CONTRACTUAL
Obra Judicializada por la Entidad	CONTRACTUAL
Incumplimiento del pago de valorizaciones u otros	CONTRACTUAL / FINANCIERA

Tabla 10: Causales de paralización consideradas para la clase positiva

Luego de aplicar los filtros de negocio en búsqueda de un conjunto de datos con características adecuadas para maximizar los resultados del entrenamiento no encontramos con un subconjunto de datos de 7,367 registros y 31 características predictoras (iniciales).

8.1.1.2. Procedimiento de Extracción

El proceso de extracción se realizó mediante scripts semi automatizados. A continuación, se presenta el pseudocódigo del proceso de adquisición:

Algoritmo 1: Adquisición de Datos desde Fuentes Oficiales

Entrada: lista_fuentes ← {MEF, CGR}

Salida: archivos_crudos almacenados en capa raw

- 1: PARA CADA fuente EN lista_fuentes HACER
- 2: url ← obtener_url_descarga(fuente)
- 3: archivo ← descargar_archivo(url)
- 4: SI validar_descarga(archivo) ENTONCES
- 5: guardar(archivo, "data/raw/" + fuente.nombre)
- 6: registrar_metadata(archivo, fecha_descarga)
- 7: FIN SI
- 8: FIN PARA

8.1.2. Carga a Área de ensayo e integración del conjunto de datos inicial

8.1.2.1. Diseño de la Capa de ensayo

La capa de se implementó en base de datos relacional como área de almacenamiento persistente que preserva los datos tal como fueron recibidos, con mínimas transformaciones y validaciones de formato. Se crearon las siguientes tablas:

Tabla	Fuente	Registros	Descripción
SA_MEF_PROYECTOS	MEF	Aprox. 200,000	Proyectos de inversión
SA_CGR_OBRAS_PARALIZADAS	CGR	Aprox. 2,500	Obras identificadas como paralizadas
SA_CGR_OBRAS_PUBLICAS	CGR	Aprox. 180,000	Catálogo general de obras

Tabla 11: Tablas de la capa de staging

8.1.2.2. Canalización de los procesos ETL

El proceso de carga se implementó mediante un pipeline ETL desarrollado en Python con las bibliotecas *pandas* y *psycopg2*. El pseudocódigo del proceso se presenta a continuación:

Algoritmo 2: Carga de Datos a Staging

Entrada: archivo_crudo, esquema_destino

Salida: tabla_staging poblada

```
1: df ← leer_archivo(archivo_crudo)
2: df ← validar_tipos_datos(df, esquema_destino)
3: df ← agregar_campos_auditoria(df, fecha_carga)
4:
5: conexion ← conectar_postgresql()
6: INICIAR TRANSACCIÓN
7:   truncar_tabla(esquema_destino.tabla)
8:   insertar_lote(df, esquema_destino.tabla)
9: CONFIRMAR TRANSACCIÓN
10:
```

11: registrar_log(registros_cargados, errores)
12: RETORNAR estadísticas_carga

8.1.2.3. Integración de Datasets

La integración se realizó mediante operaciones de cruce utilizando los campos *codigo_unico_inversion* y *codigo_infobras* como llaves de enlace entre las diferentes fuentes:

Algoritmo 3: Integración de Datasets

Entrada: SA_MEF, SA_CGR_OBRAS, SA_CGR_PARALIZADAS
Salida: dataset_integrado

```
1: df_base ← LEFT_JOIN(SA_CGR_OBRAS, SA_MEF,  
                        ON codigo_unico_inversion)  
2: df_base ← LEFT_JOIN(df_base, SA_CGR_PARALIZADAS,  
                        ON codigo_infobras)  
3: df_base["flg_paralizada"] ← SI existe_en_paralizadas  
                        ENTONCES 1 SINO 0  
4: dataset_final ← filtrar(df_base,  
                           causal = "INCUMPLIMIENTO_CONTRACTUAL")  
5: exportar_csv(dataset_final)  
6: RETORNAR dataset_final
```

Como resultado de este proceso se obtuvo un conjunto de datos (funcional) el cual se utilizará como input para el proceso de ingeniería de características.

8.1.3. Preparación y Limpieza de Datos

8.1.3.1. Proceso de Limpieza

La preparación de datos comprendió las siguientes operaciones:

a) Tratamiento de valores nulos:

Se analizó el porcentaje de valores nulos por variable. Las variables con más del 70% de nulos fueron excluidas del análisis. Para las variables restantes, se aplicaron estrategias de imputación según el tipo de dato:

- Variables numéricas: imputación por mediana

- Variables categóricas: imputación por moda o categoría “Sin información”

b) Estandarización de catálogos:

Se generaron catálogos maestros para normalizar valores de variables categóricas con alta cardinalidad:

Variable	Valores Únicos Originales	Valores Estandarizados
Departamento	47	25
Tipo de obra	156	17
Estado de ejecución	23	8

Tabla 12: Estandarización de variables categóricas

8.1.3.2. Definición de la Variable Objetivo

La columna objetivo (Target) es del tipo binario (flg_opa_incumplimiento_contractual) donde 0 indica que la obra no se paralizó y 1 indica que la obra se paralizó por causal de incumplimiento contractual ya sea por responsabilidad del contratista o la entidad contratante. La distribución de las clases final se muestra en **¡Error! No se encuentra el origen de la referencia.**




Figura 9 Distribución de clases final del conjunto de datos

Fuente: Elaboración Propia

La variable objetivo *flg_opa_incumplimiento_contractual* se construyó a partir del análisis de las causales de paralización reportadas en el sistema INFObras de la CGR el cual se expone en Tabla 100. El estudio se enfoca en la categoría CONTRACTUAL, específicamente en el incumplimiento de contrato, por su relevancia para la gestión de riesgos y su potencial predictibilidad a partir de variables observables en el alcance de la tesis.

8.1.4. Análisis Exploratorio de Datos

El análisis exploratorio se realizó mediante notebooks de Python utilizando las bibliotecas *pandas*, *matplotlib* y *seaborn*. Los principales hallazgos se resumen a continuación:

8.1.4.1. Distribución Temporal respecto a la fecha de inicio de ejecución de obras.

Considerando todas las modalidades contractuales de conjunto de datos inicial, la **¡Error! No se encuentra el origen de la referencia.** presenta la distribución del inicio de la ejecución de obras públicas.




Figura 10 Distribución de la fecha inicio de obra considerando todas las modalidades de ejecución

Fuente: Elaboración Propia

8.1.4.2. Distribución de la Variable Objetivo

El dataset integrado presenta un marcado desbalance de clases:

Clase	Descripción	Casos	Porcentaje
0	No paralizada	6,806	92.4%
1	Paralizada por incumplimiento	561	7.6%
Total		7,367	100%

Tabla 13: Distribución de la variable objetivo

Este desbalance de clases (ratio aproximada de 12:1) implica consideraciones especiales en la selección de métricas de evaluación y técnicas de entrenamiento.

8.1.4.3. Análisis de Variables Predictoras

Las 31 características (iniciales) se agrupan en las siguientes categorías:

Variables institucionales:

- Nivel de gobierno (Nacional, Regional, Local)
- Marco normativo (SNIP, Invierte.pe)
- Tipo de formato de inversión

Variables del proyecto:

- Tipo de obra (17 categorías estandarizadas)
- Monto viable aprobado
- Costo de obra en soles

Variables de ejecución:

- Número de informes de control
- Número de comentarios ciudadanos
- Número de obras relacionadas al proyecto
- Días de modificaciones de plazo
- Número de controversias
- Número de adicionales de obra
- Número de adicionales de supervisión
- Número de deductivos

Variables contextuales:

- Flag de Reconstrucción con Cambios

- Flag de Reactivación Económica
- Frecuencia de obras en la provincia

8.1.4.4. Características calculadas

A partir de los resultados preliminares obtenidos con el dataset base de 31 características, se identificó la necesidad de enriquecer el conjunto de variables predictoras mediante la incorporación de características derivadas que capturen patrones históricos de comportamiento. Esta decisión se fundamenta en la literatura de gestión de riesgos contractuales, donde el historial de desempeño de los actores involucrados constituye un predictor relevante del comportamiento futuro.

Se diseñaron e implementaron ratios de paralización que cuantifican la proporción histórica de obras paralizadas asociadas a diferentes dimensiones del contrato. Las nuevas características calculadas se presentan en la siguiente tabla:

Característica	Descripción	Fórmula
tasa_paralizacion_entidad	Proporción histórica de obras paralizadas de la entidad contratante	$\frac{\text{Obras paralizadas de la entidad}}{\text{Total obras de la entidad}}$
n_obras_x_entidad	Cantidad total de obras ejecutadas por la entidad	COUNT(obras de la entidad)
inv_monto_viable_promedio_entidad	Monto viable promedio de los proyectos de inversión de la entidad	$\frac{\sum \text{Monto viable}}{\text{Total obras de la entidad}}$
tasa_paralizacion_departamento	Proporción histórica de obras paralizadas en el departamento	$\frac{\text{Obras paralizadas en el departamento}}{\text{Total obras en el departamento}}$
tasa_paralizacion_distrito	Proporción histórica de obras paralizadas en el distrito	$\frac{\text{Obras paralizadas en el distrito}}{\text{Total obras en el distrito}}$
tasa_paralizacion_tipo_obra_nivel_1	Proporción histórica de obras paralizadas según tipología de obra	$\frac{\text{Obras paralizadas del tipo}}{\text{Total obras del tipo}}$

Tabla 14: Características de tasas de paralización y variables agregadas incorporadas en la segunda iteración

8.1.5. Ingeniería de Características

8.1.5.1. Codificación de Variables Categóricas

Las variables categóricas se transformaron mediante codificación one-hot (dummy encoding) para su uso en los algoritmos de aprendizaje automático:

Algoritmo 4: Codificación de Variables Categóricas

Entrada: df, lista_variables_categoricas

Salida: df_codificado

```
1: PARA CADA var EN lista_variables_categoricas HACER
2:   categorias ← obtener_categorias_unicas(df[var])
3:   PARA CADA cat EN categorias[1:] HACER # drop_first
4:     nombre_col ← var + "_" + cat
5:     df[nombre_col] ← SI df[var] == cat ENTONCES 1 SINO 0
6:   FIN PARA
7:   eliminar_columna(df, var)
8: FIN PARA
9: RETORNAR df_codificado
```

8.1.5.2. Frequency Encoding para Alta Cardinalidad

Para la variable *provincia* (alta cardinalidad), se aplicó frequency encoding:

$$\text{provincia_freq_enc}_i = \frac{\text{count}(\text{provincia}_i)}{N}$$

Esta transformación captura la frecuencia relativa de obras por provincia, actuando como proxy de la capacidad institucional y experiencia en gestión de proyectos.

8.1.5.3. Dataset Final para Modelamiento

El dataset resultante contiene 7,367 observaciones y 31 características (features):

Tipo	Cantidad	Ejemplos
Binarias	17	<i>nivel_gobierno_GOBIERNO NACIONAL, marco_INVIERTE</i>
Númericas continuas	10	<i>monto_viable_aprobado, n_controversias</i>

Tipo	Cantidad	Ejemplos
Numéricas discretas	4	<i>n_informes_control, n_adicionales_obra</i>

Tabla 15: Composición del vector de características

8.1.6. Entrenamiento de Modelos

8.1.6.1. Estrategia de Partición de Datos

Se aplicó una estrategia de partición estratificada para preservar la proporción de clases en cada subconjunto:

Conjunto	Porcentaje	Registros	Uso
Entrenamiento	68%	5,009	Ajuste de modelos
Validación	12%	884	Optimización de umbral
Test	20%	1,474	Evaluación final

Tabla 16: Partición de datos

8.1.6.2. Modelos Evaluados

Se evaluaron cinco familias de algoritmos de clasificación:

1. Regresión Logística: Modelo lineal con regularización L2
2. Random Forest: Ensamble de árboles de decisión con bagging
3. XGBoost: Gradient boosting con regularización
4. LightGBM: Gradient boosting con crecimiento leaf-wise
5. CatBoost: Gradient boosting con manejo nativo de categóricas

8.1.6.3. Búsqueda de Hiperparámetros

Se implementó RandomizedSearchCV con validación cruzada estratificada (5 folds) para la optimización de hiperparámetros. El pseudocódigo del proceso se presenta a continuación:

Algoritmo 5: Búsqueda de Hiperparámetros

Entrada: modelo_base, espacio_parametros, X_train, y_train

Salida: mejor_modelo, mejores_parametros

```
1: cv ← StratifiedKFold(n_splits=5, shuffle=True)
2: scorer ← "average_precision" # PR-AUC
3:
4: search ← RandomizedSearchCV(
5:     estimator = modelo_base,
6:     param_distributions = espacio_parametros,
7:     n_iter = 50,
8:     scoring = scorer,
9:     cv = cv,
10:    n_jobs = -1
11: )
12:
13: search.fit(X_train, y_train)
14:
15: mejor_modelo ← search.best_estimator_
16: mejores_parametros ← search.best_params_
17: mejor_score_cv ← search.best_score_
18:
19: RETORNAR mejor_modelo, mejores_parametros
```

8.1.6.4. Optimización de Umbral de Decisión

Dado el desbalance de clases, se optimizó el umbral de decisión en el conjunto de validación para maximizar el F2-Score:

Algoritmo 6: Optimización de Umbral

Entrada: modelo, X_val, y_val

Salida: umbral_optimo

```
1: y_proba ← modelo.predict_proba(X_val)[:, 1]
2:
3: mejor_f2 ← 0
4: umbral_optimo ← 0.5
5:
6: PARA umbral EN [0.1, 0.15, 0.20, ..., 0.90] HACER
7:     y_pred ← SI y_proba >= umbral ENTONCES 1 SINO 0
8:     f2 ← calcular_f2_score(y_val, y_pred)
9:     SI f2 > mejor_f2 ENTONCES
```

```

10:     mejor_f2 ← f2
11:     umbral_optimo ← umbral
12:   FIN SI
13: FIN PARA
14:
15: RETORNAR umbral_optimo

```

8.1.7. Comparación y Selección de Modelos

8.1.7.1. Métricas de Evaluación

Se utilizaron las siguientes métricas, priorizadas según su relevancia para el problema de clasificación desbalanceada:

Métrica	Fórmula	Prioridad
Recall	$\frac{TP}{TP + FN}$	Alta
PR-AUC	$\int_0^1 P(r)dr$	Alta
F2-Score	$(1 + 4) \cdot \frac{P \cdot R}{4P + R}$	Alta
F1-Score	$2 \cdot \frac{P \cdot R}{P + R}$	Media
Precision	$\frac{TP}{TP + FP}$	Media
ROC-AUC	Área bajo curva ROC	Baja
Accuracy	$\frac{TP + TN}{N}$	Baja (sesgada)

Tabla 17: Métricas de evaluación utilizadas

8.1.7.2. Proceso de Comparación

El módulo de análisis de experimento implementa la comparación sistemática de experimentos:

Algoritmo 7: Comparación de Experimentos

Entrada: directorio_experimentos
 Salida: ranking_modelos, reporte_comparativo
 1: experimentos ← []

```

2:
3: PARA CADA carpeta EN directorio_experimentos HACER
4:   config ← leer_yaml(carpeta + "/config.yaml")
5:   metricas ← leer_json(carpeta + "/metrics.json")
6:   experimentos.agregar({
7:     "id": carpeta.nombre,
8:     "modelo": config.modelo,
9:     "metricas": metricas
10:  })
11: FIN PARA
12:
13: # Ranking por cada métrica prioritaria
14: PARA CADA metrica EN ["recall", "pr_auc", "f2_score"] HACER
15:   ranking[metrica] ← ordenar(experimentos,
16:                               por=metrica,
17:                               descendente=True)
18: FIN PARA
19:
20: # Selección del mejor modelo
21: mejor_experimento ← ranking["f2_score"][0]
22:
23: generar_reporte_markdown(ranking, mejor_experimento)
24: RETORNAR ranking, mejor_experimento

```

8.2. Análisis de los Datos y Resultados

En esta sección se presentan los resultados de las corridas experimentales ejecutadas para la comparación de modelos (OE3). El análisis se realizó bajo un esquema homogéneo de partición (entrenamiento/validación/prueba), semilla fija y métricas consistentes, con énfasis en escenarios de clasificación desbalanceada donde la clase positiva representa un porcentaje reducido del total de observaciones.

Se ejecutaron 26 experimentos, correspondientes a configuraciones distintas por familia de modelo, con el propósito de evaluar el intercambio entre capacidad de detección (Recall), calidad de las alertas (Precision) y desempeño global bajo la curva Precision-Recall (PR-AUC). El umbral de decisión se optimizó en validación para definir el punto operativo de cada modelo y, posteriormente, se reportaron las métricas en el conjunto de prueba.

8.2.1. Métricas Comparativas en el Conjunto de Prueba

Modelo	Umbral	Recall	Precision	F2-Score	PR-AUC	ROC-AUC	Accuracy
Regresión Logística	0.7629	0.5357	0.3727	0.4926	0.3481	0.8259	0.8962
Random Forest	0.4856	0.5982	0.4527	0.5621	0.5416	0.8729	0.9145
XGBoost	0.6572	0.5893	0.6000	0.5914	0.6150	0.8915	0.9389
LightGBM	0.5545	0.5536	0.6966	0.5773	0.5900	0.8883	0.9478
CatBoost	0.6499	0.5982	0.6262	0.6036	0.6011	0.8871	0.9423

Tabla 18: Métricas comparativas (mejor corrida por modelo, conjunto de prueba)

Los resultados evidencian que los modelos basados en gradient boosting (CatBoost, XGBoost y LightGBM) presentan un desempeño superior al modelo lineal base en términos de PR-AUC y F2-Score. Asimismo, LightGBM alcanza la mayor precisión, mientras que CatBoost y Random Forest logran el mayor recall (con diferencias marginales), evidenciando distintos puntos de operación.

La **¡Error! No se encuentra el origen de la referencia.** muestra los resultados obtenidos de las métricas elegidas para evaluación de la clasificación del dataset desbalanceado, se realizó un ordenamiento colocando el mejor rendimiento (modelo) hacia la izquierda.




Figura 11: Grafico de barras de modelos, ordenado por relevancia en el valor de la métrica obtenida

Fuente: Elaboración Propia

Para poder tomar una decisión final en la elección del mejor modelo se realizó una normalización de los resultados de las diferentes métricas de evaluación para obtener un indicador global, el cual se muestra en la **¡Error! No se encuentra el origen de la referencia.**




Figura 12: Mapa de calor que muestra la normalización de los valores de las diferentes métricas para la obtención de un solo indicador de elección

Fuente: Elaboración Propia

8.2.2. Selección del Mejor Modelo y Matriz de Confusión

De acuerdo con los criterios definidos para el problema (prioridad en F2-Score y PR-AUC), el mejor desempeño global corresponde a CatBoost, con F2-Score = 0.6036 y PR-AUC = 0.6011 en el conjunto de prueba, bajo un umbral de decisión de 0.6499. Este resultado implica una capacidad de detección de aproximadamente 59.8% de casos positivos (recall), con una proporción de alertas correctas de 62.6% (precision).

	Predicción: 0	Predicción: 1
Real: 0	TN = 1322	FP = 40
Real: 1	FN = 45	TP = 67

Tabla 19: Matriz de confusión del modelo seleccionado (CatBoost, conjunto de prueba)

En términos operativos, el modelo genera 107 alertas (TP + FP) en el conjunto de prueba, de las cuales 67 corresponden a casos verdaderamente positivos. No obstante, se identifican 45 falsos negativos (FN), los cuales representan casos de riesgo no detectados; este resultado sustenta la necesidad de considerar ajustes de umbral y políticas de priorización en función de capacidades institucionales.

8.2.3. Importancia de Variables del Modelo Seleccionado

Con el objetivo de interpretar el comportamiento del modelo seleccionado y vincular la predicción con factores observables (OE1), se analizó la importancia de variables provista por el modelo CatBoost. En la Tabla 19 se reportan las diez variables con mayor contribución.

Ranking	Variable	Importancia
1	tasa_paralizacion_entidad	12.4917
2	costo_obra_soles	10.6516
3	inv_monto_viable	9.1662
4	tasa_paralizacion_distrito	7.6071
5	n_controversias	5.4106
6	departamento_target_enc	5.3432
7	inv_monto_viable_promedio_entidad	4.9626
8	tasa_paralizacion_departamento	4.9410
9	naturaleza_obra_target_enc	4.7640
10	n_informes_control	4.6190

Tabla 20: Lista de 10 variables más influyentes del mejor modelo (CatBoost)

El patrón de variables sugiere que los predictores más relevantes se asocian con

- Señales históricas de desempeño institucional y territorial (tasas de paralización por entidad y territorio).
- Magnitud económica del proyecto (costo y monto de inversión), y
- Indicadores de conflictividad y control (controversias e informes). Este resultado es consistente con la hipótesis H1, en tanto se identifican factores

observables (en registros administrativos) asociados al riesgo de paralización por incumplimiento contractual.

8.3. Discusión e Interpretación de los Resultados

8.3.1. Contraste con la Hipótesis H3

La hipótesis H3 establece que, entre los modelos considerados, al menos uno presenta desempeño superior respecto de los demás para estimar el riesgo de paralización por incumplimiento contractual. Los resultados comparativos presentados en la Tabla 17, respaldan dicha hipótesis, dado que se observa un rendimiento superior de modelos de boosting frente al modelo base lineal.

En particular, el modelo CatBoost obtiene $F2\text{-Score} = 0.6036$ y $PR\text{-AUC} = 0.6011$ en prueba, superando a la regresión logística ($F2\text{-Score} = 0.4926$; $PR\text{-AUC} = 0.3481$). Esta diferencia es relevante porque la PR-AUC es una métrica robusta para escenarios desbalanceados y la métrica F2 penaliza en mayor medida los falsos negativos, alineándose con la finalidad de identificar obras con potencial riesgo.

8.3.2. Limitaciones del Estudio

El estudio presenta limitaciones que deben considerarse para la interpretación de resultados:

- La variable objetivo se construye a partir de registros administrativos y categorizaciones de causalidad, según revisión se encontró que la categorización realizada en infobras difiere del reporte de obras paralizadas y esta a su vez difiere de la clasificación realizadas por el ministerio de economía y finanzas, en ese sentido se puede introducir sesgos por subregistro, criterios de clasificación o cambios en la calidad de reporte entre periodos.
- El análisis se basa en una partición específica de datos; aunque se mantiene consistencia experimental, una evaluación adicional con validación temporal permitiría aproximar mejor el comportamiento ante cambios de contexto.
- La importancia de variables no implica causalidad; su interpretación debe entenderse como asociación predictiva bajo el modelo ajustado.

8.4. Estimación del Impacto de la Solución

8.4.1. Impacto Operativo

El modelo seleccionado (CatBoost) alcanza un recall de 0.5982 en prueba, lo que implica que, aproximadamente, 6 de cada 10 obras con paralización por incumplimiento contractual son identificadas bajo el umbral operativo reportado. Además, con precisión de 0.6262, cerca de 6 de cada 10 alertas emitidas corresponden a casos verdaderamente positivos. En consecuencia, el sistema propuesto permite focalizar recursos de supervisión sobre un subconjunto reducido de obras con mayor probabilidad de riesgo.

8.4.2. Impacto en la Gestión de Riesgos

La solución contribuye a la gestión de riesgos al introducir un criterio cuantitativo y reproducible para priorizar intervenciones. En particular, la identificación de variables asociadas a historial institucional/territorial y señales de conflictividad permite orientar estrategias preventivas (monitoreo, control concurrente, revisiones contractuales) hacia obras con patrones de riesgo más pronunciados.

CAPÍTULO IV

CONCLUSIONES Y RECOMENDACIONES

4.1 Conclusiones

1. Los resultados experimentales confirman que existen factores observables en registros administrativos asociados al riesgo de paralización por incumplimiento contractual, en coherencia con la hipótesis H1. En particular, el modelo seleccionado asigna mayor importancia a variables agregadas institucionales y territoriales.
2. El desempeño comparativo evidencia superioridad de los modelos de gradient boosting frente al modelo lineal base, lo cual sustenta la hipótesis H3. En el conjunto de prueba, la regresión logística obtiene F2-Score = 0.4926 y PR-AUC = 0.3481, mientras que CatBoost alcanza F2-Score = 0.6036 y PR-AUC = 0.6011, y XGBoost alcanza F2-Score = 0.5914 y PR-AUC = 0.6150.
3. El modelo CatBoost presenta el mejor desempeño global bajo los criterios definidos para el problema (F2-Score y PR-AUC), con Recall = 0.5982 y Precision = 0.6262 en el conjunto de prueba (Tabla 17). Esto implica un balance operativo favorable entre la capacidad de detección y la calidad de las alertas emitidas.
4. La matriz de confusión del modelo seleccionado (Tabla 18) muestra 67 verdaderos positivos y 40 falsos positivos (107 alertas en total), junto con 45 falsos negativos. Este resultado evidencia que el modelo reduce la omisión de casos relevantes, aunque mantiene una fracción no despreciable de casos de riesgo no detectados, lo que justifica la gestión del umbral como variable de política operativa.
5. El conjunto de resultados obtenidos confirma la viabilidad de una canalización de procesos de aprendizaje automático reproducible de obtención, preparación e ingeniería de características para construir un dataset analítico aplicable al aprendizaje automático (OE2). La consistencia de métricas y la disponibilidad de artefactos por experimento (métricas y relevancia de variables) sustentan el cumplimiento del objetivo de comparación y documentación del modelo (OE3).

6. El tiempo de ejecución de cada instancia de experimento no supero los 2min en su duración lo cual es favorable y permite la validación de múltiples factores en búsqueda de la obtención del mejor resultado global.

4.2 Recomendaciones

1. A partir de las limitaciones identificadas durante el proceso de obtención y preparación de datos, se recomienda trabajar de la mano con las entidades rectoras para la mejora de la calidad de los datos en las fuentes administrativas con énfasis en la definición de catálogos maestros unificados para variables críticas como causales de paralización, tipología de obras y estados contractuales; y la publicación de diccionarios de datos y metadatos que faciliten la interoperabilidad entre fuentes.
2. Aplicar técnicas de reducción de la dimensionalidad como PCA para mejorar el rendimiento del modelo.
3. Aplicar técnicas de búsqueda de mejores hiperparametros (como por ejemplo Algoritmos evolutivos) para contrastar con el método de búsqueda aleatoria en cuadrilla usado en el presente trabajo.
4. Se recomienda definir el umbral de decisión como un parámetro de operación revisable periódicamente. Dado que el umbral modifica el número de alertas (y, por tanto, la carga de atención), su ajuste debe basarse en la capacidad institucional y en el costo relativo de falsos negativos frente a falsos positivos.
5. Se recomienda incorporar evaluación temporal (por periodos) como complemento a la evaluación por partición aleatoria. Este enfoque permitiría estimar con mayor precisión el desempeño del modelo ante cambios de contexto y mitigaría riesgos por deriva de datos.
6. Se recomienda fortalecer el control de calidad de datos y la trazabilidad de la variable objetivo, debido a que su construcción depende de criterios de registro y clasificación administrativa. En particular, se sugiere monitorear consistencia de categorizaciones, valores faltantes y cambios en catálogos entre periodos.
7. Se recomienda mantener y ampliar las variables agregadas de contexto institucional y territorial (tasas y promedios por entidad/territorio) por su contribución predictiva. De manera complementaria, se sugiere evaluar

nuevas variables de ejecución y cumplimiento contractual, en la medida que existan fuentes oficiales disponibles.

Referencias

- Alsulamy, S. (2025). Predicting construction delay risks in Saudi Arabian projects: A comparative analysis of CatBoost, XGBoost, and LGBM. *Expert Systems with Applications*, 268, 126268. <https://doi.org/10.1016/j.eswa.2024.126268>
- Bayram, F., & Ahmed, B. (2025). Towards Trustworthy Machine Learning in Production: An Overview of the Robustness in MLOps Approach. *ResearchGate*. <https://doi.org/10.1145/3708497>
- Contraloría General de la Republica del Perú. (2025). *Informe de Obras Públicas Paralizadas En El Territorio Nacional A Diciembre 2024* (No. N° 001-2025-CG/SESNC; p. 74). Contraloría general de la republica del Perú.
- Gondia, A., Siam, A., El-Dakhakhni, W., & Nassar, A. H. (2020). Machine Learning Algorithms for Construction Projects Delay Risk Prediction. *Journal of Construction Engineering and Management*, 146(1), 04019085. [https://doi.org/10.1061/\(ASCE\)CO.1943-7862.0001736](https://doi.org/10.1061/(ASCE)CO.1943-7862.0001736)
- Lundberg, S., & Lee, S.-I. (2017). *A Unified Approach to Interpreting Model Predictions* (No. arXiv:1705.07874). arXiv. <https://doi.org/10.48550/arXiv.1705.07874>
- MEF - Portal de Seguimiento. (s. f.). Recuperado 23 de junio de 2025, de <https://ofi5.mef.gob.pe/inviertews/Repseguim/ResumF12B?codigo=2314836>
- Nnaemeka Egwim, C., Alaka, H., & Olalekan Toriola-Coker, L. (2021). Applied artificial intelligence for predicting construction projects delay. *Machine Learning with Applications*, 6, 100166. <https://doi.org/10.1016/j.mlwa.2021.100166>
- Solís-Villanueva, R. (2018). Técnicas de inteligencia artificial para optimizar la eficiencia del procedimiento de selección para la contratación de obras públicas. *Interfases*, 011, Article 011. <https://doi.org/10.26439/interfases2018.n011.2951>
- Ministerio de Economía y Finanzas. (2024, 21 de junio).** *Ley N° 32069: Ley General de Contrataciones Públicas*. Diario Oficial El Peruano.
- Ministerio de Economía y Finanzas. (2016, 1 de diciembre).** *Decreto Legislativo N° 1252: Decreto Legislativo que crea el Sistema Nacional de Programación Multianual y Gestión de Inversiones*. Diario Oficial El Peruano.
- Ministerio de Economía y Finanzas. (2024).** *Reglamento de la Ley N° 32069, Ley General de Contrataciones Públicas* (Decreto Supremo N° 278-2024-EF). Diario Oficial El Peruano.

Anexos

Anexo 1 Matriz de consistencia

Título: Estimación del riesgo de paralización de obras públicas en el Perú por incumplimiento contractual usando modelos de aprendizaje automático

Problemas	Objetivos	Hipótesis
Problema General: En la gestión de obras públicas en el Perú, se presenta una insuficiente identificación y articulación de los factores asociados a la paralización de obras por incumplimiento contractual, a partir de la información disponible en la normativa vigente, la literatura especializada y los registros administrativos de fuentes públicas. Esta situación limita la comprensión integral del fenómeno y dificulta la toma de decisiones oportunas orientadas a la prevención y gestión del riesgo de paralización durante la ejecución contractual.	Objetivo General: Analizar la incidencia y articulación de los factores de riesgo asociados a la paralización de obras públicas por incumplimiento contractual, mediante el examen de la normativa vigente, la literatura especializada y la evidencia contenida en los registros administrativos de fuentes públicas oficiales, con la finalidad de generar un marco de conocimiento técnico que sustente la comprensión y prevención del riesgo en la ejecución de inversiones.	Hipótesis General: La identificación y análisis articulado de los factores de riesgo derivados de la normativa vigente, la literatura especializada y los registros administrativos de fuentes públicas oficiales permiten explicar de manera significativa la paralización de obras públicas por incumplimiento contractual, proporcionando una base técnica válida para la prevención del riesgo observado durante la ejecución del contrato.
P1. Existe una falta de identificación sistemática y actualizada de los factores de riesgo asociados a la paralización de obras por incumplimiento contractual, integrando de manera coherente la literatura especializada, la normativa vigente y los registros administrativos de fuentes públicas oficiales; esta carencia debilita el sustento conceptual y operativo del estudio.	OE1. Identificar los factores de riesgo asociados a la paralización de obras por incumplimiento contractual a partir de la literatura especializada, la normativa vigente y los registros administrativos de fuentes públicas oficiales.	H1. Existen factores observables en la literatura, la normativa y los registros administrativos que se asocian con la paralización de obras por incumplimiento contractual.
P2. Se evidencia dispersión y heterogeneidad en los datos disponibles, así como	OE2. Implementar la obtención y preparación de datos,	H2. La obtención y preparación de datos, que comprende limpieza,

Problemas	Objetivos	Hipótesis
la ausencia de procesos estandarizados de obtención, limpieza, estandarización, control de calidad e ingeniería de características, lo que impide conformar un dataset analítico reproducible adecuado para el aprendizaje automático.	incluyendo limpieza, estandarización y control de calidad, así como la ingeniería de características necesaria para el análisis con aprendizaje automático.	estandarización, control de calidad e ingeniería de características, mejora el desempeño del modelo de aprendizaje automático para estimar el riesgo de paralización de obras por incumplimiento contractual, en comparación con el uso de datos sin preprocesamiento.D7
P3. Persiste la indeterminación del modelo de aprendizaje automático más adecuado y de sus configuraciones, debido a la falta de un marco comparativo de ajuste, entrenamiento y evaluación con métricas homogéneas, lo que dificulta una selección informada y la documentación de hiperparámetros y condiciones de uso.	OE3. Comparar modelos de aprendizaje automático, mediante su ajuste, entrenamiento y evaluación con métricas pertinentes, para seleccionar el candidato de mejor desempeño y documentar sus hiperparámetros y condiciones de uso.	H3. Entre los modelos de aprendizaje automático considerados para su evaluación comparativa, al menos uno presenta desempeño superior para estimar el riesgo de paralización de obras por incumplimiento contractual respecto de los demás modelos evaluados.
P4. Existe limitada interpretabilidad de las salidas del modelo, por la ausencia de técnicas de inteligencia artificial explicable que generen interpretaciones a nivel agregado y por obra, identifiquen los factores determinantes del riesgo y establezcan criterios de interpretación claros para la toma de decisiones.	OE4. Aplicar técnicas de inteligencia artificial explicable para generar interpretaciones del modelo a nivel agregado y por obra, identificando los factores determinantes del riesgo y estableciendo criterios de interpretación para la toma de decisiones.	H4. Las técnicas de inteligencia artificial explicable aplicadas al modelo generan interpretaciones a nivel agregado y por obra, identifican de manera consistente los factores determinantes del riesgo y permiten establecer criterios claros de interpretación para su uso en la toma de decisiones.