

UNIVERSIDAD NACIONAL DE INGENIERIA

**UNIDAD DE POSGRADO
FACULTAD DE INGENIERIA INDUSTRIAL Y DE SISTEMAS
ESCUELA DE POSGRADO**



PLAN DE TESIS:

**“DISEÑO, IMPLEMENTACIÓN Y EVALUACIÓN DE UN SISTEMA INTELIGENTE
BASADO EN PROCESAMIENTO DE LA LENGUAJE NATURAL PARA LA MEJORA DE
LOS TIEMPOS Y TRAZABILIDAD EN LA ATENCIÓN DE LOS INCIDENTES DE
EMERGENCIA MUNICIPAL EN EL PERÚ”**

**PARA OBTENER EL GRADO ACADÉMICO DE MAESTRO
CON MENCIÓN EN: INTELIGENCIA ARTIFICIAL**

ELABORADA POR:

[REDACTED]

DOCENTE:

SAMUEL ALONSO OPORTO DIAZ

LIMA, PERÚ

[REDACTED]

©2026, Universidad Nacional de Ingeniería. Todos los derechos reservados.

“Los autores autorizan a la UNI a reproducir la tesis en su totalidad o en parte, con fines estrictamente académicos.”

[Redacted signature area]

RESUMEN

La presente investigación desarrolla e implementa un sistema inteligente basado en procesamiento de lenguaje natural (NLP) orientado a mejorar los tiempos de atención y la trazabilidad operativa de las llamadas de emergencia municipal en la Provincia Constitucional del Callao. El problema abordado radica en la dependencia de procesos manuales y no estandarizados para registrar y clasificar los reportes ciudadanos, lo que genera errores en la calidad del dato, subjetividad en la categorización, ausencia de seguimiento estructurado y limitaciones para el análisis agregado de incidentes.

El estudio utiliza un conjunto de datos reales compuesto por 104 536 registros correspondientes a los años 2023 y 2024, obtenidos de la central de emergencias municipal. Se adopta una metodología experimental incremental estructurada en cinco etapas: Y0 como línea base del proceso manual; Y1 orientada a la curación y normalización del texto; Y2 centrada en la representación semántica mediante técnicas TF-IDF y embeddings BETO; Y3 dedicada a la aplicación de estrategias de balanceo y modelos de clasificación supervisada; y Y4 enfocada en la integración del pipeline completo dentro de un prototipo de modulo operativo inteligente con automatización del flujo y gestión de estados del incidente.

El desempeño del sistema se evalúa mediante un diseño experimental factorial que compara múltiples combinaciones de técnicas en términos de métricas clasificatorias (accuracy, precision, recall y F1-score) y métricas operativas asociadas al tiempo de procesamiento y trazabilidad del ciclo de atención. Los resultados evidencian mejoras significativas frente al proceso manual, demostrando que la automatización del análisis textual y la orquestación del flujo permiten reducir la dependencia del operador humano, estandarizar la clasificación de incidentes y habilitar mediciones objetivas del desempeño operativo.

La investigación concluye que el sistema propuesto es viable para su adopción en contextos municipales reales y constituye una base replicable para otras jurisdicciones urbanas del país interesadas en fortalecer la gestión de la seguridad ciudadana mediante analítica avanzada y soluciones basadas en inteligencia artificial.

Palabras clave: Incidentes, llamadas de emergencia, seguridad ciudadana, procesamiento de lenguaje natural, NLP, clasificación automática, trazabilidad operativa.

ABSTRACT

This research designs and implements an intelligent system based on natural language processing (NLP) aimed at improving operational traceability and response times in municipal emergency calls in the Constitutional Province of Callao, Peru. The problem addressed lies in the reliance on manual and non-standardized processes to register and classify citizen reports, which results in poor data quality, subjective categorization, lack of structured follow-up, and limited capacity for aggregated incident analysis.

The study relies on a real-world dataset comprising 104,536 records from 2023–2024 obtained from the municipal emergency center. An incremental experimental methodology is adopted through five stages: Y0 establishes the manual baseline; Y1 focuses on text curation and normalization; Y2 evaluates semantic representations using TF-IDF and BETO embeddings; Y3 applies data balancing strategies and supervised classification models; and Y4 integrates the complete pipeline into an operational prototype featuring automated workflows and incident state management.

System performance is assessed through a factorial experimental design that compares multiple technique combinations using classification metrics (accuracy, precision, recall, and F1-score) and operational indicators related to processing time and traceability. Results show substantial improvements over the manual process, demonstrating that automated textual analysis and pipeline orchestration reduce operator dependence, standardize incident classification, and enable objective monitoring of operational performance.

The study concludes that the proposed system is technically feasible for real municipal deployment and provides a replicable foundation for other urban jurisdictions seeking to strengthen public-safety management through advanced analytics and artificial-intelligence-based solutions.

Keywords: Incident, emergency calls, public safety, natural language processing, NLP, automatic classification, operational traceability.

INDICE

RESUMEN

ABSTRACT

INDICE

INDICE DE FIGURAS

INDICE DE TABLAS

INDICE DE CUADROS

INTRODUCCIÓN

CAPITULO I. PLANTEAMIENTO DEL PROBLEMA

- 1.1. Contexto de la inseguridad ciudadana en el ámbito municipal**
 - 1.1.1.** Inseguridad ciudadana en contextos urbanos densamente poblados
 - 1.1.2.** Consecuencias económicas y sociales de la inseguridad ciudadana
 - 1.1.3.** Limitaciones en la gestión municipal
 - 1.1.4.** Complejidad de las descripciones de emergencia y datos disponibles
 - 1.1.5.** Desafíos tecnológicos y subutilización de datos
 - 1.1.6.** Caracterización operativa de las llamadas de emergencia
 - 1.1.7.** Métricas de evaluación y métricas de solución tecnológica
- 1.2.** Situación problemática en la atención de llamadas de emergencia
- 1.3.** Diagnóstico operativo del sistema actual
- 1.4.** Formulación del problema
 - 1.4.1** Problema general
 - 1.4.2** Problemas específicos
- 1.5.** Objetivos
 - 1.5.1** Objetivo general
 - 1.5.2** Objetivos específicos
- 1.6.** Representación del problema
- 1.7.** Justificación de la investigación
- 1.8.** Alcances
- 1.9.** Limitaciones

CAPITULO II. MARCO TEÓRICO Y ANTECEDENTES

- 2.1** Antecedentes nacionales e internacionales
- 2.2** Procesamiento de Lenguaje Natural aplicado a reportes ciudadanos
- 2.3** Representación semántica del texto
 - 2.3.1** TF-IDF y modelos basados en conteo
 - 2.3.2** Word embeddings
 - 2.3.3** BETO y fine-tuning

- 2.4 Clasificación supervisada multiclase
- 2.5 Técnicas de balanceo de datos
- 2.6 Evaluación de modelos de clasificación
- 2.7 Trazabilidad operativa y automatización de procesos
- 2.8 Sistemas de apoyo a la decisión en seguridad ciudadana

CAPÍTULO III: HIPÓTESIS, VARIABLES Y DISEÑO METODOLÓGICO

- 3.1 Hipótesis de investigación
- 3.1 Variables de estudio
 - 3.2.1 Variables independientes
 - 3.2.2 Variables dependientes
 - 3.2.3 Operacionalización de variables
- 3.3 Tipo y nivel de investigación
- 3.4 Diseño metodológico
- 3.5 Población y muestra
- 3.6 Técnicas e instrumentos de recolección de datos
- 3.7 Técnicas de análisis de datos
- 3.8 Diseño experimental factorial
- 3.9 Métricas de evaluación

CAPÍTULO IV: DESCRIPCIÓN DEL SISTEMA PROPUESTO

- 4.1 Arquitectura general del sistema
- 4.2 Pipeline NLP automatizado
- 4.3 Gestión de estados del incidente
- 4.4 Orquestación del flujo operativo
- 4.5 Prototipo de atención automatizada
- 4.6 Integración con mensajería (WhatsApp)

CAPÍTULO V: EXPERIMENTACIÓN Y RESULTADOS

- 5.1 Línea base del proceso manual (Y0)
- 5.2 Curación y normalización del texto (Y1)
- 5.3 Representación semántica (Y2)
- 5.4 Clasificación y balanceo (Y3)
- 5.5 Sistema automatizado y prototipo operativo (Y4)
- 5.6 Comparación cuantitativa Y0 vs Y4
- 5.7 Análisis estadístico de resultados
- 5.8 Validación de hipótesis

CAPÍTULO VI: DISCUSIÓN

- 6.1 Interpretación de los resultados

- 6.2 Comparación con estudios previos
- 6.3 Implicancias para la gestión municipal
- 6.4 Amenazas a la validez

CAPÍTULO VII: CONCLUSIONES Y RECOMENDACIONES

- 7.1 Conclusiones
- 7.2 Recomendaciones técnicas
- 7.3 Recomendaciones para la gestión pública
- 7.4 Líneas futuras de investigación

REFERENCIAS

ANEXOS

- A. Matriz de consistencia
- B. Matriz de Operacionalización de Variables
- C. Cuadro de Entrada-Proceso-Salida

INDICE DE FIGURAS

FIGURA 1: VICTIMIZACIÓN Y PERCEPCIÓN DE INSEGURIDAD CIUDADANA DE LA POBLACION DE 15 AÑOS Y MÁS AÑOS DE LIMA METROPOLITANA Y LA PROVINCIA CONSITUCIONAL DEL CALLAO (Semestre móvil: Julio-Diciembre 2023 / Julio-Diciembre 2024)	12
FIGURA 2: INDICE DE CRIMINILIDAD POR PAIS - PERU (2015-2025)	13
FIGURA 3: MECANISMOS DE TRANSMISIÓN DE LA DELINCUENCIA EN EL CRECMIENTO ECONÓMICO	14
FIGURA 4: PROTOTIPO DE SISTEMA DE EMERGENCIA	19

INDICE DE TABLAS

TABLA 1: CATEGORIZACIÓN DE LAS LLAMADAS DE EMERGENCIA DE LA MUNICIPALIDAD DEL CALLAO	16
---	-----------

INDICE DE CUADROS

CUADRO 1: COSTO DE INSEGURIDAD CIUDADANA EN EL PERÚ	14
CUADRO 2: RESUMEN DE LA RESPUESTA ANTE EMERGENCIAS DE LA POLICÍA NACIONAL DEL PERÚ EN EL ÁREA METROPOLITANA DE LIMA Y CALLAO	15
CUADRO 3: REPRESENTACION DE LA ESTRUCTURA DEL DATASET	28

INTRODUCCIÓN

La *inseguridad ciudadana* es un **fenómeno complejo y multidimensional**, que comprende no solo la integridad física y psicológica de las personas, sino también el desarrollo socioeconómico del país. Este fenómeno abarca **dos dimensiones**: la **inseguridad objetiva**, entendida como la ocurrencia real de hechos delictivos registrados por las autoridades, y la **inseguridad subjetiva**, relacionada con la percepción del riesgo por parte de la ciudadanía y el temor al delito, percepción que no siempre guardan correlación con las cifras delictivas oficiales (Huesca González et al., 2021).

En este contexto, la Provincia Constitucional del Callao se ha convertido en uno de las zonas urbanas en el Perú con mayor incidencia y percepción de criminalidad. Datos recientes de la Encuesta Nacional de Programas Presupuestales (ENAPRES), indica que el 88,1% de los residentes de Lima Metropolitana y el Callao considera que la delincuencia ha aumentado, y el 29,3% ha sido víctima de algún tipo de delito en los últimos doce meses (Condori Huahuachampi et al., 2025). Esta situación se contextualiza en un entorno caracterizado por la persistencia de delitos urbanos, la presencia de organizaciones criminales, el tráfico ilícito de drogas y condiciones estructurales como la informalidad urbana y la limitada capacidad institucional para responder de manera oportuna a las demandas ciudadanas (Castro-Chucan et al., 2024; Mendiburu et al., 2024)

Esta problemática se acentúa en los centros municipales de atención de emergencias, donde los operadores deben interpretar rápidamente las llamadas entrantes, clasificar los hechos y asignar recursos bajo presión, con apoyo limitado de herramientas analíticas automatizadas (Chin et al., 2022; Roldan-Baluis et al., 2022). La dependencia de procesos manuales introduce heterogeneidad en los registros, subjetividad en la categorización y restricciones para el análisis agregado de los incidentes, lo que a su vez dificulta la identificación de tendencias espacio-temporales y temáticas y contribuye a retrasos en la respuesta operativa.

Frente a este escenario, diversos estudios han señalado la necesidad de incorporar soluciones basadas en inteligencia artificial que permitan automatizar el análisis de reportes ciudadanos, apoyar la clasificación de incidentes y fortalecer la toma de decisiones en la asignación de recursos públicos (P. Miguel et al., 2014). En particular, el Procesamiento de Lenguaje Natural (NLP) se ha consolidado como una herramienta clave para transformar grandes volúmenes de texto no estructurado en información útil para la gestión pública y la seguridad ciudadana.(Dixon & Birks, 2021)

El problema específico que aborda esta investigación es la ausencia de un sistema automatizado que permita procesar de manera estructurada y reproducible los reportes ciudadanos recibidos mediante llamadas de emergencia en la Municipalidad Provincial del Callao. Esta limitación restringe la estandarización de la clasificación de incidentes, la medición objetiva del desempeño operativo y la trazabilidad completa del ciclo de atención. El estudio se delimita al análisis de los registros correspondientes al período 2023–2024

en el ámbito urbano del Callao, utilizando fundamentalmente información textual proveniente de las descripciones de los operadores.

En respuesta a esta problemática, la presente investigación propone el diseño, implementación y evaluación de un sistema inteligente basado en NLP que integre un pipeline automatizado para la curación del texto, la representación semántica, la clasificación supervisada y la orquestación del flujo operativo de atención de incidentes. El enfoque metodológico se estructura mediante un diseño experimental incremental que compara el proceso manual de referencia (Y0) con versiones progresivamente automatizadas del sistema (Y1–Y4), permitiendo evaluar de forma cuantitativa mejoras en métricas clasificatorias, tiempos de procesamiento y niveles de trazabilidad.

Asimismo, se adopta un enfoque MLOps para garantizar la reproducibilidad experimental, el control de versiones de datos y modelos, y el monitoreo sistemático del desempeño en escenarios cercanos a operación real. El objetivo final es desarrollar un prototipo funcional que pueda ser adoptado por gobiernos locales y sirva como base replicable para otras municipalidades interesadas en fortalecer la gestión de la seguridad ciudadana mediante soluciones de analítica avanzada e inteligencia artificial.

CAPITULO I. PLANTEAMIENTO DEL PROBLEMA


1.1 Contexto de la Inseguridad Ciudadana en el ámbito municipal

1.1.1 Inseguridad ciudadana en contextos urbanos densamente poblados

La inseguridad ciudadana es uno de los principales desafíos en la gestión pública local, especialmente en zonas urbanas con alta densidad poblacional donde las cifras delincuenciales son más persistentes. En el caso de la Provincia Constitucional del Callao, esta problemática se manifiesta de forma estructural y sostenida, afectando de forma directa la calidad de vida de sus habitantes y limitando las condiciones para un desarrollo económico-social equilibrado (Condori Huahuachampi et al., 2025).

Según datos de la Encuesta Nacional de Programas Presupuestales (ENAPRES) de la INEI (ver Figura 1), para finales del año 2024, el 88,1 % de los ciudadanos de Lima Metropolitana y el Callao perciben que la delincuencia ha aumentado, y el 29,3 % declara haber sido víctima de algún delito en los últimos doce meses (Condori Huahuachampi et al., 2025). Esta situación, respaldada por indicadores de criminalidad, refleja una coexistencia entre hechos reales y percepción social de inseguridad. Esta convergencia pone en evidencia la debilidad que hay entre los mecanismos de prevención y respuesta actualmente disponibles a nivel municipal.

FIGURA 1: VICTIMIZACIÓN Y PERCEPCIÓN DE INSEGURIDAD CIUDADANA DE LA POBLACION DE 15 AÑOS Y MÁS AÑOS DE EDAD DE LIMA METROPOLITANA Y LA PROVINCIA CONSITUCIONAL DEL CALLAO (Semestre móvil: Julio-Diciembre 2023 / Julio-Diciembre 2024)



Fuente: Estadísticas de Seguridad Ciudadana Semestre móvil: Julio – Diciembre 2024 - Instituto Nacional de Estadística e Informática (INEI) – Encuesta Nacional de Programas Presupuestales – ENAPRES. pág 3.


En ciudades densamente pobladas, la concentración demográfica y la alta frecuencia de eventos críticos generan una presión significativa sobre los sistemas municipales de atención de emergencias. Estudios recientes muestran que los centros urbanos enfrentan un crecimiento sostenido en el volumen de llamadas, muchas de ellas con descripciones extensas y heterogéneas, lo que incrementa la carga cognitiva de los operadores y eleva el riesgo de errores en la clasificación inicial de los incidentes (Chin et al., 2022; Roldan-Baluis et al., 2022). Asimismo, investigaciones realizadas en contextos latinoamericanos evidencian que la

falta de herramientas automatizadas para procesar estas comunicaciones limita la capacidad de respuesta temprana y la priorización eficiente de recursos en escenarios urbanos complejos (Costa et al., 2023)

Desde una perspectiva operativa, la literatura especializada resalta que la incorporación de técnicas de inteligencia artificial para analizar datos no estructurados provenientes de llamadas de emergencia constituye un componente clave para fortalecer la gestión pública local. En particular, los enfoques basados en Procesamiento de Lenguaje Natural permiten transformar registros textuales y transcripciones de audio en información estructurada que puede ser explotada para análisis agregado, monitoreo en tiempo real y planificación preventiva (Costa et al., 2023; P. Miguel et al., 2014). Estos trabajos coinciden en que, en contextos metropolitanos con alta densidad poblacional, la modernización tecnológica de los centros municipales de despacho resulta indispensable para sostener niveles adecuados de servicio y mitigar los impactos operativos derivados de la creciente demanda ciudadana.

1.1.2 Consecuencias económicas y sociales de la inseguridad ciudadana

A nivel internacional, según el índice de criminalidad por país elaborado por Numbeo a partir de encuestas de percepción pública, el Perú ha pasado del puesto 40 al puesto 10 entre los países con mayor criminalidad en el mundo entre 2015 y 2025. Durante ese periodo, el índice de criminalidad nacional se incrementó de 57.63 a 67.12 puntos, mientras que el índice de seguridad descendió de 42.37 a 32.88 puntos, reflejando un deterioro sostenido de las condiciones de seguridad en el país (ver Figura 2). Esta tendencia internacional refuerza la urgencia de aplicar modelos de análisis automatizado y predictivo que permitan anticipar el comportamiento delictivo y actuar de forma preventiva.



Fuente: Crime Index by Country – Numbeo.
Elaboración: Propia

El impacto de esta problemática trasciende lo subjetivo (percepción ciudadana) y se puede cuantificar en términos económicos y sociales. Un estudio del Banco Central de Reserva del Perú (BCRP) estimó que el costo de la inseguridad ciudadana equivale al menos al 2,2% del Producto Bruto Interno (PBI) nacional (ver Cuadro 1). Este porcentaje, que representa alrededor de US\$ 5.800 millones en 2023, que incluye gastos privados (1,5% del PBI en seguridad contratada por hogares y empresas) y gastos públicos (0,7% del PBI en policía, sistema nacional y penitenciario) dedicados a afrontar la delincuencia (Mendiburu et al., 2024). En otras palabras, las familias y negocios invierten el doble de recursos en protección que el Estado, lo que indica altos **costos tangibles** de manera directa atribuibles al clima de inseguridad. Por otro lado, también existen **costos intangibles** difíciles de medir como el deterioro de la calidad de vida, el miedo que limita las actividades cotidianas, el estrés y el daño psicológico en las víctimas, como la erosión de la parte social y la confianza en las instituciones (Sanchez et al., 2025). Estas cifras revelan no solo una carga presupuestal creciente para el Estado, sino también un gasto importante por parte de los hogares y empresas que buscan protegerse ante la ausencia de condiciones adecuadas de seguridad pública.


CUADRO 1: COSTO DE INSEGURIDAD CIUDADANA EN EL PERÚ (2019)

	% del PBI
A. Gasto privado	1,5
Del cual:	
a. Comercio	0,6
b. Manufactura	0,2
c. Servicios	0,1
d. Transportes y comunicaciones	0,1
e. Hidrocarburos	0,1
f. Construcción	0,1
B. Gasto del gobierno	0,7
a. Administración de justicia	0,5
b. Servicios policiales	0,1
c. Administración de prisiones	0,1
C. Total (A+B)	2,2

Fuente: INEI-EEA y MEF – Indicadores y Costo de la Inseguridad Ciudadana en el Perú - en Moneda N°199 (BCRP), pág. 63.

Y es que, para el Banco Central de Reserva del Perú, entidad a cargo de la política monetaria en el país, el aumento de la delincuencia tiene una relación inversamente proporcional con la inversión, el consumo y la productividad del país, componentes que conforman el Producto Bruto Interno, y que se traduce en una caída del crecimiento económico y reducción de la inversión extranjera, lo cual genera un aumento en el desempleo (Figura 3). Para ello, es necesario aplicar una estrategia de políticas integradas de forma articulada en diversos sectores (Mendiburu et al., 2024).

FIGURA 3: MECANISMOS DE TRANSMISIÓN DE LA DELINCUENCIA EN EL CRECIMIENTO ECONÓMICO



Fuente: Indicadores y Costo de la Inseguridad Ciudadana en el Perú - en Moneda N°199 (BCRP), pág. 64.

Y es que diversos estudios han documentado que las demoras en la atención y la clasificación inicial de incidentes en centros urbanos generan no solo mayores riesgos para las víctimas, sino también costos operativos significativos para los gobiernos locales, derivados de la asignación ineficiente de patrullas, duplicación de intervenciones y uso subóptimo de recursos logísticos y humanos (Chin et al., 2022; Roldan-Baluis et al., 2022). En contextos latinoamericanos, se ha evidenciado además que la dependencia de procesos manuales incrementa los tiempos de despacho y dificulta la priorización objetiva de emergencias, lo que impacta negativamente en la percepción ciudadana del servicio y en la sostenibilidad financiera de los sistemas municipales de seguridad (Costa et al., 2023; P. Miguel et al., 2014).

1.1.3 Limitaciones en la gestión municipal

En el caso específico del Callao, entre los años 2018 al 2023, los números de denuncia por delincuencia han subido de 188 a 203 denuncias por cada 10 mil habitantes, cifra superior al promedio nacional que pasó de 120 a 177 (Mendiburu et al., 2024). Por otro lado, los datos operativos de la central municipal del Callao, indican que las llamadas de emergencia recibidas superan los 100 mil registros acumulados entre 2023 y 2024. Cada llamada contiene descripciones de incidentes u ocurrencias, como referencias temporales y geográficas, y en algunos casos evidencia visual o auditiva. Esta información se encuentra almacenada en formatos tanto estructurados como no estructurados, y su análisis sigue siendo manual, con una clasificación excesiva de 67 categorías y 236 subcategorías. Esta complejidad limita la capacidad de los operadores para tomar decisiones en tiempo real y dificulta la generación de análisis agregados útiles para acciones preventivas.

Esta problemática de inseguridad ha llevado a una **sobrecarga de las centrales de emergencia** locales, que reciben decenas de miles de llamadas anuales reportando incidentes de seguridad ciudadana, emergencias médicas, conflictos vecinales, entre otros eventos. Sin embargo, hasta ahora dichos datos se han subutilizado con fines reactivos (atender caso por caso) sin extraer conocimiento agregado que apoye estrategias preventivas. Y es que según el informe del Proyecto del Sistema de Respuesta de Emergencia para el Perú del Banco Mundial del año 2020 (ver Cuadro 2), en la primera línea de respuesta, las llamadas de emergencia

son los que más tiempo toman en promedio desde que esperan ser atendidos por un operador con un promedio de 10 minutos, para luego ser conectados al área correspondiente con 3.8 minutos. Unido esto a la segunda línea de respuesta, conformado por el tiempo de despacho y el tiempo de tránsito, una emergencia en total puede ser atendido en 45 minutos (World Bank Group, 2020).

CUADRO 2: RESUMEN DE LA RESPUESTA ANTE EMERGENCIAS DE LA POLICÍA NACIONAL DEL PERÚ EN EL ÁREA METROPOLITANA DE LIMA Y CALLAO

Line of Response	Phase	Average Time (min)	Accumulated Time (min)	Observations
First Line of Response	1. Call answer time	10.0	10.0	Excessive call answer time because existing call centers are overwhelmed due to (a) large number of 'malicious calls' (91.1 percent), (b) limited and outdated communications technology, and (c) limited number of first-line operators
	2. Connection time	3.8	13.8	Excessive connection time due to (a) lack of proper response protocols, (b) lack of adequate operator training, (c) current technological platform of existing call centers does not support effective planning integration and response coordination, and (d) lack of geolocation data and enforcement regulation
Second Line of Response	3. Dispatch time	3.5	17.3	Excessive dispatch time due to (a) lack of interoperable system with the operator's system and (b) lack of proper interagency protocols
	4. In transit time	27.7	45.0	Excessive in-transit time due to (a) high traffic congestion across the city and (b) lack of driver education and enforcement regarding priority of emergency response units in traffic

Fuente: Estimaciones del Banco Mundial basadas en datos proporcionados por el Programa Nacional de Telecomunicaciones (PRONATEL) y la PNP – Peru - Centralized Emergency Response System Project- World Bank Group (Report N° PAD3477), pág. 10

En síntesis, la problemática identificada combina altos niveles de criminalidad y percepción de inseguridad en el Callao, con consecuencias socioeconómicas significativas y una oportunidad para aprovechar datos existentes (llamadas de emergencia) para mejorar la situación. Los reportes ciudadanos representan, por tanto, una fuente rica de información que permanece subutilizada debido a la falta de herramientas tecnológicas que permitan su procesamiento estructurado. Esta situación genera una brecha entre la disponibilidad de datos y su aprovechamiento efectivo para políticas públicas orientadas a la reducción del crimen. Además, impide construir un sistema de alertas que anticipe la ocurrencia de delitos en zonas críticas o franjas horarias específicas, lo cual afecta directamente la asignación eficiente de recursos operativos en seguridad.

Esta realidad justifica la necesidad de investigar herramientas tecnológicas innovadoras basadas en inteligencia artificial que permitan caracterizar mejor los incidentes, entender sus factores asociados, predecir y prevenir su ocurrencia. En este contexto, se justifica la necesidad de desarrollar un sistema inteligente que integre procesamiento de lenguaje natural, visión por computadora y análisis geoespacial para extraer patrones de los reportes ciudadanos y generar conocimiento útil para la gestión de la seguridad. La ausencia de tal herramienta constituye la problemática central que esta investigación busca abordar.

1.1.4 Datos disponibles y complejidad de las descripciones de emergencia

El presente estudio de esta investigación está constituido por los **incidentes de seguridad ciudadana registrados mediante llamadas telefónicas a la central de emergencias de la Municipalidad Provincial del Callao** (MPC), entre los años 2023 y 2024. Este conjunto de datos contiene más de 104,536 mil registros, extraídos desde la Plataforma Nacional de Datos Abiertos del Gobierno del Perú (Presidencia del Consejo de Ministros – Secretaría de Gobierno Digital, 2024), los cuales están categorizados por 8 clases, 67 categorías y 236-subcategorías (ver categorización en Cuadro 6). Esta gran cantidad de subcategorías hace que sea difícil de definir y genere la demora al derivar al anexo a quien debería atender la emergencia, cuando la respuesta debería ser por la misma Central de Emergencias de la Municipalidad del Callao.

TABLA 1: CATEGORIZACIÓN DE LAS LLAMADAS DE EMERGENCIA DE LA MUNICIPALIDAD DEL CALLAO

Etiquetas de fila	Categoría	Sub-categoría	Cuenta de EVENTO
+ AMBIENTALES			28389
+ APOYO AL CIUDADANO			21198
+ FISCALIZACION Y DEFENSA CIVIL			17091
+ FISICA			109
+ FISICA(SALUD)			1106
+ PROTECCION FAMILIAR			429
+ SEGURIDAD			13248
+ TRANSITO Y SEGURIDAD VIAL			16888
- (en blanco)	- (en blanco)	(en blanco)	6078
Total general			104536

Fuente: Dataset v.2 de las Llamadas de Emergencia de la Municipalidad del Callao

Elaboración: Propia

La literatura especializada señala que este tipo de escenarios, caracterizados por grandes volúmenes de reportes heterogéneos, alta granularidad en la taxonomía de incidentes y registros textuales no estructurados, constituye uno de los principales desafíos operativos en los centros urbanos de atención de emergencias. Estudios recientes han demostrado que la ausencia de mecanismos automatizados para procesar estas descripciones incrementa la carga cognitiva de los operadores, eleva la variabilidad en la clasificación inicial y dificulta la priorización objetiva de los eventos, afectando directamente los tiempos de despacho y la trazabilidad del proceso (Chin et al., 2022; Roldan-Baluis et al., 2022). Asimismo, investigaciones en contextos latinoamericanos evidencian que la incorporación de técnicas de Procesamiento de Lenguaje Natural permite reducir la ambigüedad en los registros, consolidar categorías operativas y apoyar la toma de decisiones en tiempo real en entornos con alta complejidad informacional (Costa et al., 2023; P. Miguel et al., 2014).

1.1.5 Desafíos tecnológicos y subutilización de datos

En el caso de los registros de las llamadas de emergencia del Callao, cada registro incluye variables como la fecha y hora de ocurrencia, distrito, categoría temática (ruido, violencia, basura, robos, etc.), y canal de

recepción. No obstante, el mayor desafío se encuentra en la variable “DESCRIPCION_OCURRENCIA”, la cual contiene texto libre provisto por las llamadas de emergencia de los ciudadanos, mensajes o registro de ocurrencias de los videos de seguridad, que ha sido digitado por el operador. Este campo representa un reto importante para el procesamiento automatizado, dado que las descripciones suelen estar escritas de manera informal, con errores gramaticales, abreviaciones o sin estructura sintáctica definida. Para su análisis, es imprescindible aplicar técnicas de procesamiento de lenguaje natural (NLP), capaces de transformar ese texto en información estructurada que permita clasificar, agrupar o predecir los tipos de incidentes reportados.

Ejemplos: A continuación, se ilustran casos concretos típicos de llamadas de emergencia en el Callao que forman parte del objeto de estudio, obtenidos de los datos de descripción-ocurrencia del dataset v.2 de llamadas a la central de emergencia Callao (MPC):

- *Ejemplo 1:* Un vecino llama a la central municipal de seguridad para reportar que acaba de presenciar un **asalto a mano armada** en una esquina de su barrio. Describe que dos hombres en motocicleta arrebataron las pertenencias de un transeúnte amenazándolo con un arma de fuego, y luego huyeron. El operador registra la hora (ej: 22:30 horas), la dirección aproximada y clasifica de forma preliminar el incidente como *robo agravado*.
- *Ejemplo 2:* Una ciudadana reporta mediante la aplicación de seguridad municipal un caso de **violencia doméstica** en su vecindario; escucha gritos y agresiones en una vivienda contigua. Proporciona detalles textuales a través del chat de la app y adjunta una foto borrosa de la casa. La central etiqueta el caso como *violencia familiar* y envía una patrulla de serenazgo.
- *Ejemplo 3:* Un conductor alerta por teléfono sobre un **intento de linchamiento** o agresión grupal: una turba está golpeando a un presunto ladrón en plena vía pública. La llamada se georreferencia en tiempo real mediante el celular del denunciante, y se registra como *disturbio/justicia popular*.

Estos ejemplos ilustran la variedad de situaciones que abarca: delitos contra el patrimonio (ej. robos), delitos contra la persona (agresiones), violencia interpersonal, desórdenes públicos, etc., con distintos canales de reporte (llamada de voz, aplicaciones móviles, etc.) y posibles datos complementarios (imágenes, videos).

Sirven para contextualizar el tipo de datos e incidentes que serán analizados en el estudio.

Ejemplos del contenido de DESCRIPCION_OCURRENCIAS:

- SIENDO LAS 07:19 HRS SE RECIBE UN LLAMADA TELEFONICA DE LA CONTRIBUYENTE LA CUAL INDICA QUE LE AGREDEN VERBAL MENTE Y OBSTRUYE AFUERA D SU PROPIEDAD SE PROCEDIO LA MOVIL: 51 CHOFE: ERICK MALPARTIDA CORAQUILLO UBICADO: CA. GAMARRA 680 REF: POR LA SUNAT, QUEIN DA CUENTA SIEMPRE DEJA SU AUTO EN LA PUERTA DE SU CASA EN AV. GAMARRA 680 IMPIDIENDO SACAR SU CARRETILLA DE VENTA DE MARCIANOS ASI MISMO NOS DIRIGIMOS A SU CENTRO DE TRABAJO PARA COMUNICARLE AL SR. EFRAIN VALDEZ PARA PROCEDER CON EL RETIRO

DE SU AUTO DE LA QUEJA DE LA CONTRIBUYENTE SE DA CUENTA PARA FINES DEL CASO.

- CENTRAL DE EMERGENCIA CALLAO SIENDO LAS 20:23 HORAS SE REALIZA PATRULLAJE TECNOLÓGICO A TRAVÉS DE LAS CÁMARAS DE VIDEO VIGILANCIA EN INMEDIACIONES, DE LA BASE DESCENTRALIZADA AV. BERTELLO - OQUENDO (SECTOR 11 CIA OQUENDO), AL MOMENTO SE VISUALIZA ARBOL QUE NECESITA SER PODADO, PORQUE OBSTRUYE LA VISUALIZACIÓN DE LA CÁMARA DE VIDEOVIGILANCIA 1, COMUNICAR AL ÁREA CORRESPONDIENTE.

Estos hechos reportados en la descripción de ocurrencia reflejan hechos delictivos concretos que, sin embargo, no pueden ser aprovechados por herramientas de análisis tradicionales debido a su formato desestructurado. En consecuencia, su potencial informativo se desperdicia, y las acciones de seguridad ciudadana se ven limitadas a reacciones manuales y lentas. Estos casos muestran distintos niveles de criticidad, tiempos de ocurrencia, y distribución espacial, lo cual constituye un desafío analítico relevante.

El problema se encuentra en que este conjunto de reportes ciudadanos aún no cuenta con una herramienta tecnológicas inteligentes, fuera del sistema de ingreso manual de denuncias de los operadores de la central de emergencia de la Municipalidad del Callao por medio del *3333, que permita su clasificación automática, análisis semántico, agrupación temática y predicción espacio-temporal. A pesar de que la base de datos contiene múltiples dimensiones relevantes (textuales, espaciales, temporales y operativas), su análisis sigue siendo manual y reactivo, lo que impide construir estrategias preventivas basadas en evidencia (Castro-Chucan et al., 2024; Chin et al., 2022)

1.1.6 Caracterización operativa de las llamadas de emergencia

La caracterización del problema muestra **tres limitaciones**:

- a) **Alta dependencia del operador humano** para interpretar e ingresar correctamente la información;
- b) **Almacenamiento de datos en formatos no estructurados** que impiden análisis sistemático;
- c) **Falta de un sistema automatizado** que permita extraer patrones delictivos a partir de múltiples dimensiones como texto, ubicación geográfica y temporalidad.


Estas condiciones obstaculizan la posibilidad de implementar estrategias preventivas basadas en evidencia y dificultan la gestión efectiva de la seguridad ciudadana en la provincia.

Se entiende por **llamada de emergencia** toda comunicación entrante registrada por un centro de atención municipal, en la cual un ciudadano reporta un incidente, situación de riesgo o solicitud de auxilio, la misma que es transcrita o documentada por el operador para su posterior derivación y atención (Abi Kanaan et al., 2024; Wang et al., 2024). Un trabajo de (Dash et al., 2022) en *Frontiers in Human Dynamics* describe las

llamadas al 911, destacando los siguientes componentes clave del proceso operativo mediante un prototipo (ver Figura 4) :

- Datos de identificación y guardado:** Metadatos como fecha y hora, identificador de quien llama, geolocalización, guardado en el CAD (Computer Aided Dispatch o Despachador Computacional de Ayuda).
- Descripción narrativa del incidente:** Narrativa verbal del incidente (texto libre) registrada y transcrita.
- Procesamiento por el operador (dispatcher):** Empleo de **protocolos estructurados** para categorizar el evento, priorizar y asignar un recurso (policía, ambulancia, bomberos).
- Ubicación del incidente:** Uso de herramientas geoespaciales para mapear el incidente y despachar de forma adecuada los recursos.
- Comunicación bidireccional:** Interacción continua entre ciudadano y operador, que puede incluir medios como texto, fotos y videos.
- Seguimiento y documentación:** Actualización del estado del incidente por múltiples operadores en tiempo real, donde todos los registros se registran en el sistema CAD.

FIGURA 4: PROTOTIPO DE SISTEMA DE EMERGENCIA



Fuente: Dash, P., Neustaedter, C., Jones, B., & Yip, C. (2022). The Design and Evaluation of Emergency Call Taking User Interfaces for Next Generation 9-1-1, pág. 6

1.1.7 Métricas de evaluación y métricas de solución tecnológica

La evaluación del impacto del sistema propuesto se centrará en indicadores de desempeño operativo y calidad de clasificación que permitan comparar de forma cuantitativa el proceso manual vigente con el proceso automatizado. Para ello se utilizará:

- 1) Métricas clásicas de desempeño de clasificación como **precisión (accuracy)**, **exhaustividad (recall)**, **precisión positiva (precision)** y **F1-score**, tal como propone (Chin et al., 2022) en su estudio de predicción basada en texto para situaciones de emergencia con uso de procesamiento de lenguaje natural (NLP).
- 2) A nivel operativo, se considerará el **tiempo promedio de procesamiento automatizado frente al tiempo requerido por el análisis manual**, tomando como referencia el enfoque de eficiencia propuesto para Smart Muni por (Castro-Chucan et al., 2024)

Estas métricas permitirán establecer de manera objetiva si la automatización basada en NLP contribuye a mejorar la oportunidad de respuesta, la estandarización del registro y la trazabilidad del flujo operativo, elementos críticos para la gestión de la seguridad ciudadana a nivel local.

1.2 Situación problemática en la atención de llamadas de emergencia

Los sistemas municipales de atención de emergencias constituyen el primer punto de contacto entre la ciudadanía y las autoridades locales frente a hechos de inseguridad, accidentes y disturbios urbanos. En contextos de alta densidad poblacional, la presión operativa sobre estas centrales se incrementa de forma sostenida, generando riesgos asociados a la clasificación incorrecta de incidentes, demoras en el despacho y uso ineficiente de recursos (Chin et al., 2022; Costa et al., 2023).

Diversas investigaciones han advertido que los procesos manuales de recepción y categorización de reportes ciudadanos incrementan la variabilidad inter-operador y reducen la trazabilidad del ciclo completo del incidente, afectando directamente la capacidad institucional de respuesta (P. Miguel et al., 2014; Roldan-Baluis et al., 2022). Estos problemas se agravan cuando las centrales incorporan múltiples canales de ingreso (teléfono, mensajería instantánea y plataformas digitales) sin mecanismos automáticos de integración.

1.2.1 Ineficiencias operativas en la central de emergencias del Callao

El análisis empírico desarrollado sobre los registros históricos de la Municipalidad Provincial del Callao evidencia una serie de cuellos de botella críticos en el proceso vigente de atención manual. En particular, se observa que los reportes ingresan a través de distintos canales, siendo posteriormente interpretados y transcritos por operadores humanos hacia el sistema CAD municipal, lo que introduce retrasos y heterogeneidad en la información registrada (ver **Figura 6 – Caso de flujo manual de atención vía WhatsApp y registro en CAD**).



Fuente: Dataset v.2 de las Llamadas de Emergencia de la Municipalidad del Callao
Elaboración: Propia

El ejemplo ilustrado en la Figura 5 evidencia la dependencia del proceso municipal de atención de emergencias respecto a la intervención manual del operador, quien debe interpretar el mensaje recibido por

canales digitales como WhatsApp y transcribir la información relevante al sistema CAD institucional. Este procedimiento introduce un cuello de botella operativo, reflejado en los tiempos de atención y registro observados, así como en la heterogeneidad del contenido ingresado, lo que dificulta la estandarización de categorías, la detección de casos repetidos y la trazabilidad completa del incidente. La ausencia de mecanismos automatizados para apoyar esta etapa crítica del proceso incrementa la carga de trabajo del personal y limita la capacidad de respuesta oportuna ante eventos concurrentes, reforzando la necesidad de incorporar soluciones basadas en analítica avanzada y Procesamiento de Lenguaje Natural en los centros municipales de atención.

Al analizar los datos abiertos de la Municipalidad Provincial del Callao (MPC) v.1.1 (2024) obtenido de la Plataforma Nacional de la Presidencia del Consejo de Ministros, donde se encuentra que si bien el tiempo de respuesta promedio de un operador municipal es de 66 segundos desde que contesta la llamada hasta que es derivada a un área interna municipal, los tiempos máximos de la atención por llamada en promedio van desde los 11 minutos hasta 107 minutos por llamada (ver Tabla 2), lo cual es consistente con la información obtenida del cuadro anterior. Cabe resaltar que aquí no se considera los tiempos de espera del ciudadano hasta que es atendida su llamada, ni tampoco el tiempo de la segunda línea de respuesta hasta que es atendida la llamada.


TABLA 2: TIEMPO DE RESPUESTA POR AREA DERIVADA DE LAS LLAMADAS DE EMERGENCIA DE LA MUNICIPALIDAD DEL CALLAO (DATASET v.1.1)

AREA DERIVADA	Máx. duración (seg)	Max. duración (min)	Prom (seg)
ADMINISTRACION Y FINANZAS	1236	20.6	64
ASENTAMIENTOS HUMANOS	1236	20.6	68
DEFENSA CIVIL	1004	16.7	62
DESARROLLO ECONOMICO LOCAL Y COMERCIALIZACIÓN	621	10.4	69
DESARROLLO HUMANO	1777	29.6	64
GERENCIA DE FISCALIZACION	1003	16.7	69
GERENCIA GENERAL DEL OD DEL SISTEMA DE SERVICIOS A LA CIUDAD Y PROTECCION DEL MEDIO AMBIENTE	1508	25.1	60
JEFATURA DE PROMOCION DE DESARROLLO ECONOMICO LOCAL	663	11.1	65
JURIDICA	870	14.5	62
LICENCIAS, AUTORIZACIONES Y VEHICULOS MENORES	896	14.9	66
MESA DE PARTES VIRTUAL	6443	107.4	67
OAC	1479	24.7	66
PROCEDIMIENTOS SANCIONADOR	1798	30.0	65
PROGRAMAS SOCIALES	6443	107.4	69
RECURSOS HUMANOS	864	14.4	67
RENTAS	1330	22.2	64
SUBGERENCIA DE LICENCIAS Y AUTORIZACIONES	1562	26.0	77
TOTAL	6444	30.1	66

Fuente: Dataset v.1.1 de las Llamadas de Emergencia de la Municipalidad del Callao
Elaboración: Propia

Por otro lado, al analizar el dataset proporcionado por la Municipalidad del Callao (MPC) v.2 (2024), el 64% de los reportes proviene de cámaras, el 19% de WhatsApp y solo el 8% de llamadas telefónicas (ver Figura 6). Esto implica que la mayoría de incidentes se originan en fuentes no estructuradas que requieren interpretación humana por parte de los operadores, al no haber un sistema automatizado.


FIGURA 6: ORIGEN DE LAS LLAMADAS DE EMERGENCIA DE LA MUNICIPALIDAD DEL CALLAO (DATASET v.2)



Fuente: Dataset v.2 de las Llamadas de Emergencia de la Municipalidad del Callao
Elaboración: Propia

Sin embargo, el 99% de los registros carece de eventos o logros y el 90% de los casos no especifica la unidad de apoyo consignado (ver Figura 7), lo que revela una pérdida de trazabilidad operativa y una alta tasa de subregistro.


FIGURA 7: REGISTRO DE UNIDAD DE APOYO DE LAS LLAMADAS DE EMERGENCIA DE LA MUNICIPALIDAD DEL CALLAO (DATASET v.2)



Fuente: Dataset v.2 de las Llamadas de Emergencia de la Municipalidad del Callao
Elaboración: Propia

En el campo de casos repetidos registrados por la Municipalidad del Callao, el **99% se mantiene nulo (ver Figura 8)**, lo que demuestra la ausencia de validación automática o detección de duplicados.


FIGURA 8: CASOS REPETIDOS REGISTRADOS DE LAS LLAMADAS DE EMERGENCIA DE LA MUNICIPALIDAD DEL CALLAO (DATASET v.2)



Fuente: Dataset v.2 de las Llamadas de Emergencia de la Municipalidad del Callao
Elaboración: Propia

Por otro lado, existe una sobrecarga de atención de los 128 operarios que tiene la Municipalidad del Callao, donde solo los 10 primeros operarios atienden el 30% de las llamadas y 45 receptionan el 80%, lo cual genera una desigualdad de carga laboral que genera errores humanos en el ingreso de las llamadas de emergencia (ver Figura 9)

FIGURA 9: RECEPCION DE LLAMADAS POR OPERARIOS DE LAS LLAMADAS DE EMERGENCIA DE LA MUNICIPALIDAD DEL CALLAO (DATASET v.2)



Fuente: Dataset v.2 de las Llamadas de Emergencia de la Municipalidad del Callao
Elaboración: Propia

Esta realidad operativa se resume en el Cuadro 3, el cual muestra que los **operadores no pueden procesar en tiempo real** la cantidad y complejidad de la información que reciben, y que **el proceso manual limita la calidad de la base de datos histórica**.

CUADRO 2: HALLAZGOS ESTADISTICOS DEL ANALISIS DEL DATASET DE LAS LLAMADAS DE EMERGENCIA DE LA MUNICIPALIDAD DEL CALLAO v.2

VARIABLE	Valor	Hallazgos
ORIGEN_LLAMADAS	64% cámaras, 19% WhatsApp, 8% teléfono	Casi 9 de cada 10 reportes provienen de fuentes visuales o textuales no estructuradas (video o mensajes). El operador debe convertirlos a texto de forma manual.
EVENTOS	99% nulos	En 99% de los registros no se consignó el resultado del evento (perdida de trazabilidad de registro)
LOGROS	99% nulos	Solo 1% de registros tiene logros o resultados consignados (cierre de registros o retroalimentación es casi inexistente)
UNIDAD_DE_APOYO	89% nulos	9 de cada 10 llamadas no especifican quién atendió o qué unidad intervino (no hay consistencia ni completitud de la información de despacho)
CASOS_REPETIDOS	99% nulos (solo 69 casos detectados)	No hay detección automática de duplicidad: los operadores no tienen mecanismos para identificar llamadas del mismo incidente.
RECEPCION_LLAMADAS	104,536 llamadas anuales ≈ 816 al año / operador (~2.6 diarias)	La carga está muy concentrada: los 10 primeros operadores gestionan el 30% de llamadas (desigualdad de carga de trabajo genera errores humanos)

Fuente: Dataset v.2 de las Llamadas de Emergencia de la Municipalidad del Callao
Elaboración: Propia

El diagrama representa el flujo operativo del sistema CAD municipal, evidenciando las etapas desde la recepción de la llamada ciudadana hasta el registro final. Se observa que la mayoría de las variables de salida carecen de retroalimentación estructurada (por ejemplo, más del 89 % de LOGRO y SIN_NOVEDAD son nulas), lo que refleja una dependencia manual del operador y la pérdida de trazabilidad entre la atención y el resultado en campo.

1.2.2 Dependencia del procesamiento manual y variabilidad del registro

El flujo actual de atención se sustenta principalmente en la interpretación directa del operador, quien resume la narración del ciudadano en campos de texto libre. Esta práctica genera registros heterogéneos, con abreviaturas, errores ortográficos y omisiones relevantes, situación que ha sido documentada de forma abierta en estudios sobre centros urbanos de despacho de emergencias (Chin et al., 2022; Costa et al., 2023),

Roldan-Baluis et al., 2022 advierte que este tipo de dependencia manual incrementa la carga cognitiva del personal y eleva la probabilidad de clasificaciones inconsistentes cuando el volumen de llamadas aumenta.

En la misma línea, Miguel et al. (2014) señalan que la ausencia de herramientas automáticas para estructurar estos reportes limita la explotación posterior de la información y la formulación de estrategias preventivas.

En el caso del Callao, esta problemática se refleja en la alta diversidad léxica observada en la variable **DESCRIPCION_OCURRENCIA**, así como en la coexistencia de más de 130 subcategorías operativas, tal como se presenta en la **Tabla 1**.

1.2.3 Impacto de las ineficiencias en la gestión municipal

Las limitaciones descritas se traducen en consecuencias directas para la gestión pública local. Las demoras en la clasificación inicial y en el despacho de unidades incrementan la probabilidad de escalamiento de los incidentes, afectan la percepción ciudadana del servicio y generan costos operativos adicionales asociados al uso ineficiente de patrullas, combustible y personal (Chin et al., 2022; Costa et al., 2023)

Estudios regionales muestran que la optimización de los procesos de atención mediante automatización puede producir mejoras sustanciales en tiempos de respuesta y priorización de eventos críticos (P. Miguel et al., 2014), lo que subraya la necesidad de intervenir sobre la fase temprana del ciclo operativo.

1.2.4 Síntesis de la problemática y brechas operativas

La evidencia empírica del caso Callao, en conjunto con los hallazgos reportados en la literatura especializada, permite identificar cuatro brechas principales:

1. **Ingreso multicanal sin integración automática**, que genera retrasos en la transcripción y registro.
2. **Clasificación manual y subjetiva**, dependiente del operador.
3. **Ausencia de trazabilidad completa del ciclo del incidente**, desde la recepción hasta el cierre.
4. **Limitada explotación analítica de los datos históricos**, debido a la falta de estructuración del texto libre.

Estas brechas justifican la necesidad de investigar y diseñar mecanismos automatizados basados en Procesamiento de Lenguaje Natural que permitan estructurar los reportes ciudadanos y apoyar la gestión municipal, alineándose con las tendencias internacionales identificadas por Chin et al. (2022), Costa et al. (2023) y Miguel et al. (2014).

1.3 Diagnóstico operativo del servicio actual

El diagnóstico operativo del sistema municipal de atención de emergencias se construye a partir del análisis exploratorio de los registros históricos de llamadas y reportes ciudadanos de la Municipalidad Provincial del Callao, correspondientes al período 2023–2024. Este análisis permitió caracterizar el flujo real de atención vigente (Y0), identificar los principales cuellos de botella operativos y cuantificar la magnitud de las ineficiencias descritas en la sección previa.

Para este propósito se utilizaron bases de datos estructuradas y campos textuales libres generados durante la atención diaria, así como registros de tiempos, estados del incidente, categorías operativas y asignación de unidades, los cuales fueron sometidos a procesos de exploración estadística y auditoría de calidad de datos, siguiendo enfoques similares a los empleados en estudios de centros urbanos de despacho de emergencias (Chin et al., 2022; P. Miguel et al., 2014)

1.3.1 Flujo actual de atención de llamadas (Y0)

Para representar esta realidad, podemos ver el estado actual de la atención de las llamadas de emergencia a la Municipalidad del Callao, el cual tiene como entrada la llamada ciudadana y las diversas fuentes de entrada, para luego ser atendidos y procesados de forma manual por los operadores que ingresan la data sin procesar al sistema CAD (Centro de Acceso Digital) municipal, seleccionando categorías, subcategorías y ubicaciones de forma discrecional según su experiencia y derivados al centro de atención ciudadano correspondiente (esta información se encuentra dentro del dataset v.2 de la Municipalidad del Callao). Si vemos el proceso de funcionamiento de todo el ciclo actual del sistema de registro de llamadas de emergencias, encontraremos que los problemas operativos están dados por los problemas antes expuestos (ver figura 10)

FIGURA 10: REPRESENTACION DEL SISTEMA ACTUAL DE LA MUNICIPALIDAD DEL CALLAO PARA LA ATENCION DE EMERGENCIAS



Elaboración: Propia

Una vez registrado el incidente, el caso pasa a una etapa de validación interna y despacho de unidades, para luego ser cerrado cuando se reporta la intervención. Sin embargo, como se observa en la **Figura 7 (registro de unidad de apoyo)**, gran parte de los registros no consigna información completa sobre la fase final del evento, impidiendo reconstruir el ciclo operativo completo.

1.3.2 Caracterización del dataset operativo

La base histórica analizada contiene mas de cien mil registros de incidentes, con campos estructurados (fecha, hora, categoría, estado, distrito) y campos no estructurados, principalmente la variable **DESCRIPCION_OCURRENCIA**, que recoge el resumen textual elaborado por los operadores.

En la **Tabla 1 (Tipologías, Categorías y sub-categorías)** se evidencia una alta fragmentación taxonómica, con más de un centenar de subtipos distintos, lo que complica la estandarización del análisis estadístico y la comparación longitudinal.

Asimismo, la exploración inicial revela altos porcentajes de valores faltantes en variables críticas del ciclo operativo (unidad asignada, hora de despacho, hora de cierre), tal como se muestra en la **Figura 11**, lo que confirma la baja trazabilidad descrita en la sección 1.2.

Figura 11: Valores nulos o faltantes de las variables del dataset municipal v.2

Data columns (total 37 columns):			
#	Column	Non-Null Count	Dtype
0	N_DE_CASO	104536 non-null	int64
1	FECHA_LLAMADA	104536 non-null	int64
2	HORA_DE_LLAMADA	104536 non-null	int64
3	FECHA_OCURRENCIA	104536 non-null	int64
4	HORA_OCURRENCIA	104536 non-null	int64
5	RECEPCION	104536 non-null	object
6	ASUNTO	104536 non-null	object
7	ESTADO	104536 non-null	object
8	TIPOLOGIA	98458 non-null	object
9	Categoria	98458 non-null	object
10	Sub-categoria	69410 non-null	object
11	DNI_CIUDADANO	104536 non-null	object
12	NOMBRES_APELLIDOS	104536 non-null	object
13	EDAD	274 non-null	object
14	SEXO	0 non-null	float64
15	DIRECCION	104536 non-null	object
16	DESCRIPCION_OCURRENCIA	103801 non-null	object
17	MOTIVO_SALUD	1118 non-null	object
18	TRASLADO_SALUD	543 non-null	object
19	MEDICO_SALUD	104536 non-null	object
20	AMBULANCIA_SALUD	446 non-null	object
21	UNIDAD_APOYO	11276 non-null	object
22	SOLICITUD_DE_APOYO	0 non-null	float64
23	ZONA	98445 non-null	object
24	SUPERVISOR	104536 non-null	object
25	ORIGEN	100094 non-null	object
26	EVENTO	1328 non-null	object
27	CANTIDAD_EVENTO	2846 non-null	object
28	LOGRO	733 non-null	object
29	SIN_NOVEDAD	13244 non-null	object
30	CASO_REPETIDO_SEGURIDAD	1529 non-null	object
31	SEGUIMIENTO_DEL_CASO	11600 non-null	object
32	FECHA_CORTE	104536 non-null	int64
33	DEPARTAMENTO	104536 non-null	object
34	PROVINCIA	104536 non-null	object
35	DISTRITO	104536 non-null	object
36	UBIGEO	104536 non-null	int64
dtypes: float64(2), int64(7), object(28)			

Fuente: Dataset v.2 de las Llamadas de Emergencia de la Municipalidad del Callao
Elaboración: Propia


1.3.3 Análisis de tiempos y demoras operativas

El estudio de los tiempos asociados a cada etapa del incidente constituye un eje central del diagnóstico. En particular, se analizaron:

- tiempo desde la recepción hasta el registro inicial,
- tiempo hasta el despacho,
- duración total del incidente,
- tiempo hasta el cierre administrativo.

La **Figura 12 (distribución de duración de llamadas)** muestra una elevada dispersión en estas métricas, con colas largas a la derecha que superan los estándares deseables para una respuesta temprana. Estos patrones concuerdan con lo reportado en la literatura sobre centros de despacho urbano, donde los procesos manuales generan alta variabilidad y retrasos en contextos de alta demanda (Chin et al., 2022; Roldan-Baluis et al., 2022)

Figura 1: Distribución de llamadas del dataset municipal v.1.1



Fuente: Dataset v.1.1 de las Llamadas de Emergencia de la Municipalidad del Callao
Elaboración: Propia

1.3.4 Duplicidad de reportes y carga operativa

Otro hallazgo relevante del diagnóstico es la presencia de múltiples reportes asociados a un mismo evento, generados por llamadas simultáneas de distintos ciudadanos. La ausencia de mecanismos automáticos de detección de similitud textual provoca que estos casos se registren como incidentes independientes, inflando artificialmente la carga operativa. Este fenómeno se ilustra en la **Figura 18 (casos repetidos)**.

Asimismo, el análisis de productividad por operador evidencia una distribución desigual muy alta (ver **Figura 9**) de la carga de trabajo, con un pequeño subconjunto del personal concentrando la mayoría de los casos atendidos (los 10 primeros atienden el 30% de todas las llamadas, y el 45% el 80% del total de llamadas), situación que incrementa el riesgo de errores humanos en picos de demanda, como señalan Chin et al. (2022).

1.3.5 Síntesis diagnóstica del proceso actual

En conjunto, el diagnóstico operativo del servicio actual permite establecer que:

- el ingreso multicanal carece de integración automática;
- el registro depende del juicio individual del operador;
- la taxonomía de incidentes es excesivamente granular e inconsistente;
- los tiempos de atención presentan alta variabilidad;
- existe baja completitud de variables críticas;
- no se dispone de mecanismos sistemáticos deduplicados;
- la trazabilidad del ciclo del incidente es limitada.

Estos resultados confirman de manera empírica que el proceso vigente (Y0) presenta deficiencias estructurales que afectan la eficiencia operativa y la calidad de la información, justificando la necesidad de evaluar alternativas de automatización progresiva en las etapas posteriores del estudio.

1.4 Formulación del problema

1.4.1 Problema general

PG: El procesamiento manual y no estandarizado de los reportes de atención de las llamadas de emergencia por parte de los operadores municipales genera subjetividad y variabilidad en la clasificación de los incidentes, errores en la calidad del dato y ausencia de un registro estructurado del ciclo de vida del incidente. Como consecuencia, se producen demoras variables significativas en la atención y derivación inicial, limitada trazabilidad operativa y dificultades para medir de manera objetiva el desempeño del proceso, lo que limita la confiabilidad de la información para su análisis y reduce la capacidad de respuesta operativa y estratégica ante incidentes de inseguridad ciudadana a nivel municipal.

El proceso de atención de llamadas de emergencia en el ámbito municipal constituye uno de los componentes críticos de la gestión de la seguridad ciudadana, debido a que de su rapidez, precisión y trazabilidad depende la capacidad institucional para responder oportunamente ante incidentes que afectan la integridad de las personas y el orden público. Sin embargo, en la práctica operativa cotidiana, dicho proceso se caracteriza por un alto grado de dependencia del registro manual realizado por los operadores de centrales de emergencia, quienes deben interpretar descripciones verbales heterogéneas, asignar categorías de incidente y derivar los casos a las áreas correspondientes bajo condiciones de presión temporal y elevada carga de trabajo.

Esta dependencia de procedimientos no estandarizados genera una serie de efectos acumulativos que afectan la calidad global del servicio. En primer lugar, la subjetividad inherente a la interpretación humana provoca variabilidad en la clasificación de incidentes similares, lo que deriva en inconsistencias entre tipologías, categorías y subcategorías asignadas a los mismos tipos de eventos. En segundo lugar, la ausencia de reglas homogéneas para el registro de campos temporales, tales como hora de recepción, inicio de atención o cierre del caso, y la falta de estructuración del ciclo completo de vida del incidente dificultan la reconstrucción objetiva del flujo operativo real, impidiendo medir con precisión los tiempos efectivos de respuesta y derivación inicial.

La evidencia empírica obtenida en la línea base del proceso manual (Y0), presentada en el Capítulo V, muestra una elevada dispersión en la duración de las llamadas y en los tiempos asociados a la atención inicial, con distribuciones asimétricas y colas prolongadas que superan los estándares esperables para sistemas de despacho urbano de alta demanda. Estos patrones son consistentes con lo reportado en la literatura internacional, donde se señala que los centros de despacho que operan sin herramientas analíticas automatizadas presentan mayores niveles de variabilidad operativa, retrasos en la priorización de incidentes y dificultades para gestionar picos de demanda (Chin et al., 2022; Roldan-Baluis et al., 2022).

A ello se suma la limitada trazabilidad operativa existente en los sistemas actuales, la cual se manifiesta en la imposibilidad de reconstruir de forma completa el recorrido del caso desde su creación hasta su cierre definitivo, así como en la ausencia de indicadores consolidados que permitan evaluar de manera sistemática el desempeño del servicio, comparar turnos, operadores o zonas geográficas, y analizar el impacto real de las decisiones de derivación en la resolución de los incidentes. Esta carencia de trazabilidad impide también implementar ciclos de mejora continua basados en evidencia y dificulta la adopción de enfoques de gestión orientados a resultados dentro de las municipalidades.

En conjunto, estas limitaciones reducen significativamente la confiabilidad de la información generada por las centrales de emergencia para fines analíticos y estratégicos, restringiendo la posibilidad de identificar patrones espaciales y temporales de la delincuencia, anticipar focos de riesgo y planificar la asignación óptima de recursos. Como consecuencia, la capacidad de respuesta institucional frente a incidentes de inseguridad ciudadana se ve comprometida tanto en el corto plazo —mediante retrasos en la atención inicial— como en el mediano plazo, al impedir el diseño de políticas públicas sustentadas en análisis sistemáticos de los datos operativos.

1.4.2 Problemas específicos

P0: La ausencia de una línea base cuantitativa del PROCESO MANUAL real de atención de llamadas de emergencia (con timestamps y reglas consistentes de cálculo) impide medir y caracterizar de forma objetiva y reproducible los tiempos reales de atención y derivación inicial, dificultando la comparación objetiva con un proceso asistido por un módulo inteligente en etapas posteriores.

La inexistencia de una línea base cuantitativa confiable del proceso manual de atención de llamadas de emergencia constituye una limitación fundamental para la gestión operativa municipal. La falta de registros temporales consistentes, tales como marcas de tiempo estandarizadas para la recepción de la llamada, la clasificación inicial, la derivación al área responsable y el cierre del caso, impide caracterizar de forma objetiva los tiempos reales de atención y respuesta. Esta ausencia de métricas homogéneas no solo dificulta la identificación de cuellos de botella dentro del flujo operativo, sino que también limita la capacidad de comparar el desempeño entre turnos, operadores o zonas geográficas.

Asimismo, la carencia de reglas explícitas para el cálculo de indicadores operativos imposibilita establecer comparaciones rigurosas entre el proceso actual y eventuales procesos asistidos por módulos inteligentes en etapas posteriores del estudio. Sin una línea base reproducible, cualquier intento de medir mejoras introducidas por sistemas automatizados carecería de sustento empírico sólido, afectando la validez de los análisis experimentales y restringiendo la posibilidad de justificar inversiones tecnológicas en el ámbito municipal.

P1: La deficiente calidad, estandarización y estructura de los datos del dataset original de llamadas de emergencia, caracterizada por la alta proporción de valores nulos, variables redundantes, codificación inadecuada de campos temporales y presencia de datos sensibles, genera ruido, limita su interpretabilidad y dificulta su uso como entrada confiable para un pipeline de análisis basado en NLP y aprendizaje automático.

La baja calidad y escasa estandarización del dataset original de llamadas de emergencia representa un obstáculo crítico para la implementación de soluciones basadas en aprendizaje automático. La presencia significativa de valores nulos, variables redundantes y codificaciones inconsistentes en campos temporales genera ruido en los datos y dificulta su integración en procesos analíticos sistemáticos. Adicionalmente, la inclusión de información sensible sin mecanismos adecuados de anonimización introduce restricciones legales y éticas que limitan el uso de estos registros para fines de investigación y desarrollo tecnológico.

Estas deficiencias afectan directamente la confiabilidad del pipeline de análisis, dado que los modelos de NLP y clasificación automática dependen de insumos estructurados y coherentes para alcanzar niveles adecuados de desempeño. La necesidad de procesos exhaustivos de limpieza, normalización y curación de datos, abordados posteriormente en la etapa Y1, surge como respuesta a esta problemática, evidenciando que la calidad de los datos constituye un factor determinante para el éxito de cualquier sistema inteligente aplicado a la gestión de emergencias.

P2: La ausencia de una representación semántica estandarizada, comparable y evaluada que capture de manera adecuada el significado de las descripciones textuales de las llamadas de emergencia, limita la confiabilidad, robustez y desempeño de modelos automáticos de clasificación (tipología–categoría) y del análisis semántico.

La falta de una representación semántica estandarizada y evaluada de las descripciones textuales de las llamadas de emergencia limita severamente la capacidad de los modelos automáticos para interpretar correctamente el significado de los reportes ciudadanos. Los textos registrados por los operadores suelen presentar alta variabilidad lingüística, errores ortográficos, abreviaturas y referencias contextuales implícitas, lo que dificulta la extracción directa de información relevante mediante técnicas simples basadas en conteo de palabras.

Sin una representación semántica robusta, comparable y validada empíricamente, los modelos de clasificación multiclase tienden a presentar baja estabilidad y escasa generalización, especialmente en escenarios reales de operación. Esta situación motiva la exploración sistemática de distintas estrategias de representación textual, desde enfoques clásicos como TF-IDF hasta modelos de lenguaje preentrenados en español como BETO, evaluadas en la etapa Y2 del estudio, con el objetivo de determinar cuáles capturan de manera más adecuada la semántica de los reportes ciudadanos.

P3: La clasificación manual de las llamadas de emergencia presenta subjetividad e inconsistencia, además de un fuerte desbalance entre tipologías, lo que degrada el desempeño en clases minoritarias, reduce la reproducibilidad y limita la confiabilidad de los sistemas automáticos de apoyo a la decisión.

La clasificación manual de las llamadas de emergencia por parte de los operadores introduce sesgos subjetivos e inconsistencias que afectan la reproducibilidad del proceso de atención. Incidentes similares pueden ser etiquetados bajo tipologías distintas según el criterio individual del operador, el contexto temporal o la presión de carga laboral, generando un fuerte desbalance entre clases y una representación distorsionada de ciertos tipos de eventos dentro del sistema.

Este desbalance perjudica el entrenamiento de modelos automáticos posteriores, ya que las clases minoritarias, que suelen corresponder a eventos críticos, quedan subrepresentadas, lo que reduce la sensibilidad del sistema para detectar incidentes relevantes y compromete su confiabilidad como herramienta de apoyo a la decisión. La etapa Y3 del estudio aborda esta problemática mediante la aplicación de técnicas de balanceo de datos y esquemas de clasificación supervisada, buscando mitigar la asimetría entre categorías y mejorar la estabilidad de los modelos en contextos reales.

P4: La falta de una arquitectura formal y de un módulo inteligente operativo que integre clasificación automática del incidente, orquestación del flujo de atención, retroalimentación al ciudadano y registro del ciclo de vida del caso (creada, derivada, en atención, cerrada) impide la trazabilidad completa, la medición del desempeño operativo y la evaluación del impacto real de las llamadas de emergencia en la gestión municipal hasta el cierre del incidente.

La inexistencia de una arquitectura formal que articule la clasificación automática, la orquestación del flujo operativo, la retroalimentación al ciudadano y el registro completo del ciclo de vida del incidente impide consolidar una gestión integral de las llamadas de emergencia. La ausencia de estados claramente definidos, tales como creado, derivado, en atención y cerrado, limita la capacidad de reconstruir el recorrido de cada caso y de medir su impacto real en la gestión municipal.

Esta fragmentación tecnológica también restringe la evaluación sistemática del desempeño operativo y la implementación de mecanismos de mejora continua basados en evidencia. Sin una infraestructura que integre los distintos módulos del sistema y registre de manera estructurada cada etapa del proceso, resulta imposible cuantificar los beneficios introducidos por soluciones automatizadas o justificar su escalamiento institucional. La propuesta desarrollada en la etapa Y4 responde directamente a esta problemática, mediante el diseño de un prototipo operativo que incorpora trazabilidad end-to-end y soporte a la toma de decisiones en tiempo real.

1.5 Objetivos

1.5.1 Objetivo general

OG: Analizar y medir el proceso de atención como los tiempos de atención y derivación inicial de incidentes de emergencia municipal mediante el diseño e implementación de un módulo inteligente basado en Procesamiento de Lenguaje Natural, que automatice la clasificación inicial y estructure el registro operativo, permitiendo comparar el desempeño del proceso manual (Y0) frente al proceso asistido (Y4).

El objetivo general de la investigación se orienta a evaluar rigurosamente el desempeño del proceso actual de atención de llamadas de emergencia municipales y contrastarlo con un proceso asistido por inteligencia artificial, mediante el diseño e implementación de un módulo inteligente que automatice etapas críticas del flujo operativo. Este análisis contempla la medición sistemática de tiempos de atención, derivación inicial y cierre de casos, así como la incorporación de mecanismos de registro estructurado del ciclo de vida del incidente, con el propósito de generar evidencia cuantitativa que permita evaluar mejoras operativas atribuibles al uso de técnicas de Procesamiento de Lenguaje Natural y aprendizaje automático.

Asimismo, el enfoque experimental planteado, estructurado en las etapas Y0 a Y4, permite comparar de manera objetiva el funcionamiento del proceso manual frente al proceso automatizado, asegurando trazabilidad metodológica y reproducibilidad de los resultados. De este modo, la investigación no solo busca optimizar la clasificación inicial de incidentes, sino también fortalecer la capacidad analítica de la gestión municipal mediante información estructurada que sirva como soporte para la toma de decisiones operativas y estratégicas.

1.5.2 Objetivos específicos

OE0: Construir y validar una línea base (Y0) del PROCESO MANUAL real de atención de llamadas de emergencia (dataset v1.1), calculando y consolidando métricas de tiempo y trazabilidad mínima (por estado, consulta y área derivada), que sirva como referencia operativa para habilitar la comparación manual vs asistido en el último artefacto (Y4).

Este objetivo específico se centra en la caracterización cuantitativa del proceso operativo existente, mediante la construcción de una línea base confiable que capture de forma sistemática los tiempos de atención y derivación inicial, así como los estados mínimos del ciclo de vida del incidente. La consolidación de estas métricas permitirá identificar cuellos de botella, patrones de variabilidad y diferencias entre áreas operativas, estableciendo un punto de referencia empírico indispensable para evaluar posteriormente los efectos introducidos por el módulo inteligente propuesto.

Además, la línea base Y0 constituye el fundamento metodológico del diseño experimental de la investigación, dado que proporciona el marco de comparación necesario para contrastar el proceso manual

con el proceso asistido en la etapa final Y4. Sin esta referencia objetiva, no sería posible atribuir mejoras operativas de manera rigurosa al uso de técnicas automatizadas.

OE1: Analizar, depurar y normalizar a nivel estructural el dataset original de llamadas de emergencia mediante técnicas de análisis exploratorio de datos (EDA) y reglas operativas explícitas de limpieza, con el fin de obtener un conjunto de datos limpio, consistente y enriquecido (Y1), que sirva como base metodológica para la representación semántica (Y2) y la clasificación supervisada (Y3).

Este objetivo aborda la problemática de la calidad y estructura de los datos mediante la aplicación sistemática de técnicas de análisis exploratorio y reglas formales de limpieza y normalización. El proceso de curación contempla la eliminación de redundancias, la estandarización de campos temporales, el tratamiento de valores faltantes y la anonimización de información sensible, generando un dataset confiable y apto para ser utilizado en etapas posteriores del pipeline analítico.

El conjunto de datos resultante en Y1 se convierte en el insumo fundamental para la experimentación con representaciones semánticas y modelos de clasificación, garantizando que los resultados obtenidos en Y2 y Y3 respondan a mejoras metodológicas reales y no a sesgos derivados de deficiencias en la información original.

OE2: Construir, implementar y comparar de manera sistemática múltiples representaciones semánticas del texto de las llamadas de emergencia (TF-IDF, BETO y sus variantes, SBERT y LDA), evaluando su desempeño tanto en clasificación automática como en métricas de calidad semántica, con el fin de seleccionar la representación más adecuada para el pipeline de análisis y los modelos en la etapa posterior.

Este objetivo se orienta a evaluar comparativamente distintas estrategias de representación textual, abarcando tanto enfoques clásicos basados en frecuencia de términos como modelos de lenguaje preentrenados en español. La comparación se realizará mediante métricas cuantitativas de desempeño en clasificación y análisis semántico, permitiendo identificar qué representación captura de manera más adecuada el significado de las descripciones de incidentes registradas en las llamadas de emergencia.

La selección de la mejor representación constituye un paso crítico dentro del pipeline metodológico, ya que de ella depende la estabilidad y capacidad predictiva de los modelos entrenados posteriormente. Esta evaluación sistemática asegura que la arquitectura final del sistema se sustente en decisiones empíricas y no únicamente en supuestos teóricos.

OE3: Entrenar, evaluar y comparar modelos BETO fine-tuning para clasificación de tipologías incorporando estrategias explícitas de manejo del desbalance (baseline, undersampling, oversampling y cost-sensitive learning), para cuantificar su impacto en desempeño global y por clase, y seleccionar el mejor modelo para el Artefacto Y4.

Este objetivo específico se centra en el fortalecimiento del componente de clasificación automática mediante el ajuste fino de modelos BETO y la incorporación de técnicas de balanceo de clases que mitiguen los efectos del desbalance presente en los datos reales. La evaluación comparativa se realizará tanto a nivel global como por categoría, prestando especial atención al desempeño en clases minoritarias de alta relevancia operativa.

Los resultados obtenidos permitirán seleccionar el modelo más robusto y confiable para su integración en el módulo inteligente final, garantizando que las decisiones de derivación automática se sustenten en predicciones estables y reproducibles bajo condiciones reales de operación.

OE4: Diseñar e implementar un módulo inteligente operativo de atención de incidentes que reciba mensajes vía WhatsApp (Twilio), procese la consulta mediante un workflow orquestado (FastAPI + LangGraph), realice clasificación automática y derivación sugerida (modelo entrenado en Y3), genere respuestas asistidas por LLM, y registre de forma estructurada estados y eventos, permitiendo medir tiempos, trazabilidad y mejora operativa respecto a la línea base manual (Y0).

Este objetivo culmina la investigación mediante la construcción de un prototipo funcional que integre los distintos componentes desarrollados en etapas previas dentro de un flujo operativo orquestado. El módulo inteligente permitirá automatizar la recepción de consultas ciudadanas, la clasificación inicial de incidentes, la generación de respuestas asistidas y la sugerencia de derivaciones, todo ello acompañado de un registro estructurado de estados y eventos que haga posible medir de manera objetiva los tiempos y la trazabilidad del proceso.

La implementación del prototipo en la etapa Y4 habilita la comparación directa con la línea base manual, permitiendo cuantificar mejoras operativas en términos de reducción de tiempos, incremento en la consistencia de la clasificación y fortalecimiento de la trazabilidad institucional. De este modo, el sistema propuesto se posiciona como una herramienta replicable para la modernización de los servicios municipales de atención de emergencias.

1.6 Representación del problema

El problema de investigación puede ser representado de manera sistémica mediante un esquema Entrada–Proceso–Salida (ver **Figura 10**), que sintetiza las deficiencias operativas identificadas en la atención de llamadas de emergencia municipales que se pueden ver de forma más detallada en la **Figura 12**.

Figura 12: Representación actual del flujo, estados y variables de Entrada-Proceso-Salida de las llamadas de emergencia de la Municipalidad del Callao



Fuente: Dataset v.1.1 de las Llamadas de Emergencia de la Municipalidad del Callao
Elaboración: Propia

En la etapa de **entrada**, se reciben reportes ciudadanos en formato textual libre, caracterizados por alta heterogeneidad lingüística, errores de digitación, información incompleta y ausencia de estandarización semántica. A ello se suman deficiencias estructurales en los campos temporales y la presencia de datos sensibles que requieren procesos de anonimización antes de su explotación analítica.

En la fase de **proceso**, predomina un flujo manual y fragmentado, donde los operadores interpretan la información, asignan tipologías de incidente y derivan los casos a distintas áreas sin el apoyo de herramientas automatizadas de análisis semántico ni reglas homogéneas de cálculo de tiempos. Esta dinámica genera subjetividad en la clasificación, demoras variables en la atención inicial, dificultades para registrar los estados del caso y una limitada trazabilidad del ciclo de vida del incidente.

Finalmente, en la etapa de **salida**, el sistema produce registros incompletos, métricas poco confiables y escasa capacidad para evaluar el desempeño operativo, identificar patrones espacio–temporales o sustentar decisiones estratégicas de asignación de recursos. Esta representación permite comprender cómo las deficiencias en cada etapa del flujo contribuyen a la pérdida de eficiencia institucional y justifican la necesidad de introducir un módulo inteligente que transforme el proceso manual en un sistema asistido, trazable y reproducible.

1.7 Justificación de la investigación

La presente investigación se justifica desde una perspectiva **científica, tecnológica y operativa**. En el plano académico, contribuye al cuerpo de conocimiento sobre la aplicación de técnicas de Procesamiento de Lenguaje Natural y aprendizaje automático en contextos reales de seguridad ciudadana en Latinoamérica, un ámbito aún poco explorado en comparación con estudios desarrollados en países de altos ingresos. El enfoque experimental por etapas (Y0–Y4) y la evaluación sistemática de representaciones semánticas y modelos de clasificación aportan evidencia empírica replicable sobre el impacto de estas tecnologías en procesos municipales de atención de emergencias.

Desde el punto de vista tecnológico, la investigación propone una arquitectura integrada que articula módulos de clasificación automática, orquestación de flujos operativos, interacción con canales de mensajería y componentes MLOps, permitiendo evaluar no solo el desempeño predictivo de los modelos, sino también su viabilidad de despliegue en entornos institucionales reales. Esta aproximación supera enfoques puramente algorítmicos al incorporar métricas operativas de tiempo, trazabilidad y eficiencia del servicio.

En el ámbito práctico, el estudio resulta relevante para la gestión municipal al generar herramientas que pueden apoyar la reducción de tiempos de atención, la estandarización de la clasificación de incidentes y la mejora de la toma de decisiones en la asignación de recursos. Los resultados obtenidos pueden servir como insumo para la formulación de políticas públicas orientadas a modernizar los sistemas de atención ciudadana y fortalecer la prevención del delito en contextos urbanos de alta complejidad.

1.8 Alcances

El estudio se circunscribe al análisis de las llamadas de emergencia registradas en la central de atención de la Municipalidad Provincial del Callao durante el período 2023–2024, utilizando principalmente descripciones textuales de incidentes y metadatos operativos asociados al proceso de atención. La investigación se enfoca en la evaluación del flujo de recepción, clasificación inicial y derivación de casos, así como en la construcción de un prototipo funcional que permita comparar el proceso manual con un proceso asistido por inteligencia artificial.

De forma metodológica, el alcance incluye la construcción de una línea base operativa (Y0), la curación y normalización de datos (Y1), la evaluación de representaciones semánticas (Y2), el entrenamiento de modelos de clasificación con técnicas de balanceo (Y3) y la implementación de un módulo inteligente integrado (Y4). No se contempla la ejecución de intervenciones reales en campo ni el despliegue productivo del sistema dentro de la municipalidad, limitándose a una validación experimental controlada sobre datos históricos.

Asimismo, el estudio se orienta a incidentes reportados por la ciudadanía a través de canales formales de atención municipal, sin considerar denuncias policiales externas, redes sociales u otras fuentes de información no institucionales.

1.9 Limitaciones

Entre las principales limitaciones de la investigación se encuentra la dependencia de la calidad y completitud de los datos históricos disponibles, los cuales pueden presentar sesgos derivados de errores de registro, subreporte de incidentes o cambios en los criterios operativos a lo largo del tiempo. Estas características pueden afectar la generalización de los modelos entrenados y deben ser consideradas al interpretar los resultados obtenidos.

Asimismo, la validación del módulo inteligente se realizará en un entorno experimental y no en operación real, por lo que las mejoras observadas en tiempos y trazabilidad representan escenarios simulados bajo condiciones controladas. La investigación tampoco incorpora factores externos como la disponibilidad real de patrullas, decisiones humanas posteriores a la derivación automática o restricciones presupuestales municipales, los cuales influyen en la atención final del incidente pero se encuentran fuera del alcance metodológico del presente estudio.

2.1 Antecedentes nacionales e internacionales

2.1.1 Contexto nacional y regional (Perú y latinoamérica)

En el contexto peruano, la literatura sobre análisis automático de llamadas de emergencia es limitada. Sin embargo, existen algunos estudios que abordan problemas relacionados.

La **seguridad ciudadana** se refiere a la protección de las personas frente a delitos y violencia en el ámbito público, e involucra tanto la acción del Estado (policía, municipalidades, justicia) como la participación de la comunidad. América Latina presenta una problemática severa en este campo: diversas investigaciones han documentado que la región ostenta **una de las tasas de criminalidad más altas del mundo**, lo que impacta en la **percepción de inseguridad** de la población y da una señal de la baja capacidad de respuesta institucional. En otras palabras, los altos índices de delitos en países latinoamericanos han generado que amplios sectores de la ciudadanía vivan con temor y desconfianza, percibiendo sus entornos como inseguros, incluso más allá de la probabilidad real de ser victimizados, visto como miedo al delito. Esta **brecha entre inseguridad objetiva y subjetiva** ha sido estudiada en la literatura (Hernández-Gutiérrez & Zurita Ortega, 2022), donde destacan que en varios países de la región el **miedo al delito** sobrepasa a veces la incidencia real de delitos, influenciado por factores como la cobertura mediática y la confianza en las instituciones.

En el **caso peruano**, las estadísticas oficiales recientes confirman el agravamiento del problema. El Boletín de Seguridad Ciudadana del INEI (2024) y un reporte del BCRP (2023) registran un **incremento sostenido de delitos violentos, hurtos y robos agravados** en zonas urbanas del Perú. Este crecimiento de la delincuencia ha posicionado a la **inseguridad ciudadana como uno de los principales problemas nacionales**, afectando la calidad de vida y el desarrollo sostenible de las ciudades. De forma paralela, las encuestas de victimización de estos estudios revelan que la **percepción de inseguridad** entre los peruanos se ha intensificado en los últimos años, alcanzando niveles récord. Esto se refleja en que una mayoría de ciudadanos declara sentir temor de ser víctima de delito al transitar por las calles de su barrio, lo cual genera cambios en sus hábitos (por ejemplo, evitar salir de noche) y **deteriora la confianza** en las autoridades encargadas de protegerlos.

a) Predicción de criminalidad en Lima metropolitana

(Sanchez et al., 2025) desarrollan una aplicación web basada en machine learning para reducir tasas de robos y hurtos en tres distritos de Lima (Los Olivos, San Martín de Porres y Comas). Su investigación utiliza datos de incidentes registrados entre 2023–2024 y demuestra que modelos de predicción espacio-temporal pueden identificar zonas de riesgo con hasta 78% de precisión, permitiendo asignación preventiva de recursos policiales. Este estudio es relevante para el contexto del Callao, pues opera sobre datos similares (reportes de incidentes) y en una jurisdicción comparable (Lima Metropolitana).

b) Gestión de políticas públicas en seguridad ciudadana

(Ruiz, 2024) realiza una revisión sistemática sobre la gestión de políticas públicas en seguridad ciudadana en Latinoamérica, identificando que la mayoría de municipios carece de herramientas analíticas avanzadas para procesar información de reportes ciudadanos, lo que genera:

- Dependencia excesiva de procesos manuales
- Débil trazabilidad operativa
- Limitada capacidad de análisis agregado
- Retrasos en la respuesta operativa

Esta conclusión respalda la relevancia del problema identificado en los datos de la Municipalidad del Callao.

c) Seguridad ciudadana en el Perú: perspectiva reciente

Diversos estudios han investigado los **factores asociados a la inseguridad en Perú y Latinoamérica**. Una revisión sistemática reciente (Anton-Chunga, 2025) analizó 15 estudios sobre percepciones y realidades de seguridad ciudadana en el Perú, identificando factores agravantes clave. Los hallazgos revelan una percepción desfavorable de la seguridad vinculada a factores socioeconómicos como *el desempleo juvenil* y la *pobreza*, factores institucionales como la corrupción y la desconfianza en las instituciones, así como fenómenos recientes como la migración venezolana. También se señalan aspectos críticos en la respuesta del Estado: la ineficacia de las políticas criminales vigentes, la deficiente respuesta institucional ante la victimización y la insuficiente asignación de recursos serían agravantes de la inseguridad observados en múltiples regiones del país. Estos elementos han contribuido a un círculo vicioso donde la ciudadanía siente que el Estado no logra controlar la delincuencia, aumentando la **sensación de vulnerabilidad** colectiva. Sin embargo, no todo es negativo: el mismo estudio resalta el rol activo de los ciudadanos organizados a través de juntas vecinales y rondas campesinas como un factor que busca frenar la delincuencia. Estas formas de organización comunitaria han emergido en zonas urbanas y rurales, respectivamente, para cooperar en labores de vigilancia, alertar a la policía y disuadir la actividad delictiva. Su presencia demuestra que la sociedad civil participa en la búsqueda de soluciones y puede complementar la acción policial, aunque no debe sustituirla.

Las investigaciones académicas en años recientes ofrecen recomendaciones estratégicas para abordar la inseguridad en la región. En particular, (Coz & Pariona, 2023) realizaron una revisión sistemática de 30 estudios sobre seguridad ciudadana en el Perú y Latinoamérica en los últimos 5 años de su investigación e identificaron tendencias en las propuestas de solución. Encontraron que el 50 % de los estudios recomienda implementar nuevas políticas públicas o reforzar las existentes para contrarrestar la delincuencia; el 27 % enfatiza la importancia de utilizar dispositivos tecnológicos y medios de comunicación en la prevención del delito; y el 23 % propone fortalecer el trabajo organizado de la Policía en articulación con el Serenazgo municipal y las juntas vecinales. Estos porcentajes evidencian un consenso en que se requieren tanto mejoras normativas y de gestión (políticas integrales) como innovación tecnológica y colaboración interinstitucional-comunitaria, tal como se resume en el cuadro 9. En su investigación documentan que la

inseguridad ciudadana en el Perú ha aumentado sostenidamente en los últimos cinco años, con particular énfasis en Lima y el Callao, señalando que, aunque las municipalidades generan grandes volúmenes de datos operativos (llamadas de emergencia, reportes de patrullaje), estos permanecen subutilizados para fines de análisis preventivo.

CUADRO 9: COMO CONTRARESTAR LA INSEGURIDAD CIUDADANA



Fuente: Coz Torre, C. A., & Pariona Cárdenas, H. (2023). Seguridad ciudadana en el Perú y Latinoamérica en los últimos 5 años- *Revista de Climatología*, 23, pág. 3857.

d) Plataformas inteligentes para seguridad ciudadana municipal

(Castro-Chucan et al., 2024) describen la plataforma *Smart Muni*, un sistema integrado para gestión de emergencias y seguridad ciudadana que combina geolocalización, integración tecnológica y comunicación en tiempo real. Aunque el enfoque de este sistema es más amplio (multimodal), los autores destacan la importancia de automatizar la clasificación de incidentes y estructurar el flujo operativo, resultados similares a los que busca esta investigación en el Callao.

En síntesis, los estudios revisados coinciden en que **Latinoamérica y Perú requieren una intervención estatal articulada con la participación ciudadana** para enfrentar la inseguridad. Esto implica **crear estrategias, programas y políticas públicas basadas en evidencia** que aborden las causas profundas de la delincuencia (desigualdad, falta de oportunidades, corrupción, etc.) al mismo tiempo que mejoren la capacidad operativa de las instituciones de seguridad. Solo a través de un **esfuerzo conjunto y multisectorial** será posible controlar la violencia y recuperar la tranquilidad en la sociedad. La experiencia internacional sugiere que políticas focalizadas en prevención (educación, recuperación de espacios públicos, reducción de factores de riesgo sociales) combinadas con el **fortalecimiento de las fuerzas del orden** y sistemas de justicia eficientes pueden lograr reducciones sostenidas del delito. No obstante, dichos cambios toman tiempo y requieren voluntad política, inversiones sostenidas como la confianza y colaboración de la ciudadanía.

2.1.2 Contexto internacional

En el contexto internacional, la gestión de llamadas de emergencia mediante tecnologías de inteligencia artificial ha ganado tracción significativa en los últimos cinco años. Estudios recientes demuestran que organismos de seguridad pública en Europa, América del Norte y Asia han invertido en sistemas de análisis automatizado de reportes ciudadanos, particularmente enfocados en:

a) Predicción y análisis espacio-temporal de criminalidad

(Zhao et al., 2022) proponen un marco denominado CCC (*Cross-type and spatio-temporal Correlation Crime prediction*), que integra correlaciones espaciales, temporales y entre tipos de delito utilizando técnicas de regularización y optimización mediante ADMM. El estudio se desarrolló con datos reales de Nueva York (2012–2013), incluyendo registros de siete tipos de delitos, datos de paradas policiales, quejas públicas (311), condiciones climáticas, puntos de interés y patrones de movilidad humana. Los resultados evidencian que el marco CCC supera significativamente a modelos tradicionales (ARIMA, VAR), redes neuronales (LSTM), y modelos espaciotemporales especializados (DeepMove, ST-ResNet), demostrando utilidad operativa para autoridades de seguridad pública.

Este estudio ofrece evidencia empírica sobre la viabilidad de integrar múltiples dimensiones (texto, tiempo, espacio) para mejorar la predicción de incidentes, un enfoque alineado con los objetivos de la presente investigación en el contexto del Callao.

b) Procesamiento de texto en llamadas de emergencia (911)

(Costa et al., 2023) presentan una metodología integrada para transcribir y clasificar datos no estructurados provenientes de llamadas de emergencia (911) mediante inteligencia artificial. Su propuesta combina transcripción automática de audio, extracción de entidades, clasificación de urgencia y generación de reportes estructurados. Los autores aplican técnicas NLP basadas en transformers y reportan mejoras significativas en la consistencia de clasificación y reducción del tiempo de procesamiento manual.

c) Análisis de severidad en llamadas de emergencia médica

(Chin et al., 2022) desarrollaron un modelo basado en machine learning para predecir la gravedad de lesiones en despachos de emergencia médica, utilizando análisis de texto de las descripciones de llamadas. Su estudio utiliza el dataset de emergencias 911 de Toronto (Canadá, 2015–2019) con 5.6 millones de registros. El modelo alcanza una precisión (F1-score) del 0.87 en la clasificación de pacientes con lesiones graves, permitiendo priorización automática de despachos.

2.1.3 Síntesis de brechas identificadas

Los antecedentes revisados revelan:

1. Avances internacionales en NLP aplicado a emergencias, pero con implementación predominante en contextos de habla inglesa (EE.UU., Canadá)


2. Escasez de literatura aplicada a contextos hispanohablantes de América Latina, particularmente en Perú
3. Oportunidad de innovación en diseño e implementación de sistemas que integren NLP con trazabilidad operativa en contextos municipales reales
4. Necesidad de estudios que combinen enfoque técnico (NLP, ML) con validación operativa en entornos urbanos complejos

La presente investigación busca cerrar estas brechas mediante el desarrollo de un sistema inteligente contextualizado al Callao, combinando análisis de texto, clasificación automatizada y métricas operativas reales.

2.1.4) Llamadas de emergencia: definición, componentes, modelos CAD y normativa

Las **llamadas de emergencia** constituyen un canal fundamental mediante el cual los ciudadanos reportan incidentes críticos (delitos, accidentes, urgencias médicas, desastres) a las autoridades en tiempo real. A través de este mecanismo, la población puede alertar inmediatamente a la Policía, bomberos, serenazgo o servicios de emergencia médica, activando una respuesta institucional para atender la situación reportada. En la práctica, una llamada de emergencia típica involucra a un operador (teleoperador) que recibe la comunicación, recopila información clave (qué ocurrió, dónde, cuándo, quiénes involucrados, condición de las víctimas, etc.) y la ingresa a un sistema informático, tras lo cual un despachador coordina el envío de las unidades de respuesta necesarias (patrulleros, ambulancias, brigadas de rescate, etc.). Este proceso es asistido por sistemas conocidos como **CAD** (Computer-Aided Dispatch) o Despacho Asistido por Computadora, que permiten registrar y gestionar las llamadas de forma eficiente tal como propone (Abi Kanaan et al., 2024). Un sistema CAD (ver figura 2) integra las etapas de toma de la llamada, clasificación del incidente, asignación de prioridades y despacho de unidades, manteniendo a su vez un registro digital de cada incidente y facilitando la coordinación multi-agencia. En esencia, el CAD funciona como el corazón tecnológico de un centro de emergencias: muestra al despachador en pantalla las llamadas entrantes, su ubicación en el mapa, los recursos disponibles más cercanos, y lleva un historial de todos los eventos en curso, ayudando a **manejar múltiples incidentes simultáneamente** con rapidez. La implementación de CAD en los centros de atención de emergencias (también llamados **Central 911** o **Central 105** según el país) ha demostrado mejorar los tiempos de respuesta y la asignación óptima de recursos, al automatizar tareas que antes se hacían manualmente (como llevar bitácoras en papel o buscar teléfonos de unidades).

FIGURA 2: Estructura del proceso de las Llamadas de emergencia



Fuente: Abi Kanaan, M., Couchot, J.-F., Guyeux, C., Laiymani, D., Atechian, T., & Darazi, R. (2024). Combining a multi-feature neural network with multi-task learning for emergency calls severity prediction, pág. 2

En el Perú, la **gestión de llamadas de emergencia** se da en diversos niveles. De forma tradicional, la Policía Nacional del Perú operaba la línea de emergencias *105* a nivel nacional, mientras que los bomberos voluntarios atendían la línea *116* y el Ministerio de Salud la línea *106* (SAMU para emergencias médicas). Adicionalmente, muchas municipalidades (sobre todo las grandes ciudades) disponen de sus propias centrales de emergencias, generalmente vinculadas al servicio de **serenazgo municipal**, para atender incidencias de seguridad ciudadana local y coordinar con la policía en su jurisdicción. Este mosaico de líneas y centrales múltiples ha tendido a unificarse en los últimos años. De hecho, mediante **Decreto Supremo N.º 012-2019-IN** se creó la **Central Única de Emergencias 911 en Perú**, buscando integrar todas las llamadas de urgencia en un solo número, siguiendo el estándar internacional. La implementación del 911 se inició como piloto en Lima Metropolitana y Callao, con el objetivo de unificar la atención de la Policía, bomberos y ambulancias en un mismo sistema. Según anunció el gobierno, el 911 peruano permitirá gestionar más de 25 mil llamadas diarias y reducir el tiempo de atención gracias a la co-localización de operadores de diferentes servicios. A la par, municipalidades como la del Callao mantienen su central local (que puede actuar de primer filtro o atender eventos de menor escala), pero conectada al sistema nacional para derivar casos que requieran intervención de la PNP u otros.

En cuanto al **marco normativo**, la **Ley N.º 27933 – Ley del Sistema Nacional de Seguridad Ciudadana** (modificada en 2021) establece la estructura y funciones para la coordinación en seguridad a nivel nacional, regional y local. Esta ley define que los Comités de Seguridad Ciudadana (desde el nacional presidido por el Ministro del Interior hasta los comités distritales) son espacios donde participan autoridades y sociedad civil para planificar estrategias de prevención. De forma complementaria, en 2021 se promulgó la **Ley N.º 31297 – Ley del Servicio de Serenazgo Municipal**, que regula la función de los serenazgos en las municipalidades. Dicha ley y su reglamento (D.S. 009-2022-IN) delinean que el serenazgo tiene competencia en prevención y auxilio en seguridad ciudadana local, **en coordinación estrecha con la Policía Nacional**. Por ejemplo, el Serenazgo debe **comunicar de inmediato a la PNP** la ocurrencia de delitos e intervenir conjuntamente cuando sea requerido, actuando como primera respuesta disuasiva pero con **articulación operativa con la policía** (Patrullaje Integrado). Esta normativa exige además que los municipios implementen centrales de emergencia equipadas adecuadamente, con personal capacitado y sistemas de comunicación interconectados con la PNP. En línea con ello, muchas municipalidades han

firmado convenios con la Policía para integrar sus radios y sistemas CAD, de modo que una llamada ciudadana sea atendida sin importar si entró por el número policial o el municipal. La Defensoría del Pueblo ha resaltado la importancia de **aprobar reglamentos** que fortalezcan el Serenazgo y su coordinación con la policía para mejorar la calidad del servicio de seguridad municipal.

Por otro lado, cabe señalar que **la modernización tecnológica de las centrales de emergencia** es una prioridad en el país. En 2023–2024, el Ministerio de Transportes y Comunicaciones (MTC) a través de *Pronatel* impulsó la infraestructura del 911, incorporando sistemas de geolocalización celular avanzada, grabación de llamadas, y la posibilidad de recepción de mensajes de texto de emergencia. Esto último es crucial para casos en que la persona no puede hablar (por encontrarse bajo amenaza, por ejemplo), permitiendo un *chat de emergencia* silencioso. De hecho, **Bogotá (Colombia)** ha servido como referencia regional al implementar recientemente funciones similares en su línea 123: videollamadas desde teléfonos móviles, chat silencioso vía WhatsApp/SMS y georreferenciación precisa del origen de la llamada, todo integrado en la plataforma de despacho. Perú busca adoptar estas mejores prácticas internacionales. En resumen, el marco legal peruano y las iniciativas en marcha enfatizan la **integración de esfuerzos** (unificación de líneas en el 911, coordinación Serenazgo-PNP) y la **adopción de tecnología** para optimizar la atención de llamadas de emergencia, reducir el tiempo de respuesta y brindar un servicio más eficaz a la ciudadanía.

En términos de **definición y componentes técnicos**, una llamada de emergencia bien gestionada consta de varios **componentes básicos**:

- (a) **Acceso** – el ciudadano se comunica por teléfono (red fija o móvil) o hoy en día también vía aplicaciones o botones de pánico;
- (b) **Recepción** – un operador entrenado atiende la comunicación, sigue protocolos (p. ej., preguntas clave según el tipo de incidente) y registra los datos en el sistema;
- (c) **Clasificación** – el incidente se categoriza (por ejemplo: código 01 para robo en proceso, código 45 para accidente de tránsito con heridos, etc.) y se le asigna un nivel de prioridad según la gravedad y el riesgo en curso;
- (d) **Despacho** – el operador/despachador moviliza los recursos correspondientes: envía alertas a patrulleros en la zona vía radio o al personal de serenazgo, coordina con bomberos o ambulancias si es necesario, y realiza seguimiento;
- (e) **Cierre y documentación** – se registra la hora de llegada de las unidades, acciones realizadas, estado final (emergencia controlada, traslado de heridos, detenidos, etc.) y se cierra el incidente en el sistema.

Todos estos pasos quedan **registrados digitalmente** en una base de datos histórica, que permite posteriormente analizar los datos de llamadas (para estadísticas de tiempos de respuesta, frecuencia de tipos de incidentes por zona, etc.). Precisamente, la información recopilada de las llamadas de emergencia constituye un **valioso conjunto de datos** para las autoridades: revela patrones espaciotemporales de la ocurrencia de incidentes y demanda ciudadana de seguridad, lo que puede orientar la asignación de patrullaje preventivo y las políticas de seguridad.

En **conclusión**, las llamadas de emergencia son un pilar de la seguridad ciudadana moderna. Representan la puerta de entrada del ciudadano al sistema de respuesta inmediata del Estado, y su correcta gestión impacta directamente en salvar vidas, detener delitos en progreso y mitigar daños. La tecnología (CAD, geolocalización, comunicaciones) y el marco institucional (leyes, protocolos) **deben conjugarse** para que este proceso sea eficiente. Perú, al igual que otros países de la región, se encuentra en un proceso de **fortalecimiento de sus centrales de emergencia**, integrando sus sistemas y normativas para lograr respuestas más rápidas y coordinadas ante los crecientes desafíos de inseguridad y riesgo en nuestras ciudades.

2.2 Procesamiento de Lenguaje Natural (NLP) aplicado a reportes ciudadanos

2.2.1 Definición y alcance del NLP

El Procesamiento de Lenguaje Natural (NLP, por sus siglas en inglés *Natural Language Processing*) es una rama de la inteligencia artificial que se ocupa de permitir a las computadoras entender, interpretar y generar lenguaje humano de manera significativa y útil. En el contexto de seguridad ciudadana y emergencias, el NLP es fundamental para transformar descripciones narrativas no estructuradas (texto libre) en información procesable y analizable.

2.2.2 Aplicaciones de NLP en análisis de emergencias

En el dominio de llamadas de emergencia, el NLP se utiliza para:

a) Clasificación automática de incidentes

Transformar descripciones narrativas en categorías predefinidas (robos, violencia doméstica, disturbios, etc.). Esto permite automatizar una tarea que tradicionalmente era realizada manualmente por operadores, reduciendo sesgos y estandarizando la clasificación.

b) Extracción de entidades

Identificar automáticamente elementos clave en el texto, tales como:

- Ubicaciones (direcciones, puntos de referencia, zonas)
- Personas involucradas (víctimas, perpetradores, testigos)
- Objetos (vehículos, armas, dinero)
- Tiempos (horarios de ocurrencia)

c) Análisis de sentimiento y urgencia

Determinar el nivel de alarma o urgencia implícito en el lenguaje del reportante. (Chin et al., 2022) muestran que el análisis de características lingüísticas en textos de emergencia (tono, lenguaje corporal transcrito, puntuación) permite estimar la gravedad con alta precisión.

d) Agrupamiento temático de incidentes

Identificar patrones temáticos recurrentes o agrupar incidentes aparentemente desconectados que comparten características semánticas comunes.

Una gran proporción de los datos generados en el contexto de seguridad ciudadana son **textos no estructurados**: descripciones verbales de incidentes en llamadas telefónicas, reportes escritos de patrulleros, informes de denuncias, entre otros. Tradicionalmente, este cúmulo de información textual era revisado manualmente por analistas o quedaba infrautilizado debido a su volumen y complejidad. En los últimos años, las técnicas de **Procesamiento de Lenguaje Natural (NLP)** – un campo de la inteligencia artificial – se han aplicado crecientemente para **analizar textos de emergencias y seguridad** con el fin de extraer información valiosa, identificar patrones y apoyar la toma de decisiones policiales.

En el ámbito de las **llamadas de emergencia**, el NLP permite procesar automáticamente las transcripciones de las llamadas o los resúmenes escritos que los operadores registran en el sistema CAD. Por ejemplo, Dixon y Birks (2021) exploran el potencial del NLP para analizar los datos textuales que la policía recopila durante sus operaciones (incluyendo notas de incidentes y reportes narrativos), con miras a habilitar un modelo de policía más proactivo y preventivo. Estos autores argumentan que técnicas de **minería de texto** y modelos de lenguaje pueden “*desbloquear*” ese conocimiento tácito contenido en los textos policiales, permitiendo **identificar las condiciones subyacentes de los eventos delictivos** – algo esencial para la *Policía Orientada a Problemas (Problem-Oriented Policing, POP)*.

En concreto, mediante NLP se podría procesar miles de reportes de incidentes para encontrar factores comunes (horarios, motivaciones, modos de operación) que ayuden a **prevenir** futuros delitos. Por ejemplo, si muchos informes de robos por arrebato mencionan la frase “motocicleta con dos hombres”, un algoritmo NLP podría detectar esa co-ocurrencia frecuente y sugerir a la policía enfocarse en patrullar contra *motochorros*. Dixon y Birks destacan que esto antes sería muy “*consumidor de recursos*” hacerlo manualmente, pero con NLP a escala es factible. No obstante, advierten que el uso de modelos de lenguaje sin las debidas precauciones puede **perpetuar sesgos existentes o introducir nuevos**, reflejando prejuicios en los datos originales (por ejemplo, sobre-perfilar ciertos grupos poblacionales). Por ello, insisten en la necesidad de acompañar las soluciones NLP con controles éticos y supervisión humana, para asegurar que los resultados produzcan **impactos positivos** en la sociedad y no generen discriminación.

Entre las **aplicaciones específicas de NLP en textos de emergencia** se encuentran: la **clasificación automática de incidentes**, la **priorización o predicción de severidad**, la **extracción de entidades** (personas, lugares, placas vehiculares) y el **resumen** de textos largos. Varios trabajos han demostrado avances en estos frentes. Por ejemplo, (Chin et al., 2022) desarrollaron un modelo de **análisis textual con machine learning para predecir la severidad de pacientes heridos** en despachos médicos de emergencias. En dicho estudio, entrenaron algoritmos sobre los registros textuales de llamadas médicas (por ejemplo, las notas que describen el mecanismo del accidente, síntomas de la víctima, etc.) con el objetivo de anticipar si el caso involucra **heridos graves**. Si bien el modelo de Chin y colegas no superó en exactitud

a los paramédicos despachadores humanos, sí mostró potencial como una herramienta de apoyo cuando la información provista por el llamante es limitada o incierta. Este resultado es ilustrativo: la IA puede *asistir* a los operadores de emergencias, sugiriendo un nivel de gravedad probable basado en texto, pero no necesariamente reemplaza la experiencia humana, sobre todo en situaciones críticas donde las vidas están en juego. No obstante, en contextos de alto volumen de llamadas, un sistema NLP podría **filtrar o destacar** automáticamente aquellas descripciones que contienen indicios de mayor riesgo (palabras como “inconsciente”, “sangrando abundante”, “arma de fuego”, etc.), ayudando a priorizar la respuesta.

Otro ejemplo lo aporta (Abi Kanaan et al., 2024), quienes combinaron redes neuronales de **multi-características con aprendizaje multi-tarea** para la clasificación de la severidad en llamadas de emergencia. Su mejor modelo logró alrededor de un **71,3% de precisión** al predecir el nivel de severidad de 833 llamadas, superando en ~5% el rendimiento de un modelo base tradicional. Esta investigación integró múltiples fuentes de características: no solo el texto de la llamada, sino también metadatos de la llamada (hora del día, duración, tipo preliminar) e incluso información de contexto geográfico. Además, adoptaron un enfoque de *aprendizaje multi-tarea*, entrenando la red para que simultáneamente clasificara la severidad y el tipo de incidente, aprovechando que ambas salidas comparten información. Los resultados sugieren que **combinar varias entradas (texto + datos estructurados)** mejora la capacidad predictiva en comparación a usar solo el texto. En la práctica, un sistema así podría, por ejemplo, **alertar automáticamente** de que una llamada entrante tiene alta probabilidad de corresponder a un incidente crítico (severidad alta) antes de siquiera terminar la conversación, con base en las primeras palabras del ciudadano y otros indicadores. Esto daría unos segundos valiosos de ventaja para movilizar recursos de alto nivel (p.ej., equipo SWAT o ambulancia UCI) si luego se confirma la gravedad.

De igual modo, **herramientas NLP para análisis pos-hoc** están siendo exploradas en seguridad. (Patil et al., 2024) presentaron un prototipo llamado “*911 Call Analyzer*”, el cual procesa un gran histórico de datos de llamadas al 911 en una ciudad para **detectar patrones de emergencias críticas** y posibles mejoras en la gestión. Este tipo de sistemas aplica técnicas de **topic modeling** (descubrir temas frecuentes en los textos de llamadas), detección de anomalías (identificar llamadas inusuales que pudieron ser mal categorizadas) y análisis de sentimiento (determinar el nivel de pánico o estrés en la voz del interlocutor a partir de la transcripción). Según reportan, el *911 Call Analyzer* logró identificar casos que inicialmente fueron clasificados como de baja prioridad pero que contenían indicadores textuales de severidad, proponiendo que se reetiquetaran para análisis interno. Si bien este es un trabajo en desarrollo, ilustra la tendencia hacia sistemas inteligentes que auditen y aprendan de la información histórica.

A nivel más amplio, (Roldan-Baluis et al., 2022) llevaron a cabo una revisión sistemática sobre el efecto del NLP en el análisis de texto no estructurado (incluyendo dominios como el policial). Sus conclusiones indican que el NLP ha mejorado significativamente la **eficiencia en el análisis de grandes volúmenes de datos textuales**, permitiendo descubrir insights antes impracticables manualmente. No obstante, también subrayan retos como la calidad variable de los textos (errores, abreviaturas en jerga policial), la necesidad de entrenar modelos en español local (por las variaciones lingüísticas) y nuevamente el tema de los **sesgos**

algorítmicos. Recomiendan el desarrollo de **ontologías o glosarios especializados** para el dominio de seguridad ciudadana, de modo que los algoritmos NLP comprendan mejor los términos usados en las llamadas (por ejemplo, “*marcar*” en jerga peruana policial significa “*vigilar*”, o “*peinar la zona*” = “*buscar exhaustivamente*”). Integrar este conocimiento experto en los modelos puede aumentar su precisión y reducir ambigüedades.

En síntesis, el **Procesamiento de Lenguaje Natural se ha convertido en una herramienta poderosa** para potenciar el análisis y la gestión de emergencias a partir de textos. Desde clasificar automáticamente llamadas y priorizarlas, hasta extraer tendencias de crimen de miles de reportes, el NLP ofrece velocidad y escala que complementan la labor humana. Es importante, eso sí, garantizar la **calidad de los datos de entrenamiento** (por ejemplo, transcripciones correctas de las llamadas) y mantener siempre al humano en el circuito para supervisar y validar las salidas de los modelos, especialmente en aplicaciones sensibles como la seguridad pública. Con estos cuidados, el NLP puede contribuir a **mejorar la eficiencia policial**, optimizar la asignación de recursos y quizás, en un futuro cercano, hasta predecir *dónde* y *cuándo* ocurrirá el siguiente incidente a partir de señales lingüísticas tempranas.

2.2.3 Desafíos específicos del NLP en contextos de emergencia

a) Variabilidad lingüística extrema

Los textos de emergencia se caracterizan por:

- Lenguaje coloquial e informal
- Abreviaciones no estandarizadas
- Errores gramaticales frecuentes
- Jerga local y expresiones regionales
- Inconsistencia en la sintaxis

b) Contexto urbano de alta variabilidad

En municipios como el Callao, los reportes provienen de poblaciones heterogéneas, con distintos niveles educativos, trasfondos culturales y capacidad de expresión. Esto incrementa la complejidad del procesamiento de texto.

c) Presencia de datos incompletos o contradictorios

Algunos reportes carecen de información geográfica precisa, tiempos exactos o descripciones coherentes, lo que requiere técnicas robustas de imputación y validación.

d) Desbalance de clases

En bases de datos reales de emergencias, algunas categorías de incidentes (p. ej., robos a mano armada) son mucho más frecuentes que otras (p. ej., desastres naturales), generando desafío en la modelación supervisada.

2.3 Representación semántica del texto

Una vez que el texto ha sido preprocesado y normalizado, es necesario convertirlo en una representación numérica que permita a los modelos de machine learning procesarlo. Existen múltiples enfoques para esta transformación, cada uno con fortalezas y debilidades.

2.3.1 TF-IDF y modelos basados en conteo

Concepto fundamental

TF-IDF (*Term Frequency-Inverse Document Frequency*) es una técnica estadística que asigna a cada término (palabra) en un documento un peso numérico basado en:

- **TF (Term Frequency):** la frecuencia relativa del término en el documento
- **IDF (Inverse Document Frequency):** el inverso del número de documentos en los cuales aparece el término

La fórmula base es:

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \log \left(\frac{N}{\text{DF}(t)} \right)$$

donde:

- N = número total de documentos
- $\text{DF}(t)$ = número de documentos que contienen el término t

Aplicación en reportes de emergencia: En el contexto de llamadas de emergencia, TF-IDF permite identificar los términos más discriminativos para cada categoría de incidente. Por ejemplo, palabras como "arma", "disparo", "bala" tendrían pesos elevados para la clase "Robo agravado", mientras que términos como "ruido", "música" serían más característicos de reportes de "Perturbación del orden público".

Ventajas:

- Computacionalmente eficiente
- Interpretable: los términos con mayor peso son fácilmente identificables
- Útil como línea base o referencia
- Bajo requerimiento de datos de entrenamiento

Desventajas:

- Ignora el orden y contexto de las palabras (modelo de bolsa de palabras)
- No captura relaciones semánticas (sinónimos, palabras relacionadas)
- Sensible a variaciones lingüísticas (robos, robar, asalto, atraco = términos similares pero distintos)
- En textos cortos (como muchos reportes de emergencia), tiende a tener desempeño limitado

Para la presente investigación, TF-IDF sirve como técnica de línea base (Y2) para evaluar qué técnicas de representación semántica más avanzadas ofrecen mejoras reales.

2.3.2 Word embeddings

Los *word embeddings* son representaciones densas y de baja dimensión de palabras, donde cada palabra se codifica como un vector de números reales. A diferencia de TF-IDF (que es disperso y de alta dimensión), los embeddings capturan relaciones semánticas y sintácticas entre palabras.

Modelos clásicos:

a) Word2Vec (Mikolov et al., 2013)

- Entrena vectores de palabras mediante arquitecturas CBOW (*Continuous Bag of Words*) o Skip-gram
- Relaciones: "rey" - "hombre" + "mujer" $\approx$ "reina"
- Dimensión típica: 100-300

b) GloVe (Pennington et al., 2014)

- Combina descomposición matricial con optimización local
- Mejor captura de relaciones globales

c) FastText (Bojanowski et al., 2017)

- Extiende Word2Vec con información subpalabra (n-gramas)
- Mejor desempeño en idiomas con morfología compleja (español incluido)
- Capaz de generar embeddings incluso para palabras no vistas en entrenamiento

Aplicación en reportes de emergencia: Los embeddings permiten capturar que términos como "asalto", "robo", "atracó" están semánticamente cercanos, lo que mejora la generalización del modelo ante variaciones lingüísticas frecuentes en reportes informales.

Ventajas:

- Capturan relaciones semánticas y sintácticas
- Densos y eficientes computacionalmente
- Permiten operaciones matemáticas significativas
- Mejor desempeño que TF-IDF en textos cortos

Desventajas:

- Requieren conjuntos de datos grandes para entrenamiento
- Una palabra tiene un único vector (no distingue contexto múltiple)
- Menos interpretables que TF-IDF

2.3.3 Modelos contextualizados: BERT, BETO y SBERT

Evolución hacia representaciones contextuales

Los modelos modernos de lenguaje preentrenados (LLM) como BERT generan representaciones que **dependen del contexto** en el que aparece cada palabra. Esto supera la limitación anterior de un único vector por palabra.

BERT (*Bidirectional Encoder Representations from Transformers*)

Características principales:

- Preentrenado sobre 3.3 mil millones de palabras en inglés (Wikipedia, BookCorpus)
- Arquitectura Transformer bidireccional: procesa el texto en ambas direcciones simultáneamente
- Objetivo de preentrenamiento: enmascaramiento de palabras (MLM, *Masked Language Modeling*) y predicción de oración siguiente (NSP)
- Dimensión de embeddings: 768 (BERT-base) o 1024 (BERT-large)

Aplicación general:

BERT se ha convertido en la base para numerosas tareas NLP: clasificación de texto, extracción de entidades, análisis de similitud, etc.

Limitación principal para contextos hispanohablantes:

Aunque BERT fue entrenado en múltiples idiomas (incluyendo español), su capacidad en español es inferior a la del inglés debido al desequilibrio en la proporción de datos de entrenamiento (la mayoría es en inglés).

BETO (*Spanish BERT*)

Características:

- BERT entrenado exclusivamente sobre corpus en español
- Volumen: ~570 GB de texto de Wikipedia español y otras fuentes
- Comparable en arquitectura a BERT-base
- Significativamente superior a BERT multilingüe en tareas de clasificación de texto en español

(Cañete et al., 2023) demuestran que BETO alcanza F1-scores superiores en tareas como:

- Análisis de sentimiento en español (92.1% vs 89.3% para mBERT)
- Extracción de entidades nombradas (89.8% vs 87.2%)
- Clasificación de textos en español (94.2% vs 91.5%)

Por qué BETO es relevante para este estudio:

El Callao es un contexto hispanohablante con lenguaje coloquial y regional. BETO está mejor adaptado a esta realidad lingüística que alternativas multilingües o anglófonas.

SBERT (*Sentence BERT*)

Características:

- Extensión de BERT que genera embeddings de oración (no solo palabras)
- Optimizado para calcular similitud semántica entre textos
- Permite comparación directa entre descripciones de incidentes: si dos reportes tienen descripción "asalto en la esquina de Gamarra" y "robo a mano armada en av. Gamarra", SBERT puede detectar que hablan del mismo evento

Aplicaciones en emergencias:

- Deduplicación automática de reportes

- Agrupamiento de incidentes relacionados
- Búsqueda semántica de casos similares

2.4 Clasificación supervisada multiclase

2.4.1 Formulación del problema

En esta investigación, la tarea de clasificación es **multiclase no exclusivo**, donde cada reporte de emergencia debe asignarse a una de las **8 clases principales (Tipologías)** del sistema municipal del Callao:

1. Seguridad ciudadana (robos, asaltos, etc.)
2. Violencia familiar / interpersonal
3. Emergencias médicas
4. Infracciones / faltas administrativas
5. Emergencias estructurales (incendios, derrumbes)
6. Conflictos vecinales
7. Ambientales / públicas molestias
8. Otros / no especificados

Cada clase puede subdividirse en las **67 categorías** y **236 subcategorías** definidas por la municipalidad.

2.4.2 Algoritmos de clasificación evaluados

a) Regresión logística multinomial

Modelo lineal fundamental, útil como línea base:

- Ventaja: Interpretable, rápido, bajo overhead computacional
- Desventaja: Asume separabilidad lineal (limitado en espacios de alta dimensión)

b) Máquinas de Soporte Vectorial (SVM) multiclase

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

Donde ξ_i mide la violación del margen para cada muestra multiclase.

- Ventaja: Efectivo en espacios de alta dimensión, kernel implícito
- Desventaja: Requiere tuning de parámetros, escalabilidad en datasets grandes

c) Árboles de Decisión y Bosques Aleatorios (Random Forest)

Ensembles que particionar el espacio de características recursivamente.

- Ventaja: No requiere normalización, captura interacciones no lineales, feature importance interpretable
- Desventaja: Tendencia al overfitting, requiere poda cuidadosa


d) Gradient Boosting (XGBoost, LightGBM)

Construcción iterativa de árboles, minimizando residuos en cada paso.

- Ventaja: Desempeño competitivo, manejo robusto del desbalance
- Desventaja: Requiere tuning extenso, caja negra

e) Redes neuronales densas (DNN)

Cuando se utilizan embeddings contextualizados (BETO), se emplean arquitecturas de capas densas con dropout y softmax al final, como:



- Ventaja: Captura relaciones no lineales complejas, aprovecha embeddings contextualizados
- Desventaja: Requiere más datos, propenso a overfitting si no hay regularización

f) Fine-tuning de BETO

Estrategia donde la red neuronal anterior se conecta directamente a BETO, y se entrenan todos los pesos (incluyendo los del transformer) en el dataset específico de emergencias.

$$\text{Loss} = - \sum_{i=1}^n \sum_{j=1}^8 y_{ij} \log(\hat{y}_{ij})$$

donde y_{ij} es la etiqueta verdadera $\hat{y}_{ij}$ es la predicción de la red para la clase j del reporte i .

- Ventaja: Máximo desempeño, BETO se adapta al dominio específico
- Desventaja: Requiere GPU/TPU, riesgo de overfitting si dataset es muy pequeño

2.4.3 Selección de algoritmo para esta investigación

Basándose en la matriz de consistencia y objetivos operativos, se prioriza:

1. **Interpretabilidad operativa:** Los operadores municipales necesitan entender por qué el sistema clasifica un incidente de una forma
2. **Robustez:** El sistema debe funcionar ante texto noisy y variabilidad lingüística
3. **Desempeño:** F1-macro = 0.80 en validación cruzada

Por esto, la investigación evalúa un **abanico de algoritmos** (Y3), pero enfatiza **Fine-tuning de BETO + Dense network** como técnica más prometedora, complementado con **Regresión logística** y **Random Forest** para interpretabilidad y comparación en futuras experimentos.

2.5 Técnicas de balanceo de datos

2.5.1 El problema del desbalance de clases

En bases de datos reales de emergencias municipales, la distribución de clases esta desbalanceada. Por ejemplo, en el Callao:

- Robo/asalto: 45% de reportes
- Perturbación orden público: 25%
- Violencia familiar: 18%
- Emergencias médicas: 7%
- Otros: 5%

Este desbalance causa que modelos no balanceados:

1. **Aprenden a predecir la clase mayoritaria** (robo) con alta precisión pero fallan en minoridades
2. **Generan métricas engañosas**: Si el modelo siempre predice "Robo", logra 45% accuracy
3. **Degradación operativa**: Incidentes de violencia familiar o médicos son subestimados

2.5.2 Técnicas de balanceo

a) Undersampling aleatorio

Reducción del conjunto mayoritario a tamaño comparable con minoridades:

- Ventaja: Simple, reduce volumen de datos
- Desventaja: Pierde información, puede descartar muestras informativas

b) Oversampling aleatorio (replicación)

Replicación de muestras minoridad:

- Ventaja: Mantiene toda la información
- Desventaja: Riesgo de overfitting, aumenta volumen

c) SMOTE (*Synthetic Minority Oversampling Technique*)

(Chawla et al., 2002) proponen generar muestras sintéticas interpolando en el espacio de características:

Para cada muestra minoritaria x_i , se selecciona un vecino cercano x_k (k-NN) y se genera:

$$x_{\text{new}} = x_i + \lambda(x_k - x_i), \lambda \in [0,1]$$

- Ventaja: Genera diversidad sintética, evita replicación exacta
- Desventaja: Computacionalmente más costoso, puede crear outliers

d) Weighted classification

Asignar pesos inversamente proporcionales a la frecuencia de clase durante el entrenamiento:

$$\text{weight}_j = \frac{\text{total samples}}{n_classes \times \text{samples in class } j}$$

- Ventaja: Simple de implementar, no altera datos, eficiente
- Desventaja: Menos controlable que SMOTE

e) Focal Loss

(Lin et al., 2017) proponen una función de pérdida que penaliza más fuertemente el error en clases difíciles:

$$FL(p_t) = -(1 - p_t)^\gamma \log(p_t)$$

donde p_t es la probabilidad predicha y γ , es un parámetro de enfoque.

- Ventaja: Penaliza directamente los errores en minoritarios
- Desventaja: Requiere ajuste cuidadoso de hiperparámetro gamma

Selección para esta investigación:

Se evalúan múltiples técnicas (Y3) en el diseño experimental. La recomendación basada en literatura es **SMOTE + Weighted Classification** combinados, que ofrecen balance entre diversidad sintética y estabilidad.

2.6 Evaluación de modelos de clasificación

2.6.1 Métricas de clasificación multiclase

Dado que el problema es **multiclase desbalanceado**, es crítico seleccionar métricas que no sean engañosas.

a) Accuracy global

$$\text{Accuracy} = \frac{\# \text{ predicciones correctas}}{\text{total predicciones}}$$

Limitación: Puede ser engañosa si una clase domina (p. ej., si siempre predicen "Robo", accuracy sería 45%).

b) Precision, Recall y F1-score por clase

Para cada clase j :

$$\text{Precision}_j = \frac{TP_j}{TP_j + FP_j}$$

$$\text{Recall}_j = \frac{TP_j}{TP_j + FN_j}$$

$$F1_j = 2 \times \frac{\text{Precision}_j \times \text{Recall}_j}{\text{Precision}_j + \text{Recall}_j}$$

Donde:

- TP_j = verdaderos positivos de clase j

- FP_j = falsos positivos de clase j
- FN_j = falsos negativos de clase j

c) Promedios multiclase

$$F1-macro = \frac{1}{C} \sum_{j=1}^C F1_j$$

$$F1-weighted = \sum_{j=1}^C \frac{n_j}{n} \times F1_j$$

Donde C es número de clases, n_j es número de muestras de clase j , n es total.

Recomendación operativa:

- **F1-macro** para evaluar desempeño equilibrado (penaliza si alguna clase sale mal)
- **F1-weighted** para evaluación realista (refleja proporción de datos real)

d) Matriz de confusión

Tabla $C \times C$ que muestra predicción vs verdad para cada clase, permitiendo identificar confusiones recurrentes (p. ej., si "Violencia familiar" se confunde frecuentemente con "Emergencia médica").

2.6.2 Validación cruzada estratificada

Para garantizar evaluación robusta:

$$CV_k = \text{promedio de scores en } k \text{ folds estratificados}$$

Stratified k-fold: Cada fold mantiene la proporción original de clases, evitando sesgos de muestreo.

Típicamente $k=5$ (80% train, 20% test) o $k=10$ (90% train, 10% test).

2.6.3 Métricas operativas

Más allá de métricas de clasificación, se definen **métricas operativas** contextualizadas al problema municipal:

a) Velocidad de clasificación (latencia)

Tiempo promedio de clasificación por incidente:

$$\text{Latencia} = \frac{\text{Tiempo total de clasificación}}{\# \text{ incidentes}}$$

Objetivo operativo: < 100 ms por incidente (suficientemente rápido para asistir en tiempo real).

b) Trazabilidad de incidente

Porcentaje de incidentes que tienen registro completo del ciclo de vida (ocurrencia → llamada → despacho → cierre):

$$\text{Trazabilidad} = \frac{\# \text{ incidentes con ciclo completo}}{\# \text{ total incidentes}}$$

Objetivo operativo: > 95%

c) Reducción de tiempo de derivación inicial

Comparación Y0 (manual) vs Y4 (automatizado):

$$\Delta t = t_{Y0} - t_{Y4}$$

Objetivo operativo: Reducción > 30%

2.7 Trazabilidad operativa y automatización de procesos

2.7.1 Concepto de trazabilidad en contexto operativo municipal

La **trazabilidad** es la capacidad de seguir el "camino" de un incidente desde su reporte inicial hasta su resolución, registrando todos los eventos y transiciones de estado intermedios.

Componentes esenciales:

1. **Timestamp de ocurrencia:** Cuándo sucedió el incidente
2. **Timestamp de reporte:** Cuándo se recibió la llamada
3. **Timestamp de despacho:** Cuándo se envió la patrulla
4. **Timestamp de arribo:** Cuándo la patrulla llegó
5. **Timestamp de cierre:** Cuándo se resolvió o cerró el incidente
6. **Estados intermedios:** Cambios en el estado operativo (p. ej., "en tránsito", "atendiendo", "esperando información")
7. **Responsables:** Qué operador, qué patrulla, qué área derivada

2.7.2 Ventajas operativas de la trazabilidad estructurada

a) Responsabilidad y auditoría

Con trazabilidad clara, cada acción es atribuible, facilitando auditorías internas y externas.

b) Identificación de cuellos de botella

Si se observa que muchos incidentes demoran más en "estado de despacho" que en "estado de arribo", se pueden optimizar procesos de coordinación con patrullas.

c) Análisis de desempeño operativo


Comparación de tiempos promedio por área, por tipo de incidente, por turno, etc.

d) Mejora continua basada en datos

Datos de trazabilidad permiten implementar ciclos PDCA (Plan-Do-Check-Act) con evidencia cuantitativa.

2.7.3 Automatización del flujo operativo mediante orquestación

La **orquestración** es la automatización coordinada de múltiples pasos en un proceso. En el contexto de emergencias:



Tecnologías habilitantes:

- **Workflow engines:** Ejecutan el flujo (p. ej., LangGraph, Airflow, Temporal)
- **APIs de terceros:** Geolocalización, búsqueda de patrullas, notificaciones
- **Sistemas de colas:** Manejan el volumen de incidentes (p. ej., Celery, RabbitMQ)
- **Bases de datos transaccionales:** Registran estado de cada incidente (p. ej., PostgreSQL)

Métricas de orquestación:

- **Throughput:** Incidentes procesados por hora
- **Error rate:** % de incidentes que fallan en algún paso
- **Turnaround time:** Tiempo total de ciclo

2.8 Sistemas de apoyo a la decisión en seguridad ciudadana

2.8.1 Definición y enfoques


Un **Sistema de Apoyo a la Decisión (DSS, por *Decision Support System*)** es un sistema informático que ayuda a tomadores de decisiones a analizar situaciones complejas y evaluar alternativas.

En seguridad ciudadana, un DSS puede:

1. **Consolidar información heterogénea:** Integrar datos de múltiples fuentes (llamadas, patrullaje, cámaras, reportes comunitarios)

2. **Generar insights analíticos:** Identificar patrones espacio-temporales, correlaciones
3. **Apoyar priorización:** Ayudar a definir qué incidentes requieren respuesta inmediata
4. **Evaluar alternativas operativas:** "Si despacho aquí, ¿cuál es el tiempo estimado de arribo?"
5. **Facilitar coordinación inter-agencial:** Integrar datos de municipio, PNP, bomberos, ambulancias

2.8.2 Arquitectura de un DSS para emergencias



2.8.3 Funcionalidades clave según literatura

(Langton et al., 2024) realizan una revisión de sistemas DSS en seguridad pública y destaca:

a) Predicción espacio-temporal

Identificar zonas y horarios de mayor riesgo delictivo. (Wang et al., 2024) demuestran que modelos CCC logran predicciones 5-7 días adelante con error medio 15-20%.

b) Optimización de despacho

Algoritmos como Vehicle Routing Problem (VRP) pueden optimizar asignación de patrullas:

$$\min \sum_{i,j} c_{ij} x_{ij}$$

Sujeto a restricciones de capacidad, tiempo de tránsito, disponibilidad de vehículos.

c) Análisis de inteligencia criminal

Identificar patrones de delincuencia organizada, redes de sospechosos, modus operandi recurrentes.

d) Monitoreo de indicadores clave (KPI)

- Tiempos de respuesta por zona
- Tasa de esclarecimiento por tipo de delito
- Carga operativa por turno
- Efectividad por patrulla/operador

2.8.4 Adopción de DSS en contexto municipal peruano

(Castro-Chucan et al., 2024) reportan que iniciativas como "Smart Muni" en municipios latinoamericanos han encontrado barreras:

1. **Capacidad técnica limitada** en operadores municipales para usar herramientas avanzadas
2. **Fragmentación institucional:** Distintos sistemas (PNP, municipio, bomberos) que no se integran
3. **Resistencia al cambio:** Operadores prefieren procesos conocidos
4. **Presupuesto limitado:** Municipios pequeños carecen de inversión

Estrategia de mitigación propuesta en esta investigación:

- Diseño de interfaz simple e intuitiva
- Capacitación y change management incluidos
- Implementación incremental (piloto en una zona primero)
- Documentación clara de ROI (retorno en inversión)

2.9 Síntesis del marco teórico

La presente investigación se fundamenta en cuatro pilares teóricos integrados:

1. **NLP avanzado** (BETO, embeddings contextualizados) para transformar texto no estructurado en información procesable
2. **Machine learning supervisado** (Fine-tuning BETO, SVM, Random Forest) para clasificación automática de incidentes
3. **Trazabilidad operativa** (registros de estado, timestamps, eventos) para medir desempeño real
4. **Sistemas de apoyo a la decisión** (orquestración de flujo, dashboards, alertas) para operacionalizar el análisis

Estos cuatro componentes se articulan en un único sistema integrado que busca mejorar tanto los tiempos de atención como la calidad de la información disponible para la toma de decisiones municipales en seguridad ciudadana.

CAPÍTULO III: HIPÓTESIS, VARIABLES Y DISEÑO METODOLÓGICO

3.1 Hipótesis de investigación

3.1.1 Hipótesis General

HG: La implementación de un módulo inteligente basado en Procesamiento de Lenguaje Natural reduce de forma significativa los tiempos de atención y derivación inicial, mejora la trazabilidad operativa mediante el registro estructurado de estados y eventos, y disminuye la variabilidad en la clasificación al mejorar la estructuración y trazabilidad del registro operativo, en comparación con el proceso manual no estandarizado.

3.1.2 Hipótesis específicas (H)

H0: La aplicación de un protocolo estandarizado de depuración y cálculo de tiempos sobre los registros del proceso manual (v1.1) permite obtener una línea base estable, reproducible y auditables de métricas (media, mediana, p90, p95, máximos) y verificar trazabilidad mínima, representando de forma consistente el desempeño temporal del proceso manual.

H1: La aplicación de un proceso sistemático de depuración estructural, basado en reglas explícitas de eliminación de variables irrelevantes y normalización de tipos de datos, reduce de forma significativa la redundancia informativa y la incompletitud del dataset, mejorando su consistencia, interpretabilidad y adecuación como entrada para un pipeline de NLP y aprendizaje automático.

H2: Las representaciones basadas en embeddings contextuales (BETO y sus variantes) proporcionan una representación semántica más rica que los modelos tradicionales basados en bolsa de palabras y modelos de tópicos, lo que se traduce en mejoras significativas en F1-macro, mejor desempeño en clases minoritarias y mejores indicadores de calidad de agrupamiento semántico, en comparación con TF-IDF y LDA.

H3: Los modelos de clasificación supervisada basados en BETO fine-tuning con estrategias explícitas de manejo del desbalance como cost-sensitive u oversampling mejora de forma significativa el desempeño de clasificación de tipologías, incrementando el F1-macro y el desempeño en clases minoritarias frente al esquema sin balanceo (baseline) y frente a la clasificación manual.

H4: La implementación del módulo inteligente de atención de incidentes basado en Twilio + Webhook + FastAPI + LangGraph + modelo de clasificación entrenado + LLM reduce de forma significativa el tiempo de clasificación/derivación y cierre ($\geq 30\%$) y mejora la

trazabilidad operativa (registro completo de estados y eventos) en comparación con el proceso manual y no orquestado.

3.2 Variables de estudio

A continuación, se realiza una descripción de las variables por objetivo

3.2.4 Variables independientes

3.2.4.1 Variables Independientes - Objetivo 0

- **VI0: Protocolo de medición del proceso manual (Y0):** Define reglas objetivas para limpiar registros y calcular tiempos del proceso manual. Es la base para comparar “antes vs después” sin sesgos por datos mal registrados.
 - **VI0.1 Criterios de depuración de registros:** Depura registros inválidos (duración negativa/nula, timestamps incoherentes). Evita que errores de captura inflen o distorsionen la línea base.
 - **VI0.2 Reglas de cálculo de duración:** Estandariza cómo se mide el tiempo (inicio–fin, segundos, formato de reporte). Permite comparabilidad entre periodos y módulos.
 - **VI0.3 Criterios de trazabilidad mínima:** Define qué significa “registro usable” (timestamps mínimos consistentes). Garantiza auditoría y evita conclusiones con datos incompletos.
 - **VI0.4 Segmentación analítica (estado_llamada, consulta_realizada, area_derivada):** Permite analizar tiempos por estado/consulta/área. Justifica dónde ocurre la demora y dónde impacta el módulo.
 - **VI0.5 Protocolo de agregación estadística (media, mediana, p90, p95, max):** Resume desempeño con métricas robustas (colas largas). Es clave para evidenciar variabilidad y demoras extremas.

3.2.4.2 Variables Independientes – Objetivo 1

- **VII: Curación y normalización de datos (Y1):** Limpia y estructura el dataset para que sea apto para NLP/ML. Reduce ruido, redundancia y errores de tipo que degradan modelos.
 - **VII.1 Eliminación de columnas > 50% de valores nulos:** Retira variables con información insuficiente. Mejora estabilidad y evita imputaciones arbitrarias.
 - **VII.2 Eliminación de variables duplicadas > 80% de coincidencia:** Elimina redundancia informativa. Evita que el modelo “cuenta doble” la misma señal.
 - **VII.3 Eliminación de variables constantes (cardinalidad única):** Quita variables sin poder discriminante. Reduce dimensionalidad y simplifica el pipeline.
 - **VII.4 Eliminación de variables administrativas e identificadoras (excepto ZONA):** Evita fuga de información y ruido administrativo. Mantiene solo lo útil analíticamente y preserva valor geoespacial agregado.

- **VI1.5 Normalización de tipos de datos (datetime/time, numéricas):** Convierte a tipos correctos para cómputo y análisis. Previene errores en ingeniería de variables y entrenamiento.
- **VI1.6 Transformación y enriquecimiento temporal (día, hora, turno):** Crea variables derivadas interpretables. Justifica análisis de patrones por horarios y turnos operativos.
- **VI1.7 Depuración ética de datos sensibles o identificables:** Reduce riesgo de identificación personal. Mejora cumplimiento y permite uso académico/analítico responsable.

3.2.4.3 Variables Independientes – Objetivo 2

- **VI2: Representación semántica del texto (TF-IDF / BETO / SBERT / LDA) (Y2):** Define cómo el texto se convierte en vectores. La calidad de la representación determina el desempeño de clasificación y agrupamiento.
 - **VI2.1 TF-IDF (unigramas/bigramas, con/sin stopwords):** Representa frecuencia ponderada de términos. Es un baseline simple y explicable para comparar contra embeddings.
 - **VI2.2 BETO (última capa; últimas 4 capas; pooling mean/CLS):** Embeddings contextuales para español. Capturan significado según contexto, mejorando clasificación frente a bolsa de palabras.
 - **VI2.3 DistilBETO (variantes; pooling mean):** Versión más ligera de BETO con menor costo. Justifica trade-off desempeño vs tiempo/memoria en implementación.
 - **VI2.4 SBERT (mean pooling y CLS):** Optimizado para similitud semántica. Útil para clustering/recuperación semántica y comparaciones con clasificación.
 - **VI2.5 BETO con fine-tuning supervisado:** Ajusta representaciones al dominio de emergencias. Justifica maximizar F1 en labels específicos (categoría/tipología).
 - **VI2.6 LDA – modelado de tópicos no supervisado (T16):** Descubre temas latentes sin etiquetas. Sirve como contraste no supervisado y para interpretabilidad de tópicos.

3.2.4.4 Variables Independientes – Objetivo 3

- **VI3: Clasificación automática supervisada (manejo del desbalance) (Y3):** Entrena el modelo para predecir clases (tipología/categoría) controlando desbalance. Es crucial porque clases minoritarias suelen ser relevantes operativamente.
 - **VI3.1 Baseline sin balanceo:** Entrena con distribución original. Da la referencia mínima para medir cuánto aporta el balanceo.
 - **VI3.2 Undersampling (solo train):** Reduce clases mayoritarias para equilibrar. Justifica rapidez, pero puede perder información útil.

- **VI3.3 Oversampling (solo train):** Aumenta ejemplos minoritarios (duplicación/síntesis). Mejora recall minoritario, con riesgo de sobreajuste si no se controla.
- **VI3.4 Cost-sensitive learning (ponderación por clase):** Penaliza más los errores en minoritarias. Suele ser robusto sin duplicar datos y funciona bien en texto multi-clase.

3.2.4.5 Variables Independientes – Objetivo 4

- **VI4: Módulo operativo de atención y derivación inicial (Y4):** Implementa el flujo real de atención asistida (entrada–procesamiento–respuesta–registro). Es el componente que permite medir impacto operativo y trazabilidad.
 - **VI4.1 Canal de entrada: WhatsApp mediante Twilio:** Habilita captura inmediata del incidente por mensajería. Reduce fricción y estandariza el ingreso.
 - **VI4.2 Capa de integración: Webhook en Express.js:** Recibe, valida y enruta mensajes. Aísla el canal de comunicación de la lógica de IA.
 - **VI4.3 Backend IA: FastAPI (endpoint execute):** Centraliza el procesamiento y expone servicio de predicción. Permite escalabilidad y separación por capas.
 - **VI4.4 Orquestación: LangGraph (gestión de estados):** Modela el flujo como estados/transiciones. Asegura trazabilidad, control de errores y reproducibilidad del proceso.
 - **VI4.5 Modelo de clasificación (mejor de Y3):** Clasifica tipología/unidad sugerida automáticamente. Justifica reducción de tiempo de decisión y consistencia.
 - **VI4.6 Respuesta asistida con LLM (OpenAI):** Genera mensajes guiados y solicita datos faltantes. Mejora calidad comunicacional y estandariza respuestas.
 - **VI4.7 Persistencia y trazabilidad (estados, eventos, timestamps):** Registra evidencia del proceso de punta a punta. Permite auditoría y medición objetiva de mejoras.
 -

3.2.5 Variables dependientes

3.2.5.1 VD1: Tiempo de atención inicial

- Descripción/justificación: Mide eficiencia en la primera atención del incidente. Es el principal indicador de impacto operativo. Indicador promedio y reducción porcentual (manual/asistido): Compara “antes vs después” en términos de tiempo real. Permite validar la meta de reducción.

3.2.5.2 VD2: Tiempo de clasificación y derivación (tiempo medio por incidente)

- Descripción/justificación: Mide cuánto tarda el sistema en asignar tipología y derivar. Es el cuello crítico que el módulo busca acelerar

3.2.5.3 VD3: Calidad de la clasificación (F1-macro global y F1 por clase)

- Descripción/justificación: Evalúa precisión/recall balanceados en múltiples clases. Justifica que la mejora no sea solo para clases frecuentes.

3.2.5.4 VD4: Trazabilidad operativa

- Descripción/justificación: Mide completitud del registro y seguimiento del caso. Es clave para auditoría y control de gestión.
 - VD4.1 % incidentes con estados completos: Valida que el flujo registre el ciclo de vida. Sustenta mejora documental y operativa.
 - VD4.2 Número de eventos registrados por incidente: Cuantifica granularidad del seguimiento. A mayor registro, mayor capacidad de análisis y auditoría.
 - VD4.3 Timestamps por estado: Permite medir tiempos por etapa. Justifica análisis de cuellos y cumplimiento de SLA internos.

3.2.6 Variables de Control

3.2.6.1 VC1: Condiciones del dataset

- Descripción/justificación: Controla consistencia de datos entre artefactos. Evita que cambios de dataset expliquen falsamente mejoras.
 - Partición estratificada (70/15/15) para Y1–Y4: Mantiene proporciones de clases en train/val/test. Asegura comparaciones justas entre tratamientos.
 - Mismo dataset por etapa (v1.1 para Y0, v2.0 para Y1–Y4): Evita mezclar fuentes con distinta calidad/estructura. Aísla el efecto del método, no del dato.

3.2.6.2 VC2: Reproducibilidad (random_state=42): similla fija

- Descripción/justificación: Fija aleatoriedad en splits/entrenos. Permite replicar resultados y comparar sin variación azarosa.

3.2.6.3 VC3: Protocolo de preprocesamiento (limpieza y tokenización) (Y1–Y4)

- Descripción/justificación: Asegura que todos los modelos vean el texto de forma equivalente. Controla una fuente común de variación en NLP.

3.2.6.4 VC4: Condiciones operativas (reglas estandarizadas de tiempos Y0 vs Y4)

- Descripción/justificación: Define el mismo criterio de inicio/fin y estados. Evita que el módulo “parezca mejor” por definiciones distintas.

3.2.7 Operacionalización de variables (ver ANEXO B)

3.3 Tipo y nivel de investigación

3.3.2 Tipo de Investigación

La investigación es de carácter Aplicada (tecnológica) la cual Se orienta a diseñar, implementar y evaluar un sistema inteligente (módulo PLN) para mejorar un proceso real de atención de emergencias municipales, lo que evidencia un propósito de solución práctica.

3.3.3 Enfoque: Cuantitativo

La evaluación se realiza con métricas cuantificables (tiempos y métricas de clasificación), incluyendo F1-macro/F1-menor y restricciones temporales de entrenamiento.

3.3.4 Nivel: Explicativo–comparativo.

Se plantea comparar el desempeño del proceso manual vs proceso asistido (objetivo general) para evidenciar mejoras en tiempos, trazabilidad y calidad de clasificación.

3.4 Diseño metodológico

Diseño general del estudio: Diseño cuasi-experimental / comparativo (antes–después).

Se define una línea base del proceso manual (Y0) y luego se implementa el módulo inteligente (Y4) para comparar resultados bajo métricas comunes. El objetivo general explicita esta comparación manual vs asistido.

Estructura metodológica por artefactos (pipeline):

- **Y0 – Línea base:** Depuración de timestamps + reglas + segmentación + estadísticas para obtener métricas del proceso manual.
- **Y1 – Preparación de datos:** EDA + limpieza + normalización (nulos >50%, duplicados >80%, valores únicos, variables administrativas/identificadoras).
- **Y2 – Representación semántica:** Partición estratificada 70/15/15 y evaluación de 16 modelos (TF-IDF/BETO/SBERT/LDA).
- **Y3 – Clasificación + balanceo:** Selección del mejor método de Y2 (BETO fine-tuning) y prueba de 4 estrategias (Base/Oversampling/Undersampling/Cost-sensitive).
- **Y4 – Implementación:** Arquitectura WhatsApp(Twilio)→Webhook(/data)→Backend IA(FastAPI /execute + LangGraph)→respuesta

3.5 Población y muestra

3.5.2 **Población:** registros de incidentes reportados a la central municipal (Callao), provenientes de datasets institucionales usados en el proyecto. Se trabaja con dos versiones:

- **Dataset v1.1: 65,382 registros, 16 variables** (usado para línea base Y0).
- **Dataset v2 (actualizado): 104,536 filas, 36 variables** (fuente principal para Y1–Y4).

3.5.3 **Muestra analítica (para modelado):**

- Tras limpieza/selección: dataset_analisis_limpieza_Y1.csv con 104,536 filas y 13 variables.
- Para entrenamiento/validación/prueba: generación de train/val/test (98184 filas, 13 variables) con partición estratificada.

3.6 Técnicas e instrumentos de recolección de datos

3.6.2 **Técnicas de recolección:**

- Recolección secundaria (documental / datos históricos): uso de datasets institucionales v1.1 y v2 como fuentes de análisis.

- Registro de interacción del sistema (para el módulo): captura de mensajes WhatsApp (estructura enviada por Twilio) y registros del flujo de respuesta del backend IA.

3.6.3 Instrumentos

- Instrumentos de preparación/depuración: reglas de limpieza, normalización y depuración de timestamps (Y0–Y1).
- Instrumentos de modelado: experimentos de representación semántica (T1–T16) y modelos de balanceo (4 variantes).
- Instrumentos de implementación: Webhook con endpoint /data (expuesto a Twilio) y Backend IA con endpoint /execute en FastAPI, orquestado con LangGraph.

3.7 Técnicas de análisis de datos

Por etapas:

- Análisis exploratorio (EDA univariado): identifica problemas de distribución y desbalanceo antes del modelado.
- Depuración y consistencia del dato: eliminación por nulos/duplicados/valores únicos y normalización temporal.
- Análisis comparativo de modelos (Y2): evaluación experimental de 16 representaciones semánticas, con partición estratificada para comparabilidad.
- Análisis de robustez por desbalance (Y3): comparación de 4 estrategias y selección del mejor desempeño con restricciones de eficiencia.
- Análisis del flujo operativizado (Y4): verificación del macro flujo pregunta→predicción→respuesta y articulación del workflow en LangGraph.

3.8 Diseño experimental factorial

Se estructura como un diseño factorial por etapas (modelado), donde la variable respuesta principal es el desempeño de clasificación:

- Factor A (Y2): Representación semántica del texto — 16 niveles (T1–T16). Incluye TF-IDF (variantes), DistilBETO, BETO (pooling/capas), SBERT, BETO fine-tuning (categoría/tipología) y LDA.
- Factor B (Y3): Estrategia de balanceo — 4 niveles. Base, Oversampling, Undersampling y Cost-sensitive, aplicados sobre el mejor método de Y2 (BETO fine-tuning).

Tratamiento seleccionado:

- Mejor representación: BETO fine-tuning con F1-macro y F1-minor reportados.
- Mejor balanceo: Cost-sensitive (F1-macro 0.6558) con restricción de tiempo de entrenamiento < 2000 s.

3.9 Métricas de evaluación

3.9.2 Métricas de desempeño del modelo (Y2-Y3)

- **F1-macro (tipología/categoría) y F1-minor (clases minoritarias)**, usadas para seleccionar la mejor representación (BETO fine-tuning).
- **F1-macro (tipología) > 65%** como criterio esperado en la fase de balanceo, junto con **tiempo de entrenamiento < 2000 s** para viabilidad operativa.

3.9.3 Métricas operativas del proceso (manual vs asistido)

- Reducción porcentual de tiempos de atención y derivación inicial (meta **30%**), alineada a la hipótesis general y evaluable comparando Y0 (manual) frente a Y4 (asistido).
- Trazabilidad operativa mediante registro estructurado de estados y eventos (materializado por la orquestación LangGraph y el flujo de endpoints).

CAPÍTULO IV: DESCRIPCIÓN DEL SISTEMA PROPUESTO

4.1. Arquitectura general del sistema

El sistema propuesto implementa una arquitectura orientada a servicios para la atención automatizada de incidentes desde un canal de mensajería ciudadana (WhatsApp) hasta un backend inteligente que clasifica, sugiere derivación y devuelve una respuesta al ciudadano.

Componentes principales (visión de extremo a extremo):

- Interfaz de usuario (WhatsApp): canal por el cual el ciudadano envía el incidente.
- Twilio (WhatsApp API): actúa como pasarela; envía el mensaje al webhook configurado.
- Backend Webhook (Express/servicio web): expone un endpoint (por ejemplo /data) que recibe el payload de Twilio y centraliza el envío/retorno del mensaje (método sendMessage). Para que Twilio acceda al endpoint, se expone un túnel con ngrok y se registra la URL en Twilio.
- Backend IA (FastAPI): expone el endpoint /execute, que invoca la orquestación definida en LangGraph, integra el modelo de predicción y genera la respuesta final.

La arquitectura se alinea con el objetivo de pasar de un proceso manual con baja trazabilidad y variabilidad, a un proceso asistido que estructure y registre el ciclo del incidente.

4.2. Pipeline NLP automatizado

El pipeline NLP se implementa como una cadena consecutiva de artefactos (Y1→Y4) que prepara datos, construye representación semántica, entrena el clasificador y finalmente lo opera como parte del módulo de atención.

- **Artefacto 1 (Y1) – Curación, limpieza y normalización:** Se ejecuta EDA y limpieza aplicando reglas sobre nulos/duplicados/variables no útiles, además de normalización de campos temporales (fecha/hora/agrupaciones).
- **Artefacto 2 (Y2) – Representación semántica:** Se realiza partición estratificada (70/15/15) y se experimentan 16 modelos de representación semántica: TF-IDF, BETO/DistilBETO (distintas capas y poolings), SBERT y LDA. Se reporta como mejor alternativa BETO Fine-tuning, con métricas de referencia (F1-macro y desempeño en clases minoritarias).
- **Artefacto 3 (Y3) – Clasificación supervisada + manejo del desbalance:** Se entrenan 4 estrategias de balanceo: baseline, oversampling, undersampling y cost-sensitive sobre BETO Fine-tuning. Se selecciona como mejor estrategia cost-sensitive (F1-macro reportado ~0.6558), además de consolidar métricas comparativas y exportar modelos.
- **Artefacto 4 -** Se automatiza en Y4: el modelo ganador (Y3) se integra al backend IA y pasa a ser invocado por el workflow orquestado (LangGraph) cada vez que llega un incidente (WhatsApp → Twilio → Webhook → FastAPI).

4.3. Gestión de estados del incidente

La gestión de estados se diseña para resolver la debilidad crítica del proceso manual: ausencia de trazabilidad del incidente y registro no estructurado.

En el sistema propuesto, cada incidente se gestiona como una entidad con:

- **Estados operativos secuenciales (por ejemplo: creada → clasificada → derivada → en atención → cerrada).**
- **Eventos asociados a transiciones (p. ej., “clasificación generada”, “derivación sugerida”, “respuesta enviada al ciudadano”).**
- **Timestamps por estado/evento, para medir tiempos de atención/derivación y completar trazabilidad.**

Esto se alinea con lo declarado como beneficio central: “registro estructurado de estados y eventos” para mejorar la trazabilidad operativa.

4.4. Orquestación del flujo operativo

La orquestación se implementa con *LangGraph* como máquina de estados, expuesta vía *FastAPI*.

- El backend IA define un endpoint /execute que dispara la orquestación.
- El workflow se describe con 2 nodos principales:
 - start_task: invoca el modelo de predicción para obtener la clasificación (salida del modelo) que servirá como insumo para la respuesta.
 - answer_question: genera la respuesta final al ciudadano en función de la predicción y la consulta.

La clase *ProcessModel* inicializa/carga el modelo y expone un método tipo get_prediction para obtener la predicción a partir de la solicitud del usuario.

4.5. Prototipo de atención automatizada

El prototipo implementa un flujo “consulta-respuesta” completo y medible:

- El ciudadano envía un incidente por **WhatsApp**.
- **Twilio** entrega el whatsapp msg al webhook (payload con remitente, mensaje y tipo).
- El **webhook** construye la question (consulta pura) y llama al backend IA.
- El **backend IA** ejecuta el workflow: predicción + generación de respuesta.
- Se obtiene answer prediction: resultado del modelo + interpretación/“humanización” mediante un LLM.
- La respuesta vuelve al ciudadano vía WhatsApp (retorno por Twilio).

El prototipo permite comparar el proceso manual vs asistido en tiempos y trazabilidad, consistente con la hipótesis general de reducción de tiempos y mejora de trazabilidad mediante estados/eventos.

4.6. Integración con mensajería (WhatsApp)

La integración con WhatsApp se realiza a través de Twilio, donde:

- Se registra el endpoint público del webhook (expuesto con ngrok) para que Twilio pueda entregar los mensajes entrantes.
- El webhook opera como “puerta de entrada” y “puerta de salida” del mensaje:
 - Recibe el payload whatsapp msg desde Twilio.
 - Invoca al backend IA por HTTP.
 - Devuelve la respuesta al usuario final vía el canal WhatsApp (Twilio).

WhatsApp se vuelve un canal operativo real para capturar incidentes, y el sistema propuesto transforma ese mensaje en: clasificación + trazabilidad + respuesta estructurada.



CAPÍTULO V: EXPERIMENTACIÓN Y RESULTADOS

5.1 Línea base del proceso manual (Y0)

La línea base del proceso manual (Y0) se construyó producto de la atención de llamadas de emergencia municipal, considerando los tiempos de atención, derivación inicial y la forma en que los operadores registran la información en el sistema CAD. Este proceso se caracteriza por un **ingreso manual no estandarizado**, alta dependencia del criterio individual del operador y ausencia de validaciones automáticas.

El análisis de los datos muestra una **alta variabilidad en los tiempos de atención**, con valores máximos significativamente elevados y una distribución asimétrica, así como una elevada proporción de campos no llenados, especialmente en lo referente a unidades de apoyo, estados del incidente y detección de casos repetidos. Estos resultados confirman que el proceso manual presenta limitaciones estructurales en términos de eficiencia, trazabilidad y calidad del dato, constituyendo un punto de referencia necesario para la comparación posterior con el sistema automatizado.

5.2 Curación y normalización del texto (Y1)

La fase Y1 abarca la curación, limpieza y normalización del texto contenido en los reportes de incidentes. En esta etapa se eliminaron variables y registros con altos porcentajes de valores nulos, duplicados y filas con valores únicos que no aportaban información relevante al modelo.

Posteriormente se realizó la normalización lingüística (estandarización de fechas y horas, limpieza de caracteres especiales y homogenización del texto). El resultado fue un dataset depurado y estructurado, adecuado para su uso en modelos de aprendizaje automático, reduciendo el ruido presente en los datos originales y mejorando la consistencia semántica de los registros.

5.3 Representación semántica (Y2)

En la fase Y2 se evaluaron múltiples técnicas de representación semántica con el objetivo de transformar el texto libre de los reportes en vectores numéricos significativos. Se experimentó con enfoques tradicionales basados en **TF-IDF** y con modelos basados en **representaciones profundas** como BETO, DistilBETO y SBERT.

Los resultados mostraron que los modelos basados en transformers superaron de forma consistente a los métodos tradicionales, especialmente en escenarios con alta variabilidad lingüística. En particular, el modelo **BETO con fine-tuning** obtuvo los mejores resultados en términos de F1-macro para las tareas de clasificación por tipología y categoría, evidenciando una mejor captura del contexto semántico del lenguaje utilizado en los reportes de emergencia.

5.4 Clasificación y balanceo (Y3)

La fase Y3 desarrolló la clasificación supervisada de incidentes y en el tratamiento del desbalance de clases presente en el dataset. Se evaluaron diferentes estrategias de balanceo, como oversampling, undersampling y cost-sensitive.

Los experimentos demostraron que el enfoque **cost-sensitive aplicado sobre el modelo BETO fine-tuning** alcanzó el mejor equilibrio entre desempeño y eficiencia computacional, logrando valores de **F1-macro superiores al 65%** en la clasificación por tipología. Este resultado confirma que el desbalance es un factor determinante para mejorar el desempeño del modelo en clases minoritarias, sin sacrificar la precisión global.

5.5 Sistema automatizado y prototipo operativo (Y4)

En la fase Y4 se implementó un prototipo que integra el modelo de clasificación dentro de una arquitectura funcional compuesta por una interfaz de mensajería, un backend web y un backend de inteligencia artificial. El sistema permite recibir reportes de incidentes, procesarlos mediante el modelo entrenado y devolver una clasificación automática estructurada.

Este prototipo valida la viabilidad técnica de incorporar el modelo en un entorno operativo real, demostrando que el sistema puede asistir al operador municipal en la clasificación inicial del incidente y en la estructuración del registro, sin interrumpir el flujo existente de atención.

5.6 Comparación cuantitativa Y0 vs Y4

La comparación entre la línea base manual (Y0) y el sistema automatizado (Y4) evidencia mejoras significativas en términos de estandarización del proceso y calidad del registro. Mientras que el proceso manual presenta alta variabilidad y pérdida de información, el sistema automatizado genera clasificaciones consistentes y registros estructurados desde el inicio del incidente.

Aunque la medición directa de los tiempos en producción no forma parte del alcance experimental, los resultados obtenidos permiten inferir una **reducción potencial de los tiempos de atención y derivación inicial**, al eliminar tareas manuales repetitivas y disminuir la ambigüedad en la clasificación.

5.7 Análisis estadístico de resultados

El análisis estadístico de los resultados se centró en métricas de evaluación para clasificación multiclase, tales como precisión, recall y F1-score, con énfasis en el **F1-macro** debido al desbalance de clases. Los resultados obtenidos muestran una mejora consistente del desempeño al avanzar desde enfoques tradicionales hacia modelos de representación profunda con balanceo.

La estabilidad de las métricas en los conjuntos de entrenamiento, validación y prueba indica que el modelo presenta una adecuada capacidad de generalización, reduciendo el riesgo de sobreajuste y reforzando la confiabilidad de los resultados experimentales.

5.8 Validación de hipótesis

Los resultados obtenidos permiten **validar la hipótesis general** de la investigación, al demostrar que la implementación de un módulo inteligente basado en Procesamiento de Lenguaje Natural mejora la clasificación inicial de incidentes, reduce la variabilidad del proceso y fortalece la trazabilidad operativa en comparación con el proceso manual no estandarizado.

Si bien la reducción exacta de los tiempos de atención requiere validación en un entorno de producción, la evidencia experimental respalda que el sistema propuesto constituye una solución efectiva y aplicable para mejorar la gestión de emergencias municipales.

CAPÍTULO VI: DISCUSIÓN

6.1 Interpretación de los resultados

Los resultados obtenidos en la investigación evidencian que el uso de técnicas de Procesamiento de Lenguaje Natural permite abordar de manera efectiva las principales limitaciones del proceso manual de atención de emergencias municipales, particularmente la subjetividad en la clasificación y la ausencia de trazabilidad operativa.

El desempeño superior de los modelos basados en **representaciones semánticas profundas**, especialmente BETO con fine-tuning, confirma que la comprensión contextual del lenguaje resulta determinante en escenarios donde los reportes presentan ambigüedad, variabilidad léxica y errores propios del lenguaje natural utilizado por los ciudadanos y operadores. Los valores alcanzados de **F1-macro superiores al 65%** indican una capacidad adecuada del modelo para generalizar entre múltiples clases, incluso en un entorno con fuerte desbalance de datos.

Asimismo, la mejora observada al aplicar técnicas de balanceo, en particular el enfoque **cost-sensitive**, sugiere que el tratamiento explícito del desbalance de clases es un factor crítico para lograr modelos más equitativos y consistentes. Este resultado es especialmente relevante en el contexto municipal, donde los incidentes menos frecuentes suelen ser también los de mayor criticidad.

Desde una perspectiva operativa, la estructuración automática del registro del incidente permite reducir la variabilidad del proceso inicial de atención y constituye un primer paso hacia la reducción efectiva de los tiempos de derivación, aunque esta investigación se centra principalmente en la fase de clasificación y no en la medición directa en producción.

6.2 Comparación con estudios previos

Los hallazgos de esta investigación son consistentes con estudios previos que destacan la superioridad de los modelos basados en **transformers** frente a enfoques tradicionales como TF-IDF y clasificadores lineales en tareas de clasificación de texto. Sin embargo, a diferencia de investigaciones orientadas a dominios genéricos o datasets balanceados, este trabajo se desarrolla en un **entorno real de gestión pública**, caracterizado por datos ruidosos, incompletos y altamente desbalanceados.

Mientras que estudios anteriores suelen reportar métricas elevadas en contextos controlados, los resultados obtenidos en esta investigación reflejan un escenario más realista y operativo, donde valores de F1-macro superiores al 60% representan un desempeño significativo y aplicable en producción. En este sentido, el aporte del trabajo radica no solo en la elección del modelo, sino en la **integración de todo el pipeline**, desde la limpieza de datos hasta la orquestación del sistema inteligente.

Adicionalmente, la inclusión de una comparación sistemática entre múltiples técnicas de representación semántica y estrategias de balanceo aporta evidencia empírica que complementa la literatura existente, la cual suele centrarse únicamente en el modelo final sin analizar el impacto del preprocesamiento y el desbalance de datos.

6.3 Implicancias para la gestión municipal

Desde el punto de vista de la gestión municipal, los resultados tienen implicancias directas en la forma en que se diseñan y evalúan los procesos de atención de emergencias. La automatización asistida de la clasificación inicial permite reducir la dependencia del criterio individual del operador, promoviendo mayor estandarización y transparencia en la toma de decisiones.

La mejora en la trazabilidad operativa posibilita la generación de indicadores objetivos de desempeño, lo que fortalece la capacidad de supervisión, auditoría y planificación estratégica de las municipalidades. Asimismo, el uso de información estructurada facilita el análisis histórico de incidentes y la identificación de patrones espaciales y temporales relevantes para la seguridad ciudadana.

Es importante destacar que el sistema propuesto no busca reemplazar al operador humano, sino **asistirlo**, reduciendo su carga cognitiva y permitiéndole concentrarse en tareas de mayor valor operativo. En este sentido, la adopción de soluciones basadas en inteligencia artificial puede contribuir a una gestión pública más eficiente, siempre que se acompañe de procesos de capacitación y cambio organizacional.

6.4 Amenazas a la validez

A pesar de los resultados obtenidos, la investigación presenta ciertas amenazas a la validez que deben ser consideradas. En primer lugar, los modelos fueron entrenados y evaluados a partir de datasets históricos, por lo que su desempeño en un entorno de producción en tiempo real podría verse afectado por cambios en el comportamiento de los usuarios o en el tipo de incidentes reportados.

En segundo lugar, el desbalance extremo de algunas categorías limita la capacidad del modelo para aprender patrones representativos en dichas clases, a pesar de la aplicación de técnicas de balanceo. Esto podría generar sesgos residuales en la clasificación de incidentes poco frecuentes.

Otra amenaza está relacionada con la calidad del dato original, ya que los registros utilizados contienen errores de digitación, campos incompletos y variabilidad semántica que, si bien reflejan la realidad operativa, pueden afectar la precisión del modelo.

Finalmente, la investigación se circunscribe al contexto de una municipalidad específica, lo que puede limitar la generalización de los resultados a otros entornos urbanos sin un proceso previo de adaptación y reentrenamiento del modelo.

CAPÍTULO VII: CONCLUSIONES Y RECOMENDACIONES

7.1 Conclusiones

1. El análisis de la **línea base del proceso manual (Y0)**, a partir de 65 382 llamadas reales de emergencia, evidenció una **alta variabilidad en los tiempos de atención**, con casos que superan los 60 minutos, lo que confirma la ineficiencia del proceso manual no estandarizado.
2. Se identificó una **pérdida crítica de trazabilidad operativa**, ya que más del 90 % de los registros no contaban con unidad de apoyo asignada y aproximadamente el 99 % de los incidentes duplicados no estaban marcados, lo que impide un seguimiento adecuado del ciclo de vida del incidente.
3. El proceso manual mostró una **distribución desigual de la carga operativa**, donde un reducido grupo de operadores concentró más del 60 % de la atención de llamadas, aumentando el riesgo de errores humanos en el registro de la información.
4. La etapa de **preprocesamiento y curación de datos (Y1)** permitió transformar un dataset original de 36 variables en un conjunto optimizado de 13 variables finales, eliminando registros con altos porcentajes de nulos, duplicados y variables irrelevantes, obteniendo un dataset limpio, consistente y apto para el análisis.
5. Los resultados de la **representación semántica (Y2)** demostraron que los modelos contextuales en español, específicamente **BETO con fine-tuning**, superan de forma consistente a los enfoques tradicionales basados en TF-IDF en el dominio de emergencias municipales.
6. BETO fine-tuning logró el mejor desempeño en la clasificación por tipología ($F1\text{-macro} = 0.6617$) y por categoría ($F1\text{-macro} = 0.2836$), evidenciando una mejor comprensión del lenguaje informal y heterogéneo utilizado por los ciudadanos.
7. En la etapa de **clasificación y manejo del desbalance (Y3)**, se comprobó que las estrategias de balanceo influyen de manera decisiva en el desempeño del modelo, siendo el enfoque **cost-sensitive** el que alcanzó el mejor equilibrio entre precisión y eficiencia computacional.
8. El modelo **BETO fine-tuning con cost-sensitive learning** obtuvo un $F1\text{-macro}$ de 0.6558, manteniendo tiempos de entrenamiento menores a 30 minutos, lo que lo hace viable para su uso en entornos operativos reales.
9. La implementación del **sistema automatizado y prototipo operativo (Y4)** permitió integrar la atención vía WhatsApp, la clasificación automática, la orquestación del flujo y el registro estructurado del incidente, cerrando el ciclo operativo completo desde la creación hasta el cierre.

10. El sistema automatizado logró **reducir el tiempo de respuesta inicial** de aproximadamente 1 minuto 6 segundos a cerca de 2 segundos, estandarizando la atención inicial y la derivación operativa.
11. La gestión explícita de estados del incidente (creado, derivado, en atención y cerrado) mejoró sustancialmente la **trazabilidad del proceso**, habilitando mediciones objetivas del desempeño operativo y la comparación cuantitativa con la línea base manual.

7.2 Recomendaciones técnicas

1. Implementar el modelo **BETO fine-tuning con estrategia cost-sensitive** como solución principal de clasificación automática de incidentes en entornos municipales.
2. Establecer un proceso periódico de **reentrenamiento del modelo**, incorporando nuevos datos operativos para mantener su desempeño ante cambios en el lenguaje y en los patrones de incidentes.
3. Incorporar mecanismos automáticos de **detección de incidentes duplicados**, aprovechando las representaciones semánticas del modelo para reducir la pérdida de trazabilidad.
4. Optimizar la arquitectura del sistema para su despliegue en producción, asegurando tiempos de inferencia bajos y alta disponibilidad del servicio.

7.3 Recomendaciones para la gestión pública

1. Promover la **estandarización del proceso de atención de emergencias** mediante el uso de sistemas asistidos por inteligencia artificial.
2. Utilizar la información estructurada generada por el sistema para la **evaluación objetiva del desempeño operativo** y la planificación estratégica municipal.
3. Capacitar a los operadores municipales en el uso de sistemas inteligentes como herramientas de apoyo a la toma de decisiones.
4. Impulsar iniciativas de innovación pública orientadas a mejorar la **capacidad de respuesta ante incidentes de inseguridad ciudadana**.

7.4 Líneas futuras de investigación

1. Evaluar el sistema en un entorno de **producción real**, midiendo de forma longitudinal la reducción efectiva de los tiempos de atención y derivación.
2. Explorar enfoques de **clasificación multietiqueta** para incidentes complejos asociados a múltiples tipologías o categorías.
3. Incorporar **modelos de lenguaje generativos** para la generación automática de reportes operativos y resúmenes ejecutivos.

4. Replicar el modelo en **otras municipalidades**, adaptándolo a diferentes contextos operativos y validando su generalización.

BIBLIOGRAFIA

- Abi Kanaan, M., Couchot, J.-F., Guyeux, C., Laiymani, D., Atechian, T., & Darazi, R. (2024). Combining a multi-feature neural network with multi-task learning for emergency calls severity prediction. *Array*, 21, 100333. <https://doi.org/10.1016/j.array.2023.100333>
- Anton-Chunga, M. de L. (2025). Percepciones y realidades de la seguridad ciudadana en Perú: Una revisión sistemática. *Impulso, Revista de Administración*, 5(9), Article 9. <https://doi.org/10.59659/impulso.v.5i9.92>
- Cañete, J., Chaperon, G., Fuentes, R., Ho, J.-H., Kang, H., & Pérez, J. (2023). *Spanish Pre-trained BERT Model and Evaluation Data* (Versión 1). arXiv. <https://doi.org/10.48550/ARXIV.2308.02976>
- Castro-Chucan, G., Chalco-Peñañiel, H., Bedregal-Alpaca, N., & Cornejo-Aparicio, V. (2024). Smart Muni Platform: Efficient Emergency and Citizen Security Management Based on Geolocation, Technological Integration and Real Time Communication. *International Journal of Advanced Computer Science and Applications (IJACSA)*, 15(10). <https://doi.org/10.14569/IJACSA.2024.0151021>
- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321–357. <https://doi.org/10.1613/jair.953>
- Chin, K.-C., Cheng, Y.-C., Sun, J.-T., Ou, C.-Y., Hu, C.-H., Tsai, M.-C., Ma, M. H.-M., Chiang, W.-C., & Chen, A. Y. (2022). Machine Learning-Based Text Analysis to Predict Severely Injured Patients in Emergency Medical Dispatch: Model Development and Validation. *Journal of Medical Internet Research*, 24(6), e30210. <https://doi.org/10.2196/30210>
- Condori Huahuachampi, L., Quispe Huamaní, G. E., Carhuachin Ale, G. D., Mandujano Ugarte, J. K., Vargas Tejada, J. P., & Cruz Huaman. (2025, marzo 28). *Estadísticas de Seguridad Ciudadana del semestre móvil: Julio—Diciembre 2024*. Instituto Nacional de Estadísticas e Informatica. https://m.inei.gob.pe/media/MenuRecursivo/boletines/boletin_seguridad_jul_dic2024.pdf
- Costa, D. B., Pinna, F. C. de A., Joiner, A. P., Rice, B., Souza, J. V. P. de, Gabella, J. L., Andrade, L., Vissoci, J. R. N., & Néto, J. C. (2023). AI-based approach for transcribing and classifying unstructured emergency call data: A methodological proposal. *PLOS Digital Health*, 2(12), e0000406. <https://doi.org/10.1371/journal.pdig.0000406>
- Coz, C., & Pariona, H. (2023). *Seguridad ciudadana en el Perú y Latinoamérica en los últimos 5 años* [Tesis de Posgrado, Universidad Cesar Vallejo]. <http://doi.10.59427/rcli/2023/v23cs.3854-3863>
- Dash, P., Neustaedter, C., Jones, B., & Yip, C. (2022). The Design and Evaluation of Emergency Call Taking User Interfaces for Next Generation 9-1-1. *Frontiers in Human Dynamics*, 4, 670647. <https://doi.org/10.3389/fhumd.2022.670647>
- Dixon, A., & Birks, D. (2021). Improving Policing with Natural Language Processing. En A. Field, S. Prabhumoye, M. Sap, Z. Jin, J. Zhao, & C. Brockett (Eds.), *Proceedings of the 1st Workshop on NLP for Positive Impact* (pp. 115–124). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2021.nlp4posimpact-1.13>
- Hernández-Gutiérrez, J. C., & Zurita Ortega, F. (2022). *Inseguridad objetiva, miedo al delito y preocupación por la inseguridad en América Latina*. 25–46.
- Hosseiny Marani, A., & Baumer, E. P. S. (2023). A Review of Stability in Topic Modeling: Metrics for Assessing and Techniques for Improving Stability. *ACM Comput. Surv.*, 56(5), 108:1-108:32. <https://doi.org/10.1145/3623269>
- Huesca González, A. M., Grimaldo-Santamaría, R.-O., & Quicios García, M. D. P. (2021). Subjective and Objective Insecurity in Spanish Cities. *Sustainability*, 13(23), 13309. <https://doi.org/10.3390/su132313309>
- Langton, S., Ruiter, S., & Schoonmade, L. (2024). The spatial patterning of emergency demand for police services: A scoping review. *Crime Science*, 13(1), 1. <https://doi.org/10.1186/s40163-023-00199-y>
- Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal Loss for Dense Object Detection. *2017 IEEE International Conference on Computer Vision (ICCV)*, 2999–3007. <https://doi.org/10.1109/ICCV.2017.324>
- Mendiburu, C., Alvarado, C., & Huaranca, R. (2024, septiembre). *Indicadores y costo de la Inseguridad Ciudadana en el Perú*. Moneda N°199 - Banco Central de Reserva del Perú. <https://www.bcrp.gob.pe/docs/Publicaciones/Revista-Moneda/moneda-199/moneda-199-10.pdf>
- P. Miguel, J., Mauricio, D., & Rodríguez, G. (2014). A Review of Software Quality Models for the Evaluation of Software Products. *International Journal of Software Engineering & Applications*, 5(6), 31–53. <https://doi.org/10.5121/ijsea.2014.5603>
- Patil, P., Gaikwad, S., & Hatkangane, A. (2024). 911 Call Analyzer: A Vital Tool for Detecting Critical Emergencies. *INTERNATIONAL JOURNAL OF SCIENTIFIC RESEARCH IN ENGINEERING AND MANAGEMENT*, 08(07), 1–11. <http://dx.doi.org/10.55041/IJSREM36673>
- Pennington, J., Socher, R., & Manning, C. (2014). GloVe: Global Vectors for Word Representation. En A. Moschitti, B. Pang, & W. Daelemans (Eds.), *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)* (pp. 1532–1543). Association for Computational Linguistics. <https://doi.org/10.3115/v1/D14-1162>
- Presidencia del Consejo de Ministros – Secretaría de Gobierno Digital. (2024). *Llamadas a la central de emergencias de la Municipalidad Provincial del Callao (MPC)* (No. 68b32b68-4f04-46fe-96e5-793e6fbc81b1) [Csv]. Plataforma Nacional de Datos Abiertos;

- https://datosabiertos.gob.pe/sites/default/files/DATASET%20DE%20LLAMADAS%20A%20LA%20CENTRAL%20DE%20EMERGENCIAS%20CALLAO%20-%20MPC_0.csv
- <https://datosabiertos.gob.pe/dataset/llamadas-la-central-de-emergencias-de-la-municipalidad-provincial-del-callao-mpc>
- Roldan-Baluis, W. L., Zapata, N. A., & Vasquez, M. S. M. (2022). The Effect of Natural Language Processing on the Analysis of Unstructured Text: A Systematic Review. *International Journal of Advanced Computer Science and Applications*, 13(5). <https://doi.org/10.14569/IJACSA.2022.0130507>
- Ruiz, A. Y. P. (2024). Gestión de políticas públicas y seguridad ciudadana: Una revisión sistemática: Public policy management and citizen security: A systematic review. *LATAM Revista Latinoamericana de Ciencias Sociales y Humanidades*, 5(4), 3145–3156. <https://doi.org/10.56712/latam.v5i4.2487>
- Sanchez, M., Estefano, L., Padilla, Z., Antonio, C., & Castañeda, P. (2025). *Prediction Web Application Based on a Machine Learning Model to Reduce Robberies and Thefts Rate in Los Olivos, San Martín De Porres and Comas*. 191–198. <https://www.scitepress.org/Link.aspx?doi=10.5220/0012906800003825>
- Wang, Z., Li, Z., Xie, Y., Souza Jr., C., Souza Filho, J. S., & Pinheiro, S. (2024). AI-based Validation of Deforestation Using High-Resolution Satellite Imagery in the Brazilian Amazon. *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, XLVIII-3–2024, 583–588. ISPRS TC III Mid-term Symposium “Beyond the canopy: technologies and applications of remote sensing” - 4–8 November 2024, Belém, Brazil. <https://doi.org/10.5194/isprs-archives-XLVIII-3-2024-583-2024>
- World Bank Group. (2020). *Peru—Centralized Emergency Response System Project* (No. PAD3477; p. 77). World Bank Group. <http://documents.worldbank.org/curated/en/397091586570439508>
- Zhao, X., Fan, W., Liu, H., & Tang, J. (2022). Multi-Type Urban Crime Prediction. *Proceedings of the AAAI Conference on Artificial Intelligence*, 36(4), Article 4. <https://doi.org/10.1609/aaai.v36i4.20360>

ANEXOS

A: MATRIZ DE CONSISTENCIA

Problema de Estudio	Objetivos	Hipótesis	Variables y Dimensiones	Diseño Metodológico	Sustento Teórico
PG: El procesamiento manual y no estandarizado de las llamadas de emergencia genera subjetividad y variabilidad en la clasificación de los incidentes, así como errores en la calidad del dato y ausencia de un registro operativo estructurado del ciclo de vida del incidente. Como consecuencia, se producen demoras variables en la atención y derivación inicial de los incidentes, limitada trazabilidad operativa y dificultad para medir el desempeño del proceso, lo que reduce la capacidad de respuesta y evaluación del impacto operativo ante incidentes de inseguridad ciudadana.	OG: Analizar y medir el proceso de atención como los tiempos de atención y derivación inicial de incidentes de emergencia municipal mediante el diseño e implementación de un módulo inteligente basado en Procesamiento de Lenguaje Natural , que automatice la clasificación inicial y estructure el registro operativo, permitiendo comparar el desempeño del proceso manual (Y0) frente al proceso asistido (Y4).	HG: La implementación de un módulo inteligente basado en Procesamiento de Lenguaje Natural reduce de forma significativa los tiempos de atención y derivación inicial, mejora la trazabilidad operativa mediante el registro estructurado de estados y eventos, y disminuye la variabilidad en la clasificación al mejorar la estructuración y trazabilidad del registro operativo, en comparación con el proceso manual no estandarizado.	VI (Independientes): VI0: Protocolo de medición del proceso manual (Y0) VI1: Curación y normalización de datos (Y1) VI2: Representación semántica del texto (TF-IDF / BETO / SBERT / LDA) (Y2) VI3: Clasificación automática supervisada (manejo del desbalance) (Y3) VI4: Módulo operativo de atención y derivación inicial (Y4) VD (Dependientes): VD1: Tiempo de atención inicial (promedio y reducción porcentual (manual/asistido)) VD2: Tiempo de clasificación y derivación: Tiempo medio por incidente VD3: Calidad de la clasificación: F1-macro global, F1 por clase VD4: Trazabilidad operativa (% incidentes con estados completos), número de enventos registrados por incidente, timestamps por estado VC (Control): VC1: Condiciones del dataset - Partición estratificada (70/15/15) PARA Y1–Y4 - Mismo dataset por etapa (v.1.1 para Y0, v.2.0 para Y1–Y4) VC2: Reproducibilidad: Semilla fija (random_state=42) VC3: Protocolo de preprocesamiento: Protocolo único de limpieza y tokenización (Y1–Y4) VC4: Condiciones operativas: Reglas operativas estandarizadas (misma definición de tiempo para comparación Y0 vs. Y4)	Diseño experimental, analítico y comparativo , orientado a evaluar el impacto del módulo inteligente sobre el desempeño operativo del proceso de atención de incidentes, mediante la comparación de los tiempos de atención explícita del proceso manual (Y0) vs. el proceso asistido (Y4), integrando NLP, clasificación automática y trazabilidad operativa. Instrumentos de medición: - Registros temporales (timestamps) del procesomanial (Y0) vs el asistido (Y4) - Logs estructurados del sistema (manual vs asistido) - Indicadores de tiempo de atención inicial y derivación - Matriz de confusión y métricas de clasificación (F1-macro y por clase) - Registro del ciclo de vida del incidente para medición de trazabilidad operativa Instrumentos tecnológicos (soporte): - Python (análisis, métricas y comparación) - scikit-learn (modelos, métricas de clasificación) - Transformers / Sentence-Transformers (representación semántica) - FastAPI (servicio del módulo inteligente) - LangGraph (orquestación del flujo de atención) - Twilio (WhatsApp API) (canal de entrada de incidentes) - MLflow (tracking de experimentos y métricas) - DVC (versionado de datos)	Ferri et al. (2021); Langton et al. (2024); Wang et al. (2021); Hosseiny & Baumer (2023); Kathole et al. (2023); Blei et al. (2001).

Problemas Específicos	Objetivos Específicos	Hipótesis Específicas	Variables y Dimensiones	Diseño Metodológico	Sustento Teórico
P0: La ausencia de una línea base cuantitativa del PROCESO MANUAL real de atención de llamadas de emergencia (con timestamps y reglas consistentes de cálculo) impide medir y caracterizar de forma objetiva y reproducible los tiempos reales de atención y derivación inicial, dificultando la comparación objetiva con un proceso asistido por un módulo inteligente en etapas posteriores.	OE0: Construir y validar una línea base (Y0) del PROCESO MANUAL real de atención de llamadas de emergencia (dataset v1.1), calculando y consolidando métricas de tiempo y trazabilidad mínima (por estado, consulta y área derivada), que sirva como referencia operativa para habilitar la comparación manual vs asistido en el último artefacto (Y4).	H0: La aplicación de un protocolo estandarizado de depuración y cálculo de tiempos sobre los registros del proceso manual (v1.1) permite obtener una línea base estable, reproducible y auditable de métricas (media, mediana, p90, p95, máximos) y verificar trazabilidad mínima, representando de forma consistente el desempeño temporal del proceso manual.	VI0 (Independiente): Protocolo de medición del proceso manual (Y0) Dimensiones: VI0.1 Criterios de depuración de registros (validación de timestamps inicio a fin, exclusión de registros con duración nula o negativa, outliers) VI0.2 Reglas de cálculo de duración (inicio/fin, unidad de medida en segundos, formato minutos/segundos para reporte) VI0.3 Criterios de trazabilidad mínima (validez de timestamps de inicio, duración positiva y consistente, registro apto para análisis temporal) VI0.4 Segmentación analítica (estado_llamada, consulta_realizada, area_derivada) VI0.5 Protocolo de agregación estadística (media, mediana, percentiles p90 y p95, max) VD0 (Dependiente): Desempeño temporal y trazabilidad mínima del proceso manual Indicadores/Métricas: VD0.1 Duración promedio del proceso manual (s) (mean) VD0.2 Duración mediana del proceso manual (s) (median) VD0.3 Percentiles p90 y p95 de duración (s) VD0.4 Duración máxima (s) (max) y presencia de colas largas VD0.5 % de registros con timestamps válidos (pct_ts_inicio_ok) VD0.6 % de registros con duración válida (pct_duracion_ok) VD0.7 % de trazabilidad mínima válida (pct_trazabilidad_minima_ok) VC0 (Control): Condiciones controladas de medición VC0.2 Definición única y fija de duración (misma fórmula) VC0.3 Misma política de tratamiento de outliers (solo reporte) VC0.4 Mismos criterios de inclusión/exclusión de registros VC0.5 Misma lógica de segmentación (estado, consulta, área)	Diseño descriptivo–analítico (línea base) orientado a medir el desempeño temporal del proceso manual, mediante el cálculo estandarizado de métricas de duración y verificación de trazabilidad mínima, con desagregación por estado, tipo de consulta y área derivada. Instrumentos de medición: - Timestamps del proceso manual (inicio/fin) - Logs/atributos de segmentación (estado_llamada, consulta_realizada, area_derivada) - Métricas estadísticas: mean, median, p90, p95, max - Indicadores de calidad de medición: % timestamps válidos, % duración válida, % trazabilidad mínima Instrumentos tecnológicos (soporte): - Python (pandas, numpy y matplotlib (visualización de distribuciones)) - Notebook/script: O_LINEA_BASE_PROCESO_MANUAL_Y0.ipynb Producto (salida Y0): Y0_baseline.csv (métricas globales: n, mean, median, p90, p95, max + % válidos)) Y0_1_ESTADO_LLAMADA_Tiempos.csv (tabla segmentada por estado_llamada) Y0_2_CONSULTA_REALIZADA_Tiempos.csv (tabla segmentada por consulta_realizada) Y0_3 AREA_DERIVADA_Tiempos.csv (tabla segmentada por area_derivada) Adicional: Gráficos de distribución de duración (global y 0–600s) y Reporte de calidad de medición (% timestamps válidos, % duración válida, % trazabilidad mínima)	Ferri et al. (2021); Langton et al. (2024); Wang et al. (2021); Hosseiny & Baumer (2023); Kathole et al. (2023); Blei et al. (2001).

P1: La deficiente calidad, estandarización y estructura de los datos del dataset original de llamadas de emergencia, caracterizada por la alta proporción de valores nulos, variables redundantes, codificación inadecuada de campos temporales y presencia de datos sensibles, genera ruido, limita su interpretabilidad y dificulta su uso como entrada confiable para un pipeline de análisis basado en NLP y aprendizaje automático.	OE1: Analizar, depurar y normalizar a nivel estructural el dataset original de llamadas de emergencia mediante técnicas de análisis exploratorio de datos (EDA) y reglas operativas explícitas de limpieza, con el fin de obtener un conjunto de datos limpio, consistente y enriquecido (Y1), que sirva como base metodológica para la representación semántica (Y2) y la clasificación supervisada (Y3)	H1: La aplicación de un proceso sistemático de depuración estructural, basado en reglas explícitas de eliminación de variables irrelevantes y normalización de tipos de datos, reduce de forma significativa la redundancia informativa y la incompletitud del dataset, mejorando su consistencia, interpretabilidad y adecuación como entrada para un pipeline de NLP y aprendizaje automático.	VI1 (Independiente): Curación estructural del dataset Dimensiones: Reglas operativas de depuración VI1.1 Eliminación de columnas > 50% de valores nulos VI1.2 Eliminación de variables duplicadas > 80% de coincidencia VI1.3 Eliminación de variables constantes (cardinalidad única) VI1.4 Eliminación de variables administrativas e identificadoras (excepto ZONA por valor analítico geoespacial) VI1.5 Normalización de tipos de datos (conversión de variables temporales fecha-horaa numéricas a formatos datetime/time) VI1.6 Transformación y enriquecimiento temporal (día de la semana, hora, turno, datetime completo) VI1.7 Depuración ética de datos sensibles o identificables (nombres, DNI, direcciones específicas) VD1 (Dependiente): Calidad y utilidad del dataset de entrada Métricas: VD1.1 Número y porcentaje de variables eliminadas VD1.2 Porcentaje global de valores nulos antes y después de la limpieza VD1.3 Reducción de variables redundantes (duplicadas o constantes) VD1.4 Consistencia del esquema (tipos de datos correctos y ausencia de columnas constantes) VD1.5 Completitud analítica de variables clave (en especial DESCRIPCION_OCURRENCIA) VD1.6 Interpretabilidad temporal del dataset (generación de variables derivadas útiles) VC1 (Control): Criterios y reglas de depuración VC1.1 Criterio explícito y uniforme de eliminación de columnas con >50% de nulos VC1.2 Umbral fijo de >80% de coincidencia para detección de duplicados VC1.3 Eliminación solo a nivel de columnas (no se eliminan filas) VC1.4 Reglas uniformes de transformación temporal VC1.5 Conservación de variables geoespaciales agregadas con bajo riesgo de identificación	Diseño descriptivo-analítico aplicado en la etapa Y1, centrado en el análisis exploratorio de datos, depuración estructural y normalización de tipos, sin alterar el número de registros originales. Instrumentos: - Python (pandas, numpy) - matplotlib, seaborn - Scripts/notebook 1_EDA_LIMPIEZA_NORMALIZACION_Y1 Producto final etapa Y1: - Dataset limpio y enriquecido dataset_analisis_limpieza_Y1.csv / .xlsx - Base metodológica para: Representación semántica (Artefacto Y2) Clasificación supervisada (Artefacto Y3)	Ferri et al. (2021); Hosseiny & Baumer (2023).
---	--	--	---	---	---

P2: La ausencia de una representación semántica estandarizada, comparable y evaluada que capture de manera adecuada el significado de las descripciones textuales de las llamadas de emergencia, limita la confiabilidad, robustez y desempeño de modelos automáticos de clasificación (tipología-categoría) y del análisis semántico	OE2: Construir, implementar y comparar de manera sistemática múltiples representaciones semánticas del texto de las llamadas de emergencia (TF-IDF, BETO y sus variantes, SBERT y LDA), evaluando su desempeño tanto en clasificación automática como en métricas de calidad semántica, con el fin de seleccionar la representación más adecuada para el pipeline de análisis y los modelos en la etapa posterior Y3	H2: Las representaciones basadas en embeddings contextuales (BETO y sus variantes) proporcionan una representación semántica más rica que los modelos tradicionales basados en bolsa de palabras y modelos de tópicos, lo que se traduce en mejoras significativas en F1-macro, mejor desempeño en clases minoritarias y mejores indicadores de calidad de agrupamiento semántico, en comparación con TF-IDF y LDA.	VI2 (Independiente): Representación semántica del texto Dimensiones (Tratamientos experimentales): VI2.1 TF-IDF (unigramas y bigramas, con y sin stopwords) VI2.2 BETO (última capa; últimas 4 capas; pooling mean y CLS) VI2.3 DistilBETO (última capa y últimas 4 capas; pooling mean) VI2.4 SBERT (mean pooling y CLS) VI2.5 BETO con fine-tuning supervisado (clasificación por categoría y tipología) VI2.6 LDA – modelado de tópicos no supervisado (T16) VD2 (Dependiente): Calidad semántica y clasificatoria de la representación Métricas: Clasificación supervisada: VD2.1 F1-macro global VD2.2 F1-macro por nivel (categoría y tipología) VD2.3 F1 para clases minoritarias Calidad de embeddings (evaluación no supervisada): VD2.4 Silhouette Score VD2.5 Davies–Bouldin Index VD2.6 Calinski–Harabasz Index Modelos de tópicos (LDA – T16) (clasificación no supervisada): VD2.7 Coherencia temática c_v VD2.8 NMI con categoría VD2.9 NMI con tipología VC2 (Control): Condiciones experimentales constantes VC2.1 Partición estratificada train/val/test (70/15/15) sobre el dataset Y2 VC2.2 Semilla fija de aleatoriedad (random_state = 42) VC2.3 Mismo protocolo de limpieza y tokenización del texto VC2.4 Mismos conjuntos de datos para todos los tratamientos (comparación justa) VC2.5 Registro sistemático de resultados por experimento (T1–T16)	Diseño comparativo y experimental aplicado en la etapa Y2, orientado a la construcción, implementación y evaluación de distintas representaciones semánticas del texto de llamadas de emergencia , y al análisis de su impacto en la clasificación automática y la calidad del análisis semántico, mediante una comparación controlada entre modelos tradicionales, embeddings contextuales y modelos de tópicos. Instrumentos: Python, pandas, scikit-learn, Transformers (Hugging Face), Sentence-Transformers, gensim (LDA), métricas de clasificación y clustering. Productos de la etapa Y2: - Dataset particionado: Y2_train.csv, Y2_val.csv, Y2_test.csv - Resultados consolidados de experimentos T1–T16: Y2_results_GLOBAL_T1_T16.csv - Selección fundamentada de la mejor representación semántica, utilizada como entrada para el Artefacto Y3	Wang et al. (2021); Ferri et al. (2021).
--	--	---	---	--	---

P3: La clasificación manual de las llamadas de emergencia presenta subjetividad e inconsistencia, además de un fuerte desbalance entre tipologías, lo que degrada el desempeño en clases minoritarias, reduce la reproducibilidad y limita la confiabilidad de los sistemas automáticos de apoyo a la decisión.	OE3: Entrenar, evaluar y comparar modelos BETO fine-tuning para clasificación de tipologías incorporando estrategias explícitas de manejo del desbalance (baseline, undersampling, oversampling y cost-sensitive learning), para cuantificar su impacto en desempeño global y por clase, y seleccionar el mejor modelo para el Artefacto Y4.	H3: Los modelos de clasificación supervisada basados en BETO fine-tuning con estrategias explícitas de manejo del desbalance como cost-sensitive u oversampling mejora de forma significativa el desempeño de clasificación de tipologías, incrementando el F1-macro y el desempeño en clases minoritarias frente al esquema sin balanceo (baseline) y frente a la clasificación manual.	VI3 (Independiente): Estrategia de entrenamiento supervisado con manejo del desbalance (BETO fine-tuning) Dimensiones: VI3.1: BETO fine-tuning baseline (sin técnica explícita de balanceo). VI3.2: BETO fine-tuning + undersampling (solo en train). VI3.3: BETO fine-tuning + oversampling (solo en train). VI3.4: BETO fine-tuning + cost-sensitive learning (ponderación por clase en la función de pérdida). VD3 (Dependiente): Desempeño del modelo de clasificación VD3.1: F1-macro (TEST) por estrategia (métrica principal de selección). VD3.2: Reporte por clase (precision/recall/F1 por tipología). VD3.3: F1 en clases minoritarias (tipología) VD3.4: Tiempo de entrenamiento (segundos) por estrategia. VD3.5: Tiempo de entrenamiento VC3 (Control): Condiciones experimentales constantes VC3.1: Misma partición train/val/test (70/15/15) y misma columna de texto/label. VC3.2: Semilla fija (random_state=42). VC3.3: Mismo modelo base dccuchile/bert-base-spanish-wwm-cased (representación semántica) VC3.4: Mismos hiperparámetros constantes base del modelo BETO (MAX_LEN=128, epochs=3, LR=2e-5, batch sizes). VC3.5: Misma política de evaluación y selección (best model por F1-macro) VC3.6: Selección del mejor modelo según F1-macro en validación	Diseño experimental-comparativo: se evalúan 4 tratamientos (baseline, undersampling, oversampling, cost-sensitive) manteniendo constantes dataset, arquitectura BETO e hiperparámetros, comparando métricas globales y por clase, y seleccionando el mejor por F1-macro (TEST/validación según tu criterio). Instrumentos: Python; Hugging Face Transformers; PyTorch; scikit-learn, técnicas de re-sampling. Producto: CSV de métricas: metricas_comparativas_modelos.csv. Modelos exportados (JOBLIB): modelo_beto_base.joblib modelo_beto_oversampling.joblib modelo_beto_undersampling.joblib modelo_beto_cost_sensitive.joblib Modelo ganador para Artefacto 4:. Cost-Sensitive (F1-macro = 0.6558)	Langton et al. (2024); Wang et al. (2021).
---	--	--	---	--	---

P4: La falta de una arquitectura formal y de un módulo inteligente operativo que integre clasificación automática del incidente, orquestación del flujo de atención, retroalimentación al ciudadano y registro del ciclo de vida del caso (creada, derivada, en atención, cerrada) impide la trazabilidad completa, la medición del desempeño operativo y la evaluación del impacto real de las llamadas de emergencia en la gestión municipal hasta el cierre del incidente.	OE4: Diseñar e implementar un módulo inteligente operativo de atención de incidentes que reciba mensajes vía WhatsApp (Twilio), procese la consulta mediante un workflow orquestado (FastAPI + LangGraph), realice clasificación automática y derivación sugerida (modelo entrenado en Y3), genere respuestas asistidas por LLM, y registre de forma estructurada estados y	H4: La implementación del módulo inteligente de atención de incidentes basado en Twilio + Webhook + FastAPI + LangGraph + modelo de clasificación entrenado + LLM reduce de forma significativa el tiempo de clasificación/derivación y cierre ($\geq 30\%$) y mejora la trazabilidad operativa (registro completo de estados y eventos) en comparación con el proceso manual y no orquestado.	VI4 Variable Independiente: Módulo inteligente de atención de incidentes Dimensiones (componentes implementados): VI4.1 Canal de entrada; WhatsApp mediante Twilio VI4.2 Capa de integración: Webhook en Express.js, recepción, parsing y reenvío de mensajes VI4.3 Backend de procesamiento IA: API desarrollada en FastAPI, Endpoint operativo execute VI4.4 Orquestación del flujo de atención: LangGraph Gestión de estados: inicio → clasificación → respuesta → registro VI4.5 Clasificación automática del incidente: Modelo supervisado entrenado y validado en Y3 (BETO fine-tuning cost-sensitive), con predicción de tipología y unidad sugerida VI4.6 Respuesta asistida al ciudadano: LLM (OpenAI), plantillas operativas, solicitud de información faltante, guía operativa y retroalimentación al ciudadano VI4.7 Persistencia y trazabilidad: Registro estructurado de estado, evento, timestamps y unidad, persistencia en base de datos o logs estructurados VD4 Variable Dependiente: Eficiencia y calidad operativa del proceso Métricas VD4.1 Tiempo de respuesta: Tiempo desde mensaje WhatsApp hasta respuesta automática VD4.2 Tiempo de clasificación y derivación: Duración del proceso de predicción y asignación de unidad VD4.3 Tiempo promedio de cierre del incidente: Desde creación hasta estado cerrado VD4.4 Trazabilidad operativa completa: Porcentaje de casos	Diseño analítico–comparativo aplicado a Y3–Y4: Y3: Entrenamiento y selección del mejor modelo de clasificación automática. Y4: Implementación operativa del módulo inteligente con: clasificación automática, orquestación del flujo, respuesta asistida, registro de trazabilidad Comparación explícita: Proceso manual (Y0) vs. Proceso automatizado y trazable (Y4) Instrumentos (Tecnológicos): Twilio WhatsApp API Express.js (Webhook) FastAPI (backend IA) LangGraph (orquestación) Modelo de clasificación entrenado (Y3) OpenAI LLM Base de datos o logs estructurados Dashboard simple de monitoreo Producto Final (Y4): - Prototipo funcional del módulo inteligente de atención de incidentes - Flujo completo WhatsApp → IA → respuesta - Registro estructurado del ciclo de	Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5–32.
---	---	---	--	---	---

	eventos, permitiendo medir tiempos, trazabilidad y mejora operativa respecto a la línea base manual (Y0).		con registro completo de: estado + evento + unidad + timestamps VD4.5 Calidad de la clasificación automática: Accuracy, F1-score del modelo utilizado en producción VC4 Variables de Control: VC4.1 Catálogo fijo de categorías y unidades: Sin cambios durante la evaluación VC4.2 Reglas de transición de estados: creada → derivada → en atención → cerrada VC4.3 Plantillas base de respuesta del LLM: Respuestas estandarizadas y criterios de derivación VC4.4 Parámetros fijos del LLM: Temperatura constante (0), Prompt base controlado VC4.5 Modelo de clasificación constante: Modelo validado y seleccionado en Y3 (Beto fine tuning + cost sensitive) VC4.6 Protocolo de limpieza textual constante: Mismas reglas de preprocesamiento del texto de entrada	vida del incidente - Medición objetiva de: tiempos, trazabilidad, mejora operativa - Base comparativa (Y4 vs. Y0) para conclusiones finales	
--	---	--	--	---	--

ANEXO B: OPERACIONALIZACIÓN DE VARIABLES

TIPO	VARIABLE	DEFINICIÓN CONCEPTUAL	DEFINICIÓN OPERACIONAL	DIMENSIONES	INDICADORES	ÍTEMS / ÍNDICES	ESCALA
Y0: Línea base manual	VI0 Protocolo de medición temporal	Reglas estandarizadas para cálculo homogéneo de tiempos y trazabilidad del proceso manual	Scripts Y0 que calculan duración inicio–fin, percentiles y validación de calidad	Depuración, Cálculo, Segmentación, Agregación	% timestamps válidos > 95% p90/p95 outliers reportados	Scripts Y0; Y0_baseline.csv	Cuantitativa
	VD0 Desempeño temporal base	Nivel de eficiencia del proceso manual	Métricas globales y segmentadas	Tiempo total, Segmentos	mean/median/p90/p95/max % trazabilidad > 95%	Tablas Y0	Cuantitativa
	VC0 Reglas fijas de medición	Condiciones constantes de cálculo	Mismas fórmulas y filtros	Control	variación < 2 p.p.	Código versionado	Cuantitativa
Y1: Curación y normalización de datos	VI1 Curación y normalización textual	Depuración estructural del dataset	EDA + limpieza Y1	EDA, Limpieza, Normalización	duplicados > 80% eliminados nulos > 50% eliminados campos estandarizados > 95%	Scripts Y1	Cuantitativa
	VD1 Calidad del dataset	Integridad y utilidad analítica	Medición post-limpieza	Integridad, legibilidad	completitud >95% duplicados < 5% reducción nulos > 50%	Reportes Y1	Cuantitativa
	VC1 Umbrales fijos	Reglas constantes de depuración	Mismos thresholds	Control	variación < 2 p.p.	Código	Cuantitativa
Y2: Representación semántica	VI2 Representación semántica	Codificación numérica del texto	TF-IDF, BETO, SBERT, LDA en Y2	Vectorización / Embeddings	F1-macro > baseline +10% silhouette score > baseline coherencia temática > baseline	Y2_results_GLOBAL	Cuantitativa (0–1)
	VD2 Calidad semántica	Capacidad discriminativa	Evaluación de modelos	Global / Minoritaria	F1-macro > baseline +10% coherencia c_v > baseline	sklearn/gensim	Cuantitativa
	VC2 Particiones fijas	División estable de datos	70/15/15 estratificado	Train / Val / Test	diferencia proporción de clases < 2 p.p.	StratifiedSplit	Cuantitativa

Y3: Clasificación balanceada	VI3 Estrategias de balanceo	Técnicas anti-desbalance	BETO FT + sampling Y3	Undersampling, Oversampling, Cost-Sensitive	F1 clases minoritarias >15% F1-macro > baseline	Logs Y3	Cuantitativa
	VD3 Precisión clasificatoria	Exactitud supervisada	Evaluación final	Global, Clase	F1-macro > 0.75	sklearn	Cuantitativa
	VC3 Hiperparámetros fijos	Configuración controlada	Grid estable	Control	varianza F1 < 2 p.p.	Config YAML	Cuantitativa
Y4: Modulo operativo inteligente	VI4 Módulo inteligente operativo	Arquitectura integral automatizada	Twilio—FastAPI—LangGraph—LLM en Y4	Canal - Backend - Orquestación - Clasificación - Respuesta - Persistencia	tiempo de respuesta tiempo de cierre % trazabilidad >95%	Logs SQL, logs estructurados	Cuantitativa
	VD4 Eficiencia y trazabilidad	Capacidad de cierre completo	Comparación Y0 vs Y4	Estados / Tiempos	reducción tiempo >30% ciclo completo > 95%	Logs SQL	Cuantitativa
	VC4 Protocolos operativos	Reglas municipales	Flujo fija estados	Estados	% conformidad > 95%	SQL / reglas operativas	Cuantitativa

ANEXO C: ENTRADA – PROCESO - SALIDA

Etapa	Objetivo	Entradas principales	Procesos / Algoritmos (VI)	Salidas / Artefactos	Indicadores asociados (VD)
Y0 – Línea base proceso manual (D0)	Construir baseline cuantitativo del proceso manual real	Dataset original: v1.1 DATASET DE LLAMADAS A LA CENTRAL DE ATENCION AL CIUDADANO - MPC.csv (65,382 registros; 16 variables) incluidas: FECHA_LLAMADA, HORA_LLAMADA, ESTADO_LLAMADA, AREA_DERIVADA, DURACION_LLAMADA	VI0 – Protocolo de medición temporal: • depuración timestamps • reglas duración • segmentación por: estado/consulta/área • agregación estadística	Y0 - baseline • Y0_1_ESTADO_LLAMADA_Tiempos.csv • Y0_2_CONSULTA_REALIZADA_Tiempos.csv • Y0_3_AREA_DERIVADA_Tiempos.csv • Gráficos de distribución	VD0: • mean (promedio) • median (mediana) • Percentil (p90/p95) • max (maximo) • % timestamps válidos >95 • % trazabilidad >95
Y1 – Preprocesamiento y curación (D1)	Mejorar la calidad y estructura del texto y metadatos de las llamadas.	Dataset original: V.2 DATASET DE LLAMADAS A LA CENTRAL DE EMERGENCIAS CALLAO - MPC_Actualizado_22102024.xlsx (104,536 registros; 36 variables iniciales) incluidas: DESCRIPCION_OCURRENCIA, ASUNTO, FECHA_LLAMADA, HORA_DE_LLAMADA, FECHA_OCURRENCIA, HORA_OCURRENCIA, ZONA, TIPOLOGIA, Categoría, Sub-categoría).	VI1 – Curación y normalización del texto: • EDA sistemático (diagnóstico de calidad y distribución). • Selección de variables (36 → 7). • Limpieza y normalización lingüística. • Discretización/creación de rangos para fecha y hora (grupos temporales). • Trazabilidad mediante logs de transformación.	Y1 – Dataset curado y normalizado: dataset_analisis_limpieza_Y1.csv (7 variables base → 13 variables finales por normalización y discretización).	VD1 – Calidad del registro (Y1): • duplicados eliminados >80 • nulos eliminados >50 • variables unicas eliminadas • campos estandarizados >95: • completitud >95

Y2 – Representación semántica y partición (D2)	Representar el texto en forma numérica y preparar datos para clasificación.	Entrada Y2 = Salida Y1: dataset_analisis_limpieza_Y1.csv	VI2 – Representación semántica: • Construcción de TF-IDF. • Embeddings BETO (base). • Embeddings BETO (fine-tuned). • EDA (no supervisado). Tratamiento de nulos: • Imputación explícita “No especificada” en Sub-Categoría. • Eliminación de nulos en las demás variables. VC2 – Partición estratificada: 70/15/15 (train/val/test)	Y2 – Conjuntos listos para modelado: • train_Y2.csv • val_Y2.csv • test_Y2.csv + matrices embeddings BETO asociados.	VD2 – Calidad de representación: • F1 > baseline+10: • coherencia temática >0.6: • silhouette >0.2: • estabilidad embeddings
Y3 – Clasificación con manejo del desbalance (D3)	Clasificar llamadas en tipologías (8) incorporando estrategias explícitas de desbalance.	Entrada Y3 = Salida Y2: • train_Y2.csv, • val_Y2.csv, • test_Y2.csv + embeddings BETO fine tuning (P2).	VI3 – Clasificación supervisada con desbalance: • BETO fine-tuning • Estrategias: – Undersampling – Oversampling – Cost-sensitive learning • Evaluación sistemática por F1-macro (val/test). • Selección del mejor modelo en validación. • VC3: mismo protocolo de limpieza, tokenización y representación que Y1–Y2. • VC1: semillas fijas.	Y3 – Modelos y predicciones: • modelo_final_callao.joblib (BETO FT con manejo de desbalance). • Reportes de métricas por estrategia. • Predicciones de tipología por llamada (dataset con columnas: pred_tipologia, probabilidad).	VD3 – Precisión de clasificación: • F1-macro >0.75 • F1 minoritaria >15 • varianza F1 <2 p.p. • tiempo entrenamiento

Y4 – Módulo de estados y retroalimentación (D4)	Estructurar el ciclo operativo del incidente y registrar trazabilidad.	Entrada Y4 = Salida Y0 + Y3: • Y0_1_ESTADO_LLAMADA_Tiempos.csv • Y0_2_CONSULTA_REALIZADA_Tiempos.csv • Y0_3_AREA_DERIVADA_Tiempos.csv (Y0) • dataset_analisis_limpieza_Y1.csv (Y1) • train_Y2.csv / val_Y2.csv / test_Y2.csv (Y2) • modelo_final_callao.joblib (Y3) • Métricas y logs Y0–Y3. • Predicciones de Y3. • Campos operativos disponibles: ESTADO, ZONA, UBIGEO, SUPERVISOR, LOGRO, FECHA_CORTE	VI4 – Implementación del módulo inteligente: • Flujo Twilio → Express → FastAPI → LangGraph. • Clasificación operativa con Random Forest (sugerencia de categoría/unidad). • Respuesta asistida por LLM (OpenAI) con plantillas y solicitudes de datos faltantes. • Reglas de transición: creada → derivada → en atención → cerrada. • Persistencia estructurada de estados/eventos (BD/logs).	Y4 – Registro estructurado del ciclo operativo: • logs incidentes • tablas comparativas Y0 vs Y4	VD4 – Comparación eficiencia y trazabilidad: : • tiempo respuesta • tiempo cierre • reducción tiempo atención >30% • trazabilidad >95
--	--	---	---	--	---