UNIVERSIDAD NACIONAL DE INGENIERÍA

UNIDAD DE POSGRADO FACULTAD DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS / ESCUELA DE POSGRADO

TESIS:

"DEEP LEARNING PARA LA DETECCIÓN AUTOMÁTICA DE AVERÍAS EN RIELES DEL FERROCARRIL CENTRAL DEL PERÚ"

PARA OBTENER EL GRADO ACADÉMICO DE MAESTRO EN CIENCIAS CON MENCIÓN EN:

MAGISTER EN INTELIGENCIA ARTIFICIAL

ELABORADA POR:

[redacted]

[redacted]

> Dedicatoria

- Agradecimientos

ÍNDICE DE CONTENIDOS

Resumen. 8

INTRODUCCIÓN 9

CAPíTULO l. PLANTEAMIENTO DEL PROBLEMA 12

1.1 Diagnóstico 12

1.2 Identificación y Descripción del Problema de Estudio 14

1.2.1 Vías Férreas. 14

1.2.2 Rieles Ferroviarias. 16

1.2.3 Los rieles del Ferrocarril Central 17

1.2.4 Tipificación de las fallas y averías en Rieles. 18

1.3 Formulación del Problema 19

1.3.1 Limitaciones punto de vista de la realidad. 19

1.3.1 Formulación del Problema General. 20

1.3.2 Formulación de los Problemas Específicos 20

1.3.3 Justificación y Alcances 21

1.4 Objetivos 23

1.4.1 Objetivo general 23

1.4.2 Objetivos Específicos 23

1.5 Variables Independiente, Parámetros y Variables Dependientes. 24

1.6 Metodología 24

1.6.1 Tipo de investigación 24

1.6.2 Método de trabajo 25

1.6.3 Tipo de Diseño 26

1.6.4 Herramientas. 27

1.6.5 Población y Muestra 27

1.6.6 Técnicas e Instrumentos de Recolección de Datos 29

1.6.7 Técnicas e Instrumentos de Análisis y Procesamiento de Datos 29

CAPíTULO ll: MARCO TEóRICO 32

2.1 Antecedentes bibliográficos 32

2.1.1 A Review of Deep Learning Applications for Railway Safety. 32

2.1.2 Railway Track Deterioration Models: A Review of the State of the Art. 33

2.1.3 A systematic literature review of defect detection in railways using machine vision-based inspection methods. 34

2.1.4 Automatic Detection of Railway Faults Using Neural Networks: A Comparative Study of Transfer Learning Models and YOLOv11 35

2.1.5 Fault Detection from Images of Railroad Lines Using the Deep Learning Model Built with the Tensorflow Library. 36
2.1.6 Fault Detection and Semantic Segmentation on Railway Track Using Deep Fusion Model. 37
2.1.7 RAP-DETR: Enhancing RT-DETR for Railway Track Defect Detection. 38
2.1.8 Rail surface defect detection using a transformer-based network. 38
2.1.9 Railway Track Fault Detection with ResNet Deep Learning Models. 39
2.2 Bases Teóricas 40
2.2.1 Inteligencia Artificial (IA) y Machine Learning (ML) 40
2.2.2 Deep Learning (DL): 41
2.2.3 YOLO (You Only Look Once) 41
2.2.4 Real-Time Detection Transformer RT-DETR 43
2.2.5 ResNet50 y Faster R-CNN. 44
2.2.5 MLOps (Machine Learning Operations): 45
2.3 Definición de Términos 45
CAPITULO III: PROPUESTA Y DESARROLLO DE LA SOLUCIÓN 47
3.1 Presentación de la Propuesta de Solución 47
3.2 Desarrollo de la Propuesta de Solución 48
3.2.1 Construcción del conjunto de datos. 48
3.2.2 El aumentado de datos. 50
3.2.2 Preprocesamiento del conjunto de datos. 55
3.2.4 Diseñar, entrenar y optimizar los modelos. 56
3.3 Análisis de los Datos y Resultados 71
3.4 Discusión e Interpretación de los Resultados. 72
3.5 Estimación del Impacto de la Solución. 73
CAPITULO IV CONCLUSIONES Y RECOMENDACIONES 74
4.1 CONCLUSIONES 74
4.2 RECOMENDACIONES 75
REFERENCIAS 76
ANEXOS 77

LISTA ILUSTRACIONES

Figura 1: Toneladas métricas transportadas por el ferrocarril central del 2008 al 2023 9
Figura 2: Tipo de carga transportada por el Ferrocarril Central promedio del 2008 al 2023. 10
Figura 3: Variación en % de Exportaciones Mineras Metálicas Ene-Abr del 2024 y 2025 10
Figura 4: Incidencia Anual de descarrilamientos del 2001 al 2024. 12
Figura 5: Descarrilamientos de tren y vagones con ácido sulfúrico. 13
Figura 6: Descarrilamientos de tren en Arequipa. 13
Figura 7: Inspecciones de rutina en las vías férreas. 14
Figura 8: Componentes de la vía férrea. 15
Figura 9: La Eclisa. 15
Figura 10: Partes de un riel. 16
Figura 11: Mapa ontológico centrado en los rieles ferroviarios. 17
Figura 12: Tipo de averías en rieles ferroviarios 19
Figura 13: Clasificación de este proyecto de investigación según ACM 25
Figura 14: Esquema de trabajo basado en MLOps 25
Figura 15: Diagrama de alto nivel de la solución para el modelo de Deep Learning de detección de averías en rieles ferroviarios. 26
Figura 16: Dron - Instrumento para capturar la data de entrenamiento. 29
Figura 17: Segmentación de la avería en una imagen del riel ferroviario 31
Figura 18: Composición del software y hardware utilizado en el sistema de detección de defectos en rieles. 34
Figura 19: Arquitectura alto nivel del modelo Deep Fusion. 37
Figura 20: Inteligencia Artificial, Machine Learning y Deep Learning. 41
Figura 21: Arquitectura alto nivel de YOLOv8 y proceso de detección. 42
Figura 22: YOLOv11 Arquitectura. 42
Figura 23: Resumen de las principales mejoras arquitectónicas. 43
Figura 24: Resumen de la arquitectura RT-DETR. 44
Figura 25: Componente de la arquitectura Faster R-CNN Backbone ResNet. 45
Figura 26: MLOps Implementación de principios dentro de los componentes técnicos. 45
Figura 27: Propuesta de solución al problema principal planteado. 47
Figura 28: Mapa ontológico simplificado. 48
Figura 29: Imágenes recolectadas en los distritos de El Agustino y Ate. 49
Figura 30: Imagen de riel tomada en la costa con oxidación. 49
Figura 31: Imagen de riel tomada a medio día con sombras que podrían ocultar averías. 50
Figura 32: Imagen original vs Imagen Aumentada volteada Horizontalmente. 51
Figura 33: Imagen original vs Imagen Aumentada rotada 5 grados. 52
Figura 34: Imagen original vs Imagen Aumentada aplicando Clahe. 53
Figura 35: Imagen original vs Imagen Aumentada aplicando Corrección Gamma (bajar iluminación). 54
Figura 36: Imagen original vs Imagen Aumentada con división vertical. 54
Figura 37: Etiquetado de avería clase desprendimiento. 55
Figura 38: Distribución 80% para entrenamiento y 20% para validación estructura YOLO. 56
Figura 39: Métricas de desempeño ResNet50 a 30 épocas. 57
Figura 40: Matriz de confusión normalizada ResNet50 FasterRCNN a 30 épocas. 58
Figura 41: Métricas de desempeño YOLOv11m a 60 y 180 épocas. 59
Figura 42: Matriz de confusión normalizada de YOLOv11m a 60 épocas. 60
Figura 43: Matriz de confusión normalizada de YOLOv11m a 180 épocas. 61

Figura 44: Etiquetas para la validación del entrenamiento de YOLO. 61
Figura 45: Detección de averías en la etapa de validación durante el entrenamiento con YOLOv11m 60 épocas. 61
Figura 46: Detección de averías en la etapa de validación durante el entrenamiento con YOLOv11m 180 épocas. 62
Figura 47: Métricas de desempeño YOLOv8m a 60 y 180 épocas. 63
Figura 48: Métricas de desempeño curvas de perdida para YOLOv8 en cajas delimitadoras y clases. 63
Figura 49: Matriz de confusión normalizada de YOLOv8m a 60 épocas. 64
Figura 50: Matriz de confusión normalizada de YOLOv8m a 180 épocas. 65
Figura 51: Métricas de desempeño RT-DETR a 45 y 90 épocas. 66
Figura 52: Matriz de confusión normalizada de RT-DETR a 45 épocas. 67
Figura 53: Matriz de confusión normalizada de RT-DETR a 90 épocas. 68
Figura 54: Etiquetas para la validación del entrenamiento de RT-DETR. 69
Figura 55: Detección de averías en la etapa de validación durante el entrenamiento con RT-DETR 45 épocas. 70
Figura 56: Detección de averías en la etapa de validación durante el entrenamiento con RT-DETR 90 épocas. 71

LISTA DE CUADROS

Tabla 1: Costos de explotación de bienes del Ferrocarril Central. 14
Tabla 2: Tipos de Rieles AREMA. 17
Tabla 3: Longitud del Ferrocarril Central. 28
Tabla 4: Variables y medición para el proceso de la data. 29
Tabla 5: Técnicas de análisis y procesamiento a las imágenes de rieles ferroviarios 30
Tabla 6: Instrumentos de análisis y procesamiento de imágenes de rieles ferroviarios 30
Tabla 7: Áreas del sistema ferroviario con aplicaciones de inteligencia artificial. 32
Tabla 8: Modelos de Machine Learning usados en áreas específicas del sistema ferroviario. 33
Tabla 9: Métodos de Visión Artificial para la Detección de Defectos en Componentes Ferroviarios. . 35
Tabla 10: Rendimiento de modelos pre-entrenados considerados para el aprendizaje por transferencia. 36
Tabla 11: Comparación del estudio realizado por los autores con otros similares. 37
Tabla 12: Métricas de modelos de detección de objetos comparados en la investigación. 38
Tabla 13: Resultados experimentales de comparación de algoritmos convencionales. 38
Tabla 14: Métricas obtenidas en el entrenamiento y su comparación con otros modelos. 39
Tabla 15: Métricas obtenidas en el entrenamiento de modelos ResNet. 40
Tabla 16: Definición de términos relacionados a Aprendizaje Profundo. 46
Tabla 17: Términos de visión por computador usado en esta investigación. 46
Tabla 18: Métricas obtenidas durante el entrenamiento de RT-DETR. 66
Tabla 19: Métricas obtenidas comparación ente modelos ResNet50, Yolo y RT-DETR. 72
Tabla 20: Matriz de Consistencia Problemas, Objetivos, Hipótesis y variables. 3

Resumen.

La investigación se originó en la necesidad crítica de automatizar la inspección en el Ferrocarril Central, enfrentando limitaciones técnicas que impedían la aplicación de sistemas de visión estándar, y fue abordada mediante una estrategia metodológica incremental que resolvió cada desafío específico. En primer lugar, la ausencia de un conjunto de datos representativo de la compleja geografía peruana se superó mediante una adquisición estratificada de imágenes en distintos pisos altitudinales y horarios, complementada con la aplicación de Transfer Learning inductivo para estabilizar el aprendizaje con datos limitados. Posteriormente, la dificultad de detectar fisuras sutiles y de bajo contraste se resolvió con técnicas avanzadas de procesamiento de imagen, como CLAHE para realzar bordes y la División Vertical para simular oclusiones, además de sustituir el etiquetado rectangular por poligonal, lo que permitió a la red concentrarse en la morfología de las fallas. En tercer lugar, se identificó la incompatibilidad geométrica de arquitecturas tradicionales como Faster R-CNN, incapaces de encapsular defectos lineales debido a su dependencia de cajas de anclaje, lo que motivó la migración hacia modelos modernos sin anclas. Finalmente, el equilibrio entre precisión y velocidad se alcanzó con la implementación de RT-DETR que supero a YOLOv8 y YOLOv11 gracias a que cuenta con una arquitectura anchor-free basada en mecanismos de atención, que ejecutada sobre hardware de alto rendimiento (NVIDIA A100) logró un mAP@50 de 0.7047, demostrando que la comprensión global de la imagen supera a la convolución local en entornos ferroviarios complejos y consolidando una herramienta robusta y viable para garantizar la seguridad operativa.

INTRODUCCIÓN

En esta sección se presenta la importancia del sistema ferroviario, seguido de la situación de este medio de transporte de Perú especialmente en el Ferrocarril Central dedicado principalmente al transporte de minerales y finalmente se describe el propósito de esta investigación la detección de averías en las vías férreas usando modelos de Deep Learning y redes neuronales convolucionales.

El sistema ferroviario es un elemento crucial en el transporte por tierra, siendo un elemento vital para alcanzar cadenas de abastecimiento sostenibles y eficaces. El transporte por ferrocarriles se distingue no solo por su logística de funcionamiento, sino también por su efecto beneficioso en el ambiente y la economía mundial. Su importancia se basa en tres elementos clave: primero sus costos reducidos proporcionando una alternativa asequible para el traslado de bienes; segundo es amigable con el medio ambiente ya que produce menos emisiones de CO2 al utilizar menos energía por tonelada-kilómetro y tercero su capacidad y descongestión urbana facilitando el traslado de grandes cantidades de carga en periodos de tiempo limitados reduciendo el tráfico trasladando grandes volúmenes de materias primas y productos manufacturados de manera rápida y segura situándose como una solución esencial para sectores industriales con gran cantidad de operaciones (Kamran et al., 2022).

El sistema ferroviario en el Perú juega un papel importante en el desarrollo de diversos sectores económicos principalmente del sector minero de la zona central peruana. El Ferrocarril Central desde el año 2008 ha tenido un crecimiento sostenido en el transporte de minerales y desde el 2015 ha superado la barrera de los 2.5 millones de toneladas transportadas en promedio anualmente de concentrado de cobre, zinc y otros productos (Organismo Supervisor de la Inversión en Infraestructura de Transporte de Uso Público, s. f.) (Gerencia de Regulación y Estudios Económicos, 2025) tal como se puede ver en la figura 1. Para Mantener en constante funcionamiento esta importante infraestructura ferroviaria hace falta mecanismos nuevos de supervisión ya que, comúnmente, la inspección de rieles es realizada mediante procedimientos manuales o semiautomáticos, los cuales son lentos, costosos, subjetivos y susceptibles a fallos humanos, particularmente en extensas redes de trenes como las del Ferrocarril Central (*Estandares Minimos - Directiva N° 01-2007-MTC/14*, 2007).

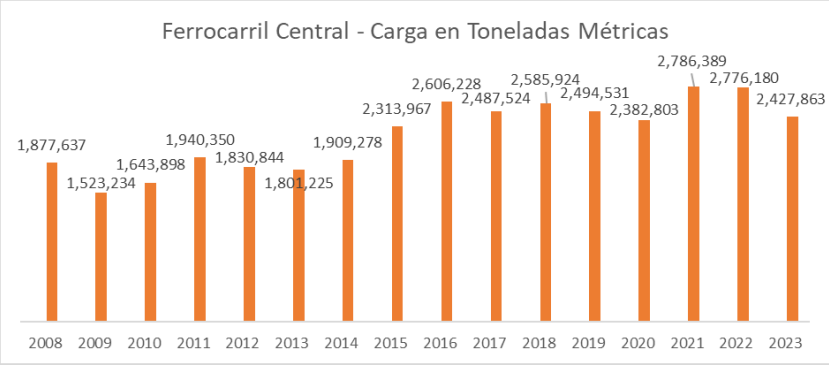


Figura 1: Toneladas métricas transportadas por el ferrocarril central del 2008 al 2023
Fuente: Organismo Supervisor de la Inversión en Infraestructura de Transporte de Uso Público (OSITRAN)[2].

En la figura 2 se muestra los productos principales que se transportan en el Ferrocarril Central desde el 2008 al 2023, en primer lugar, encontramos el concentrado de cobre con 31% en promedio, seguido del ácido sulfúrico con un 21% el cual es usado para la separación de los minerales de la roca y tercero el concentrado de zinc con un 20% y finalmente un 28% de varios productos como concentrado de plomo, cemento y cal viva (Ositran, 2023) (Gerencia de Regulación y Estudios Económicos, 2025).

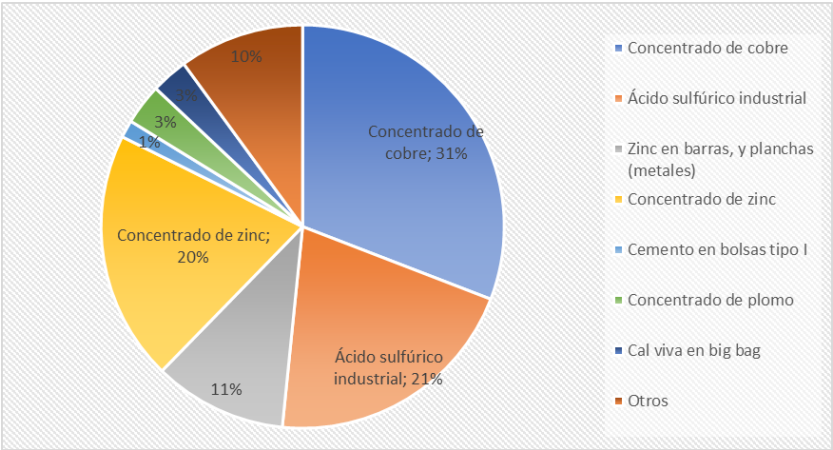


Figura 2: Tipo de carga transportada por el Ferrocarril Central promedio del 2008 al 2023.
Fuente: Organismo Supervisor de la Inversión en Infraestructura de Transporte de Uso Público [2].

Considerando los meses de enero a abril del año 2024 y 2025 las exportaciones mineras se han incrementado, especialmente las explotadas en la sierra central del Perú las cuales mantienen un crecimiento constante, el zinc y el cobre obtuvieron un 15.5% y 36.0% de crecimiento, tal como se puede ver en la figura 3 según el Ministerio de Energía y Minas (Ministerio de Energía y Minas, 2025). Estos números de manera indirecta reflejan la importancia de tener un sistema ferroviario en constante operación.



Figura 3: Variación en % de Exportaciones Mineras Metálicas Ene-Abr del 2024 y 2025
Fuente: Ministerio de Energía y Minas en su Boletín Estadístico Minero de mayo del 2025 [5].

Para que el transporte ferroviario de minerales no se detenga es necesario aplicar tecnología de vanguardia para asegurar su funcionamiento por lo tanto esta investigación se enfocará en la detección de averías en los rieles ferroviarios que son parte fundamental de este tipo de transporte debido a que guían y dan estabilidad a los trenes y vagones. Los rieles del Ferrocarril Central están hechos de acero que están sometidas a diversos factores como: las cargas pesadas, vibraciones , factores ambientales y operacionales que provocan un deterioro progresivo los cuales se manifiestan en grietas, fisuras, desprendimiento, desalineación, corrosión y desalineación (*Estandares Minimos - Directiva N° 01-2007-MTC/14*, 2007). Si estas averías no son identificadas y solucionadas oportunamente pueden provocar accidentes, descarrilamientos de tren con serias repercusiones, interrupciones paralizando el servicio y altos costos de mantenimiento.

Un mecanismo innovador para la detección de averías y fallas que se está aplicando en el sector transporte y en especial al sistema ferroviario es la Inteligencia Artificial (IA), una definición elemental de IA es dotar a una máquina de la inteligencia humana. Explicado de forma práctica la IA consiste en permitir que dispositivos electrónicos como las computadoras o celulares con la capacidad de realizar tareas y procesos que normalmente requerirían inteligencia humana como: interpretar imágenes, leer, analizar datos y resolver problemas (Szeliski, 2022). Uno de los campos de la IA que ha ganado popularidad gracias a que hay más recursos computacionales es la Visión por Computador (VC) que

engloba modelos que interpretan, aprenden y toman decisiones basados en contenido multimedia visual como imágenes y videos. Los modelos de VC usan redes neuronales convolucionales (CNN), esta red neuronal que tiene cientos de miles de nodos pueden procesar millones de parámetros y grandes cantidades de datos que les permite la capacidad para encontrar representaciones complejas directamente de imágenes o videos facilitando la identificación, segmentación y categorización de objetos o patrones con gran exactitud (Szeliski, 2022).

Este proyecto de investigación tiene como objetivo el diseño de un modelo de redes neuronales convolucionales (CNN) para identificar fallos en los rieles del Ferrocarril Central del Perú con el propósito de colaborar con la seguridad para evitar accidentes, el modelo ofrecerá información oportuna para el mantenimiento correctivo de las averías. En este contexto, se ha optado por utilizar modelos de Deep Learning especializados en visión por computador.

CAPITULO I. PLANTEAMIENTO DEL PROBLEMA

1.1 Diagnóstico

Los sistemas ferroviarios son complejos y vulnerables a interrupciones causadas por desastres naturales, condiciones climáticas, factores operacionales y errores humanos. Este tipo de transporte no solamente son cruciales para el traslado de personas y mercaderías, sino que son también el reflejo del desarrollo y modernización de un país. El Ferrocarril Central enfrenta desafíos para mantener las vías férreas en buen estado debido a que el conjunto de componentes que integran su sistema está sujetos a múltiples factores que causan grietas, fisuras, rotura de soldaduras defectuosas, desalineamientos o la falta de algún componente esencial (*Estandares Minimos - Directiva N° 01-2007-MTC/14*, 2007). Las consecuencias de no adoptar una detección automática de estas averías y un mantenimiento oportuno son los descarrilamientos, accidentes y paralizaciones

El número de descarrilamientos puede proporcionar una visión parcial sobre el estado de la vía, ya que estos incidentes no solo están relacionados con defectos en la infraestructura ferroviaria, sino que también pueden ser consecuencia de la suma de varios factores como condiciones operativas, fenómenos climáticos adversos o maniobras inapropiadas por parte del operador de la locomotora (Gerencia de Regulación y Estudios Económicos, 2025). Según el OSITRAN organismo que regula el transporte público los descarrilamientos en el Ferrocarril Central al 2024 se incrementaron significativamente en un 166,7 %, al pasar de 3 a 8 eventos con respecto al 2023 (Gerencia de Regulación y Estudios Económicos, 2025). Tal como se puede ver en la figura 3. Estos descarrilamientos, aunque relativamente pocos ocasionan grandes pérdidas económicas y sociales llegando a perderse incluso vidas humanas.

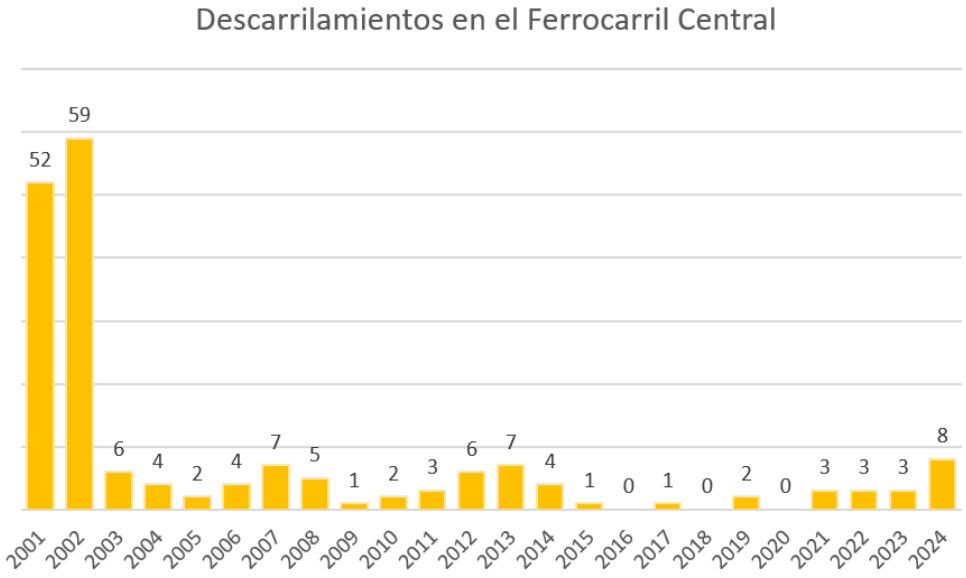


Figura 4: Incidencia Anual de descarrilamientos del 2001 al 2024.
Fuente: Informe de desempeño 2024 – OSITRAN [3].

Un accidente que sucedió el junio del 2012 fue el descarrilamiento de dos vagones del tren que transportaban ácido sulfúrico este hecho aconteció en el concurrido distrito limeño de Ate Vitarte se presume que algunos pernos de los rieles habrían sido sustraídos lo que ocasionó una inestabilidad de la vía férrea provocando que los vagones salieran de su carril y colisionaron contra una vivienda. El ferrocarril no solo transporta minerales sino también cargas peligrosas

usados en la minería que requiere un transporte seguro sin poner en riesgo la salud pública. En este hecho afortunadamente no hubo víctimas mortales solo pérdidas materiales.



Figura 5: Descarrilamientos de tren y vagones con ácido sulfúrico.
Fuente: Andina Agencia Peruana de Noticias - publicado en junio 2012 .

Estos accidentes traen muchas consecuencias como la paralización parcial o total de las vías férreas que pueden tomar horas o hasta días en resolver retrasando la actividad económica del sector minero ya que normalmente el Ferrocarril Central del Perú depende de una sola vía.



Figura 6: Descarrilamientos de tren en Arequipa.
Fuente: Andina Agencia Peruana de Noticias - publicado en enero de 2025.

Otra problemática relacionada a la no detección oportuna de averías en las vías férreas son los altos costos. Según el informe de desempeño para el 2024 hubo un incremento del 10.2% con respecto al 2023 en materiales para operación, seguridad y otros. Así mismo, el material de mantenimiento de vías tuvo un incremento del 326.7% tomando como referencia el año 2023 (Ministerio de Energía y Minas, 2025) datos que se pueden ver en el cuadro 1. Estos incrementos guardan relación con el aumento de descarrilamientos al 2024 mostrados anteriormente en la figura 4.

Costo de explotación de bienes en concesión, 2023 – 2024			
Categoría	**Consumo 2024 (Miles de soles)**	**Consumo 2023 (Miles de soles)**	**Variación (%)**
Combustibles y lubricantes	367	418	-12,1%
Material de mantenimiento mecánico	89	106	-15,6%
Materiales para operación, seguridad y otros	114	103	10,2%
Repuestos y accesorios para autovías, camiones y otros	57	57	-0,6%
Materiales de servicio de ingeniería	29	-	-
Repuestos de autovagones, coches y vagones	13	10	38,1%
Material de mantenimiento de edificios e instalaciones	7	4	61,3%
Material de mantenimiento de vías	4	1	326,7%
Repuestos y accesorios para locomotoras	1	0	184,4%

Tabla 1: Costos de explotación de bienes del Ferrocarril Central.
Fuente: Informe de desempeño 2024[3]

Parte de esta problemática también se origina en la dependencia de inspecciones visuales, manuales y generalmente retardadas, lo que limita la capacidad de detección oportuna de averías. Esta limitación se acentúa en el caso del Ferrocarril Central, una extensa ruta de aproximadamente 489 kilómetros que atraviesa diversos pisos altitudinales, desde la costa hasta alcanzar los 4,835 metros sobre el nivel del mar en la sierra central. Bajo estas condiciones geográficas y climáticas extremas, resulta especialmente complejo llevar a cabo inspecciones efectivas sin el apoyo de tecnologías adecuadas (*Estandares Minimos - Directiva N° 01-2007-MTC/14*, 2007).

Inspecciones de rutina realizadas en el campo para la verificación de componentes y la geometría de la vía férrea se muestran en la figura 8.



Figura 7: Inspecciones de rutina en las vías férreas.
Fuente: Directiva N° 01-2007-MTC/14 [4]

1.2 Identificación y Descripción del Problema de Estudio

1.2.1 Vías Férreas.

La vía férrea está integrado y trabaja en sinergia con diversos componentes como: Las rieles que están compuestos de un perfil laminado de acero por donde se deslizan las ruedas de los trenes; los rieles son fijadas a las durmientes mediante sujeciones o ganchos; los durmientes son de madera o concreto de acuerdo a su uso o entorno sirven como puentes entre los rieles y el balasto; el balasto es la capa de piedra chancada que se esparce debajo de las durmientes

sirven como amortiguador, como absorbente de vibraciones, drenaje y distribuidor de las cargas; el subbalasto es una capa granular que se sitúa debajo del balasto que ayuda a incrementar la vida útil de la vía al mantenerlo compactado para evitar deformaciones; el subsuelo es el terreno natural o tratado donde se apoya toda la infraestructura; la plataforma es una base compactada y nivelada (*Estandares Minimos - Directiva N° 01-2007-MTC/14*, 2007).

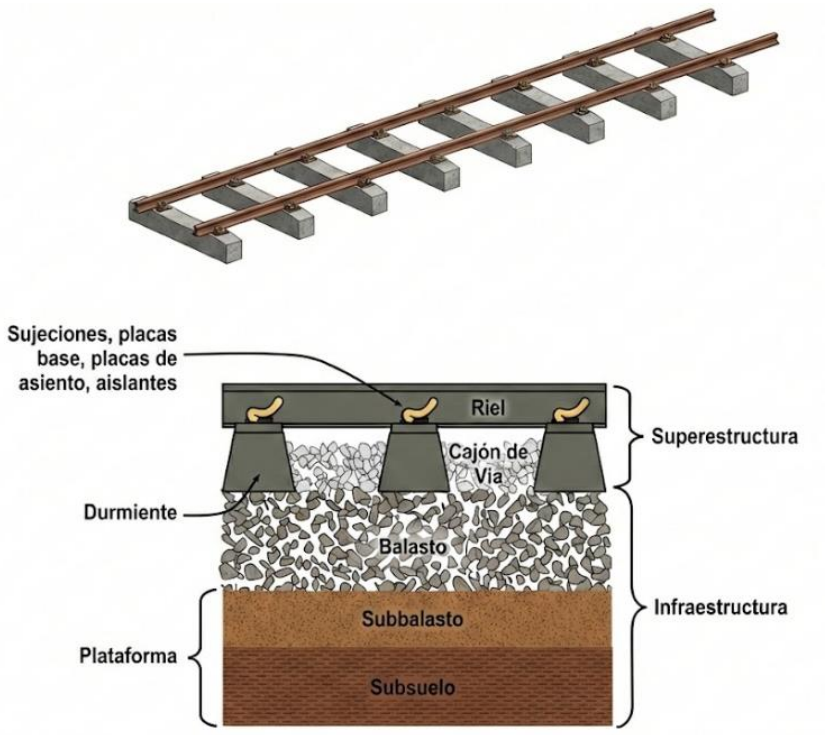


Figura 8: Componentes de la vía férrea.
Fuente: Elaboración Propia.

En vías férreas se denomina eclisas o bridas a los elementos utilizados para la unión de carriles conectándolos firmemente mediante pernos para crear una línea continua y segura, soportando cargas, reduciendo el impacto del tren y manteniendo la distancia correcta entre carriles.

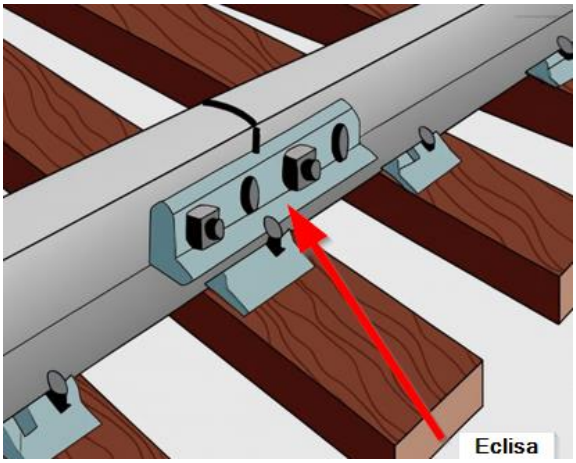


Figura 9: La Eclisa.
Fuente: Elaboración Propia.

1.2.2 Rieles Ferroviarias.

Las partes principales de un riel ferroviario son la cabeza (o hongo), el alma y el patín. La cabeza es la parte superior que entra en contacto con las ruedas del tren, el patín es la base que se apoya en las durmientes, y el alma es la sección que une la cabeza y el patín.

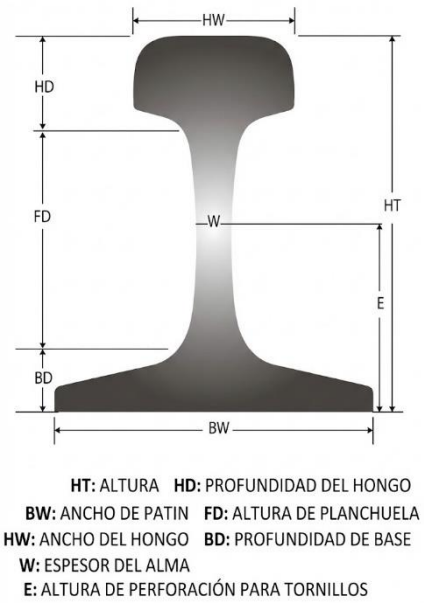


Figura 10: Partes de un riel.
Fuente: AREMA

En el siguiente mapa ontológico se indican las entidades relacionadas a los rieles ferroviarios como su tipología, fallos comunes, modo de inspección entre otros (ver figura 10).

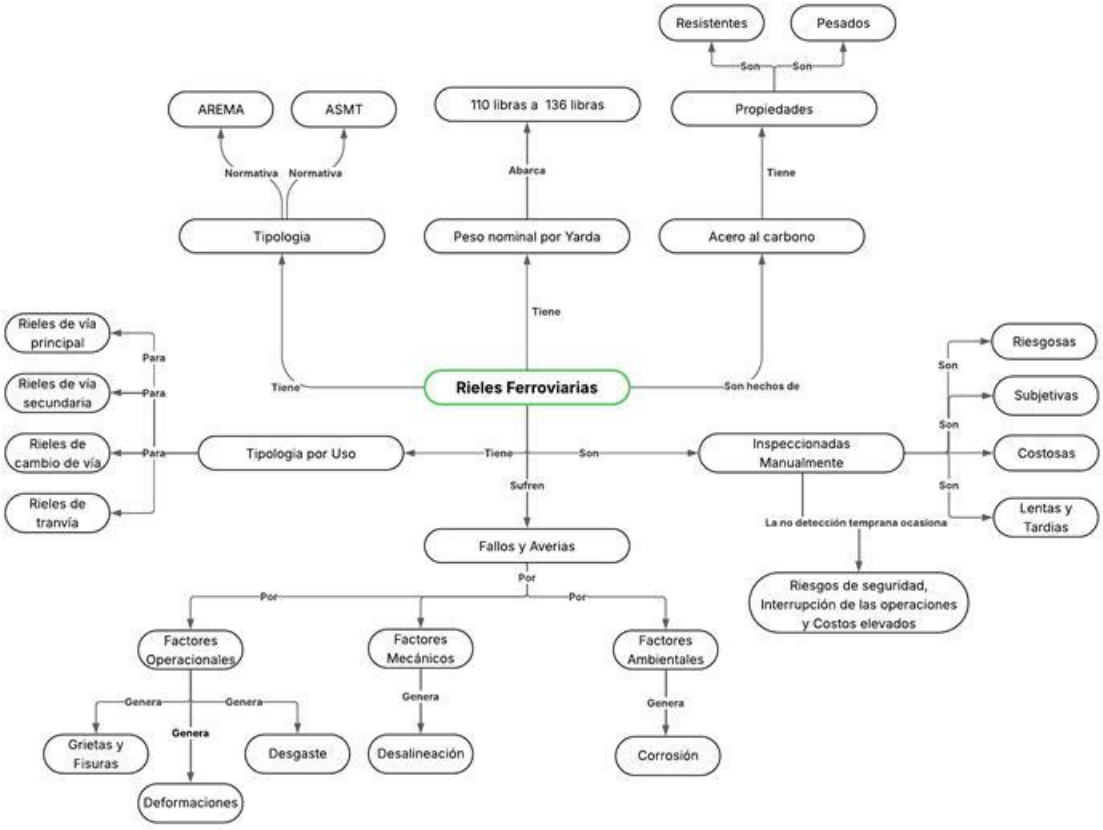


Figura 11: Mapa ontológico centrado en los rieles ferroviarios.
Fuente: Elaboración propia.

1.2.3 Los rieles del Ferrocarril Central

El riel 115RE, empleado en la vía principal por donde circulan los trenes, es un tipo de riel pesado fabricado en acero, con un peso de 115 libras por yarda (Ositran, 2016), equivalente a aproximadamente 57.1 kg por metro. Su uso es común tanto en el transporte de carga como en el de pasajeros, destacando por su alta resistencia y durabilidad, lo que lo hace especialmente adecuado para soportar cargas intensas y condiciones operativas exigentes.

Su composición de acero al carbono de alta resistencia, ofrece gran resistencia al desgaste y estabilidad en la conducción. Cumple con los estándares de la Asociación Americana de Ingeniería Ferroviaria y Mantenimiento de Vías (AREMA) y se instala sobre durmientes de hormigón o madera, asegurando un rendimiento óptimo.

TIPO DE RIEL: AREMA											
PESO NOMINAL POR YARDA	HT	BW	HW	H	HD	FD	BD	E	SECCION DEL RIEL		
100 lb	6	5 3/8	2 11/16	9/16	1 21/32	3 9/32	1 1/16	2 45/64	10025	100RE	
115 lb.	6 5/8	5 1/2	2 23/32	5/8	1 11/16	3 13/16	1 1/8	2 7/8	11525	115RE	TR57
112 lb.	6 5/8	5 1/2	2 23/32	19/32	1 11/16	3 13/16	1 1/8	2 7/8	11228	112RE	1121
136 lb.	7 5/16	6	2 15/16	11/16	1 15/16	4 3/16	1 3/16	3 3/32	13625	136RE	1360/TR68

Tabla 2: Tipos de Rieles AREMA.

Fuente: Elaboración Propia

1.2.4 Tipificación de las fallas y averías en Rieles.

Grietas: Son defectos que comprometen la seguridad de la vía férrea. Pueden ser: horizontales y verticales. Las grietas horizontales se originan en el interior del hongo o cabeza y avanzan lateralmente, mientras que las verticales atraviesan el centro de la cabeza del riel. (*Estandares Minimos - Directiva N° 01-2007-MTC/14*, 2007).

Fisuras compuestas: Es una fisura horizontal pero que sigue su curso también de forma vertical en dirección arriba o abajo. Las fisuras compuestas requieren la inspección de ambos lados de la fractura para localizar la grieta horizontal superior desde la cual inicia. (*Estandares Minimos - Directiva N° 01-2007-MTC/14*, 2007).

Fisuras transversales: Es una fractura transversal progresiva que comienza en la parte central comprometiendo el alma del riel en dirección a la cabeza u hongo donde se propaga al exterior como una superficie. (*Estandares Minimos - Directiva N° 01-2007-MTC/14*, 2007).

Desprendimiento: Es una forma de daño superficial en los rieles que se manifiesta como desprendimientos o cavidades ovaladas o circulares en la cabeza del riel.

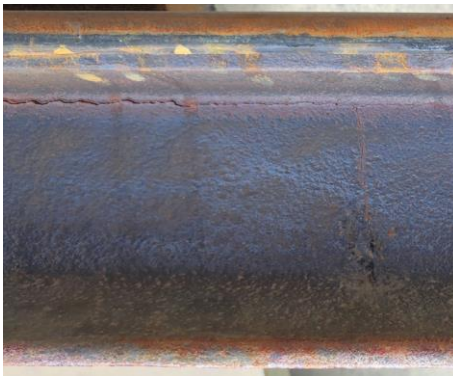
Grieta en Eclisa: La grieta en eclisa se manifiesta como una rajadura tiene el mismo patrón de las grietas y fisuras de riel, este tipo de defecto reduce la tensión de apriete en las uniones de dos rieles.

Eclisa sin pernos: Es el vacío dejado por un perno ausente. El perno debidamente instalado y en conjunto con eclisa son los encargados de mantener la continuidad y alineación entre dos rieles.

En la figura 11 se muestran las diferentes averías que afectan a los rieles ferroviarios.



Grieta Riel



Fisura Riel



Desprendimiento



Eclisa sin perno



Grieta en Eclisa.



Otros

Figura 12: Tipo de averías en rieles ferroviarios
Fuente: Elaboración propia.

1.3 Formulación del Problema

1.3.1 Limitaciones punto de vista de la realidad.

1.3.1.1 Relacionadas con los Datos.

Escasez y Calidad de Datos: Una barrera recurrente es la falta de conjuntos de datos grandes, diversos y bien etiquetados. Muchos estudios se basan en conjunto de datos pequeños, de laboratorio/simulación o con datos desbalanceados (muchas imágenes normales vs. pocas con defectos) . Esto dificulta el entrenamiento de modelos robustos y propicia el sobreajuste (overfitting). La calidad de las imágenes también es un problema, viéndose afectada por ruido, baja resolución o artefactos (Min et al., 2022; Oh et al., 2022; Rodríguez-Abreo et al., 2025) (Hadj-Mabrouk, 2025).

Falta de Variedad Contextual: Los conjunto de datos a menudo carecen de representatividad de las condiciones operativas reales. Faltan imágenes bajo diversas condiciones climáticas (lluvia, nieve) y de iluminación (día/noche, túneles, sombras, reflejos) , lo que limita la generalización y robustez de los modelos. Además, la apariencia de los componentes puede variar regionalmente (Min et al., 2022; Oh et al., 2022; Rodríguez-Abreo et al., 2025) (Hadj-Mabrouk, 2025).

1.3.1.2 Desafíos ambientales.

Entornos Complejos y Variables: Las vías férreas operan en exteriores hostiles. Factores como suciedad, óxido, pintura descascarada o vegetación pueden ocultar defectos o ser confundidos con ellos (falsos positivos). Las vibraciones del tren también introducen ruido en los datos (Kumar & Harsha, 2024) (Oh et al., 2022).

1.3.1.2 Dificultades Inherentes a los Defectos.

Variedad y Sutileza de Defectos: Las averías presentan una gran variedad de formas, tamaños y texturas , desde defectos pequeños, sutiles o delgados (como fisuras) hasta daños más extensos. La detección de objetivos pequeños u ocluidos densamente es un desafío particular. A menudo hay una pequeña diferencia visual entre el defecto y el fondo (el riel normal, balasto, etc.) , especialmente con interferencias como óxido o suciedad (Min et al., 2022; Wang et al., 2024).

1.3.1.2 Limitaciones de los Algoritmos y Hardware.

Limitaciones de los Algoritmos y Hardware: Algunos modelos, aunque precisos (ej. Yolo versión m, DETR), pueden ser computacionalmente costosos y lentos , lo que dificulta su despliegue en tiempo real o en hardware con recursos limitados (como drones o sistemas embarcados)(Min et al., 2022; Xie et al., 2025).

1.3.1 Formulación del Problema General.

La escasez de conjuntos de datos públicos, diversos y debidamente etiquetados que representen las condiciones operativas, geográficas y climáticas específicas de la red ferroviaria del país. Y por ende los modelos no pueden generalizar de manera robusta más allá de los entornos controlados de laboratorio, limitando su capacidad para una detección automática, precisa y en tiempo real de un espectro amplio de averías estructurales y, por ende, comprometiendo su aplicabilidad práctica para la seguridad ferroviaria. (Kumar & Harsha, 2024) (Oh et al., 2022) (Wang et al., 2024) (Hadj-Mabrouk, 2025).

1.3.2 Formulación de los Problemas Específicos

Para abordar el problema general para la detección oportuna de averías en rieles ferroviarias usando Deep learning, se desglosan los siguientes problemas específicos:

1.3.2.1 Problema específico 1

Disponibilidad de conjunto de datos: El proceso completo de adquisición, análisis, estructuración, formalización e interpretación de datos representa un "problema crucial" en el transporte ferroviario (Hadj-Mabrouk, 2025).

1.3.2.2 Problema específico 2

Datos incompletos, desbalanceado y sin etiquetas: El diseño y desarrollo de modelos de Deep Learning se ve desafiado por "limitaciones prácticas en el volumen o la calidad de los datos" y por la insuficiencia de "datos etiquetados". La disponibilidad de datos y la escasez de datos etiquetados son barreras importantes para la adopción de estos métodos de detección automática (Hadj-Mabrouk, 2025) (Oh et al., 2022). La falta de variedad de imágenes bajo diversas condiciones climáticas no aporta a la robustez ni generalización (Kumar & Harsha, 2024).

1.3.2.3 Problema específico 3

Configuración y entrenamiento del modelo de Deep Learning y visión por computador para la detección de averías: Validación arquitecturas de Redes Neuronales Profundas, principalmente a través de transfer learning y modelos de detección de objetos adaptados para clasificación, sus respectivos optimizadores, funciones de perdida, épocas y capas [2].

1.3.2.4 Problema específico 4

Analizar resultados, la robustez y generalización del modelo entrenado: Muchos estudios se realizan con datos de simulación o de laboratorio, por lo que "se necesita una validación in situ para la aplicación práctica". Los datos reales pueden contener condiciones "más diversas y complejas que rara vez se cubren en los experimentos de laboratorio".[3]

1.3.3 Justificación y Alcances

1.3.3.1 Justificación

La presente investigación se justifica desde varias perspectivas:

Ineficacia de la Inspección Manual: Las inspecciones manuales son lentas, costosas y propensas a errores humanos y subjetividad. Por lo tanto, se requiere un sistema automatizado para evaluar con precisión las condiciones de la vía y prevenir descarrilamientos.(Rodríguez-Abreo et al., 2025).

Alto Riesgo de Fallas no Detectadas: Los accidentes ferroviarios pueden causar "daños inmensos" , y el mantenimiento de la infraestructura es "desafiante y costoso". Esto subraya la urgencia de encontrar métodos de detección más efectivos. (Oh et al., 2022).

Viabilidad del Deep Learning: Múltiples estudios confirman que los modelos de Deep Learning son una solución prometedora. Arquitecturas como YOLOv11 y modelos de transfer learning como VGG16 han demostrado una alta precisión (superiores al 89% y 92% respectivamente) en la clasificación de fallas. Específicamente, se han usado redes neuronales convolucionales profundas (DCNN) para detectar automáticamente defectos en la superficie de los rieles a partir de imágenes (Hadj-Mabrouk, 2025; Rodríguez-Abreo et al., 2025).

Relevancia Social y Seguridad Operacional: La detección temprana y precisa de averías en los rieles es un factor crítico para la seguridad de las operaciones ferroviarias. Accidentes causados por fallas en la vía pueden tener consecuencias sociales. Un sistema automático de detección de fallas en vías férreas reducirá drásticamente la ocurrencia de tales incidentes, protegiendo al personal, la carga y las vías.

Impacto Económico y Eficiencia Operacional: El Ferrocarril Central del Perú es una arteria vital para el transporte de minerales. Las interrupciones del servicio debido a averías no detectadas generan costos operativos elevados, retrasos en la cadena de suministro y pérdida de ingresos. La implementación de un sistema de detección automática basado en Deep Learning permitirá un mantenimiento predictivo y proactivo, optimizando la asignación de recursos, reduciendo los costos de reparaciones de emergencia y minimizando el tiempo de inactividad de la vía.

Innovación Tecnológica y Avance del Conocimiento: Este proyecto representa una aplicación de vanguardia de la Inteligencia Artificial en un sector crucial para el desarrollo de Perú. El uso de modelos de visión por computador, un modelo de última generación en detección de objetos, combinado con la integración de principios de MLOps, contribuirá al avance del conocimiento en la aplicación de Deep Learning en entornos industriales complejos.

Demostrará la viabilidad y el potencial de estas tecnologías para transformar las prácticas de inspección y mantenimiento en infraestructuras críticas.

Ventaja Competitiva y Modernización: La adopción de tecnologías avanzadas como el Deep Learning posicionará al Ferrocarril Central del Perú a la vanguardia de la innovación en infraestructura. Esto no solo mejorará la eficiencia interna, sino que también puede sentar un precedente para la modernización de otras redes ferroviarias en la región.

Alineación con las Tendencias Globales: La automatización de la inspección de infraestructuras mediante visión por computadora y IA es una tendencia global en la ingeniería y el mantenimiento. Esta investigación se alinea con esos esfuerzos, aprovechando los avances de la comunidad científica internacional para resolver un problema local específico y de gran impacto.

1.3.3.2 Alcances

Los alcances de esta investigación se definen de la siguiente manera:

Desarrollar un modelo de Redes Neuronales Convoluciones (CNN): Que tenga como fundamento la arquitectura YOLO para la identificación automática de averías en los rieles ferroviarios del Ferrocarril Central.

Enfoque en Detección de Objetos: El proyecto se centrará exclusivamente en la detección y clasificación de los seis tipos de averías definidos (grietas, fisuras, desprendimiento, desalineación, corrosión y desalineación) mediante la localización de sus cajas delimitadoras en imágenes

Modelo de Deep Learning YOLO: La investigación se limitará a la implementación y evaluación de la arquitectura YOLO, aprovechando sus capacidades de velocidad y precisión. Se realizarán las comparaciones entre los modelos v8 y v11 de YOLO.

Fuentes de Datos: Se buscará la colaboración con el Ferrocarril Central del Perú para la obtención de un conjunto de datos de imágenes reales. En caso de no ser posible la obtención de datos suficientes del entorno real, se hará uso de conjunto de datos públicos disponibles, reconociendo explícitamente esta limitación en la generalización directa de los resultados al contexto del Ferrocarril Central del Perú.

Validación en Entorno Controlado/Offline: La fase experimental del proyecto se realizará en un entorno de laboratorio/offline, donde el modelo será entrenado y evaluado utilizando el conjunto de datos de imágenes.

No incluye Desarrollo de Hardware: El proyecto no abarca el diseño ni la construcción de equipos de hardware de captura de imágenes (cámaras, soportes, sistemas de iluminación).

No incluye Intervención Correctiva: El sistema propuesto se enfocará únicamente en la detección y alerta de averías. La planificación y ejecución de las reparaciones o acciones correctivas en la vía no forman parte del alcance de esta investigación.

1.4 Objetivos

1.4.1 Objetivo general

Diseñar y validar un modelo optimizado basado en Deep Learning para la detección y clasificación multiclase de averías estructurales (fisuras, grietas y desprendimientos en rieles y grieta en eclisas y eclisas sin perno) en la infraestructura del Ferrocarril Central del Perú, utilizando un conjunto de datos original y contextualizado para superar las limitaciones de generalización y robustez identificadas en la literatura.

Métrica: El modelo debe de tener una precisión mínima de 90%.

Para representar el desempeño se usará la métrica de precisión.

Precisión (Precision): $P = \frac{TP}{FP+TP}$. Los verdaderos positivos entre el total de predicciones.

Métrica: El rendimiento global mAP@50 para considerar una predicción "correcta", la caja del modelo debe solaparse al menos un 50% (IoU >= 0.50) con la caja real.

1.4.2 Objetivos Específicos

1.4.2.1 Objetivo específico 1.

Construir un conjunto de datos de imágenes original y contextualizado para la red del Ferrocarril Central. Este objetivo aborda directamente la escasez de datos específicos para el Perú.

- **Recopilar** un corpus de imágenes representativo de las diversas condiciones geográficas y climáticas de la ruta (costa y sierra), asegurando una cobertura proporcional a los pisos altitudinales (Hadj-Mabrouk, 2025)(Kumar & Harsha, 2024; Oh et al., 2022).

  Métrica**:** 1,500 segmentos de riel (300 por cada clase de los cuales 150 con avería y 150 sin fallas) de los cuales se usará el 20% para validación

1.4.2.2 Objetivo específico 2.

Preprocesar un conjunto de datos. Este objetivo aborda directamente la escasez de datos específicos para sistema ferroviario peruano. Las acciones a realizar son:

- **Etiquetar** las imágenes con un esquema de clasificación claro para las averías de interés (fisuras, grietas, desprendimientos, etc.).
- **Aumentar y balancear** el conjunto de datos para mitigar el desequilibrio de clases y mejorar la capacidad de generalización del modelo (Kumar & Harsha, 2024; Wang et al., 2024).

  Métrica**:** Etiquetado por tipos de fallas (grietas, fisuras, desprendimiento, etc.)

1.4.2.3 Objetivo específico 3.

Diseñar, entrenar y optimizar modelos basados en Deep Learning para la detección de averías. Este objetivo se centra en la fase experimental de encontrar la mejor configuración. Las acciones son:

- **Seleccionar y adaptar** diferentes arquitecturas de *transfer learning* y modelos de detección de objetos que han demostrado ser efectivos en la literatura.
- **Definir y ajustar** los hiperparámetros clave del entrenamiento, incluyendo el optimizador (ej. Adam), la función de pérdida (*categorical cross-entropy*) y el número de épocas para cada arquitectura, con el fin de maximizar el rendimiento y evitar el sobreajuste.

  Métrica**:** La precisión al pintar el bounding box el IoU (Intersection Over Unión) de las cajas delimitadoras que rodean al objeto detectado.

1.4.2.4 Objetivo específico 4.

Validar la robustez y la capacidad de generalización del modelo optimizado en condiciones que simulen un entorno real. Este objetivo busca probar que el modelo no solo funciona con los datos de entrenamiento, sino que es viable para su aplicación práctica. Las acciones son:

- **Evaluar** el rendimiento del modelo final utilizando un conjunto de datos de prueba independiente y representativo de las condiciones del Ferrocarril Central.
- **Analizar** las métricas de rendimiento clave (precisión, *recall*, F1-score) para cuantificar su efectividad en la detección de cada clase de avería.
- **Comparar** los resultados con los obtenidos en la literatura para determinar la competitividad y viabilidad del modelo desarrollado.

  Métrica**:** La precisión con otros conjunto de datos públicos variará entre +5% y -5%.

1.5 Variables Independiente, Parámetros y Variables Dependientes.

La gestión rigurosa y la operacionalización de variables, tal como se plantea en la matriz de consistencia, constituyen el fundamento de la validez interna y externa de la investigación experimental en Inteligencia Artificial. Identificar y aislar las Variables Independientes (como la arquitectura o el *learning rate*) permite establecer una relación causal directa con el desempeño del modelo (Variables Dependientes como el mAP@50), garantizando que las mejoras observadas sean atribuibles a la solución técnica propuesta y no al azar o a factores de confusión. Asimismo, el control estricto de los Parámetros (hardware y condiciones de entrenamiento) asegura la reproducibilidad del estudio, permitiendo que otros investigadores repliquen los experimentos bajo las mismas restricciones técnicas. En el contexto de la seguridad ferroviaria, esta estructuración es vital para certificar que el modelo final es robusto no por casualidad, sino como resultado de una optimización sistemática frente a la variabilidad del entorno.

La matriz de operacionalización de variables y matriz de consistencia están detalladas en el Anexo 1.

1.6 Metodología

1.6.1 Tipo de investigación

De acuerdo a la Association for Computing Machinery (ACM) el problema de esta investigación es representado como un modelo de detección de objetos y patrones. El tipo de investigación será la aplicación usando modelos de Visión por Computador para la detección de averías en las vías férreas. En la siguiente figura 19 se muestra la clasificación del proyecto de investigación.

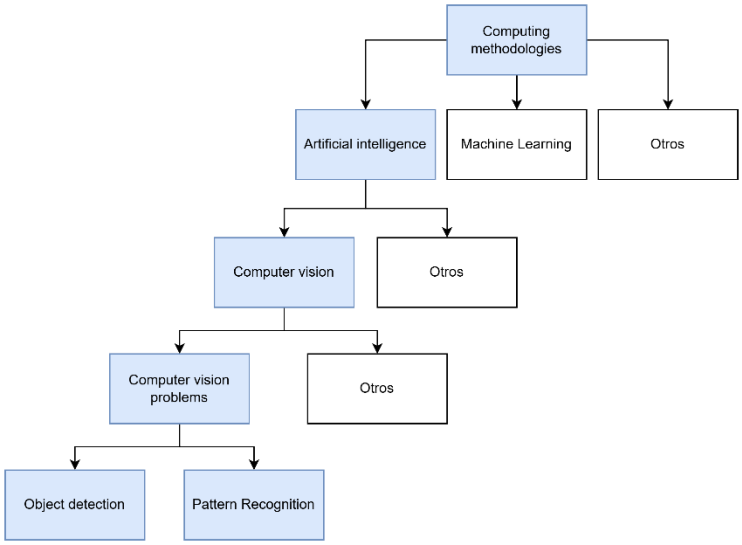


Figura 13: Clasificación de este proyecto de investigación según ACM
Fuente: Elaboración Propia (https://www.acm.org/)

1.6.2 Método de trabajo

La metodología de este proyecto se basará en un enfoque de investigación aplicada, siguiendo un ciclo de vida iterativo y adaptable, aplicando los principios y buenas prácticas recomendadas de MLOps con el propósito de asegurar la robustez y mantenibilidad de la solución. Se consideran las fases de planificación y recopilación de datos (i), preprocesamiento y etiquetado de la data (ii), diseño y entrenamiento del modelo (iii), evaluación y refinamiento del modelo (iv). Con el cumplimiento de estas fases se asegurará la calidad del modelo para la detección de averías en los rieles gracias a múltiples interacciones y una retroalimentación constante entre estas fases.

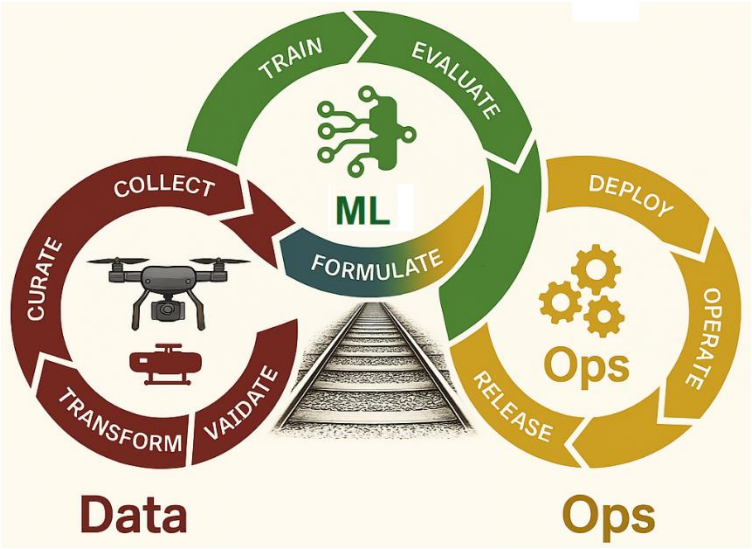


Figura 14: Esquema de trabajo basado en MLOps
Fuente: Propia

1.6.3 Tipo de Diseño

El diagrama de alto nivel del modelo de la solución para el modelo de Deep Learning de detección de averías en rieles ferroviarios, se representan los componentes interrelacionados cada uno con una actividad específica asociados a una entrada y una salida que su predecesor o antecesor necesita. Estos componentes son lo que se van a desarrollar e implementar para el presente proyecto de investigación.

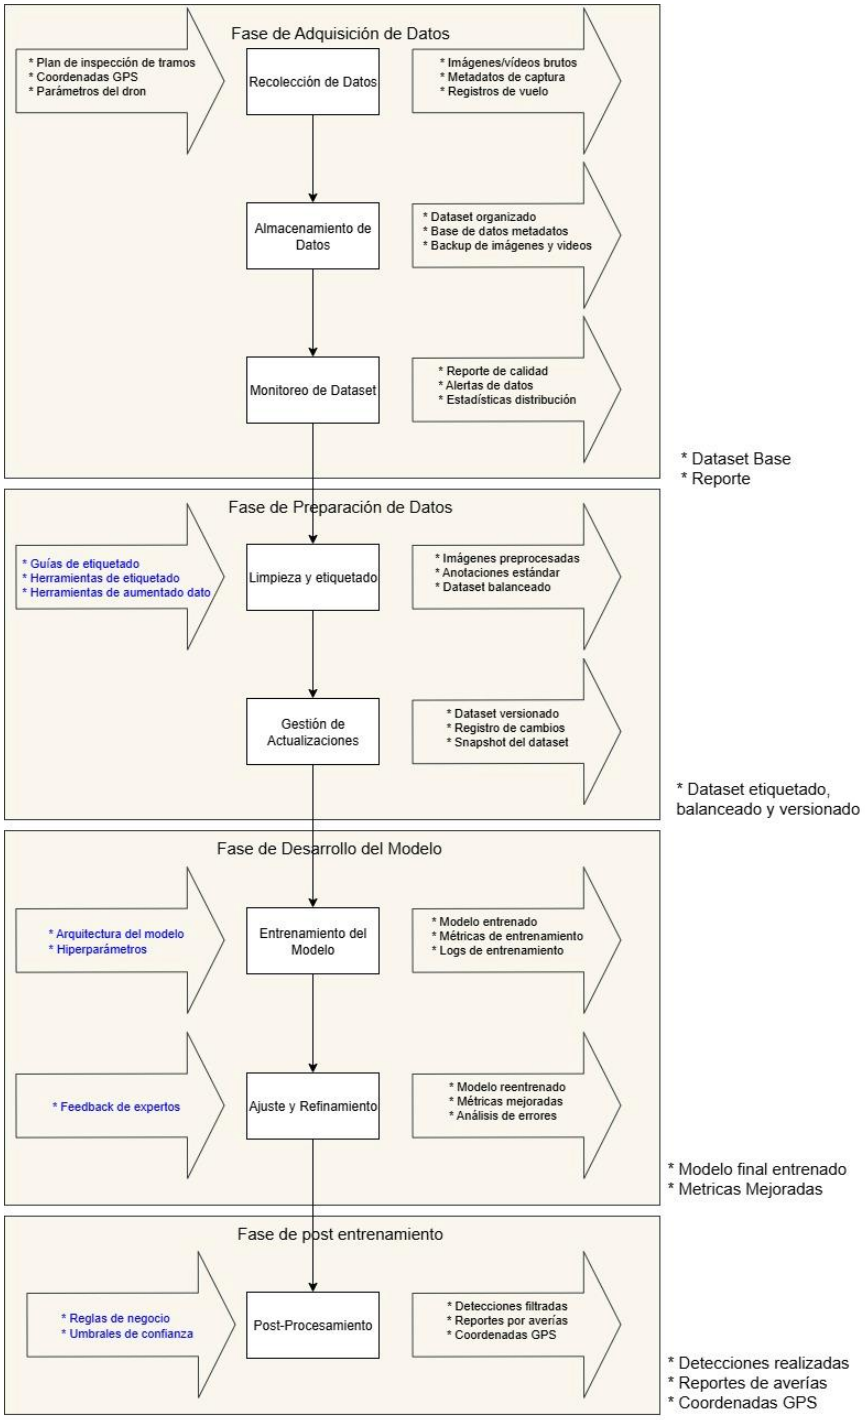


Figura 15: Diagrama de alto nivel de la solución para el modelo de Deep Learning de detección de averías en rieles ferroviarios.
Fuente: Elaboración Propia

1.6.4 Herramientas.

Dron DJI Air 2S: Dron compacto con autonomía de 10 km y batería de 1 hora. Permite capturar imágenes aéreas de alta resolución, ideal para inspección de rieles ferroviarios y detección de anomalías en grandes extensiones de infraestructura.

Cámara Sensor 64 MP + TeleMacro: Cámara de 64 megapíxeles para fotos claras y detalladas. Incluye sensor telemacro de 5 MP con autoenfoque, útil para capturar defectos en rieles a corta distancia (3–7 cm), asegurando precisión en la documentación visual de averías.

Visual Studio Code: Editor de código fuente ligero y extensible. Ofrece depuración, integración con Git y soporte para múltiples lenguajes, facilitando el desarrollo de scripts y modelos de detección de fallas ferroviarias.

Google Colab (Jupyter Notebook, GPU A100): Entorno en la nube para ejecutar notebooks Jupyter con acceso a GPU A100. Permite entrenar modelos de visión computacional de manera eficiente sin necesidad de infraestructura local.

GitHub: Plataforma de control de versiones y colaboración. Permite almacenar, compartir y gestionar código, conjunto de datos y modelos, asegurando trazabilidad y trabajo en equipo en proyectos de detección de fallas.

DVC (Data Version Control): Herramienta para versionar conjunto de datos e imágenes. Facilita la gestión de grandes volúmenes de datos y etiquetas, garantizando reproducibilidad en experimentos de machine learning.

Label Studio: Plataforma de etiquetado flexible para imágenes y datos. Permite crear anotaciones precisas en defectos ferroviarios, integrándose con flujos de entrenamiento de modelos de visión.

MLflow: Framework para gestionar el ciclo de vida de modelos de machine learning. Incluye seguimiento de experimentos, registro de parámetros y despliegue, asegurando control en el desarrollo de modelos predictivos.

Anaconda: Distribución de Python orientada a ciencia de datos. Simplifica la instalación de librerías y entornos virtuales, facilitando la gestión de dependencias para proyectos de visión computacional y machine learning.

1.6.5 Población y Muestra

Se recolectará imágenes de alta resolución considerando el nivel de altitud sobre el nivel del mar por donde pasa la vía férrea esto debido a las condiciones ambientales de cada zona generan diferentes patrones de fallos sobre los rieles. Se tomarán fotografías de alta resolución de 1 metro de longitud de los rieles del Ferrocarril Central del Perú. Como estrategia de contingencia se usarán conjunto de datos públicos que fueron usadas en las investigaciones citadas en las referencias estudiadas previa validación de su aplicabilidad a la realidad del sistema estudiado.

1.6.5.1 Población

Sistema estudiado: El Ferrocarril Central como principal medio de transporte de productos mineros en la región central del país, cubre importantes áreas mineras ubicadas en el departamento de Pasco, Junín y Lima.

El Ferrocarril Central cuenta con 489.60 Kilómetros de longitud de vía férrea y está dividida en los tramos que se indican en la tabla 10.(Gerencia de Regulación y Estudios Económicos, 2025)

FERROCARRIL	ENTIDAD Y TRAMO	2023
		489.6
Centro	**Ferrovías Central Andina S.A 4/**	**489.6**
	Callao - La Oroya	222.0
	La Oroya - Huancayo	124.0
	La Oroya - Cerro de Pasco	131.0
	Cut off - Huascacocha (ramal)	12.6

Tabla 3: Longitud del Ferrocarril Central.
Fuente: Ministerio Transportes y Comunicaciones del Perú.

Unidad de análisis: Segmentos individuales de rieles ferroviarias (secciones de 1 metro de longitud) capturados mediante imágenes.
Variables controladas: El tipo de sensor o cámara que se utilizará para la captación, la resolución de las imágenes que se adapten al modelo, la distancia del sensor que capturará la imagen del riel y las condiciones de iluminación que juegan un papel importante en la capturar la realidad.
Variables no controladas: La captura de datos para la investigación que podrían introducir sesgos o podrían interferir en la recolección de datos y posteriormente en los resultados del modelo son: las condiciones climáticas durante la toma de muestra que son cambiantes a lo largo de las vías férreas, las vibraciones del tren o vehículo de inspección que pueden alterar la captura de imágenes, el grado de suciedad u oxidación del riel que impediría capturar detalles del riel y el ferroviario en el momento de la toma de imágenes o la inspección.
Instrumento de medición: Dron con cámaras de alta resolución con capacidad de capturar imágenes de al menos 1920x1080 píxeles y los canales RGB (3 canales).

1.6.5.2 Tamaño de muestra.

El conjunto de datos específico que se recolectarán para el entrenamiento del modelo contará con un mínimo 1,500 segmentos de riel (300 por cada clase de las cuales 150 con avería y 150 en perfecto estado) de las cuales 20% será para validación.

Se usarán técnicas de aumentado de datos para duplicar las muestras recolectadas aplicando transformaciones geométricas como: volteado horizontal y rotación +-5 grados, de igual manera, aplicando transformaciones del espacio de color como: cambiando los canales de color RGB o HSV y ajustando el brillo y el contraste.

Variables y medición:

Categoría	Descripción
Variable independiente	Toma de imagen con metadatos: nombre, fecha, longitud, latitud y altitud.
Variable dependiente	Imagen etiquetada con la situación real del riel (falla o no falla).
Variable a medir	Estado de la vía férrea: condición superficial del riel.
Instrumento o método de medición	Sensor óptico (cámara RGB) montado en un dron o tren de inspección. Adquisición de imágenes 2D (fotografía).

Unidad de medida	Imagen 2D representada como una matriz de píxeles.
Frecuencia de medición	Durante inspecciones periódicas programadas (mensuales).
Escala de medición	Nominal: se clasifica la condición del riel según la falla detectada.
Canales	3 canales RGB.
Dimensiones de la medición	Bidimensional (2D): matriz de píxeles por imagen.

Tabla 4: Variables y medición para el proceso de la data.
Fuente: Propia.

1.6.6 Técnicas e Instrumentos de Recolección de Datos

Representación de la realidad

La realidad será representada mediante capturas de imágenes de los rieles ferroviarios mediante sensores de alta resolución (cámaras) se considerará los canales RGB para que el modelo pueda capturar detalles con mayor exactitud. La iluminación, contraste y la posición del sensor también son factores claves para abstraer la realidad y que el modelo pueda interpretar los patrones importantes. En la figura 22 se visualizan las características del dron que ayudará con la recolección de datos.

Instrumentos para capturar la realidad.

- Dron con cámaras de alta resolución.
  DJI Air 2S, dron con cámara cardán de 3 ejes, vídeo de 5.4K, sensor CMOS de 1 pulgada, 4 direcciones de detección de obstáculos.
- Canales: Imágenes 1920x1088 RGB (3 canales).
- Sistema GPS para la georeferenciación de las averías.



Figura 16: Dron - Instrumento para capturar la data de entrenamiento.
Fuente: Propia

1.6.7 Técnicas e Instrumentos de Análisis y Procesamiento de Datos

Las técnicas que se aplicaran en el desarrollo de esta investigación se detallan en la tabla 11, la segmentación semántica que ayudará a entender al modelo de detección de objeto la localización y clasificación. El Transfer Learning técnica que permitirá usar un modelo preentrenado para una detección con mayor precisión y el análisis de textura para la detección de patrones en las imágenes

Técnica	Aplicación específica en tu caso
Etiquetado	Identificar y separar regiones dañadas del riel (grietas, fisuras y desprendimiento).
Detección de objetos (YOLO, ResNet, RT-DETR)	Localizar y clasificar tipos de averías en imágenes con bounding boxes.
Transfer Learning	El uso de modelos preentrenados y adaptados al conjunto de datos de rieles ferroviarios.
Análisis de textura e iluminación	Resaltar patrones sombras y bordes para resaltar defectos pequeños como fisuras.
Aumento de datos	Incrementar la cantidad y balancear los datos.

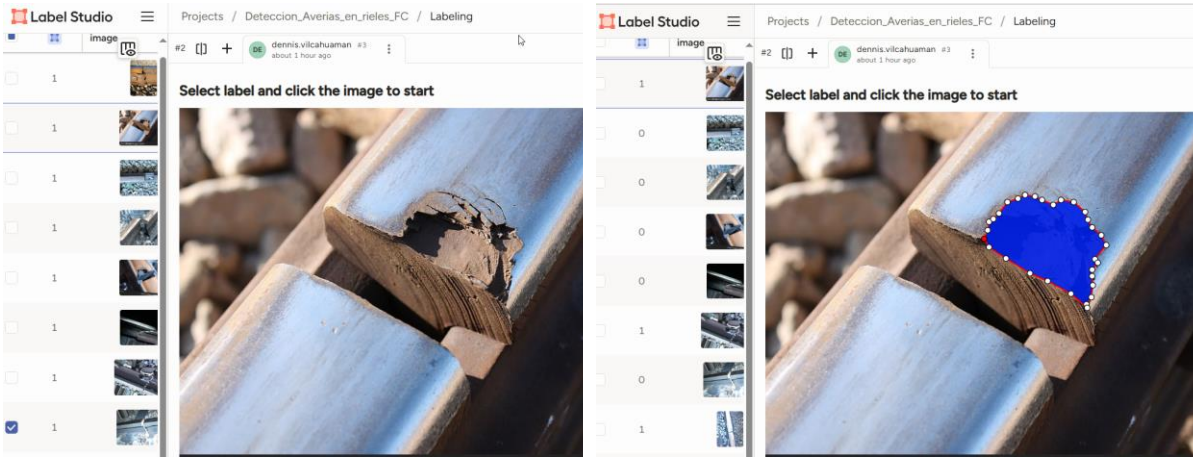
Tabla 5: Técnicas de análisis y procesamiento a las imágenes de rieles ferroviarios
Fuente: Elaboración propia

Como instrumentos de trabajo para el procesamiento del conjunto de datos esta investigación usará Label Studio para el etiquetado y segmentación, OpenCV y Python para el análisis morfológico de imágenes y Matplotlib para la visualización de métricas relacionados a las muestras.

Instrumento	Función principal
Label Studio	Etiquetado manual y automático, compatible con YOLO y etiquetato poligonal.
OpenCV + Python	Procesamiento de imágenes: filtros, detección de bordes, análisis morfológico y aumento de datos.
Matplotlib / Seaborn	Visualización de métricas de segmentación y precisión del modelo.

Tabla 6: Instrumentos de análisis y procesamiento de imágenes de rieles ferroviarios
Fuente: Elaboración propia

La segmentación es un paso importante en el procesamiento de las imágenes es fundamental en el campo de la visión por computador [6]. En la figura 22 se aprecia la segmentación de una avería de un riel y su respectivo etiquetado.



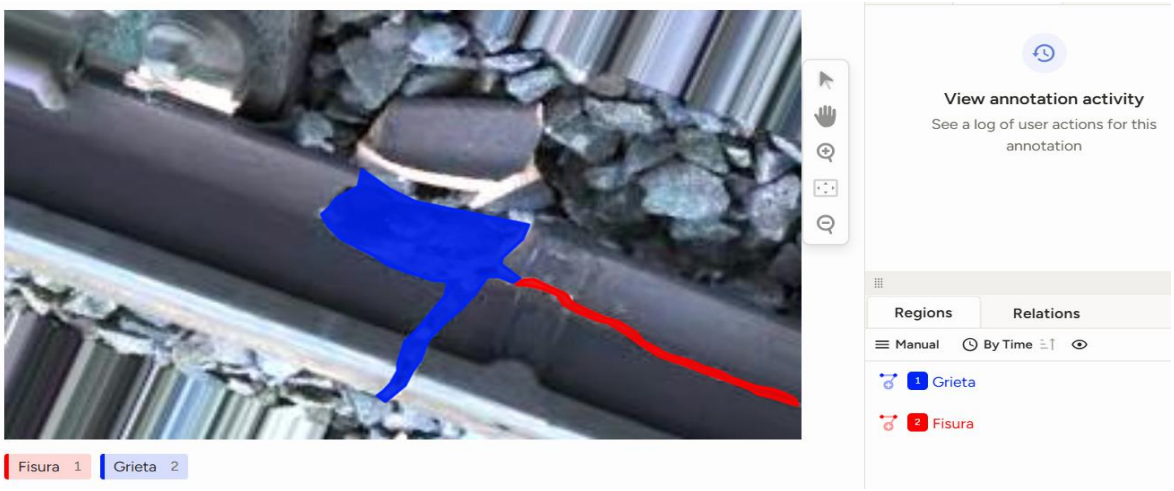


Figura 17: Segmentación de la avería en una imagen del riel ferroviario
Fuente: Elaboración propia.

CAPITULO II: MARCO TEORICO

2.1 Antecedentes bibliográficos

Se analizaron trabajos previos y el estado del arte de cómo diferentes autores afrontaron los problemas de la detección de averías en rieles ferroviarias, se puso especial atención a los modelos y arquitecturas de redes neuronales profundas que diferentes autores aplicaron a sus investigaciones. Adicionalmente se revisó las técnicas empleadas de preprocesamiento y aumentado de datos que se aplicaron a los conjunto de datos, las métricas obtenidas, así como los desafíos que se afrontaron y las mejoras recomendadas.

Se usó el siguiente string de búsqueda en diferentes bases de datos de artículos científicos.

DOI(((“Automatic fault detection” OR "fault detection" OR "railway track inspection methods") AND (“railway tracks” OR "Railroad Lines" OR "railways")) OR (("Artificial Intelligence" OR “Deep learning” OR "Machine learning“ OR “Object detection”) AND (“Railway Safety” or "railway" or "railway track")))

Fundamentos y Revisiones Generales del Estado del Arte y Revisiones:

2.1.1 A Review of Deep Learning Applications for Railway Safety.

Autor: K. Oh et al. (2022).

El autor describe de manera general y exhaustiva las aplicaciones de modelos Deep Learning en la seguridad ferroviaria. Esta revisión permite entender la aplicabilidad de los modelos en las diferentes áreas del sistema de ferrocarriles (infraestructura, tren, operación y estación) y el tipo de averías comunes a cada área y los modelos usados para la detección (Oh et al., 2022).

El autor lista diferentes artículos y los compara considerando el alcance que cada uno tuvo en relación al área de aplicación en el sistema ferroviario, el tipo de datos usados (imágenes u otros) y el año de publicación, el autor resalta que su investigación (review) estudio todas las áreas del sistema ferroviario de manera casi completa. Un dato importante brindado por este artículo y mostrado en la tabla 6 es que la mayoría de investigaciones usaron imágenes como fuente principal de entrenamiento en sus modelos para ayudar en la seguridad ferroviaria.

Papers		Application Areas [1]				Data Types	
Ref	Year	Railway Infra	Train	Operation	Station	Image	Others [2]
Tang et al. [11]	2022	○	△	△	△	○	○
Liu et al. [12]	2019	○	○	△	△	○	×
Ghofrani et al. [13]	2018	△	△	△	×	○	○
Hu et al. [14]	2021	△	×	×	×	○	×
Sedghi et al. [15]	2021	△	△	△	△	×	△
Yin et al. [16]	2020	△	×	×	△	○	△
Wen et al. [17]	2019	×	×	×	△	○	○
Chenariyan et al. [18]	2019	△	×	×	×	○	△
This study	2022	○	○	○	○	○	○

[1] ○: almost subdomains listed in Sections 4–7, △: about half of the subdomains, ×: rarely covered. [2] ○: more than two other types, △: one type, ×: none.

Tabla 7: Áreas del sistema ferroviario con aplicaciones de inteligencia artificial.

Fuente: A Review of Deep Learning Applications for Railway Safety (Oh et al., 2022)

El autor del artículo recopila información histórica de investigaciones aplicadas al sistema ferroviario y hace hincapié en los modelos de inteligencia artificial usados en áreas específicas del sistema ferroviario, sus respectivos componentes, así como el tipo de dato que se usó para el entrenamiento de los modelos en la detección de averías. Con respecto a la detección de averías en rieles los investigadores indicados en este paper review indican que normalmente se usan imágenes y los modelos de aprendizaje profundo preferidos como YOLOv3, SegNet, CNN (VGG, ResNet) (Oh et al., 2022). tal como se puede ver en la tabla 7.

Área Principal	Subcategoría	Modelos de IA Utilizados	Aplicación Específica
Infraestructura Ferroviaria	Catenaria	- Faster R-CNN, YOLOv3, RetinaNet, Autoencoders	Detección de defectos en aisladores, péndol pasadores y anillos de corriente.
	Superficie de rieles	- YOLOv3, SegNet, CNN (VGG, ResNet), PCA	Identificación de grietas, desgastes y defect en rieles.
	Componentes (clips, juntas)	- CNN, RNN, SVM, k-means	Detección de fallos en clips, juntas y máqui de agujas.
	Geometría de vías	- CNN-LSTM, GRU con atención	Evaluación de calidad de vías mediante vibraciones del tren.
Tren y Bogie	Puertas	- CNN 1D, k-NN	Diagnóstico de fallos en puertas mediante señales de corriente.
	Ruedas	- SVM, CNN, DWT (Wavelets)	Detección de planos o deformaciones en ruedas.
	Suspensión y rodamientos	- Bayesian Deep Learning, DBN (Deep Belief Networks), LAMSTAR	Diagnóstico de fallos en amortiguadores y rodamientos usando vibraciones.
	Otros componentes	- Faster R-CNN, SSD, MFF-Net (Multi-Feature Fusion)	Localización de piezas faltantes o rotas en bogies (pernos, cadenas, etc.).
Operación	Intrusión en vías	- Mask R-CNN, LiDAR + SSD	Detección de peatones, vehículos u obstácul en vías.
	Detección de vías	- RailNet (ResNet50 + FCN), CNN	Segmentación de vías en imágenes frontale para prevenir descarrilamientos.
	Riesgo por viento	- LSTM con atención (MAL-MIL)	Predicción de riesgos por vientos fuertes en trenes de alta velocidad.
	Seguridad en marcha	- DNN-RNN híbridos	Predicción de coeficientes de descarrilamie mediante vibraciones.
	Informes de accidentes	- Word2Vec, GloVe, LSTM	Clasificación automática de causas de accidentes en informes narrativos.
Estaciones	Prevención de accidentes	- CNN	Detección de caídas, resbalones o tropiezos plataformas mediante CCTV.
	Calidad del aire	- Memoria en RNN, LSTM	Monitoreo de contaminantes y fallos en sensores de aire.
	Simulación y programación	- LSTM, 3D-CNN, Redes con atención espaciotemporal	Predicción de retrasos y flujos de pasajeros usando registros históricos.

Tabla 8: Modelos de Machine Learning usados en áreas específicas del sistema ferroviario.
F*uente: A Review of Deep Learning Applications for Railway Safety* [9]

2.1.2 Railway Track Deterioration Models: A Review of the State of the Art.

Autor: Rempelos et al. (2024).

El autor de este artículo no se centra en la detección visual de averías, sino que ayuda a comprender los mecanismos de deterioro de las vías proporcionando una base conceptual sobre cómo se desarrollan las averías, lo que es crucial para la interpretación de los datos y el diseño de modelos de detección (Rempelos et al., 2024).

Este artículo ha revisado críticamente las ventajas y limitaciones de los enfoques existentes de modelización del deterioro de las vías ferroviarias y ha proporcionado una taxonomía sistemática de estos modelos. A partir de esto, se propuso una clasificación jerárquica basada en el nivel de detalle y la funcionalidad del modelo (Rempelos et al., 2024).

Si bien se ha avanzado considerablemente en la ampliación de las capacidades de los modelos de predicción del deterioro relacionado con las vías, aún existen varios desafíos que requieren mayor consideración de las variaciones y dependencias espaciales y temporales, así como, los modelos no realizan la identificación de diferentes covariables presentes a lo largo de las vías férreas. Por ejemplo, el autor indica que los modelos de Machine Learning no tienen la capacidad de relacionar los fallos o averías con el medio ambiente u otros factores que influyen en su deterioro (Rempelos et al., 2024).

2.1.3 A systematic literature review of defect detection in railways using machine vision-based inspection methods.

Autores: A. Kumar y S. P. Harsha. (2024).
Los investigadores de este artículo indican que la visión por computador en la detección de defectos en vías férreas ha ganado mucho interés. Esta investigación indica que los modelos de detección de objetos se han vuelto predominantes y muestran resultados superiores en la detección y clasificación de defectos aplicados a la mayoría de los componentes ferroviarios como parte de la inspección ya que los modelos basados en visión por computador tienen gran capacidad para aprender características complejas directamente de las imágenes (Kumar & Harsha, 2024). La figura 17 muestra la composición del software y hardware de los sistemas de detección de defectos en rieles normalmente usados por diferentes investigadores.

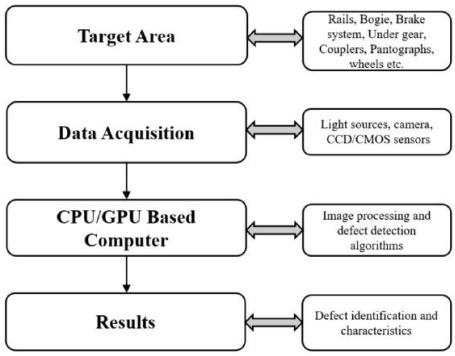


Figura 18: Composición del software y hardware utilizado en el sistema de detección de defectos en rieles. Fuente: A systematic literature review of defect detection in railways using machine vision-based inspection methods (Kumar & Harsha, 2024).

Los autores de este artículo muestran la relación del componente ferroviario, sus defectos comunes y la técnica de visión por computador usado para la detección de averías esto se puede ver en la tabla 8. En el cuadro se observa que para los rieles ferroviarios los modelos de visión por computador normalmente usados son YOLO y Faster R-CNN previa tratamiento de las imágenes con técnicas de mejora de contraste, análisis de texturas y detección de bordes.

Componente Ferroviario	Tipos de Defectos Comunes	Métodos y Técnicas de Visión Artificial Utilizados
Rieles	Grietas (longitudinales, transversales), Desgaste (corrugación, lateral), Defectos superficiales (squats, spalling)	- Procesamiento de Imágenes: Filtrado, mejora de contraste, segmentación de imágenes. - Análisis de Características: Detección de bordes, extracción de características de textura. - Aprendizaje Automático (ML): SVM, Random Forest (para clasificación de defectos basados en características extraídas).- Aprendizaje Profundo (DL): Redes Neuronales Convolucionales (CNNs), modelos de detección de objetos (YOLO, Faster R-CNN) para detección y localización de grietas y defectos superficiales.
Ruedas	Planos en la banda de rodadura, defectos en la llanta (brida), grietas, desgaste excesivo.	- Procesamiento de Imágenes: Medición de geometría, análisis de perfiles. - Visión 3D: Cámaras estereoscópicas, luz estructurada (para medición de desgaste y planos). - Aprendizaje Automático/Profundo: Clasificación y detección de anomalías visuales en la superficie de la rueda.
Fijaciones	Faltantes, sueltas, rotas, mal posicionadas (p. ej., pernos, clips, placas).	- Procesamiento de Imágenes: Detección de objetos, reconocimiento de patrones (para identificar la presencia/ausencia o estado de las fijaciones). - Análisis de Componentes Conectados: Para identificar partes individuales. - Aprendizaje Automático/Profundo: Clasificadores para determinar el estado de la fijación (dañada/intacta).
Durmientes y Balasto	Durmientes: Agrietados, rotos, podridos, desalineados. Balasto: Nivel insuficiente, suciedad, distribución irregular.	- Procesamiento de Imágenes: Segmentación (para separar durmientes de balasto), análisis de textura (para balasto). - Detección de Bordes/Formas: Para identificar la integridad y alineación de los durmientes. - Aprendizaje Automático/Profundo: Clasificación de la condición de los durmientes y evaluación de la uniformidad del balasto.
Panto y Catenaria	Desgaste del pantógrafo, desalineación de la catenaria, cables rotos/dañados, defectos en los aisladores.	- Procesamiento de Imágenes: Detección de líneas, seguimiento de objetos (para el cable de la catenaria). - Visión 3D: Medición de la geometría de la catenaria. - Aprendizaje Automático/Profundo: Detección de anomalías en la superficie del pantógrafo o en la continuidad/integridad de la catenaria y sus componentes.

Tabla 9: Métodos de Visión Artificial para la Detección de Defectos en Componentes Ferroviarios.
Fuente: A systematic literature review of defect detection in railways using machine vision-based inspection methods (Kumar & Harsha, 2024).

2.1.4 Automatic Detection of Railway Faults Using Neural Networks: A Comparative Study of Transfer Learning Models and YOLOv11.

Autor: Rodríguez-Abreo et al. (2025).
El autor de este artículo realizo un estudio comparativo de modelos pre entrenado contra la versión v11 de YOLO. La investigación respalda el uso de modelos YOLO para le detección de fallos gracias a los altos índices de precisión obtenidos, siendo ideales y completamente aplicables al sistema ferroviario peruano. Este artículo hace hincapié que el desarrollo de sistemas fiables de detección de fallos en ferrocarriles es crucial para garantizar la seguridad y la eficiencia operativa. Los modelos pre entrenados que menciona el artículo son ResNet50, Xception, VGG16, MobileNet e InceptionV3 que usaron ImageNet (una gran base de datos de 14 millones de imágenes) los cuales mostraron diferentes métricas de rendimiento (Rodríguez-Abreo et al., 2025).

La fuente de datos que usaron en esta investigación para el entrenamiento para la detección de fallos en rieles provino de Kaggle que contenía un total de 2,225 imágenes (antes de aumentación) con patrones correctos y fallos. Estas imágenes se expandieron usando aumentación de data a 6,068 con la cual se hicieron los experimentos.

Los modelos pre entrenados que usaron los autores para luego compararlos con YOLOv11 mostraron diferentes rendimientos como se muestra en la siguiente tabla 4 (Rodríguez-Abreo et al., 2025).

Model	Size (MB)	Accuracy Top 1	Accuracy Top 5	Parameters	Depth	Time (ms) per Inference Step CPU	Time (ms) per Inference Step GPU
ResNet50V2	98	76.0%	93.0%	25.6 M	103	45.6	4.4
Xception	88	79.0%	94.5%	22.9 M	81	109.4	8.1
VGG16	528	71.3%	90.1%	138.4 M	16	69.5	4.2
MobileNet	16	70.4%	89.5%	4.3 M	55	22.6	3.4
InceptionV3	92	77.%	93.7%	23.9 M	189	42.2	6.9

Tabla 10: Rendimiento de modelos pre-entrenados considerados para el aprendizaje por transferencia. Fuente: Automatic Detection of Railway Faults Using Neural Networks (Rodríguez-Abreo et al., 2025).

Los autores presentan la metodología única utilizada para entrenar YOLOv11 (una versión optimizada de YOLO para clasificación de fallos ferroviarios), destacando su enfoque en aumentación de datos dinámica y eficiencia computacional. Adaptar YOLOv11 para clasificación binaria (no solo detección de objetos) y manteniendo su capacidad de procesamiento en tiempo real. Los investigadores realizaron la comparación entre el mejor modelo de Transfer Learning vs YOLOv11 y como dato importante señalan que la arquitectura de YOLO11 es más ligera (2.6M parámetros) que modelos como VGG16 (138.4M) que lo hace conveniente para proyectos de detección de fallas en tiempo real (Rodríguez-Abreo et al., 2025). En el informe se indica que el rendimiento obtenido con YOLOv11 supero al VGG16 en 3.46% y una mejor eficiencia usando 50 veces menos parámetros logrando una precisión en entrenamiento de 99.87%, un 96.24% en validación y 92.64% en pruebas (Rodríguez-Abreo et al., 2025).

Los investigadores de este artículo citan dentro de sus referencias a Y. Min, J. Guo, y K. Yang (2022)- "Research on real-time detection algorithm of rail-surface defects based on improved YOLOX." (Min et al., 2022) el cual hace uso del modelo YOLO con algunas variaciones a la arquitectura como: la adición de capas para la identificación información semántica, se agregaron bloques de convolución para ayudar en el entrenamiento para la detección de averías y fallos en el sistema ferroviario y cuyos resultados alcanzaron un 96% de precisión y una velocidad de procesamiento de imágenes de 49 frames por segundo métricas que respaldan el uso es este modelo para la detección de fallos en tiempo real.

Una de las referencias citadas en esta investigación la de los autores Y. Wang, K. Zhang, L. Wang, y L. Wu (2024)- An Improved YOLOv8 Algorithm for Rail Surface Defect Detection (Wang et al., 2024). Los investigadores demuestran que los modelos mejorados y basados en YOLOv8 son capaces de adaptarse al sistema ferroviario específicamente a la superficie de las rieles para la detección de fallas pequeñas o medianas gracias a la modificación de la arquitectura YOLOv8 incorporando capas adicionales de convolución y manejo de los hiper parámetros. Con este modelo se alcanzó una precisión del 93.9%.

2.1.5 Fault Detection from Images of Railroad Lines Using the Deep Learning Model Built with the Tensorflow Library.

Autores: A. Şener, B. Ergen, y M. Toğaçar. (2022).

La investigación propone un nuevo modelo llamado Designed ESA, que incluye una red neuronal convolucional (CNN) basada en TensorFlow, con capas convolucionales de agrupación, normalización y funciones de activación ReLU, y se utilizó Softmax como

clasificador. Este estudio llevado a cabo en 2022 se contrastó con diferentes modelos como YOLOv3, GLCM y LBP y el modelo ESA registró índices de rendimiento (92.21% de Accuracy) superiores a los de YOLOv3 resultado prometedor pero menores a GLCM (94.90%), estas métricas resultantes son mostradas en la tabla 10 (Şener et al., 2022).

Article	Year	Model	Accuracy (%)
Ya-Wen Lin vd. [7]	2019	Yolo-V3	89
Hovad vd. [9]	2021	Yolo-V3	84
Rajagopa vd. [11]	2018	GLCM, LBP, ESA	94,9
This study	2022	Designed ESA	92,21

Tabla 11: Comparación del estudio realizado por los autores con otros similares.
Fuente: Fault Detection from Images of Railroad Lines Using the Deep Learning Model Built with the Tensorflow Library (Şener et al., 2022).

En el caso del Ferrocarril Central la arquitectura propuesta serán las últimas versiones de YOLO v11 v8 que son en arquitectura y rendimiento al modelo YOLO v3 usado en esta investigación. También se tomará en cuenta que el rendimiento de un modelo está ligado a una buena captura de datos y el pre procesamiento realizado al conjunto de datos y el manejo de hiper parámetros de entrenamiento para la identificación de fallos.

2.1.6 Fault Detection and Semantic Segmentation on Railway Track Using Deep Fusion Model.

Autor: Rampriya et al. (2024).

Este trabajo se enfoca en la segmentación semántica de fallas, lo cual proporciona una localización más granular que la detección de objetos. Se analizará cómo su modelo "Deep Fusion Model" aborda el problema, las ventajas de la segmentación (precisión a nivel de píxel) su relevancia radica en la validación de la capacidad del Deep Learning para identificar fallas complejas y su aplicabilidad al dominio. El artículo propone el desarrollo un modelo de fusión profunda que integre detección y segmentación semántica para inspección automatizada de componentes ferroviarios defectuosos (clips, púas, rieles) con alta precisión (evitar falsos positivos/negativos) y eficiencia computacional (tiempo real en GPU) (Rampriya et al., 2024).

El artículo indica que tuvo acceso al repositorio de imágenes de Kaggle (1,500 imágenes).

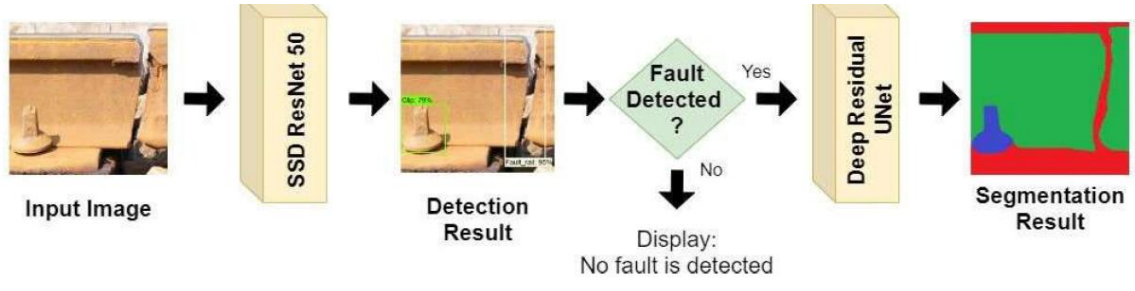


Figura 19: Arquitectura alto nivel del modelo Deep Fusion.
Fuente: Fault Detection and Semantic Segmentation on Railway Track Using Deep Fusion Model [16].

Los investigadores de este artículo hacen la comparación de diversos modelos de detección incluido YOLOv8 e indican que el mejor modelo de detección de objetos considerando su

conjunto de datos fue el ResNet50 con un Accuracy de 0.91 mientras que YOLOv8 obtuvo 0.88 estos resultados se muestran la tabla 6.

Model	Precision	Recall	F1-Score	Accuracy
SSD MobileNet V2 [43]	0.8407	0.8503	0.8413	0.86
SSD EfficientDet [44]	0.8102	0.7868	0.7850	0.80
SSD ResNet 50	0.9168	0.9180	0.9130	0.91
SSD ResNet 101 [30]	0.8631	0.8531	0.8625	0.87
Faster RCNN [45]	0.8312	0.8437	0.8419	0.85
CenterNet Hourglass [46]	0.7432	0.7643	0.7643	0.77
YOLO v4 Darknet [47]	0.8156	0.8363	0.8156	0.84
YOLO v8 [48]	0.8723	0.8643	0.8745	0.88

Tabla 12: Métricas de modelos de detección de objetos comparados en la investigación.
Fuente: Fault Detection and Semantic Segmentation on Railway Track Using Deep Fusion Model.

2.1.7 RAP-DETR: Enhancing RT-DETR for Railway Track Defect Detection.

Autores: Xie, H., Zhou, H., Chen, R., & Wang, B

Los autores de este articulo indican que los detectores convencionales CNN como YOLO requieren pasos adicionales como NMS (Non-Maximum Suppression), lo que afecta la velocidad y robustez. Por otro lado, los modelos basados en Transformers (RT-DETR) mejoran la precisión, pero presentan limitaciones en la detección de defectos pequeños, alto consumo de recursos y convergencia lenta. Para afrontar las limitaciones mencionadas los autores proponen un modelo que equilibre precisión, velocidad y eficiencia computacional para escenarios ferroviarios reales al cual denominaron RAP-DETR.(Xie et al., 2025)

El articulo menciona que el modelo RAP-DETR demuestra gran potencial para detección automática de defectos ferroviarios en tiempo real, reduciendo dependencia de inspecciones manuales. El modelo experimentalmente ha logrado un mAP@0.5 = 84.8% (↑4.4% respecto a RT-DETR), Precisión ↑2.3%, Recall ↑4.7%. tal como se muestra en la tabla.(Xie et al., 2025)

Mainstream algorithm comparison experimental results.

Methods	P	R	mAP@0.5	Classes				mAP@0.5:0.95
	/%	/%	/%	spalling	wheel burn	squat	corrugation	/%
YOLOv11 [42]	67.9	75	76.5	71.6	79.8	84.8	70.0	51.4
YOLOv10 [43]	61.9	76.2	74.0	67.0	77.9	85.2	66.2	51.3
YOLOv9 [44]	66.8	86.7	81.5	76.9	83.2	89.6	76.5	82.7
Faster R-CNN [7]	48.8	84.9	72.8	81.6	76.1	64.1	69.4	42.3
SSD [10]	73.3	57.8	65.6	47.3	79.6	74.0	61.5	35.4
DETR [20]	37.4	45.1	38.7	32.2	37.8	63.2	21.8	19.5
RTDETR [21]	70.6	77.7	80.4	78.3	83.0	89.1	71.2	58.3
Literatures [45]	72.0	78.3	81.3	78.9	82.9	89.4	73.9	58.8
Literatures [46]	66.2	87.9	81.9	81.7	84.7	88.4	72.9	58.8
RAP-DETR	72.9	82.4	**84.8**	78.8	**90.1**	88.4	**81.7**	58.5

Tabla 13: Resultados experimentales de comparación de algoritmos convencionales.
Fuente: RAP-DETR: Enhancing RT-DETR for Railway Track Defect Detection

2.1.8 Rail surface defect detection using a transformer-based network.

Autores: Guo, F., Liu, J., Qian, Y., & Xie, Q.

Los autores del articulo muestran preocupación por los defectos en la superficie de los rieles que pueden provocar inestabilidad en la interacción rueda–riel e incluso descarrilamientos, lo que representa un riesgo crítico para la seguridad ferroviaria. Indican que los métodos

tradicionales (ultrasonido, láser, radiografía e inspección visual) son costosos, lentos y poco robustos frente a condiciones ambientales variables (luz, polvo, óxido). Con respecto a los algoritmos convencionales basados en CNN indican que han mejorado la detección, pero tienden a perder defectos pequeños o dispersos debido a operaciones convolucionales consecutivas.(Guo et al., 2024)

El articulo indiaca que las CNN tradicionales no logran modelar adecuadamente las relaciones jerárquicas y globales entre píxeles, lo que limita la detección precisa de defectos pequeños y dispersos. A lo cual proponen un modelo basado en Transformers (RailFormer) con la capacidad de preservar detalles finos, mejorara la robustez y mantuviera eficiencia en escenarios de inspección ferroviaria en tiempo real.(Guo et al., 2024)

RailFormer obtuvo el mejor desempeño en mIoU y visualización, superando a los otros modelos tal como se muestra en la siguiente tabla.

Training performance of different models on the customized RSD dataset.

Loss	Model	IoU (%)	Accuracy (%)
BCE loss	SegFormer	80.90	88.24
	Swin Transformer	80.16	86.63
	ViT	73.44	87.53
	UNet	76.55	88.53
	RailFormer	**81.11**	**91.21**
Dice loss	SegFormer	**79.30**	**90.66**
	Swin Transformer	77.67	88.51
	ViT	69.04	76.99
	UNet	\	\
	RailFormer	77.96	89.97
Focal loss	SegFormer	80.35	85.84
	Swin Transformer	80.94	**88.28**
	ViT	72.57	82.88
	UNet	73.13	87.09
	RailFormer	**81.46**	87.12

Tabla 14: Métricas obtenidas en el entrenamiento y su comparación con otros modelos.
Fuente: Rail surface defect detection using a transformer-based network

2.1.9 Railway Track Fault Detection with ResNet Deep Learning Models.

Autores: M. Mustafa Saritas, Yavuz Selim Taspinar, Ilkay Cinar, Murat Koklu.

Los autores de la investigación resaltan la importancia de detectar fallos en la vía férrea (como rieles rotos, elementos de soporte deteriorados, corrosión y deformación) que son cruciales para la seguridad del transporte de pasajeros y mercancías. La motivación de los autores era superar las limitaciones de la inspección manual y optimizar los procesos de mantenimiento mediante la automatización mediante inteligencia artificial (Saritas et al., 2023).

Utilizaron el conjunto de datos "Railway Track Fault Detection" de Kaggle, que consta de 383 imágenes en total (191 defectuosas y 192 no defectuosas). El 80% se usó para entrenamiento y el 20% para pruebas, combinando conjuntos de validación y prueba.

Modelos: Implementaron redes neuronales convolucionales (CNN) utilizando arquitecturas ResNet-18, ResNet-50 y ResNet-101. Emplearon Transfer Learning (transferencia de

aprendizaje) para aprovechar el conocimiento de modelos preentrenados y reducir el tiempo de entrenamiento. Evaluaron el rendimiento mediante la matriz de confusión, precisión (accuracy), sensibilidad (sensitivity), especificidad (specificity), precisión (precision) y puntuación F1 (F1 Score). (Saritas et al., 2023).

	Values		
Measure	**ResNet-18**	**ResNet-50**	**ResNet-101**
Sensitivity	0.9825	0.9298	0.9123
Specificity	0.6552	0.6897	0.6379
Precision	0.7368	0.7465	0.7123
Accuracy	0.8174	0.8087	0.7739
F1 Score	0.8421	0.8281	0.8000

Tabla 15: Métricas obtenidas en el entrenamiento de modelos ResNet.
Fuente: Railway Track Fault Detection with ResNet Deep Learning Models

Los autores observaron que el modelo más profundo (ResNet-101) tuvo el peor rendimiento en términos de precisión (accuracy) en comparación con los modelos más ligeros, lo que sugiere que, para este conjunto de datos específico, una mayor profundidad no garantizó mejores resultados.

2.2 Bases Teóricas

2.2.1 Inteligencia Artificial (IA) y Machine Learning (ML)

Inteligencia Artificial: Son programas y modelos con la habilidad de aprender y razonar como humanos (Szeliski, 2022). La IA es una rama de las ciencias computacionales encargado del estudio y creación de algoritmos. La IA cada vez tiene más aplicaciones y se están usando en diferentes sectores económicos y sociales. Aunque muchos temen que llegara a reemplazar las actividades de los hombres en realidad está ayudando a transformar el mundo.

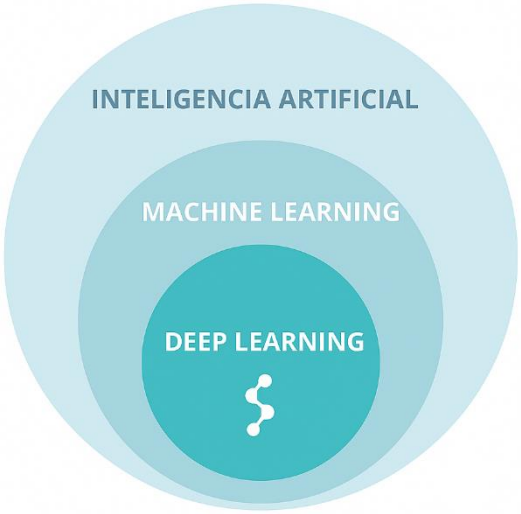


Figura 20: Inteligencia Artificial, Machine Learning y Deep Learning.
Fuente: Propia.

Machine Learning: Algoritmos capaces de aprender por sí mismos en base a experiencias (Szeliski, 2022). Los modelos supervisados usan datos etiquetados es decir que dependen de un experto. Los modelos no supervisados aprender por si solos gracias a la cauterización de los datos.

2.2.2 Deep Learning (DL):

El Deep Learning es parte de la Inteligencia Artificial y del Machine Learning estos modelos trabajan con grandes conjuntos de datos normalmente usan más recursos computacionales CPU, Memoria y GPU esto de acuerdo a las capas dependiendo de su arquitectura. Los tipos más conocido de Deep Learning son:

Redes Neuronales Recurrentes (RNN): Los casos de uso de estas redes neuronales recurrentes son comúnmente el Procesamiento de Lenguaje Natural NPL (Szeliski, 2022) como la generación y traducción de textos, análisis de sentimientos y reconocimiento de voz entro otras esto gracias a que pueden procesar datos con dependencias y contexto a largo plazo.

Redes Neuronales Convolucionales (CNNs): Esta red neuronal está adaptada para aprender de grandes volúmenes de imágenes y videos son especializadas para el reconocimiento de objetos y la detección de patrones mediante un proceso de segmentación (Szeliski, 2022). Las aplicaciones comunes de los CNNs analizar imágenes médicas y encontrar patrones para ayudar a los doctores, otra aplicación es la video vigilancia permite reconocer personas y detectar actividades sospechosas.

2.2.3 YOLO (You Only Look Once)

Es un modelo de detección de objetos de una sola etapa que predice las cajas delimitadoras y las probabilidades de clase directamente a partir de una imagen completa, en una sola pasada. Esto lo hace extremadamente rápido.

YOLOv8: Es uno de los modelos que marcó un hito en la detección de objetos gracias a su arquitectura novedosa que ofrece múltiples capacidades no vistas antes. Usada ampliamente en proyecto de visión por computador (Yaseen, 2024).

La arquitectura de YOLOv8 procesa las imágenes y video a altas velocidades gracias a que no tiene canalizaciones complejas y puede procesar imágenes a 45 fotogramas por segundo. el bloque BackBone o columna vertebral es la encargada de extraer las características resaltantes de la imagen de entrada mediante las convoluciones, el bloque Neck o cuello donde se combinan las características detectadas en el BackBone mejorando la resolución espacial a diferentes escalas y finalmente el bloque de la cabeza o Head donde se realiza la predicción. Estos detalles se muestran en la Figura 21.

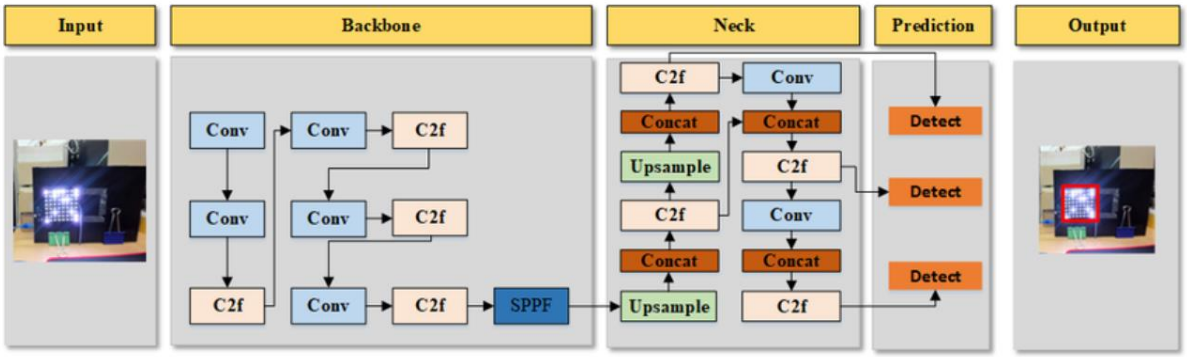


Figura 21: Arquitectura alto nivel de YOLOv8 y proceso de detección.
Fuente: What is YOLOv8: An In-Depth Exploration of the Internal Features of the Next-Generation Object Detector (Yaseen, 2024).

YOLOv11: Es la última versión del modelo de detección de objetos desarrollado por Ultralytics esta nueva arquitectura trae consigo mejoras sustanciales que a los modelos previos de la misma familia. Esta nueva versión es ideal para la detección de objetos en tiempo real, segmentación de instancias, clasificación de imágenes, estimación de pose, detección orientada de objetos (OBB) y seguimiento de objetos. Este nuevo modelo usa menos parámetros que sus predecesores lo que la hace más preciso, la velocidad y la eficiencia computacional (Khanam & Hussain, 2024).

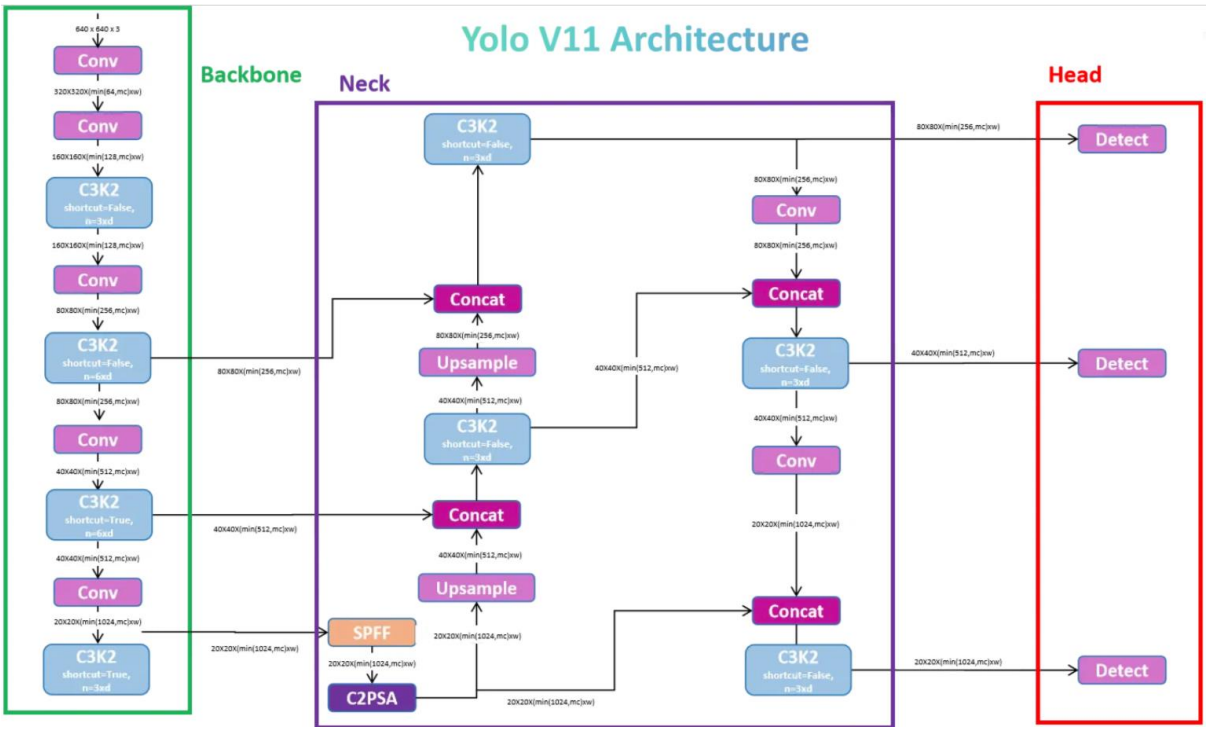


Figura 22: YOLOv11 Arquitectura.

Fuente: Yolov11: An Overview of the Key Architectural Enhancements.

Las mejoras arquitectónicas con respecto a YOLOv8 es el uso del módulo C3k2 que realiza convoluciones más pequeñas para reducir la carga computacional y la innovación dentro de los módulos SPPF y C2PSA que mejoran la extracción de características con atención espacial, enfocándose en regiones importantes de la imagen así sean objetos pequeños o estén ocluidos. Estas mejoras son mostradas en alto nivel en la figura 22.

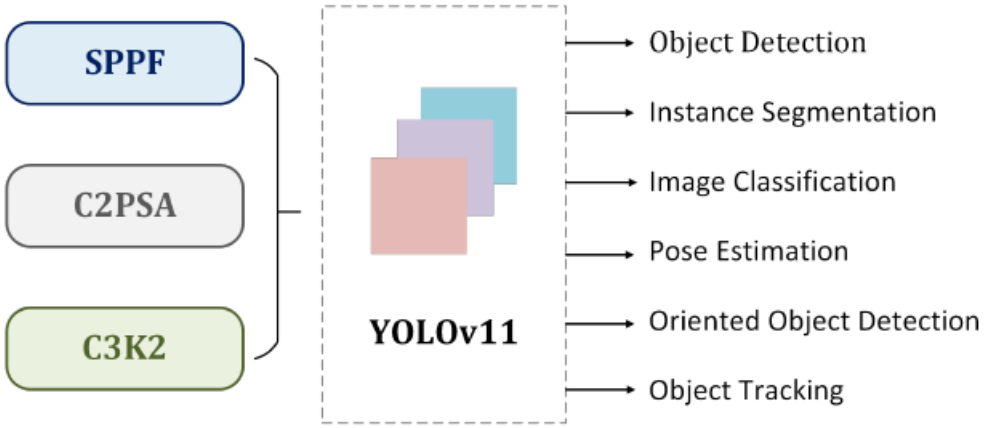


Figura 23: Resumen de las principales mejoras arquitectónicas.
Fuente: YOLOv11 an overview of the key architectural enhancements

2.2.4 Real-Time Detection Transformer RT-DETR

El modelo RT-DETR (Real-Time DEtection TRansformer) representa un cambio de paradigma respecto a los detectores tradicionales basados en CNN (como la familia YOLO). Se define como el primer detector de objetos basado en Transformers que logra operar en tiempo real sin sacrificar precisión. Su principal innovación radica en la eliminación del post-procesamiento Non-Maximum Suppression (NMS), un componente crítico en los detectores basados en anclajes que suele introducir latencia y afectar la precisión en escenarios densos.(Zhao et al., 2024)

Codificador Híbrido Eficiente y Módulo AIFI.

Para procesar características multiescala de manera eficiente, RT-DETR incorpora un codificador híbrido que desacopla las interacciones *intra-escala* (dentro del mismo nivel) de las *cross-scale* (entre niveles). Específicamente, utiliza el módulo de Interacción de Características Intra-escala Basado en Atención (AIFI). Este módulo aplica mecanismos de auto-atención únicamente a las características de alto nivel semántico (S5), lo que reduce significativamente el costo computacional redundante presente en variantes anteriores de DETR, permitiendo una inferencia veloz adecuada para aplicaciones industriales.(Zhao et al., 2024)

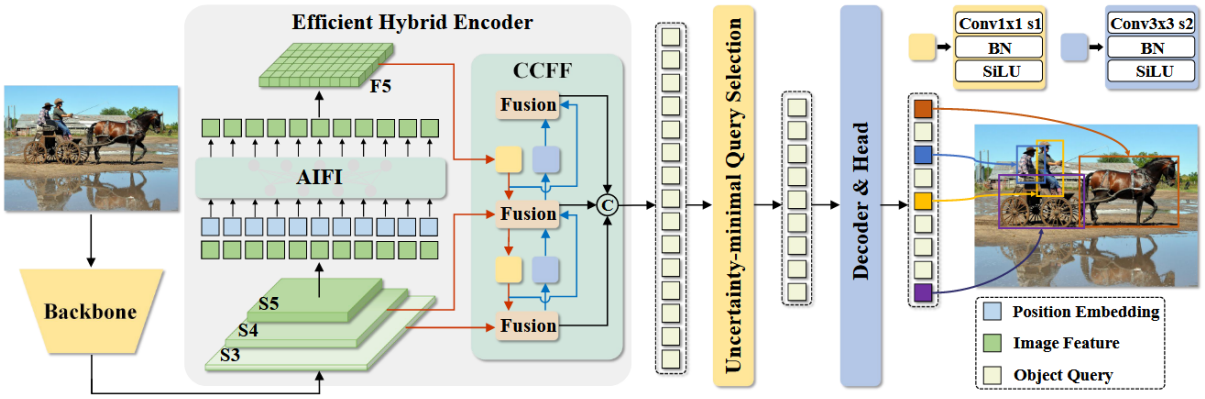


Figura 24: Resumen de la arquitectura RT-DETR.
Fuente: DETRs Beat YOLOs on Real-time Object Detection (Zhao et al., 2024)

Selección de Consultas Consciente de IoU (IoU-aware Query Selection).

A diferencia de los métodos que utilizan anclajes fijos o consultas aprendibles estáticas (YOLO), RT-DETR implementa una selección de consultas dinámica consciente de la calidad (IoU-aware). Durante la inferencia, el modelo selecciona las características de mayor confianza del codificador para inicializar las consultas del decodificador. Esto mejora la estabilidad del entrenamiento y permite que el modelo se adapte mejor a objetos con geometrías irregulares, superando las limitaciones de las cajas de anclaje rígidas tradicionales (Zhao et al., 2024).

2.2.5 ResNet50 y Faster R-CNN.

La arquitectura Faster R-CNN con ResNet50 como backbone es un modelo de detección de objetos que combina una red convolucional profunda con un sistema eficiente de propuestas de regiones. El componente principal, ResNet50, actúa como extractor de características, procesando la imagen de entrada mediante bloques residuales que permiten capturar patrones jerárquicos sin degradación del gradiente. A través de sus capas Conv2_x a Conv5_x, se generan mapas de características ricos en semántica y detalle espacial (Patki, 2024).

Sobre estos mapas actúa la Region Proposal Network (RPN), que aplica convoluciones para identificar regiones candidatas que podrían contener objetos. Cada propuesta se evalúa en términos de probabilidad de contener un objeto y se ajustan sus coordenadas mediante regresión. Las regiones seleccionadas se procesan mediante RoI Align, que extrae características específicas de cada región, preservando la precisión espacial (Patki, 2024).

Finalmente, estas características se envían al head de detección, compuesto por un clasificador y un regresor de cajas. El clasificador asigna una etiqueta de clase a cada región, mientras que el regresor ajusta las coordenadas de la caja delimitadora. Esta arquitectura permite una detección precisa y robusta, siendo especialmente eficaz en escenarios donde se requiere identificar objetos pequeños o con alta variabilidad estructural (Patki, 2024).

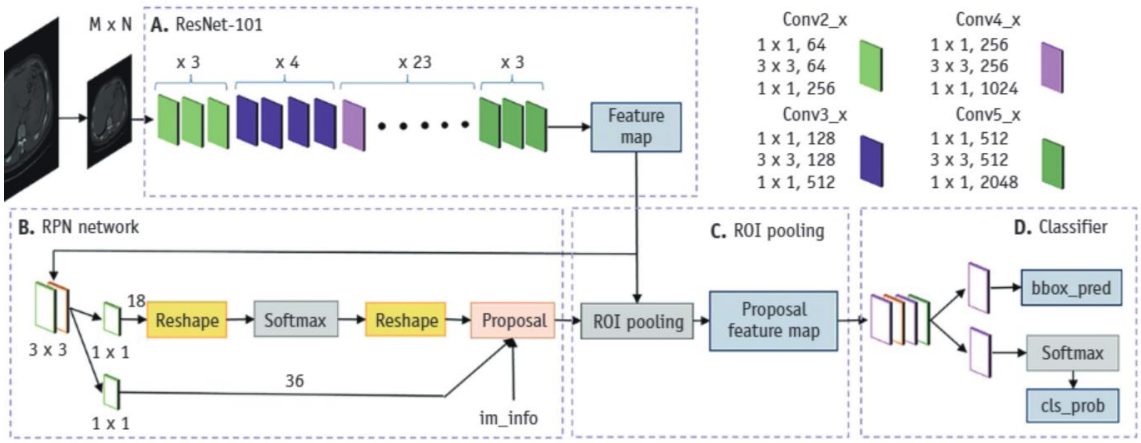


Figura 25: Componente de la arquitectura Faster R-CNN Backbone ResNet.
Fuente: Object Detection Using Faster R-CNN

2.2.5 MLOps (Machine Learning Operations):

Con el auge de los modelos de machine learning y con el objetivo de organizar de una manera óptima los proyectos de Inteligencia Artificial nace MLOps el cual aportar principios y buenas prácticas al ciclo de vida de los modelos brindando un enfoque ágil (Kreuzberger et al., 2022).

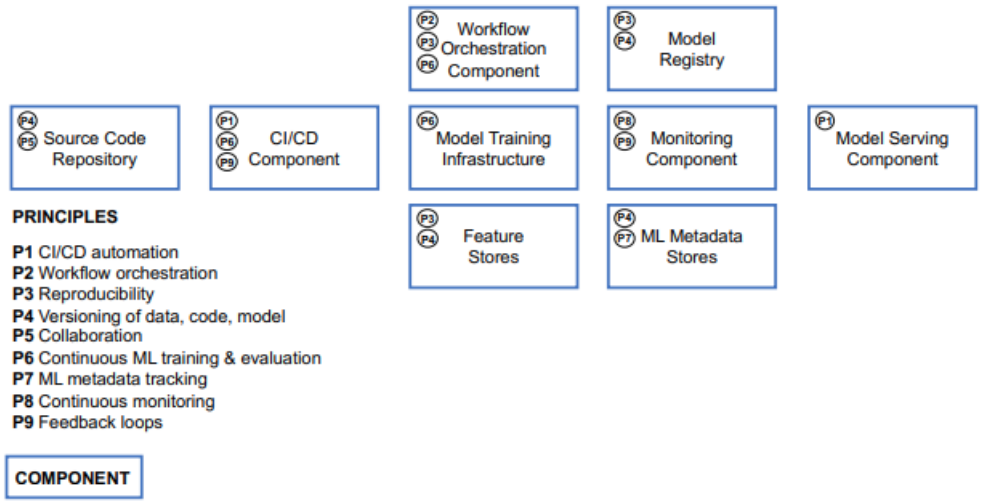


Figura 26: MLOps Implementación de principios dentro de los componentes técnicos.
Fuente: Machine Learning Operations (MLOps).

2.3 Definición de Términos

Los términos usados relacionados a los modelos Deep Learning o Aprendizaje Profundo son los que se indican en la siguiente tabla 10 [6].

Término	Significado
CNN (Red neuronal convolucional)	Usada en visión por computadora para detectar patrones espaciales
Backpropagation	Algoritmo para entrenar redes ajustando pesos
Epoch	Una pasada completa por todos los datos de entrenamiento
Batch	Subconjunto de datos usados en cada paso de entrenamiento
Dropout	Técnica para evitar sobreajuste apagando neuronas aleatorias
Activación (ReLU, Sigmoid, etc.)	Funciones que determinan la salida de una neurona
Optimizer (Adam, SGD)	Algoritmo que ajusta los parámetros para minimizar el error
Loss function	Mide el error del modelo.

Tabla 16: Definición de términos relacionados a Aprendizaje Profundo.
Fuente: Elaboración propia.

Los términos usados relacionados a los modelos de visión por computador son los que se indican en la siguiente tabla [6].

Término	Descripción
YOLO (You Only Look Once)	Arquitectura rápida para detección de objetos en tiempo real. YOLOv8/v11 integran clasificación, segmentación y tracking.
Bounding Box	Rectángulo que encierra un objeto detectado. Se define por coordenadas (x, y, ancho, alto).
Segmentation (Semántica / Instance)	Proceso de asignar etiquetas por píxel: semántica (clase), instancia (objeto individual).
Anotación/Etiquetado	Proceso de etiquetar imágenes con bounding boxes, máscaras o keypoints.
Data Augmentation	Técnicas como flipping, brightness, ruido, para mejorar generalización. Importante en contextos con pocos datos.
mAP (mean Average Precision)	Métrica que evalúa precisión en detección: combina precisión y recall sobre distintas clases.
NMS (Non-Max Suppression)	Algoritmo para eliminar detecciones duplicadas con alto overlap.
Preprocessing	Incluye resizing, normalización, padding. Fundamental para compatibilidad con modelos.
Transfer Learning	Uso de pesos preentrenados para acelerar y mejorar el entrenamiento en conjuntos personalizados.
Heatmap / Feature Map	Representación visual de activaciones en capas profundasútil para debugging y explainability.
Anchor Boxes	Cuadros predefinidos usados para detección.
IoU (Intersection over Union)	Métrica que evalúa el solapamiento entre predicción y ground truth.

Tabla 17: Términos de visión por computador usado en esta investigación.
Fuente: Elaboración propia.

CAPITULO III: PROPUESTA Y DESARROLLO DE LA SOLUCIÓN

3.1 Presentación de la Propuesta de Solución

La propuesta de esta investigación permitirá la mejora de la detección de averías en los rieles ferroviarios mediante el proceso mostrado en la figura 27 donde se visualiza como primer paso la inspección donde se usará un vehículo de inspección o un dron para la captura de imágenes, seguidamente se hará el preproceso de la imagen, como tercer paso se ejecuta el modelo Deep Learning para la extracción de características de las imágenes recolectadas, seguido de la clasificación y finalmente determinar por intermedio de probabilidades la avería detectada como sexto paso la alerta temprana y finalmente el mantenimiento correctivo que disminuirá los descarrilamiento, accidentes y paralizaciones.

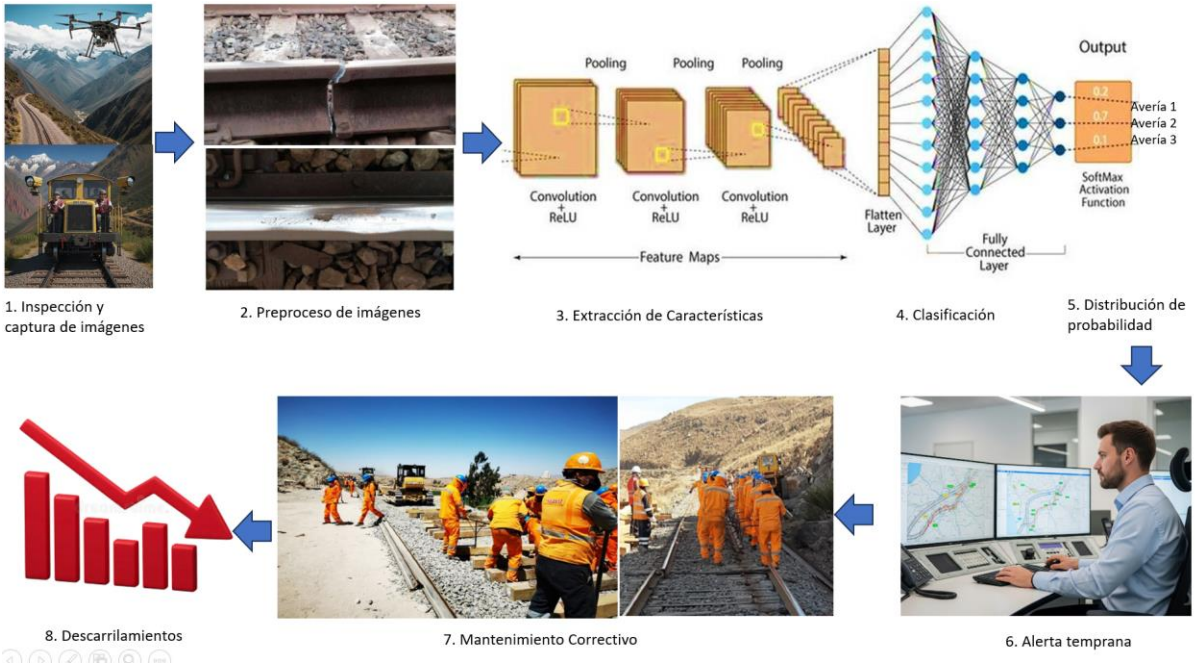


Figura 27: Propuesta de solución al problema principal planteado.
Fuente: Elaboración propia.

La problemática central de esta investigación radica en los descarrilamientos, accidentes y paralizaciones ocasionados por el estado de las vías y la insuficiencia de los métodos actuales de inspección y detección de averías en las vías férreas que garanticen una seguridad operativa óptima y un mantenimiento eficiente. Las averías en rieles es la consecuencia de un sistema interconectado donde diversos elementos como el tráfico ferroviario, condiciones climáticas, factores operacionales y falta de inspección oportuna ocasionan defectos estructurales en las vías férreas si no son controlados terminan en descarrilamientos o accidentes con gran impacto económico y social tal como se muestra en la figura 24.

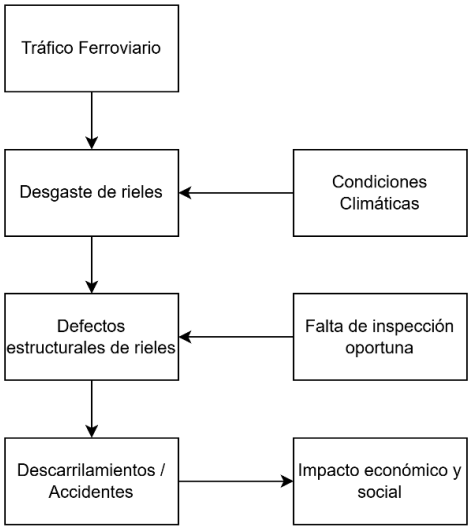


Figura 28: Mapa ontológico simplificado.
Fuente: Propia

Esta investigación aplicara la Inteligencia Artificial (IA) y su rama de visión por computador para la detección objetos y patrones (averías en los rieles) del Ferrocarril Central con el uso de redes neuronales convolucionales (CNN) para el diseño de un modelo de detección automática de averías en los rieles.

3.2 Desarrollo de la Propuesta de Solución

3.2.1 Construcción del conjunto de datos.

Con respecto al objetivo específico 1 indicado en la sección 1.4.2.1 construir un conjunto de datos de imágenes es un pilar fundamental para el éxito de esta investigación, ya que transforma el proceso de una simple acumulación de datos a una construcción planificada de un conjunto de datos robusto y representativo. Para esta investigación se han recolectado imágenes en tramos de la vía en los distritos de El Agustino aproximadamente a 197 msnm, Ate Huaycan a 628 msnm, Chosica a 850 msnm, Chilca – Huancan a 3253 msnm y Huancayo – El tambo a 3196 msnm. Una porción de las imágenes recolectadas se puede ver en la Figura 25.



Figura 29: Imágenes recolectadas en los distritos de El Agustino y Ate.
Fuente: Propia

Otro factor importante que se está considerando para la construcción del conjunto de datos de imágenes de rieles es el entorno operativo único del Ferrocarril Central del Perú que exige un muestreo estratificado por piso altitudinal (Hadj-Mabrouk, 2025), reconociendo que la apariencia de las averías, como el óxido, cambia drásticamente con la altitud y la humedad (ver figura 27). Ignorar esta variabilidad resultaría en un modelo que solo funciona en un único entorno.



Figura 30: Imagen de riel tomada en la costa con oxidación.
Fuente: Propia

En el muestreo se está considerando la variabilidad lumínica (soleado y nublado), capturando imágenes en distintos bloques de tiempo (mañana, mediodía y tarde) para asegurar que el modelo sea robusto a sombras duras y reflejos intensos, los cuales actualmente ocultan defectos.



Figura 31: Imagen de riel tomada a medio día con sombras que podrían ocultar averías.
Fuente: Propia

3.2.2 El aumentado de datos.

En el contexto del entrenamiento de redes neuronales convolucionales (CNN) y arquitecturas basadas en Transformers (como RT-DETR) para la detección de fallas en vías férreas, la calidad del dato prevalece sobre la cantidad. Dado que defectos críticos como las fisuras transversales y las grietas longitudinales se manifiestan como discontinuidades de bajo espesor, las técnicas tradicionales de aumentado de datos que introducen ruido estocástico o desenfoque (blur) resultan contraproducentes, pues degradan la integridad de los bordes del defecto. Por lo tanto, en esta investigación se aplicaron las siguientes técnicas de aumentado de datos.

Transformaciones Geométricas Rígidas (Invarianza Espacial)

El objetivo de estas transformaciones es desacoplar el aprendizaje del modelo de la orientación de la cámara, garantizando que la red neuronal aprenda la topología del defecto y no su posición en el cuadro (Zeng, 2024).

Reflexión Horizontal (Horizontal Flip): Se aplica una transformación de simetría especular respecto al eje vertical. En el dominio de la inspección ferroviaria, la física de la fractura del material es invariante a la lateralidad; una grieta vista desde la izquierda o derecha posee la misma firma espectral de peligrosidad. Esta técnica duplica el conjunto de datos sin interpolación de píxeles, garantizando una pérdida de información nula (Zeng, 2024).





Figura 32: Imagen original vs Imagen Aumentada volteada Horizontalmente.
Fuente: Propia

Rotación Limitada (+- 5°): Se introducen perturbaciones rotacionales menores para simular variaciones en el ángulo de ataque del sensor o vibraciones del vehículo de inspección. Se restringe el ángulo al intervalo [**- 5°**, + **5°**] para minimizar los artefactos de *aliasing* (bordes dentados) generados por la interpolación bicúbica, preservando la rectitud de las fisuras lineales (Zeng, 2024).





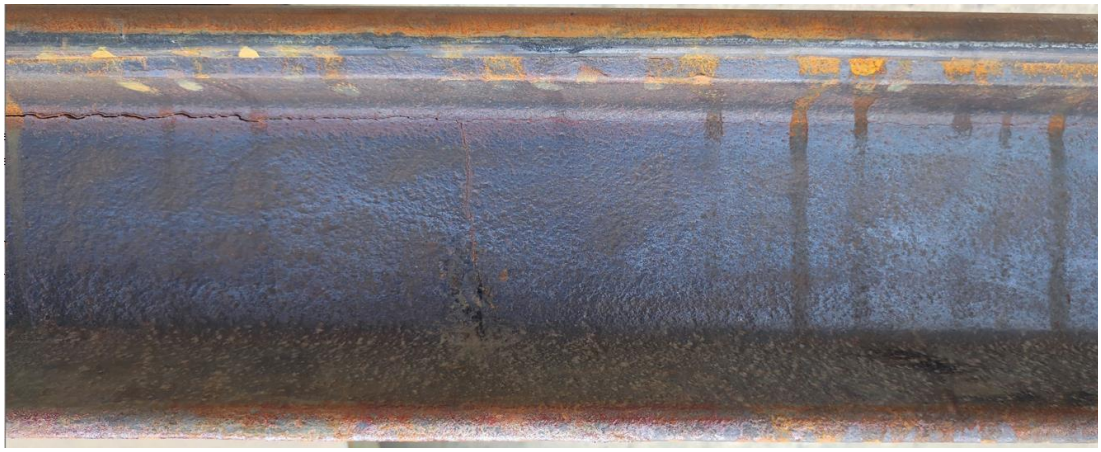
Figura 33: Imagen original vs Imagen Aumentada rotada 5 grados.
Fuente: Propia

Transformaciones Fotométricas de Realce (Mejora de la Relación Señal-Ruido)

A diferencia de la adición de ruido gaussiano, que contamina la imagen, las siguientes técnicas operan sobre el histograma de intensidades para hacer más evidentes los defectos existentes, especialmente en condiciones de iluminación adversa o superficies oxidadas.

Ecualización de Histograma Adaptativa Limitada por Contraste (CLAHE):

Esta técnica es fundamental para la detección de grietas en superficies metálicas texturizadas (óxido). A diferencia de la ecualización global, CLAHE opera en pequeñas regiones locales (tiles). Incrementa el contraste local entre la fisura (zona oscura) y el hongo del riel (zona oxidada/clara). Esto facilita que los kernels de convolución extraigan bordes con mayor precisión, resaltando la morfología de la grieta sin alterar su geometría (Zeng, 2024).



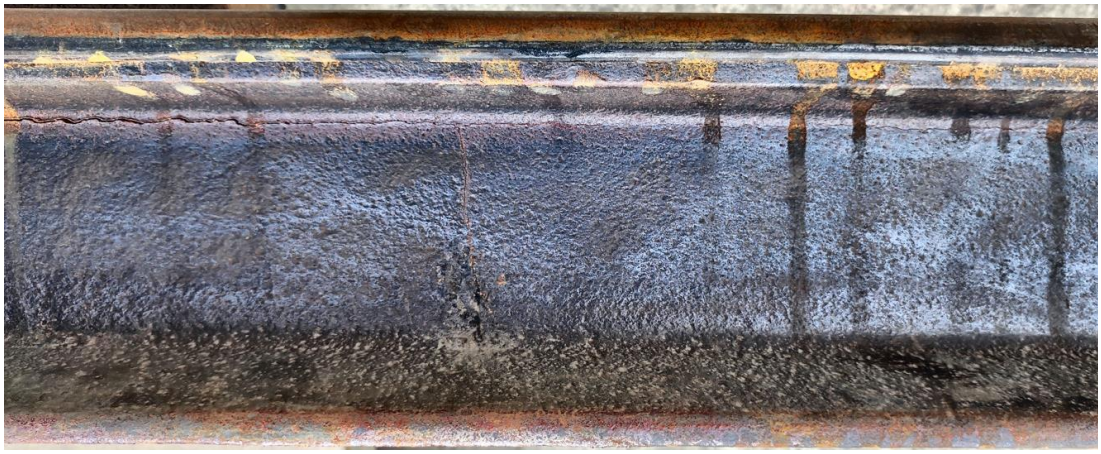


Figura 34: Imagen original vs Imagen Aumentada aplicando Clahe.
Fuente: Propia

Corrección Gamma (γ):

Se aplica una transformación de ley de potencia ($V_out = \mathrm{V_in}^{\gamma}$) para simular variaciones no lineales en la iluminación (días nublados vs. soleados). Al utilizar un $\gamma \neq 1$, se ajusta la luminancia de los píxeles de rango medio sin saturar los negros (donde reside la información de la grieta), asegurando que el modelo sea robusto ante cambios de luz ambiental (Zeng, 2024).





Figura 35: Imagen original vs Imagen Aumentada aplicando Corrección Gamma (bajar iluminación).
Fuente: Propia

División vertical de la imagen:

En lugar de depender solo de la imagen completa, el modelo debe reconocer patrones en fragmentos. Esto ayuda a que la red sea más robusta frente a oclusiones o recortes en imágenes reales.



Figura 36: Imagen original vs Imagen Aumentada con división vertical.
Fuente: Propia

3.2.2 Preprocesamiento del conjunto de datos.

El preprocesamiento del conjunto de datos es una etapa metodológica crítica, actuando como el puente esencial entre la recolección de datos en bruto y el entrenamiento de un modelo de alto rendimiento. Su importancia es máxima, ya que un modelo solo puede ser tan bueno como la calidad de los datos que consume (Kumar & Harsha, 2024; Wang et al., 2024). En el contexto de esta investigación, donde las imágenes y sus clases son complejas de identificar (alta variabilidad por piso altitudinal, climático e iluminación) (Şener et al., 2022) (Oh et al., 2022) se capturan con alta precisión mediante polígonos en Label Studio (ver imagen 35).

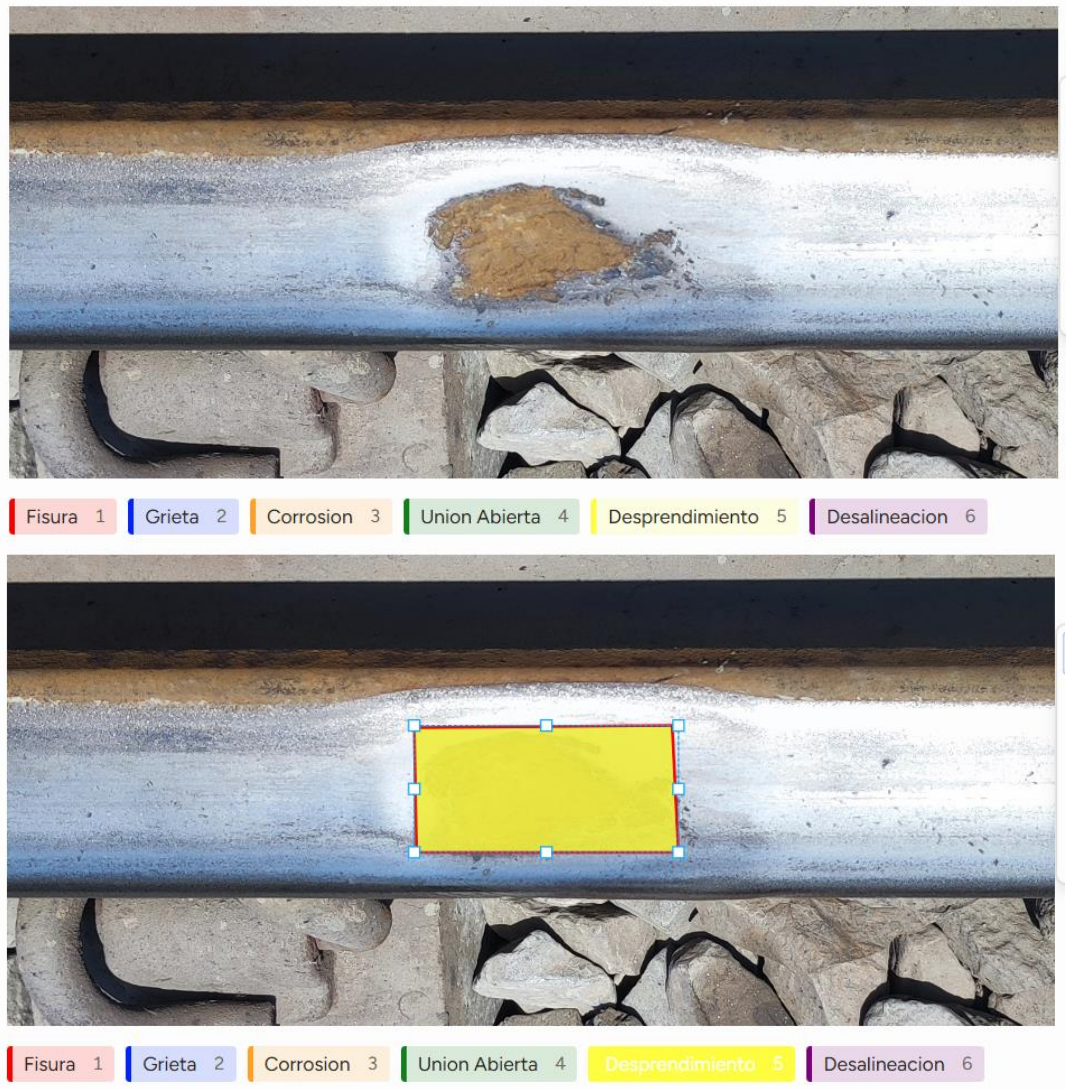


Figura 37: Etiquetado de avería clase desprendimiento.
Fuente: Propia - Label Studio

La división de entrenamiento y validación mantenga la proporción no solo de nuestras clases, sino también de nuestros entornos de recolección (Costa, Sierra o piso altitudinal). Esto garantizara que nuestras métricas de validación sean un reflejo fiel del desempeño del modelo en todos los escenarios. Adicionalmente, para combatir el severo desbalanceo de clases, se implementará un sobremuestreo (oversampling) offline de las clases minoritarias

(desalineación, fisura y desprendimiento), utilizando aumentación de datos (rotación, brillo) y técnicas avanzadas como copy-paste para crear imágenes sintéticas (Hadj-Mabrouk, 2025). Este paso es vital para proveer al modelo de los ejemplos que necesita para aprender a detectar las averías menos frecuentes.

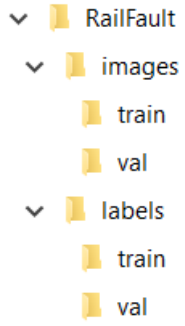


Figura 38: Distribución 80% para entrenamiento y 20% para validación estructura YOLO.
Fuente: Propia.

3.2.4 Diseñar, entrenar y optimizar los modelos.

3.2.4.1 Entrenamiento del modelo ResNet50 FasterRCNN.

La evaluación experimental conducida sobre la arquitectura Faster R-CNN con backbone ResNet50 permitió establecer una línea base de rendimiento, alcanzando su punto máximo de eficacia operativa mediante una configuración de tasa de aprendizaje de 0.005 y escalado de entrada (*Input Scaling* a 1024px), logrando un mAP@50 de 0.308 tal como se puede ver en la figura 39. Si bien este escenario demostró una competencia sólida en la identificación de fallas macroscópicas y volumétricas como la ausencia de pernos o desprendimientos evidentes, el análisis granular de las matrices de confusión normalizadas reveló una deficiencia sistemática en la detección de averías lineales finas, específicamente en las clases "Fisura" y "Grieta" tal como se puede ver en la figura 39.

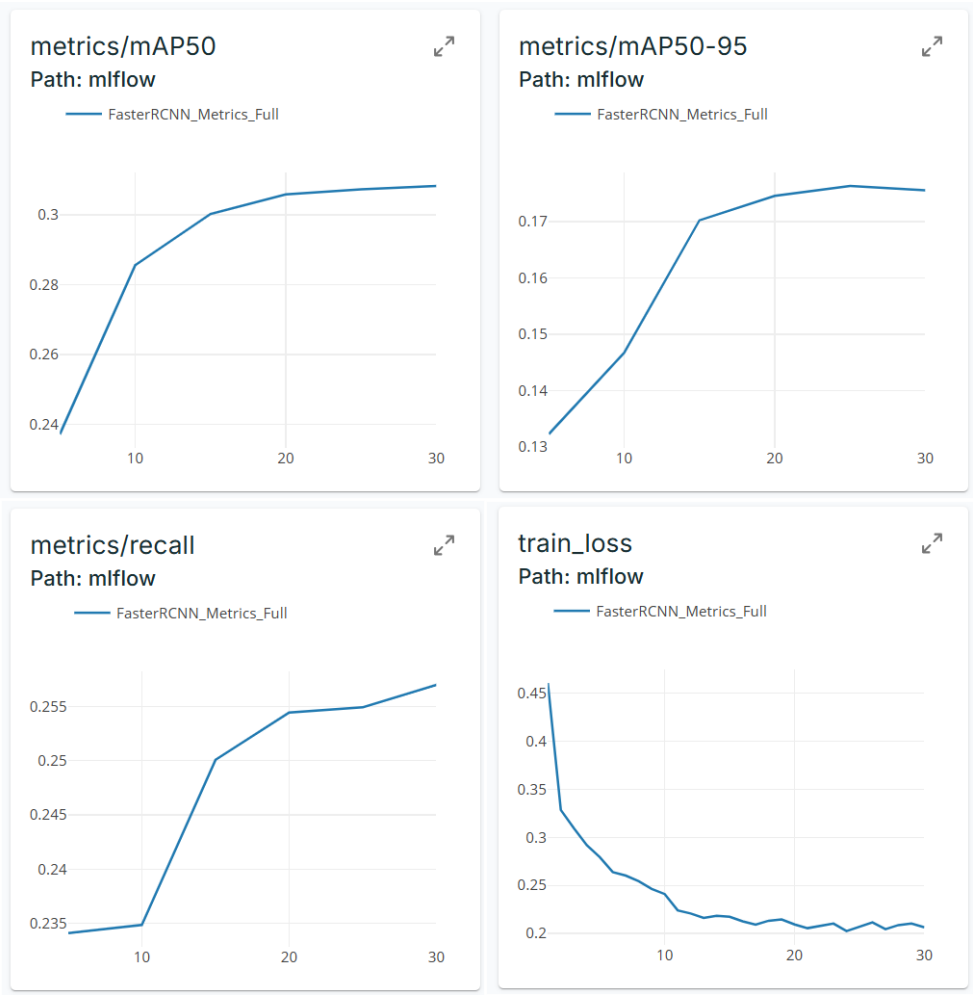


Figura 39: Métricas de desempeño ResNet50 a 30 épocas.
Fuente: Propia - MLflow.

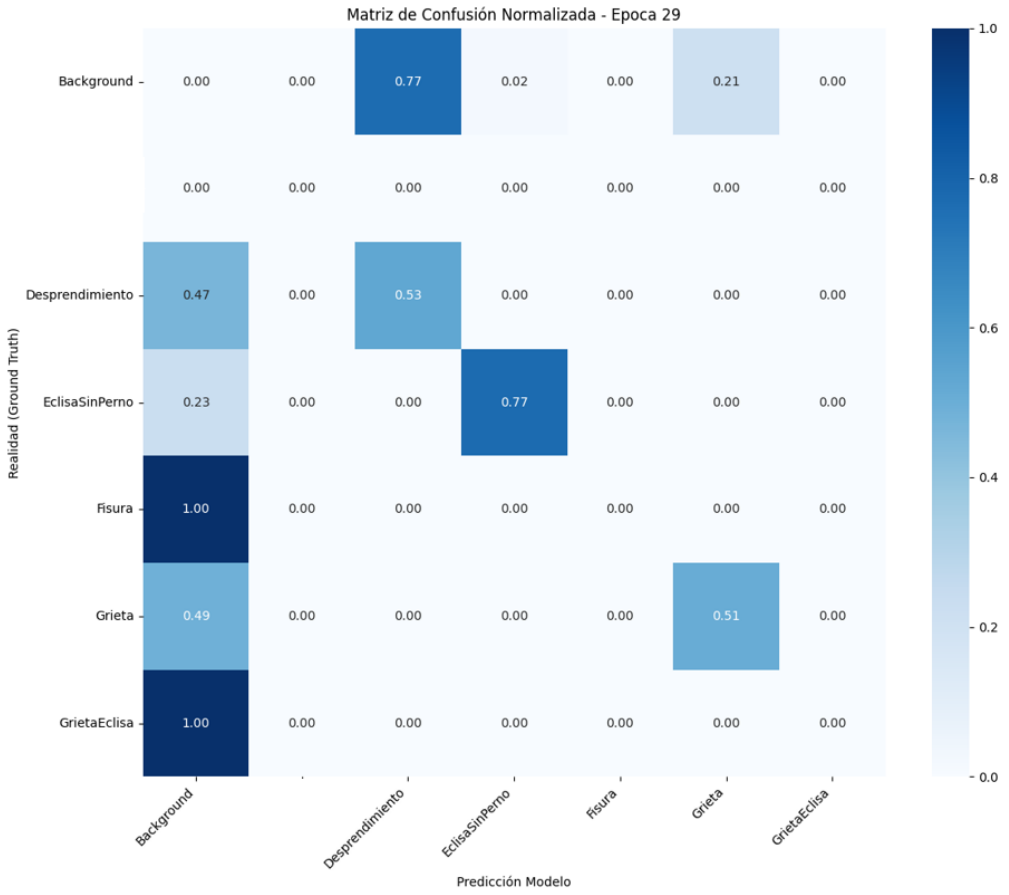


Figura 40: Matriz de confusión normalizada ResNet50 FasterRCNN a 30 épocas.
Fuente: Propia - MLflow.

De acuerdo a la matriz de confusión de la figura 40 la pérdida de sensibilidad hacia los detalles de alta frecuencia (ceguera estructural en grieta y fisura) no debe atribuirse meramente a un desbalance de los datos, dado que incluso las estrategias de muestreo ponderado (*WeightedRandomSampler*) no lograron mitigar el problema, sino a una discordancia geométrica fundamental entre el etiquetado y la morfología del defecto. Las "Anchor Boxes" predeterminadas, diseñadas con relaciones de aspecto cuasi-cuadradas, resultan ineficaces para encapsular objetos de alta excentricidad y espesor mínimo como una fisura longitudinal; esto impide que la red alcance un umbral de Intersección sobre Unión (IoU) suficiente para considerar la región como un "objeto positivo" durante el entrenamiento. Adicionalmente, el proceso de submuestreo (*downsampling*) inherente a las capas profundas de ResNet50 tiende a disolver espacialmente estos rasgos sutiles dentro de los mapas de características, haciendo que la señal visual de una grieta se confunda con la textura del balasto o de la riel. En consecuencia, el modelo converge hacia un mínimo local donde resulta estadísticamente más rentable clasificar estas trazas filiformes como "Fondo" (Background) para minimizar la función de pérdida global, sacrificando la detección de detalles finos en favor de la estabilidad general métrica lograda en nuestro mejor escenario experimental.

3.2.4.2 Entrenamiento del modelo YOLO.

Evaluación del Rendimiento de YOLOv11m en Alta Resolución (1280px): Análisis de Convergencia y Limitaciones Arquitectónicas.

Se llevó a cabo una evaluación exhaustiva del modelo **YOLOv11m** utilizando imágenes de alta resolución (1280px), contrastando su comportamiento en dos regímenes de entrenamiento diferenciados: corta duración (60 épocas) y larga duración (180 épocas). El objetivo fue determinar si un entrenamiento prolongado permitiría a la arquitectura convolucional resolver la detección de características finas.

El análisis cuantitativo de las métricas revela un fenómeno marcado de **rendimientos decrecientes**. Si bien extender el entrenamiento a 180 épocas logró incrementar el **mAP50-95** global de aproximadamente **0.36** a **0.41**, el mAP50 de **0.6174** a **0.6191** y precisión de **0.6106** a **0.6818** este aumento marginal no justificó el triple costo computacional invertido. Las curvas de evolución métrica muestran un estancamiento asintótico a partir de la época 100, donde la disminución continua de la función de pérdida de caja (train/box_loss) sin una mejora proporcional en la precisión de validación sugiere un inicio de sobreajuste (*overfitting*).

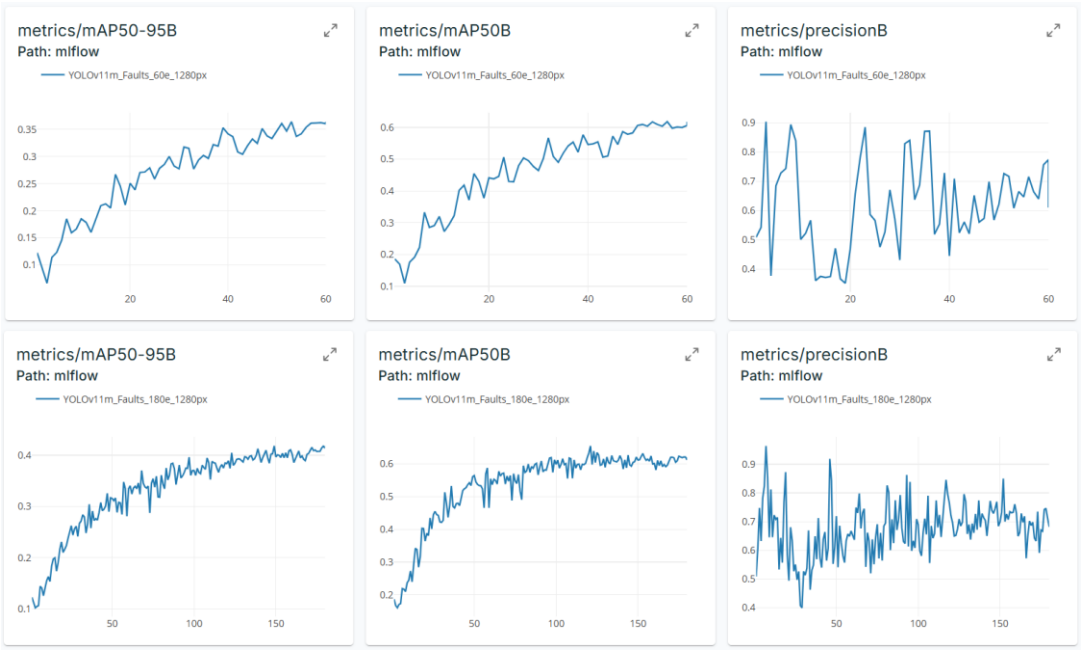


Figura 41: Métricas de desempeño YOLOv11m a 60 y 180 épocas.
Fuente: Propia - MLflow.

A nivel cualitativo, el examen de las Matrices de Confusión Normalizadas expone una limitación estructural crítica. Independientemente de la duración del entrenamiento, el modelo exhibió una **"ceguera persistente"** ante la clase *Fisura*, manteniendo una tasa de error del **72%** (falsos negativos clasificados como fondo) tanto en 60 como en 180 épocas. De igual manera, la clase *Desprendimiento* presentó una alta tasa de falsos positivos (~67-68%), indicando una tendencia del modelo a "alucinar" fallas en tramos de vía sanos.

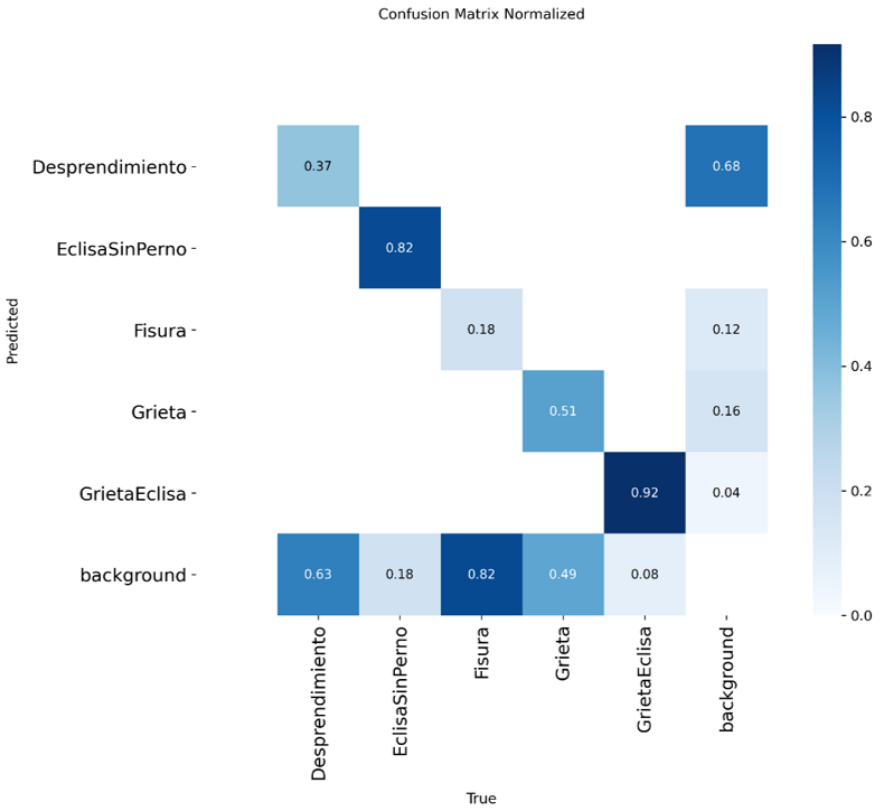


Figura 42: Matriz de confusión normalizada de YOLOv11m a 60 épocas.
Fuente: Propia - MLflow.

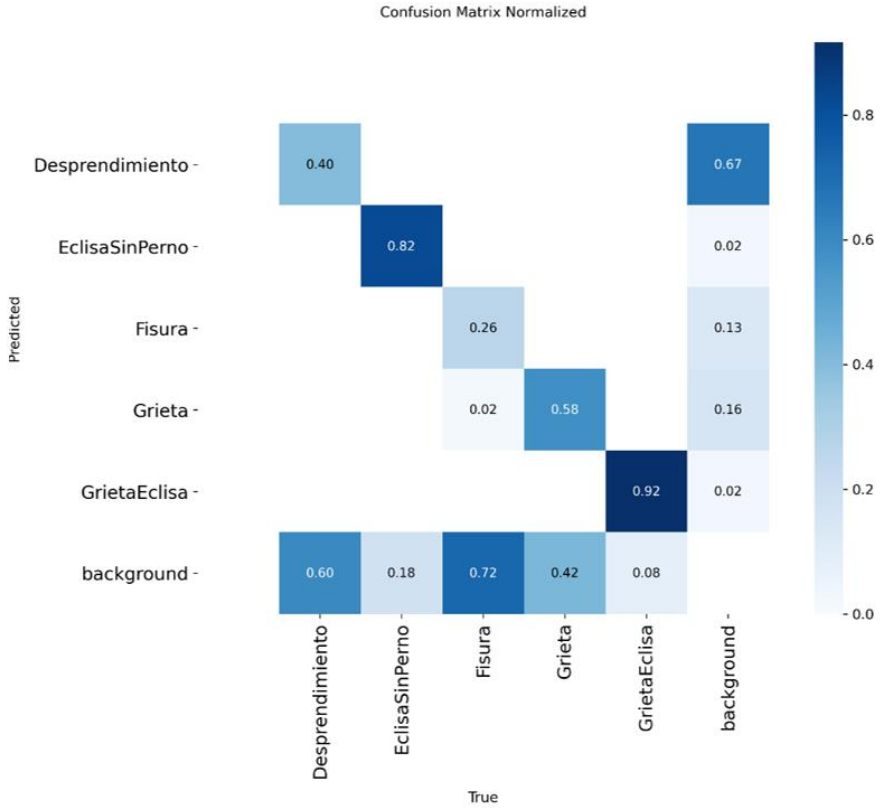


Figura 43: Matriz de confusión normalizada de YOLOv11m a 180 épocas.
Fuente: Propia - MLflow.

Las matrices de confusión normalizada demuestran que aumentar la profundidad del entrenamiento en YOLOv11m no resuelve su incapacidad para extraer características de texturas sutiles (fisuras) frente a fondos ruidosos. La limitante principal no radica en la convergencia del modelo, sino en la arquitectura CNN misma, la cual pierde información vital de micro-defectos incluso trabajando a resoluciones de 1280px.

En la imagen 40 se muestran unas imágenes usadas para la validación en el entrenamiento del modelo YOLO.



Figura 44: Etiquetas para la validación del entrenamiento de YOLO.
Fuente: Propia - MLflow.

En la imagen 41 se muestra la predicción que ha realizado el modelo YOLOv11m a 60 épocas y se puede notar que en la parte derecha omitió en detectar dos desprendimientos.



Figura 45: Detección de averías en la etapa de validación durante el entrenamiento con YOLOv11m 60 épocas.
Fuente: Propia - MLflow.

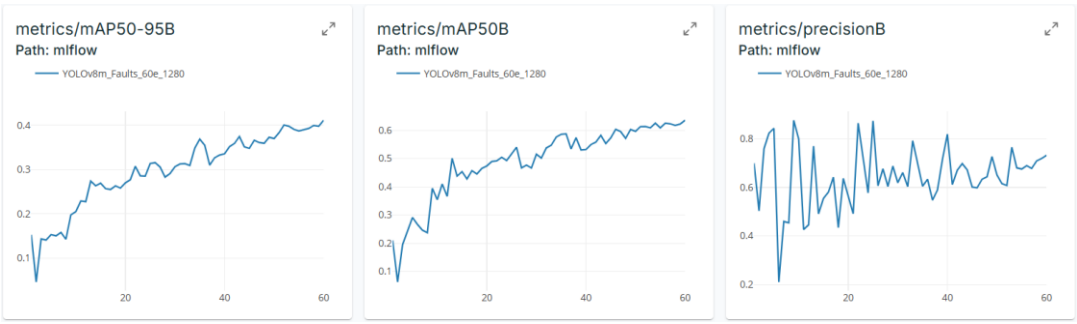
En la imagen 46 se muestra la predicción que ha realizado el modelo YOLOv11m a 180 épocas y se puede notar que en la parte derecha apareció 1 defecto adicional etiquetado con eclisa como falso negativo.



Figura 46: Detección de averías en la etapa de validación durante el entrenamiento con YOLOv11m 180 épocas. Fuente: Propia - MLflow.

Análisis Comparativo del Rendimiento de YOLOv8m en Alta Resolución: Estabilidad frente a la Evolución Arquitectónica

La evaluación experimental del modelo **YOLOv8m** con imágenes de 1280px se desarrolló bajo dos esquemas de entrenamiento (60 y 180 épocas) para determinar el impacto de la duración del aprendizaje en la detección de fallas ferroviarias. Los resultados cuantitativos evidencian un comportamiento de saturación temprana: el modelo alcanzó un **mAP50-95** de **0.41** a las 60 épocas, incrementándose marginalmente a **0.42** tras extender el entrenamiento a 180 épocas. Este aumento de apenas 0.01 puntos porcentuales confirma la existencia de rendimientos decrecientes, donde el costo computacional adicional no se traduce en una mejora significativa de la capacidad de generalización. Con respecto a las otras métricas se obtuvieron un mAP50 de 0.6350 a 0.6339 una precisión de 0.7307 a 0.7620 respectivamente para 60 y 180 épocas.



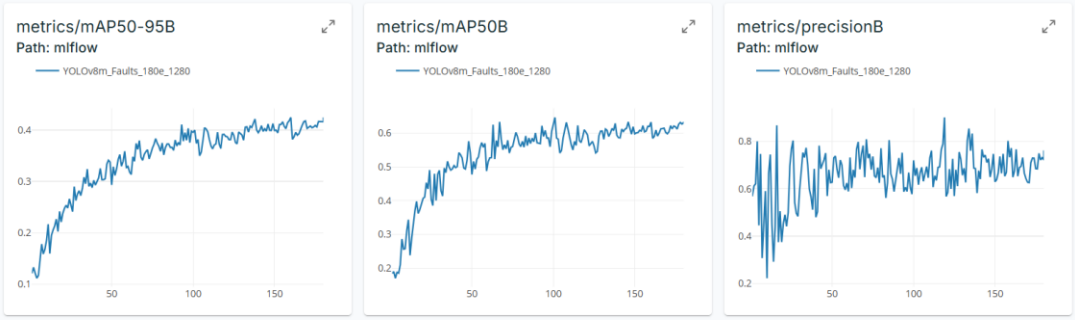


Figura 47: Métricas de desempeño YOLOv8m a 60 y 180 épocas.
Fuente: Propia - MLflow.

Al contrastar estos hallazgos con el modelo de nueva generación **YOLOv11m**, se observa un patrón de estancamiento arquitectónico para este dominio específico. Mientras que YOLOv11m requirió 180 épocas para alcanzar una precisión comparable (~0.41), YOLOv8m logró este umbral de rendimiento con mayor rapidez y estabilidad. Sin embargo, ambas arquitecturas compartieron las mismas deficiencias estructurales: una tasa crítica de falsos negativos en la clase *Fisura* y una propensión al sobreajuste en la clase *Desprendimiento*. Las curvas de pérdida (train/box_loss) en ambos modelos muestran una tendencia a la memorización de coordenadas sin una mejora correlativa en la validación a partir de la época 100.

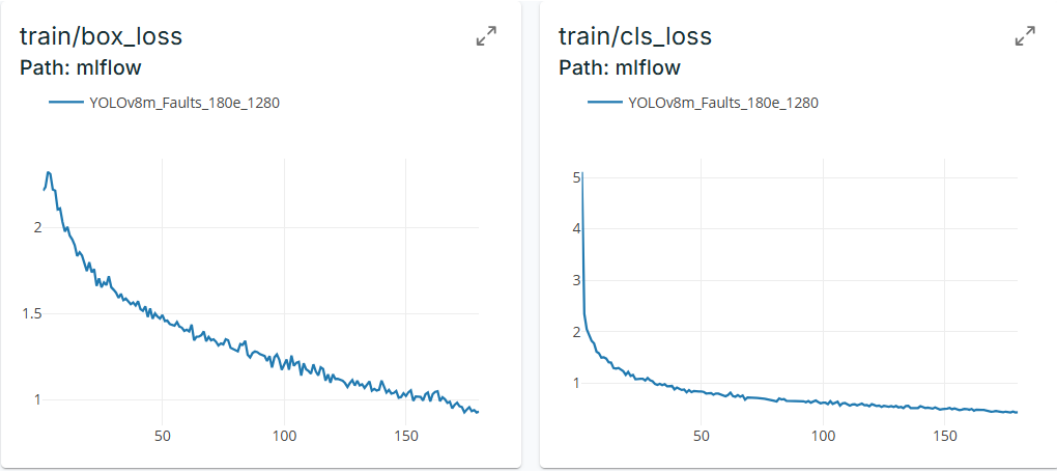


Figura 48: Métricas de desempeño curvas de perdida para YOLOv8 en cajas delimitadoras y clases.
Fuente: Propia - MLflow.

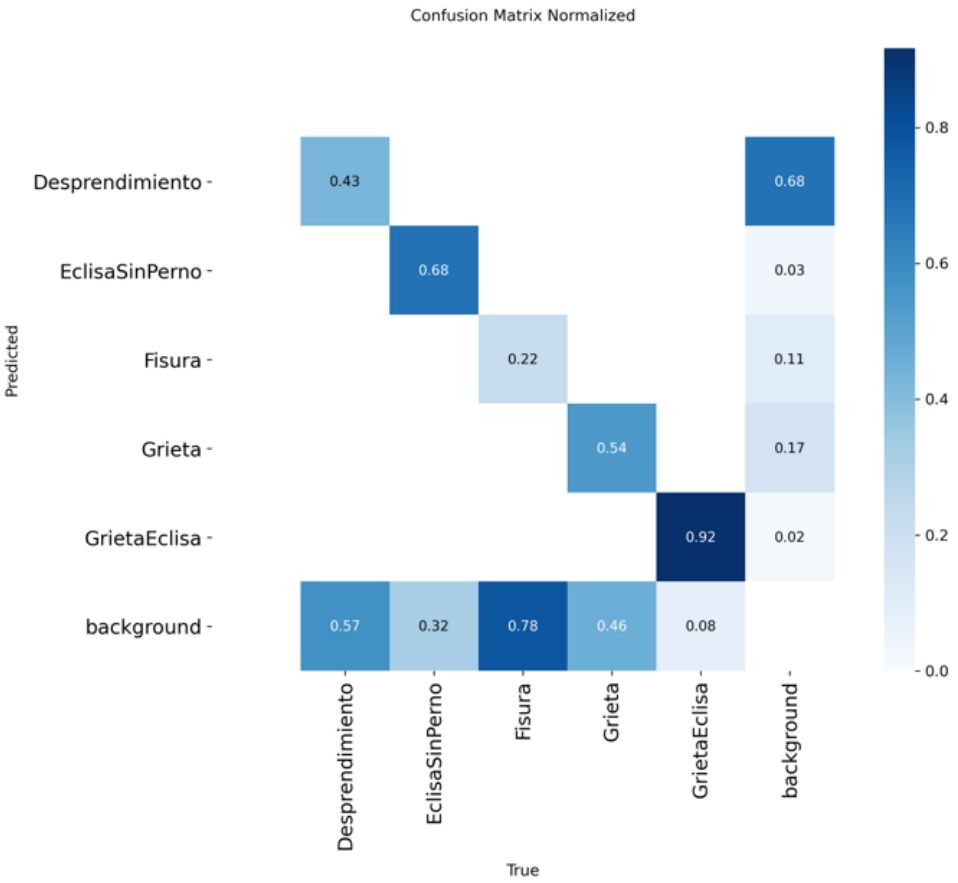


Figura 49: Matriz de confusión normalizada de YOLOv8m a 60 épocas.
Fuente: Propia - MLflow.

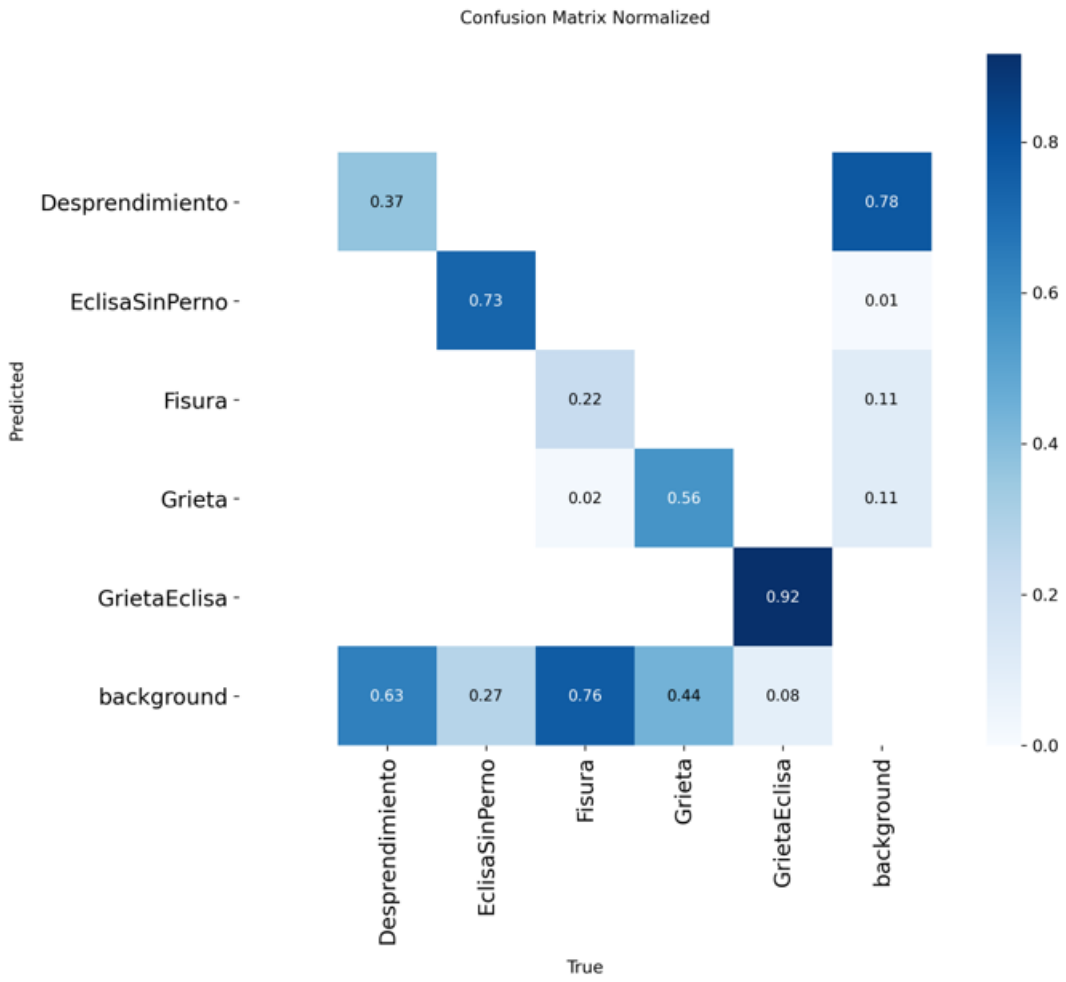


Figura 50: Matriz de confusión normalizada de YOLOv8m a 180 épocas.
Fuente: Propia - MLflow.

La transición de YOLOv8m a YOLOv11m no aportó ventajas sustanciales en la resolución de micro-defectos (fisuras) en imágenes de alta resolución. La limitante principal identificada no es la antigüedad de la versión, sino la dificultad intrínseca de las redes convolucionales (CNN) para preservar características de alta frecuencia tras múltiples etapas de *downsampling*, independientemente de la profundidad del entrenamiento.

3.2.4.3 Entrenamiento de Real-Time Detection Transformer RT-DETR

La aplicación de arquitecturas basadas en DETR en el entorno ferroviario ha demostrado ser superior en el manejo de fondos complejos y ruidosos, típicos de las vías férreas (balasto, durmientes, vegetación). Estudios recientes validan que la capacidad de atención global de RT-DETR permite mitigar la interferencia de texturas de fondo (como el óxido o piedras), mejorando la tasa de detección de defectos sutiles frente a los enfoques convolucionales estándar(Xie et al., 2025).

Evaluación de la Arquitectura RT-DETR-L: Eficiencia de los Vision Transformers frente a Redes Convolucionales en la Detección de Fallas

Esta investigación se centró en la evaluación del modelo **RT-DETR-L** (Real-Time Detection Transformer), operando con imágenes de resolución estándar. Se compararon dos regímenes de entrenamiento, a 45 y 90 épocas, para identificar el punto óptimo de convergencia y estabilidad.

El análisis de las métricas evolutivas revela que el modelo alcanzó su máximo rendimiento operativo en el régimen de corta duración. Específicamente, hacia la época 45, el modelo logró un **mAP50-95** superior a **0.44**, demostrando una capacidad de generalización robusta. Por el contrario, la extensión del entrenamiento a 90 épocas resultó contraproducente; los datos muestran una degradación del rendimiento global hacia un **mAP50-95** de **0.41** y una inestabilidad notable en la función de pérdida de validación a partir de la época 50. Esto confirma que el mecanismo de atención del Transformer converge rápidamente y es susceptible al sobreajuste (*overfitting*) si se entrena excesivamente con este conjunto de datos.

Métricas RT-DETR	45 épocas	90 épocas
metrics/mAP50-95B	0.4497	0.4147
metrics/mAP50B	0.7047	0.6613
metrics/precisionB	0.7784	0.7209
metrics/recallB	0.6536	0.6164
train/cls_loss	0.3554	0.3209
train/giou_loss	0.2879	0.2590
train/l1_loss	0.1071	0.0864

Tabla 18: Métricas obtenidas durante el entrenamiento de RT-DETR.
Fuente: Elaboración propia.

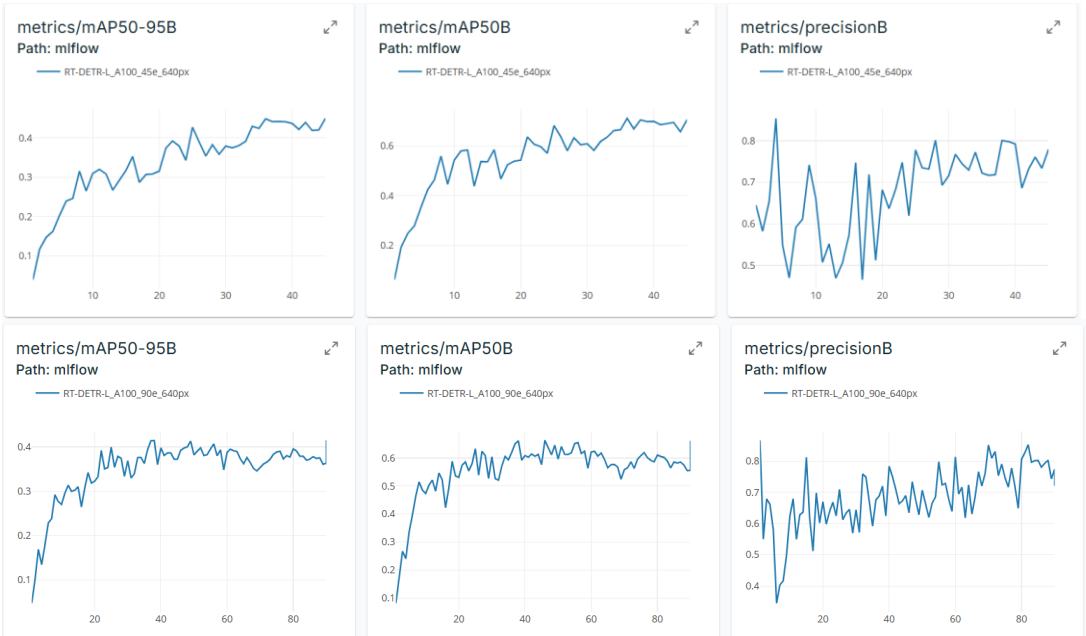


Figura 51: Métricas de desempeño RT-DETR a 45 y 90 épocas.
Fuente: Propia - MLflow.

Al contrastar estos hallazgos con los modelos **YOLOv8m** y **YOLOv11m**, la superioridad de RT-DETR resulta técnica y arquitectónicamente significativa. Mientras que las arquitecturas YOLO (basadas en CNN) requirieron imágenes de alta resolución (1280px) y entrenamientos

prolongados (180 épocas) para alcanzar apenas un mAP de 0.42, RT-DETR superó este umbral utilizando el tamaño estándar para las imágenes y una cuarta parte de las épocas. La ventaja decisiva de RT-DETR radica en su capacidad para resolver la clase crítica *Fisura*. Las redes convolucionales como YOLO, debido a sus operaciones de *pooling* y *downsampling*, tienden a diluir la información de texturas finas, volviéndose funcionalmente "ciegas" ante micro-defectos o confundiéndolos con el ruido de fondo del riel. En cambio, el mecanismo de **Auto-Atención (Self-Attention)** del RT-DETR permite capturar dependencias globales y preservar características sutiles incluso a baja resolución, evitando que el ruido visual de alta frecuencia sature la detección.

El análisis comparativo de las matrices de confusión normalizadas entre las 45 y 90 épocas (ver figura 50 y 51) revela la maduración del discriminador de características dentro de la arquitectura RT-DETR. En la etapa intermedia de **45 épocas**, aunque la diagonal principal comienza a definirse, la normalización suele evidenciar todavía una "fuga" de probabilidad hacia las clases adyacentes o hacia la categoría de *background* (fondo), lo que señala una tasa de falsos negativos aún perfectible y cierta ambigüedad semántica entre objetos similares.

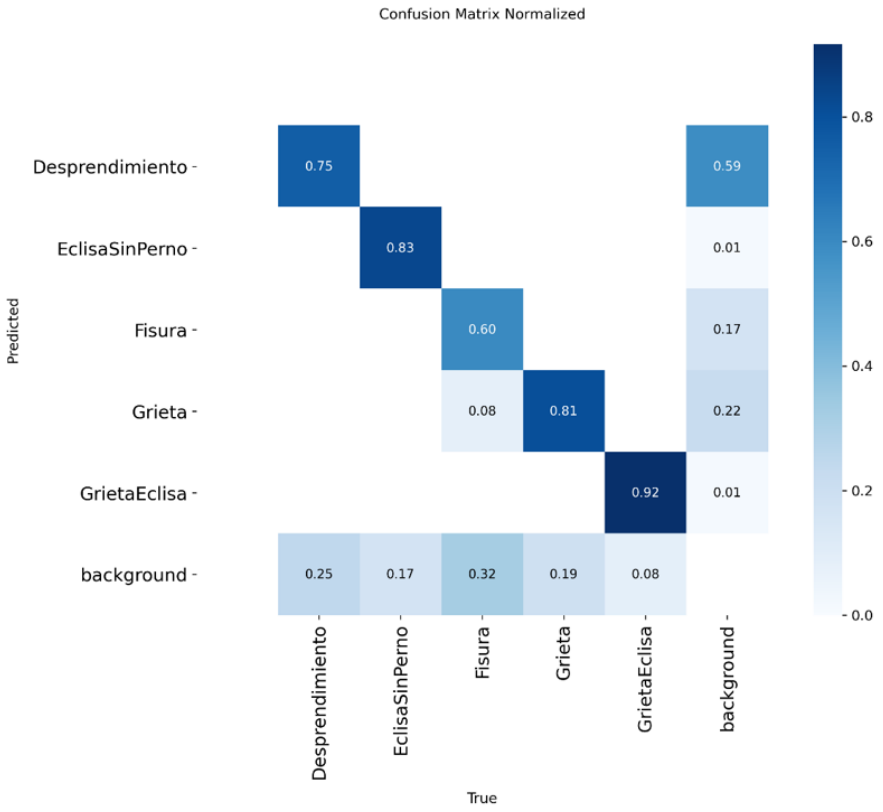


Figura 52: Matriz de confusión normalizada de RT-DETR a 45 épocas.
Fuente: Propia - MLflow.

Al extender el entrenamiento a **90 épocas**, se observa un marcado "afilamiento" de la diagonal principal. La ventaja crítica de utilizar matrices normalizadas aquí es que permiten verificar que la mejora en la sensibilidad (Recall) es estructural y no sesgada por el volumen de datos de cada clase. Se destaca una reducción sistemática en los valores fuera de la diagonal, lo que indica que el mecanismo de atención del transformador ha logrado desacoplar características visuales complejas que generaban confusión anteriormente. En esencia, la transición a 90

épocas representa el paso de un aprendizaje generalista a una especialización robusta, donde el modelo minimiza la incertidumbre y maximiza la confianza probabilística de sus predicciones correctas, incluso en clases minoritarias.

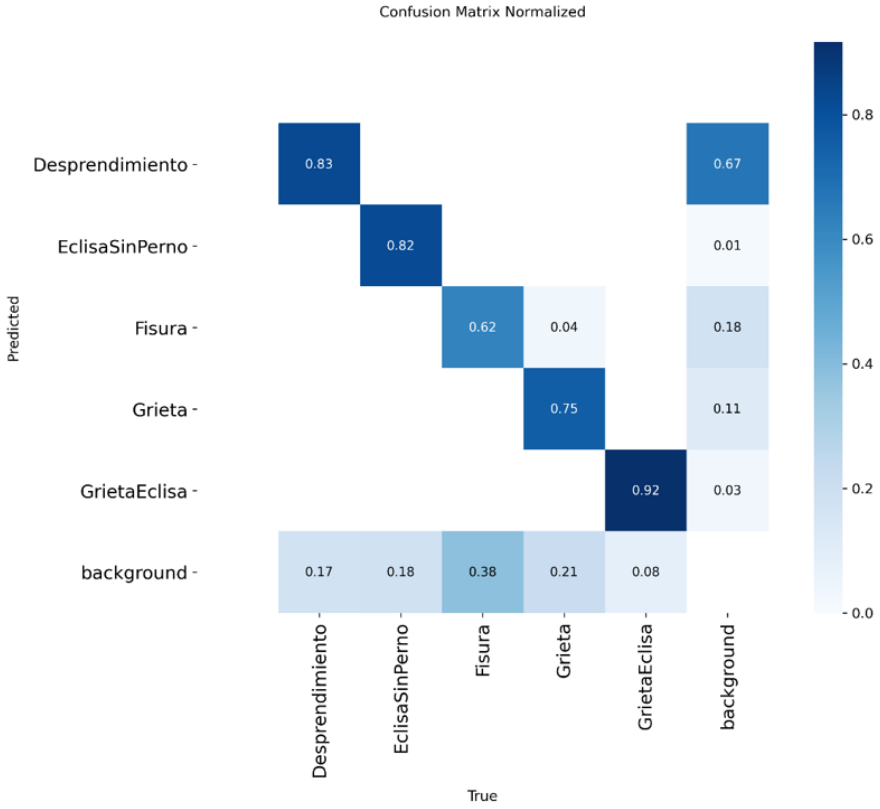


Figura 53: Matriz de confusión normalizada de RT-DETR a 90 épocas.
Fuente: Propia - MLflow.

En la figura 52 se muestran las etiquetas con la cual se hace la validación del entrenamiento para el modelo RT-DETR, en la parde derecha se muestran las imágenes de rieles con sus etiquetas de defectos y en la izquierda imágenes de rieles sanas.



Figura 54: Etiquetas para la validación del entrenamiento de RT-DETR.
Fuente: Propia - MLflow.

En la figura 53 se muestra la predicción que ha realizado el modelo RT-DETR a 45 épocas y se puede notar que en la parte izquierda donde había rieles sin defectos aparecieron defectos lo cual indica 2 falsos negativos con la etiqueta desprendimiento.



Figura 55: Detección de averías en la etapa de validación durante el entrenamiento con RT-DETR 45 épocas.
Fuente: Propia - MLflow.

En la figura 54 se muestra la predicción que ha realizado el modelo RT-DETR a 90 épocas y se puede notar que en la parte izquierda donde había rieles sin defectos aparecieron defectos lo cual indica 3 falsos negativos con la etiqueta desprendimiento y en la parte derecha aparecieron 3 defectos adicionales a los etiquetados con eclisa sin perno lo que indica que el modelo a 90 épocas se sobre entreno (overfitting) y alucino defectos.



Figura 56: Detección de averías en la etapa de validación durante el entrenamiento con RT-DETR 90 épocas.
Fuente: Propia - MLflow.

3.3 Análisis de los Datos y Resultados

Para la validación de la hipótesis planteada, se ejecutó una serie experimental exhaustiva comparando tres arquitecturas de vanguardia: Faster R-CNN, YOLOv8/v11 y RT-DETR (Basado en Transformers). Los modelos fueron entrenados y evaluados utilizando el mismo conjunto de datos de validación para garantizar la comparabilidad de las métricas. El entorno de hardware utilizado consistió en una GPU NVIDIA A100 (40GB VRAM), lo que permitió explorar resoluciones de entrada de hasta 1280 píxeles.

A continuación, en la tabla 19 se presenta el resumen cuantitativo de los mejores resultados obtenidos por cada arquitectura:

Modelo	Épocas	Resolución (px)	mAP@50	mAP@50-95	Recall	Precision	Tiempo Entrenamiento

RT-DETR-L	**45**	**640**	**0.7047**	**0.4497**	**0.6536**	**0.7784**	**~24 min**
YOLOv8m	180	1280	0.6339	0.4247	0.5356	0.7621	~1.2 h
YOLOv8m	60	1280	0.6350	0.4109	0.5476	0.7307	~24 min
YOLOv11m	180	1280	0.6192	0.4181	0.5829	0.6819	~1.4 h
YOLOv11m	60	1280	0.6175	0.3639	0.5715	0.6106	~29 min
Faster R-CNN (ResNet50)	30	1024	0.3083	0.1756	0.2,570	- *	~56 min

Tabla 19: Métricas obtenidas comparación ente modelos ResNet50, Yolo y RT-DETR.
Fuente: Elaboración propia

El análisis de los datos revela una jerarquía clara en el desempeño:

Dominio de RT-DETR: El modelo basado en Transformers alcanzó el **mAP@50 más alto (0.7047)**, superando al segundo mejor modelo (YOLOv8m) por más de 7 puntos porcentuales. Este resultado es notablemente eficiente, ya que se logró con una resolución de imagen estándar de 640 píxeles y en un tiempo de entrenamiento reducido (45 épocas).

Saturación en Modelos CNN: Se observa que aumentar drásticamente las épocas de entrenamiento en YOLO (de 60 a 180) no se tradujo en una mejora lineal del rendimiento, evidenciando una convergencia temprana.

Deficiencia en Faster R-CNN: A pesar de utilizar una resolución alta (1024 px) y un backbone robusto (ResNet50), este modelo presentó las métricas más bajas del estudio, con una recuperación (Recall) de apenas 0.2570, indicando una alta tasa de falsos negativos.

3.4 Discusión e Interpretación de los Resultados.

La superioridad métrica de **RT-DETR** frente a las arquitecturas convolucionales tradicionales (CNN) puede interpretarse a través de la diferencia fundamental en sus mecanismos de atención. Mientras que YOLO y Faster R-CNN dependen de operaciones de convolución local que procesan la imagen por "ventanas", RT-DETR utiliza mecanismos de **auto-atención (Self-Attention)** que permiten al modelo correlacionar características visuales distantes en una sola pasada. Esto resultó crítico para distinguir fallas complejas como "Grietas" en entornos ruidosos (balasto), donde el contexto global de la vía férrea ayuda a confirmar la existencia de la falla.

Un hallazgo cualitativo crucial se desprende del análisis de las **Matrices de Confusión Normalizadas**. Los modelos basados en anclas fijas (**Faster R-CNN** y, en menor medida, **YOLO**) mostraron una "ceguera estructural" ante las clases **"Fisura"** y **"Grieta"**.

- **Interpretación Geométrica:** Las fisuras son defectos filiformes (líneas delgadas) que no coinciden con la geometría cuadrada o rectangular (ratios 1:1, 1:2) de las *Anchor Boxes* predeterminadas. Al no lograr un solapamiento (IoU) suficiente durante el entrenamiento, la red Faster R-CNN penalizó estas detecciones, clasificándolas erróneamente como "Fondo" (Background), lo que explica su bajo Recall (0.2570).
- **La Ventaja *Anchor-Free*:** RT-DETR, al ser una arquitectura libre de anclas (*anchor-free*), no sufre de esta limitación geométrica. Predice cajas delimitadoras directamente a partir de las consultas (*object queries*) del Transformer, adaptándose

dinámicamente a la forma irregular y alargada de las fisuras, lo que le permitió recuperar detalles que los otros modelos ignoraron.

Finalmente, la relación **Costo-Beneficio Computacional** favorece a las arquitecturas modernas. A pesar de la complejidad teórica de los Transformers, el uso de Tensor Cores en la GPU A100 permitió que RT-DETR entrenara en tiempos equivalentes a YOLOv8 (aprox. 24 minutos), desmitificando la idea de que los modelos más precisos son necesariamente más lentos de entrenar.

3.5 Estimación del Impacto de la Solución.

La implementación del modelo propuesto (RT-DETR) tendría un impacto transformador en tres dimensiones operativas del mantenimiento ferroviario:

Impacto en la Seguridad Operacional: La capacidad del modelo para detectar fallas con una Precisión del 77.8% implica una reducción significativa del error humano. En el método actual de inspección manual, la fatiga visual de los operarios puede llevar a omitir micro-fisuras críticas. El sistema automatizado actúa como un "segundo par de ojos" infatigable, capaz de alertar sobre anomalías incipientes antes de que evolucionen a fracturas catastróficas, elevando los estándares de seguridad preventiva del Ferrocarril Central.

Impacto Económico y Eficiencia: El modelo RT-DETR demostró ser capaz de procesar imágenes en milisegundos, lo que viabiliza la inspección en tiempo real a velocidades comerciales. Esto permitiría aumentar la frecuencia de las inspecciones (pasando de mensuales a semanales o diarias) sin incrementar proporcionalmente los costos de mano de obra. La detección temprana de una "Eclisa sin perno" o una "Grieta" permite reparaciones programadas de bajo costo, evitando los costos exorbitantes asociados a descarrilamientos o reparaciones de emergencia que detienen la operación de la vía.

Impacto Tecnológico: Esta investigación valida la viabilidad de desplegar arquitecturas de Deep Learning de última generación (Transformers) en entornos industriales locales. Demuestra que no es necesario disponer de millones de imágenes (gracias al Transfer Learning) para obtener herramientas funcionales, sentando un precedente tecnológico para la modernización de la infraestructura de transporte en el país mediante el uso de Inteligencia Artificial aplicada.

CAPITULO IV CONCLUSIONES Y RECOMENDACIONES

4.1 CONCLUSIONES

La no disponibilidad de un conjunto de datos contextualizado a la realidad del Ferrocarril Central se solucionó gracias a la estrategia de recolección de datos, estratificada por pisos altitudinales y variabilidad horaria (mañana, mediodía, tarde), fue determinante para dotar al modelo de invarianza ambiental. Al exponer a la red neuronal a una diversidad de fondos (*backgrounds*) que varían desde la aridez de la costa hasta la geomorfología rocosa de la sierra y a distintos rangos dinámicos de iluminación, se logró mitigar el sesgo. Esto impidió que el modelo aprendiera patrones espurios (como asociar un tipo específico de color de piedra o una sombra alargada con una falla), forzándolo en su lugar a extraer características intrínsecas de las averías. Como resultado, el sistema final no solo es preciso en condiciones ideales, sino que demuestra una capacidad de generalización robusta apta para la operación continua a lo largo de la geografía cambiante del Ferrocarril Central.

El problema de no contar con un conjunto de datos balanceado y etiquetado se resolvió gracias al preprocesamiento realizado al conjunto de datos recolectado por lo tanto se concluye que las técnicas de preprocesamiento y la estrategia de etiquetado fueron factores determinantes para superar los desafíos de baja visibilidad en fallas críticas. Específicamente, la aplicación del realce de contraste adaptativo CLAHE (Contrast Limited Adaptive Histogram Equalization) demostró ser esencial para acentuar las características de alta frecuencia de fisuras y grietas, desacoplándolas visualmente de la textura homogénea del acero y el balasto. Asimismo, la técnica de división vertical de imágenes permitió simular escenarios de oclusión parcial, obligando al modelo a aprender patrones locales robustos en lugar de depender de la vista completa del objeto, mejorando su capacidad de generalización en campo.

Los limitados modelos de Deep Learning que realicen la detección de averías fue solucionado gracias al entrenamiento con el conjunto de datos preprocesado y contextualizado donde se demostró la superioridad de la Arquitectura basada en Transformers (RT-DETR): La evaluación comparativa determinó que el modelo RT-DETR (Real-Time DEtection TRansformer) es la arquitectura más eficaz para la detección de fallas en rieles, alcanzando un mAP@50 de 0.7047 en solo 45 épocas de entrenamiento. Este resultado supera significativamente a las arquitecturas CNN tradicionales evaluadas, incluyendo a YOLOv8m (mAP@50 0.6350), YOLOv11m (mAP@50 0.6191) y Faster R-CNN (mAP@50 0.3082). Se concluye que el mecanismo de atención propia (self-attention) de los Transformers permite una mejor comprensión global de la imagen y una extracción de características más robusta frente a la variabilidad del balasto y el metal. Eficacia en la Detección de Patologías Complejas (Fisuras): A diferencia de los modelos basados en anclas fijas (como Faster R-CNN y YOLO), RT-DETR demostró una capacidad superior para identificar fallas de geometría fina y alargada, específicamente en las clases "Fisura" y "Grieta". El análisis de la matriz de confusión normalizada evidenció que RT-DETR logró reducir drásticamente los falsos negativos en estas clases críticas. Esto valida la hipótesis de que las arquitecturas anchor-free (sin anclas) eliminan las limitaciones geométricas impuestas por las cajas predeterminadas, adaptándose mejor a defectos irregulares sin requerir un diseño manual de ratios de aspecto. Eficiencia de Resolución y Convergencia: Un hallazgo técnico notable es que RT-DETR logró su máximo rendimiento utilizando imágenes de resolución media (640 px), superando incluso a los modelos YOLOv8 y YOLOv11 que fueron entrenados con imágenes de alta resolución (1280 px). Esto indica que la calidad de la arquitectura del modelo tiene un peso mayor que la

densidad de píxeles bruta. Además, RT-DETR convergió a su solución óptima en menos iteraciones (45 épocas) comparado con los ciclos extensos requeridos por YOLO (60 a 180 épocas), demostrando una mayor eficiencia en el aprendizaje de características transferidas.

4.2 RECOMENDACIONES

Implementación Operativa de RT-DETR: Se recomienda adoptar la arquitectura RT-DETR como el núcleo del sistema de inspección visual automatizada. Dada su alta precisión (Precision 0.778) y recuperación (Recall 0.653), este modelo ofrece el mejor balance entre confiabilidad de detección y seguridad operativa, minimizando el riesgo de pasar por alto fallas críticas como fisuras en el riel.

Exploración de Alta Resolución en Transformers: Considerando que RT-DETR dominó las pruebas con imágenes de 640 px, se recomienda para trabajos futuros evaluar el impacto de escalar la entrada de este modelo a 1280 px (si el hardware lo permite). Es altamente probable que esto potencie aún más la detección de micro-fisuras incipientes que actualmente podrían estar en el límite de la visibilidad, aunque esto conllevará un incremento en el costo computacional.

Optimización de Hardware para Inferencia: Si bien YOLOv8 ofreció tiempos de inferencia competitivos, la superioridad métrica de RT-DETR justifica la inversión en hardware de aceleración (GPUs con soporte para Tensor Cores) para su despliegue en campo. Se recomienda utilizar dispositivos de borde (Edge AI) de gama alta, como NVIDIA Jetson Orin, que son capaces de ejecutar arquitecturas Transformer en tiempo real, aprovechando la precisión del modelo sin sacrificar la velocidad de inspección del vehículo ferroviario.

Dataset Incremental para Clases Minoritarias: Aunque RT-DETR mejoró la detección de fisuras, se recomienda mantener una estrategia de Active Learning (Aprendizaje Activo), recolectando y etiquetando más ejemplos específicos de fisuras bajo condiciones de iluminación adversa (sombras, lluvia). Esto permitirá refinar el modelo específicamente en los casos de borde donde la confianza de predicción aún puede ser mejorada.

REFERENCIAS

Estándares Mínimos de Seguridad para Vías Férreas de Trocha de 914 Milímetros. (2007).

Gerencia de Regulación y Estudios Económicos. (2025, junio). *INFORME DE DESEMPEÑO 2024—Concesión del Ferrocarril del Centro*. https://www.gob.pe/institucion/minem/informes-publicaciones/6971828-boletin-estadistico-minero-mayo-2025

Guo, F., Liu, J., Qian, Y., & Xie, Q. (2024). Rail surface defect detection using a transformer-based network. *Journal of Industrial Information Integration*, *38*, 100584. https://doi.org/10.1016/j.jii.2024.100584

Hadj-Mabrouk, H. (2025). Contributions and limitations of AI and machine learning in railway operations, maintenance, and safety: A literature review. *Proceedings of the Institution of Mechanical Engineers Part O Journal of Risk and Reliability*, 1-30. https://doi.org/10.1177/1748006X251364324

Kamran, G., Esmaeil, Z., & Mohammad, Y. (2022). Railway Transport and Its Role in the Supply Chains: Overview, Concerns, and Future Direction. *ResearchGate*. https://doi.org/10.1007/978-3-030-89822-9_95-1

Khanam, R., & Hussain, M. (2024). *YOLOv11: An Overview of the Key Architectural Enhancements* (No. arXiv:2410.17725). arXiv. https://doi.org/10.48550/arXiv.2410.17725

Kreuzberger, D., Kühl, N., & Hirschl, S. (2022). *Machine Learning Operations (MLOps): Overview, Definition, and Architecture* (No. arXiv:2205.02302). arXiv. https://doi.org/10.48550/arXiv.2205.02302

Kumar, A., & Harsha, S. P. (2024). A systematic literature review of defect detection in railways using machine vision-based inspection methods. *International Journal of Transportation Science and Technology*. https://doi.org/10.1016/j.ijtst.2024.06.006

Min, Y., Guo, J., & Yang, K. (2022). Research On Real-time Detection Algorithm Of Rail-surface Defects Based On Improved YOLOX. *Journal of Applied Science and Engineering*, *26*(6), 799-810. https://doi.org/10.6180/jase.202306_26(6).0006

Ministerio de Energía y Minas. (2025, Edición N). *Boletín Estadístico Minero—Mayo 2025*. ESTAMIN - Declaración Estadística Mensual.

Oh, K., Yoo, M., Jin, N., Ko, J., Seo, J., Joo, H., & Ko, M. (2022). A Review of Deep Learning Applications for Railway Safety. *Applied Sciences*, *12*(20), Article 20. https://doi.org/10.3390/app122010572

Organismo Supervisor de la Inversión en Infraestructura de Transporte de Uso Público, O. (s. f.). *Anuario Estadístico 2023—OSITRAN*. https://www.ositran.gob.pe/anterior/publicaciones/anuario-estadistico-2023/#flipbook-df_rand306539983/1/

Ositran. (2016). *Ferrovias Central Andina—Reporte Anual 2015*. https://www.ositran.gob.pe/anterior/wp-content/uploads/2017/12/PDN_FVCA_2016.pdf

Ositran. (2023). *Anuario estadístico | Año 2023*. https://www.ositran.gob.pe/anterior/publicaciones/anuario-estadistico-2023/

Patki, Y. (2024). *Object Detection Using Faster R-CNN*.

Rampriya, R. S., Jenefa, A., Beni Prathiba, S., Sabarinathan, Jerart Julus, L., Selvaraj, A. K., & Rodrigues, J. J. P. C. (2024). Fault Detection and Semantic Segmentation on Railway Track Using Deep Fusion Model. *IEEE Access*, *12*, 136183-136201. https://doi.org/10.1109/ACCESS.2024.3462822

Rempelos, G., Ognibene, G., Le Pen, L., Blainey, S., Preston, J., & Powrie, W. (2024). Railway Track Deterioration Models: A Review of the State of the Art. *Transportation Geotechnics*, *49*, 101377. https://doi.org/10.1016/j.trgeo.2024.101377

Rodríguez-Abreo, O., Quiroz-Juárez, M. A., Macías-Socarras, I., Rodríguez-Reséndiz, J., Camacho-Pérez, J. M., Carcedo-Rodríguez, G., & Camacho-Pérez, E. (2025). Automatic Detection of

Railway Faults Using Neural Networks: A Comparative Study of Transfer Learning Models and YOLOv11. *Infrastructures*, *10*(1), Article 1. https://doi.org/10.3390/infrastructures10010003

Saritas, M., Taspinar, Y., Cinar, I., & Koklu, M. (2023). *Railway Track Fault Detection with ResNet Deep Learning Models*.

Şener, A., Ergen, B., & Toğaçar, M. (2022). Fault Detection from Images of Railroad Lines Using the Deep Learning Model Built with the Tensorflow Library. *Turkish Journal of Science and Technology*, *17*. https://doi.org/10.55525/tjst.1056283

Szeliski, R. (2022). *Computer Vision: Algorithms and Applications*. Springer International Publishing. https://doi.org/10.1007/978-3-030-34372-9

Wang, Y., Zhang, K., Wang, L., & Wu, L. (2024). An Improved YOLOv8 Algorithm for Rail Surface Defect Detection. *IEEE Access*, *12*, 44984-44997. https://doi.org/10.1109/ACCESS.2024.3380009

Xie, H., Zhou, H., Chen, R., & Wang, B. (2025). RAP-DETR: Enhancing RT-DETR for Railway Track Defect Detection. *Measurement*, *258*, 119058. https://doi.org/10.1016/j.measurement.2025.119058

Yaseen, M. (2024). *What is YOLOv8: An In-Depth Exploration of the Internal Features of the Next-Generation Object Detector* (No. arXiv:2408.15857). arXiv. https://doi.org/10.48550/arXiv.2408.15857

Zeng, W. (2024). Image data augmentation techniques based on deep learning: A survey. *Mathematical Biosciences and Engineering*, *21*, 6190-6224. https://doi.org/10.3934/mbe.2024272

Zhao, Y., Lv, W., Xu, S., Wei, J., Wang, G., Dang, Q., Liu, Y., & Chen, J. (2024). *DETRs Beat YOLOs on Real-time Object Detection* (No. arXiv:2304.08069). arXiv. https://doi.org/10.48550/arXiv.2304.08069

ANEXOS

ANEXO 1 Matriz de Consistencia

Problema de estudio	**Problemas**	**Objetivos**	**Hipótesis**	**Variables**	**Metodología**
Problema General	La escasez de conjuntos de datos públicos, diversos y debidamente etiquetados que representen las condiciones operativas, geográficas y climáticas específicas de la red ferroviaria del país. Y por ende los modelos de visión por computador no pueden generalizar de manera robusta más allá de los entornos controlados de laboratorio, limitando su capacidad para una detección automática, precisa y en tiempo real de un espectro amplio de averías estructurales y, por ende, comprometiendo su aplicabilidad práctica para la seguridad ferroviaria.	Diseñar y validar un modelo optimizado basado en Deep Learning para la detección y clasificación multiclase de averías estructurales (fisuras, grietas, desprendimiento en rieles, grieta en eclisa y eclisa sin perno) en la infraestructura del Ferrocarril Central del Perú, utilizando un conjunto de datos original y contextualizado para superar las limitaciones de generalización y robustez identificadas en la literatura.	Hipótesis General (Hg): Es posible el diseño y validación de un modelo de Deep Learning que logre de detectar automáticamente las averías en rieles con una precisión (≥90%) y tenga la capacidad de generalizar en condiciones reales.	**Variable Independiente:** O1_VI1: Estrategia de Muestreo Geográfico. (Región Natural: costa y sierra o Piso Altitudinal: 0-500, 500-2300, 2300-3500, 4000-4800) **Parámetros:** O1_P1: Resolución del Sensor de captura de imágenes (mínimo 1920x1080) O1_P2: Nivel de Luminosidad (Día Soleado o día nublado) O1_P3: Tipos de Avería **Variable Dependiente:** O1_VD1: Cantidad de Imágenes recolectadas. (1500 imágenes)	Tipo: Aplicada, Experimental.
Problema Específico 1	Disponibilidad de conjunto de datos propio y contextualizado para la red del Ferrocarril Central.	Construir un conjunto de datos de imágenes original y contextualizado para la red del Ferrocarril Central.	Hipótesis Específica 1 (He1): Es posible la recopilación de conjunto de datos de 1500 imágenes de rieles.	**Variable Independiente:** O1_VI1: Estrategia de Muestreo Geográfico. (Región Natural: costa y sierra o Piso Altitudinal: 0-500, 500-2300, 2300-3500, 4000-4800) **Parámetros:** O1_P1: Resolución del Sensor de captura de imágenes (mínimo 1920x1080) O1_P2: Nivel de Luminosidad (Día Soleado o día nublado) O1_P3: Tipos de Avería **Variable Dependiente:** O1_VD1: Cantidad de Imágenes recolectadas. (1500 imágenes)	Población y muestra: Conjunto de datos de imágenes de repositorios públicos y propios que cumplan con los criterios de alcance.
Problema Específico 2	Datos incompletos, desbalanceado y sin etiquetas.	Preprocesar conjunto de datos de imágenes y realizar	Hipótesis Específica 2 (He2): Es posible el preprocesamiento de	**Variable Independiente:**	

		el etiquetado, aumentadas y balanceadas.	conjunto de datos de imágenes de rieles.	O2_VI1: Técnicas de Procesamiento de Imágenes (Aumentado y Transformación) O2_VI2: Criterio de Etiquetado (Bounding Box y Segmentación Semántica) **Parámetros:** O2_P1: Herramienta de Etiquetado (Label Studio) **Variable Dependiente:** O2_VD1: Dataset Balanceado (% Ratio entre Clases) O2_VD2: Calidad de Anotación (Precisión de las máscaras)	
Problema Específico 3	Limitados modelos de Deep Learning que realicen la detección de averías y que generalicen con el conjunto de datos contextualizado propio.	Diseñar, entrenar y optimizar modelos de Redes Neuronales Convolucionales (CNN) para la detección de averías.	Hipótesis Específica 3 (He3): Es posible entrenar diferentes modelos de visión por computador capaces de detectar diferentes tipos de averías en los rieles.	**Variable Independiente:** O3_VI1: Lista de algoritmos (YOLOv8,YOLOv10,YOLOv11, RT-DETR, RESNET). O3_VI2: Tamaño del Modelo (Nano, Small, Medium) O3_VI3: Dataset (Original y Aumentado Automático) O3_VI4: Cantidad de Épocas (50, 100, 150, 200, 250) O3_VI5: Learning Rate (0.001 y 0.0001) O3_VI6: Optimizador (Adam, AdamW) **Parámetros:** O3_P1: Capacidad del Hardware (GPU, Memoria RAM) **Variable Dependiente:** O3_VD1: Eficacia de Detección (mAP@0.5, y F1-Score) O3_VD2: Precisión de Localización (IoU Intersection over union)	Instrumentos: Modelos de Deep Learning como Yolo y ResNet Métricas de rendimiento: (FPS, mAP, IoU, F1 score).
Problema Específico 4	Analizar resultados, y validar la robustez y generalización del modelo entrenado.	Validar la robustez y la capacidad de generalización del modelo optimizado en condiciones que simulen un entorno real.	Hipótesis Específica 4 (He4): Es posible que el modelo entrenado tenga la capacidad de generalizar con otros conjuntos de datos.	**Variable Independiente:** O4_VI1: Dataset Externo Público (Kaggle) O4_VI2: Escenario de Prueba imagen (Luz Directa (Soleado) y Luz Difusa (nublado)) **Parámetros:**	Análisis: Loss (train vs. val).Si la pérdida en entrenamiento baja, pero la de validación sube → overfitting Accuracy (train vs. val) Alta en entrenamiento, pero

				O4_P1: Pesos finales del Artefacto entrenado **Variable Dependiente:** O4_VD1: Capacidad de generalización (% Variación de la precisión.)	baja en validación → mala generalización

Tabla 20: Matriz de Consistencia Problemas, Objetivos, Hipótesis y variables.
Fuente: Elaboración propia